第一章　数学与概率工具

本章摘要。本章为后文组织数据、求解参数和描述不确定性准备数学工具。向量与矩阵用于表示多维观测和线性计算。投影、正定性与矩阵分解用于分析解的存在性、唯一性和数值敏感性。微积分说明目标函数怎样随参数变化。概率部分建立条件分布、期望和贝叶斯公式，并说明信息量、期望微分与指数族的计算条件。阅读具体模型时，可以返回相应小节核对记号与假设。

1.1　向量、矩阵与基本运算

设备的一次观测可能同时包含温度、振动和转速。向量把同一次观测中的数值排在一起，矩阵把多次观测或多条计算规则排在一起。本节先说明这些对象的维度，再定义后文计算预测值和误差时需要的运算。不同单位的特征可以组成向量，但直接计算长度或距离会受单位选择影响。用于距离比较前，通常需要按训练数据确定尺度变换。

1.1.1　对象与记号

标量是单个数。本章除特别说明外使用实数，实数集合记为 $\mathbb{R}$。向量默认为列向量，写作 $\boldsymbol{x} = (x_1, \dots, x_d)^{\mathsf{T}} \in \mathbb{R}^d$。矩阵 $A = (A_{ij}) \in \mathbb{R}^{m \times d}$ 有 m 行、d 列，A_{ij} 是第 i 行第 j 列的元素。上标 T 表示转置，即 $(A^{\mathsf{T}})_{ji} = A_{ij}$，转置后矩阵的维度为 $d \times m$。

零向量与零矩阵分别记为 $\mathbf{0}$ 与 0，维度由上下文确定。$I_d \in \mathbb{R}^{d \times d}$ 表示单位矩阵。$\operatorname{diag}(a_1, \dots, a_d)$ 表示对角元素为 $a_1, \dots, a_d$、其余元素为零的对角矩阵。$\mathbb{1}\{B\}$ 是指示函数，命题 B 成立时为 1，否则为 0。本章的 $\log$ 均表示自然对数。

向量或矩阵只有在维度相同时才能逐元素相加。数乘将每个元素乘以同一个标量。若 $\boldsymbol{v}_j \in \mathbb{R}^d$、$a_j \in \mathbb{R}$，则 $\sum_{j=1}^{k} a_j \boldsymbol{v}_j \in \mathbb{R}^d$ 称为线性组合。

1.1.2 内积、范数与距离

实向量的欧氏内积与欧氏范数定义为

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^{\mathsf{T}} \boldsymbol{y} = \sum_{j=1}^{d} x_j y_j, \qquad \|\boldsymbol{x}\|_2 = \sqrt{\boldsymbol{x}^{\mathsf{T}} \boldsymbol{x}}. \tag{1.1}$$

这里 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$，内积是标量。内积为零称为正交。范数满足非负性、绝对齐次性和三角不等式，且仅零向量的范数为零。柯西–施瓦茨不等式（Cauchy–Schwarz inequality）为 $|\boldsymbol{x}^{\mathsf{T}} \boldsymbol{y}| \le \|\boldsymbol{x}\|_2 \|\boldsymbol{y}\|_2$，等号成立当且仅当两向量线性相关。

对 $1 \le p < \infty$ 定义 $\|\boldsymbol{x}\|_p = (\sum_j |x_j|^p)^{1/p}$，另定义 $\|\boldsymbol{x}\|_\infty = \max_j |x_j|$。相应距离为

$$d_1(x, y) = \|x - y\|_1 = \sum_{j=1}^{d} |x_j - y_j|, \tag{1.2}$$

$$d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{j=1}^{d} (x_j - y_j)^2}, \tag{1.3}$$

$$d_p(x, y) = \|x - y\|_p = \left(\sum_{j=1}^{d} |x_j - y_j|^p \right)^{1/p}, \quad p \ge 1, \tag{1.4}$$

$$d_\infty(x, y) = \|x - y\|_\infty = \max_j |x_j - y_j|. \tag{1.5}$$

这里沿用 $x, y \in \mathbb{R}^d$ 表示两个向量。四式分别称为曼哈顿距离（Manhattan distance）、欧氏距离（Euclidean distance）、闵可夫斯基距离（Minkowski distance）和切比雪夫距离（Chebyshev distance）。度量要求非负、对称、满足三角不等式，且距离为零当且仅当两对象相同。上述距离均为度量。$0 < p < 1$ 时同一幂和表达式一般不满足范数的三角不等式。

非零向量的余弦相似度（cosine similarity）与余弦距离（cosine distance）为

$$s_{\cos}(x, y) = \frac{x^{\mathsf{T}} y}{\|x\|_2 \|y\|_2}, \qquad d_{\cos}(x, y) = 1 - s_{\cos}(x, y), \quad x \neq 0,\ y \neq 0. \tag{1.6}$$

相似度等于夹角余弦，范围为 $[-1, 1]$。余弦距离的范围为 $[0, 2]$，但一般不是度量，正比例向量可有零距离，三角不等式也未必成立。对等长离散符号序列，汉明距离

（Hamming distance）为

$$d_{\mathrm{H}}(x,y)=\sum_{j=1}^{d}\mathbb{1}\{x_j\neq y_j\}. \tag{1.7}$$

它计数不同坐标的位置，在固定长度的同一符号集合上满足度量条件。

1.1.3 矩阵乘法与线性变换

若 $A\in\mathbb{R}^{m\times d}$、$B\in\mathbb{R}^{d\times k}$，则

$$(AB)_{i\ell}=\sum_{j=1}^{d}A_{ij}B_{j\ell},\qquad AB\in\mathbb{R}^{m\times k}. \tag{1.8}$$

相邻的两个维度必须相等。特别地，$A\boldsymbol{x}\in\mathbb{R}^m$ 且 $(A\boldsymbol{x})_i=\sum_j A_{ij}x_j$。映射 $\boldsymbol{x}\mapsto A\boldsymbol{x}$ 保持加法与数乘，称为线性变换。矩阵乘法满足结合律和分配律，一般不满足交换律。转置满足 $(AB)^{\mathsf{T}}=B^{\mathsf{T}}A^{\mathsf{T}}$。对 $\boldsymbol{x}\in\mathbb{R}^m$、$\boldsymbol{y}\in\mathbb{R}^d$，外积 $\boldsymbol{x}\boldsymbol{y}^{\mathsf{T}}\in\mathbb{R}^{m\times d}$ 的元素为 x_iy_j。

弗罗贝尼乌斯范数（Frobenius norm）与谱范数（spectral norm）定义为

$$\|A\|_{\mathrm{F}}=\left(\sum_{i,j}A_{ij}^2\right)^{1/2},\qquad \|A\|_2=\sup_{\|\boldsymbol{x}\|_2=1}\|A\boldsymbol{x}\|_2. \tag{1.9}$$

前者计入全部元素，后者度量单位输入向量的最大输出长度。维度相容时 $\|AB\|_2\le\|A\|_2\|B\|_2$。

1.2 线性空间与矩阵运算性质

1.2.1 线性无关与秩

向量组 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k$ 线性无关，是指 $\sum_j a_j\boldsymbol{v}_j=\boldsymbol{0}$ 仅在全部 $a_j=0$ 时成立。全部线性组合构成它们张成的空间。子空间的一组线性无关生成向量称为基，基中向量的个数称为维数。

对 $A\in\mathbb{R}^{m\times d}$，列空间与零空间为

$$\mathcal{C}(A)=\{A\boldsymbol{x}:\boldsymbol{x}\in\mathbb{R}^d\}\subseteq\mathbb{R}^m,\qquad \mathcal{N}(A)=\{\boldsymbol{x}\in\mathbb{R}^d:A\boldsymbol{x}=\boldsymbol{0}\}\subseteq\mathbb{R}^d. \tag{1.10}$$

列空间包含全部可能输出，零空间包含映射为零的输入。行空间为 $\mathcal{C}(A^{\mathsf{T}})$。秩（rank）定义为列空间的维数，满足

$$\operatorname{rank}(A) = \operatorname{rank}(A^{\mathsf{T}}), \qquad \operatorname{rank}(A) + \dim \mathcal{N}(A) = d. \tag{1.11}$$

第二式称为秩–零度定理。正交直和分解为 $\mathbb{R}^d = \mathcal{C}(A^{\mathsf{T}}) \oplus \mathcal{N}(A)$、$\mathbb{R}^m = \mathcal{C}(A) \oplus \mathcal{N}(A^{\mathsf{T}})$，其中 $\oplus$ 表示两子空间正交，且每个向量有唯一的分解。

秩不超过 $\min(m, d)$。秩为 d 称为满列秩，要求 $m \geq d$。秩为 m 称为满行秩，要求 $m \leq d$。维度相容时，

$$\operatorname{rank}(AB) \leq \min\{\operatorname{rank}(A), \operatorname{rank}(B)\}, \qquad \operatorname{rank}(A^{\mathsf{T}}A) = \operatorname{rank}(A). \tag{1.12}$$

后一结论来自 $\mathcal{N}(A^{\mathsf{T}}A) = \mathcal{N}(A)$：$A^{\mathsf{T}}A\boldsymbol{x} = \mathbf{0}$ 蕴含 $\|A\boldsymbol{x}\|_2^2 = 0$，反向蕴含直接成立。

1.2.2 迹与行列式

方阵 $A \in \mathbb{R}^{d\times d}$ 的迹（trace）为 $\operatorname{tr}(A) = \sum_j A_{jj}$。迹是标量，具有线性性质，且 $\operatorname{tr}(A^{\mathsf{T}}) = \operatorname{tr}(A)$。若 $A \in \mathbb{R}^{m\times d}$、$B \in \mathbb{R}^{d\times m}$，则

$$\operatorname{tr}(AB) = \sum_{i=1}^{m}\sum_{j=1}^{d} A_{ij}B_{ji} = \operatorname{tr}(BA). \tag{1.13}$$

循环移动可推广到多个因子，只要各乘积有定义且是方阵。一般不能任意交换因子。另有 $\|A\|_{\mathrm{F}}^2 = \operatorname{tr}(A^{\mathsf{T}}A)$。若 $B \in \mathbb{R}^{d\times d}$，则 $\boldsymbol{x}^{\mathsf{T}}B\boldsymbol{x} = \operatorname{tr}(B\boldsymbol{x}\boldsymbol{x}^{\mathsf{T}})$。

行列式（determinant）是关于方阵各列交替多线性的标量函数，由 $\det I_d = 1$ 确定。绝对值表示体积缩放因子，符号表示定向。同阶方阵满足 $\det(AB) = \det A \det B$、$\det(A^{\mathsf{T}}) = \det A$。三角矩阵的行列式为对角元素之积。$|A|$ 也表示行列式。

1.2.3 逆与线性方程组

若方阵 $A \in \mathbb{R}^{d\times d}$ 存在 A^{-1} 满足 $AA^{-1} = A^{-1}A = I_d$，则称为可逆，A^{-1} 是唯一的逆矩阵（inverse matrix）。可逆等价于 $\operatorname{rank}(A) = d$、$\mathcal{N}(A) = \{\mathbf{0}\}$、$\det A \neq 0$，也等价于对每个 $\boldsymbol{b} \in \mathbb{R}^d$，$A\boldsymbol{x} = \boldsymbol{b}$ 恰有一个解。可逆同阶方阵满足

$$(AB)^{-1} = B^{-1}A^{-1}, \qquad (A^{\mathsf{T}})^{-1} = (A^{-1})^{\mathsf{T}}. \tag{1.14}$$

对一般 $A \in \mathbb{R}^{m\times d}$，方程有解当且仅当 $\boldsymbol{b} \in \mathcal{C}(A)$。若 $\boldsymbol{x}_0$ 为一个解，则全部解为 $\boldsymbol{x}_0 + \mathcal{N}(A)$。解存在时，唯一性等价于满列秩。矩形矩阵没有上述双侧逆，但满列秩矩阵有左逆，满行秩矩阵有右逆。

1.2.4 穆尔–彭罗斯伪逆

每个 $A \in \mathbb{R}^{m\times d}$ 均有唯一的穆尔–彭罗斯伪逆（Moore–Penrose pseudoinverse）$A^{+} \in \mathbb{R}^{d\times m}$，定义条件为

$$AA^{+}A = A, \qquad A^{+}AA^{+} = A^{+}, \tag{1.15}$$

$$(AA^{+})^{\mathsf{T}} = AA^{+}, \qquad (A^{+}A)^{\mathsf{T}} = A^{+}A. \tag{1.16}$$

可逆方阵的伪逆等于逆。满列秩时 $A^{+} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，满行秩时 $A^{+} = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}$。一般构造将在奇异值分解中给出。

AA^{+} 是到列空间的正交投影，$A^{+}A$ 是到行空间的正交投影。对任意 $\boldsymbol{b} \in \mathbb{R}^{m}$，$A^{+}\boldsymbol{b}$ 是使 $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$ 最小的全部解中范数最小的唯一解。全部最小平方残差解为

$$\boldsymbol{x} = A^{+}\boldsymbol{b} + (I_d - A^{+}A)\boldsymbol{z}, \qquad \boldsymbol{z} \in \mathbb{R}^{d}. \tag{1.17}$$

其输出均为 $\boldsymbol{b}$ 到列空间的投影。第二项属于零空间，与行空间中的 $A^{+}\boldsymbol{b}$ 正交，加入非零第二项会增大解的范数。

1.3 正交投影与正定性

1.3.1 正交矩阵与投影

方阵 $U \in \mathbb{R}^{d\times d}$ 满足 $U^{\mathsf{T}}U = I_d$ 时称为正交矩阵（orthogonal matrix）。它也满足 $UU^{\mathsf{T}} = I_d$，故 $U^{-1} = U^{\mathsf{T}}$。正交变换保持内积与欧氏范数。

若 $U_r \in \mathbb{R}^{d\times r}$ 满足 $U_r^{\mathsf{T}}U_r = I_r$，其列为一个 r 维子空间的标准正交基。令 $P = U_rU_r^{\mathsf{T}}$，则

$$\boldsymbol{x} = P\boldsymbol{x} + (I_d - P)\boldsymbol{x}, \qquad \|\boldsymbol{x}\|_2^2 = \|P\boldsymbol{x}\|_2^2 + \|(I_d - P)\boldsymbol{x}\|_2^2. \tag{1.18}$$

两项分别位于该子空间及其正交补。投影矩阵满足 $P = P^{\mathsf{T}}$ 和 $P^2 = P$。幂等性表示重复投影不改变结果，对称性进一步保证投影方向与目标子空间正交。对称且幂等的实矩阵均为正交投影矩阵。

图1.1取 $\boldsymbol{x}=(2,1)^{\mathsf{T}}$，并投影到第一个坐标轴。投影保留第一坐标，残差保留第二坐标。两者正交，因此长度平方满足 $5=4+1$。后文最小二乘会把同样的分解用于样本预测向量。

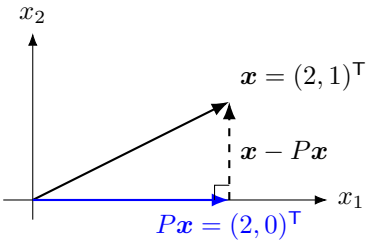


图 1.1: 向量到横轴的正交投影。实线箭头分别表示原向量和投影向量，虚线箭头表示与横轴垂直的残差。

单位向量 $\boldsymbol{u}$ 张成的直线具有投影 $\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}$。其系数由

$$\frac{d}{da}\|\boldsymbol{x}-a\boldsymbol{u}\|_2^2=-2\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}+2a=0 \tag{1.19}$$

确定。这里 $\|\boldsymbol{u}\|_2=1$、$a\in\mathbb{R}$，二阶导数为 2，故 $a=\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}$ 是唯一最小点。非单位的非零向量具有系数 $\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}/(\boldsymbol{u}^{\mathsf{T}}\boldsymbol{u})$。

1.3.2 二次型与正定矩阵

实方阵 $A\in\mathbb{R}^{d\times d}$ 满足 $A=A^{\mathsf{T}}$ 时称为对称矩阵（symmetric matrix）。本章对实对称矩阵定义正定性：

$$A\succeq 0 \iff \boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}\geq 0 \quad \text{对所有}\boldsymbol{v}\in\mathbb{R}^d, \tag{1.20}$$

$$A\succ 0 \iff \boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}>0 \quad \text{对所有非零}\boldsymbol{v}\in\mathbb{R}^d. \tag{1.21}$$

第一种性质称为半正定（positive semidefinite，PSD），第二种称为正定（positive definite，PD）。标量 $\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}$ 称为二次型。负定与半负定分别由 $-A\succ 0$ 与 $-A\succeq 0$ 定义。二次型既取正值又取负值时称为不定。任意实方阵的二次型只取决于对称部分 $(A+A^{\mathsf{T}})/2$。

对称矩阵之间记 $A\succeq B$ 表示 $A-B\succeq 0$。半正定矩阵的非负系数线性组合仍半正定。若 $A\succeq 0$、$C\in\mathbb{R}^{d\times k}$，则 $C^{\mathsf{T}}AC\succeq 0$，因为对 $\boldsymbol{z}\in\mathbb{R}^k$ 有

$$\boldsymbol{z}^{\mathsf{T}}C^{\mathsf{T}}AC\boldsymbol{z}=(C\boldsymbol{z})^{\mathsf{T}}A(C\boldsymbol{z})\geq 0. \tag{1.22}$$

若 $A \succ 0$，则 $C^{\mathsf{T}}AC$ 正定当且仅当 C 满列秩。任意 $B \in \mathbb{R}^{m\times d}$ 都有 $B^{\mathsf{T}}B \succeq 0$，且正定当且仅当 B 满列秩。

正定矩阵必可逆，逆矩阵也正定。半正定矩阵可能奇异，但任意 $\epsilon > 0$ 均使 $A + \epsilon I_d \succ 0$。西尔维斯特判据（Sylvester criterion）指出，对称矩阵正定等价于全部顺序主子式为正。顺序主子式是前 k 行、前 k 列形成方阵的行列式。半正定等价于全部主子式非负，主子式允许选取任意相同的行列指标，仅检查顺序主子式不足以判定半正定。

1.3.3 分块矩阵与舒尔补

设对称分块矩阵为

$$M = \begin{pmatrix} A & B \\ B^{\mathsf{T}} & C \end{pmatrix}, \qquad A \in \mathbb{R}^{d\times d},\ B \in \mathbb{R}^{d\times k},\ C \in \mathbb{R}^{k\times k}. \tag{1.23}$$

当 A 可逆时，$S = C - B^{\mathsf{T}}A^{-1}B \in \mathbb{R}^{k\times k}$ 称为关于 A 的舒尔补（Schur complement）。消去分块方程中的第一组未知量后，第二组未知量所满足的方程就由 S 决定。下面进一步假设 $A \succ 0$，用配方判断整个矩阵的正定性。配方给出

$$\begin{pmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{pmatrix}^{\mathsf{T}} M \begin{pmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{pmatrix} = (\boldsymbol{x} + A^{-1}B\boldsymbol{y})^{\mathsf{T}} A (\boldsymbol{x} + A^{-1}B\boldsymbol{y}) + \boldsymbol{y}^{\mathsf{T}} S \boldsymbol{y}. \tag{1.24}$$

这里 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{y} \in \mathbb{R}^k$。在 $A \succ 0$ 的前提下，$M \succ 0$ 等价于 $S \succ 0$，$M \succeq 0$ 等价于 $S \succeq 0$。

1.4 矩阵分解

矩阵分解将一个矩阵表示为结构较简单的矩阵的乘积。三角矩阵便于逐项解方程，正交矩阵保持欧氏长度，对角矩阵使各坐标的作用分离。各分解的存在条件不同。

1.4.1 LU 分解

下三角–上三角分解（Lower–Upper decomposition，LU 分解）写为 $A = LU$，其中 L 为单位下三角矩阵，U 为上三角矩阵。非奇异方阵 $A \in \mathbb{R}^{d\times d}$ 的全部顺序

主子式非零时，这样的分解存在且唯一。

一般非奇异方阵需要允许交换行，形式为

$$PA = LU, \qquad P, L, U \in \mathbb{R}^{d\times d}. \tag{1.25}$$

P 为置换矩阵，满足 $P^{-1} = P^{\mathsf{T}}$。通过选择非零主元，任意非奇异方阵均有这一分解。求解 $A\boldsymbol{x} = \boldsymbol{b}$ 可依次解 $L\boldsymbol{z} = P\boldsymbol{b}$、$U\boldsymbol{x} = \boldsymbol{z}$，分别从首行向末行、从末行向首行代入。选主元有助于控制舍入误差，但不能消除方程对扰动的敏感性。

1.4.2 QR 分解

正交–三角分解（Orthogonal–Triangular decomposition，QR 分解）对任意 $A \in \mathbb{R}^{m\times d}$ 存在：

$$A = QR, \qquad Q \in \mathbb{R}^{m\times m}, \quad Q^{\mathsf{T}}Q = I_m, \quad R \in \mathbb{R}^{m\times d}. \tag{1.26}$$

R 为上梯形矩阵，即 $i > j$ 时 $R_{ij} = 0$。当 $m \geq d$ 时，可取简化形式 $A = Q_1 R_1$，其中 $Q_1 \in \mathbb{R}^{m\times d}$、$Q_1^{\mathsf{T}} Q_1 = I_d$、$R_1 \in \mathbb{R}^{d\times d}$ 为上三角矩阵。A 满列秩且规定 R_1 对角元素为正时，简化分解唯一。

正交分解给出

$$\|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \|R_1\boldsymbol{x} - Q_1^{\mathsf{T}}\boldsymbol{b}\|_2^2 + \|(I_m - Q_1 Q_1^{\mathsf{T}})\boldsymbol{b}\|_2^2. \tag{1.27}$$

这里 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{b} \in \mathbb{R}^m$。满列秩时，最小平方残差解由 $R_1\boldsymbol{x} = Q_1^{\mathsf{T}}\boldsymbol{b}$ 唯一确定。秩不足时 R_1 奇异，不能使用唯一解结论。豪斯霍尔德反射（Householder reflection）和吉文斯旋转（Givens rotation）可通过正交变换构造 QR 分解。

1.4.3 特征分解

若 $A \in \mathbb{R}^{d\times d}$ 与非零向量 $\boldsymbol{u}$ 满足 $A\boldsymbol{u} = \lambda\boldsymbol{u}$，则 λ 称为特征值（eigenvalue），$\boldsymbol{u}$ 称为特征向量（eigenvector）。特征值是 $\det(A - \lambda I_d) = 0$ 的根，一般实矩阵可能有复特征值。

在所讨论数域上，A 有 d 个线性无关的特征向量时称为可对角化，此时

$$A = V\Lambda V^{-1}, \qquad \Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_d). \tag{1.28}$$

V 的列为特征向量。一般方阵未必可对角化。不同特征值的特征向量线性无关，因此 d 个互异特征值足以保证可对角化。

实对称矩阵的谱定理（spectral theorem）保证特征值为实数，且

$$A = U\Lambda U^{\mathsf{T}}, \qquad U^{\mathsf{T}}U = I_d. \tag{1.29}$$

由 $\boldsymbol{v} = U\boldsymbol{z}$ 得到 $\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v} = \sum_j \lambda_j z_j^2$。所以半正定等价于全部特征值非负，正定等价于全部特征值为正。另有

$$\operatorname{tr}(A) = \sum_j \lambda_j, \qquad \det A = \prod_j \lambda_j, \qquad \lambda_{\min} \le \frac{\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}}{\boldsymbol{v}^{\mathsf{T}}\boldsymbol{v}} \le \lambda_{\max}. \tag{1.30}$$

最后一式要求 $\boldsymbol{v} \neq \mathbf{0}$，比值称为瑞利商（Rayleigh quotient），端点由对应特征向量达到。一般方阵的迹与行列式仍等于特征值之和与之积，按代数重数计入。

半正定矩阵有唯一的对称半正定平方根 $A^{1/2} = U\operatorname{diag}(\sqrt{\lambda_j})U^{\mathsf{T}}$。正定时还可定义 $A^{-1/2} = U\operatorname{diag}(\lambda_j^{-1/2})U^{\mathsf{T}}$。重特征值空间内的标准正交基不唯一，但这些矩阵函数不依赖基的选择。

1.4.4 奇异值分解

奇异值分解（Singular Value Decomposition，SVD）对任意 $A \in \mathbb{R}^{m\times d}$ 存在：

$$A = U\Sigma V^{\mathsf{T}}, \qquad U \in \mathbb{R}^{m\times m}, \quad V \in \mathbb{R}^{d\times d}, \quad \Sigma \in \mathbb{R}^{m\times d}. \tag{1.31}$$

U, V 均正交。令 $q = \min(m, d)$，Σ 只在 (j, j) 位置可能非零，且 $\sigma_1 \ge \cdots \ge \sigma_q \ge 0$，称为奇异值（singular values）。此处 Σ 为奇异值矩阵，概率部分的同一字母表示协方差矩阵，须按所在公式区分。

若 $r = \operatorname{rank}(A)$，则恰有 r 个正奇异值。取相应列组成 $U_r \in \mathbb{R}^{m\times r}$、$V_r \in \mathbb{R}^{d\times r}$，得到

$$A = U_r \operatorname{diag}(\sigma_1, \ldots, \sigma_r) V_r^{\mathsf{T}}, \tag{1.32}$$

$$A^{+} = V_r \operatorname{diag}(\sigma_1^{-1}, \ldots, \sigma_r^{-1}) U_r^{\mathsf{T}}. \tag{1.33}$$

零矩阵的伪逆为零。也可写 $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$，$\Sigma^{+} \in \mathbb{R}^{d\times m}$ 将正奇异值取倒数，将零奇异值保持为零。

因为 $A^{\mathsf{T}}A = V\Sigma^{\mathsf{T}}\Sigma V^{\mathsf{T}}$，其非零特征值为 σ_j^2，且 $\|A\|_2 = \sigma_1$、$\|A\|_{\mathrm{F}}^2 = \sum_j \sigma_j^2$。对 $0 \le k < r$，截断矩阵 $A_k = \sum_{j=1}^{k} \sigma_j \boldsymbol{u}_j \boldsymbol{v}_j^{\mathsf{T}}$ 的秩至多为 k，满足低秩近似定理：

$$\min_{\operatorname{rank}(B)\le k} \|A - B\|_2 = \sigma_{k+1}, \qquad \min_{\operatorname{rank}(B)\le k} \|A - B\|_{\mathrm{F}}^2 = \sum_{j=k+1}^{q} \sigma_j^2. \tag{1.34}$$

A_k 达到这两个最小值，其中 $\boldsymbol{u}_j$ 和 $\boldsymbol{v}_j$ 分别为 U 和 V 的第 j 列，k 为整数。把正的小奇异值置零后再取倒数，得到截断矩阵的伪逆，一般不同于原矩阵的精确伪逆。截断舍去数据约束较弱的方向，可能减小噪声影响，也会改变原来的最小二乘解。

1.4.5 Cholesky 与对称分解

实对称正定矩阵 $A \in \mathbb{R}^{d\times d}$ 具有唯一的乔列斯基分解（Cholesky decomposition）$A = LL^{\mathsf{T}}$，其中 L 是对角元素严格为正的下三角矩阵。反过来，可逆下三角矩阵 L 使 LL^{T} 正定。解方程可依次解 $L\boldsymbol{z} = \boldsymbol{b}$ 与 $L^{\mathsf{T}}\boldsymbol{x} = \boldsymbol{z}$。同时 $\det A = \prod_j L_{jj}^2$，故 $\log\det A = 2\sum_j \log L_{jj}$。

半正定矩阵可写为 BB^{T}，但 B 可能秩不足，不能要求严格正对角元素的 Cholesky 因子。对称不定矩阵可使用带对称置换的 $PAP^{\mathsf{T}} = LDL^{\mathsf{T}}$，其中 L 为单位下三角矩阵，D 为具有 1×1 或 2×2 对角块的对称分块对角矩阵。允许 2×2 块可处理无法使用标量主元的情形。

1.4.6 条件数与投影恒等式

可逆方阵的二范数条件数（condition number）为

$$\kappa_2(A) = \|A\|_2\|A^{-1}\|_2 = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \ge 1. \tag{1.35}$$

若 $A\boldsymbol{x} = \boldsymbol{b}$ 且只扰动右端，$\delta\boldsymbol{x} = A^{-1}\delta\boldsymbol{b}$。当 $\boldsymbol{b} \ne \boldsymbol{0}$ 时，

$$\frac{\|\delta\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} \le \kappa_2(A)\frac{\|\delta\boldsymbol{b}\|_2}{\|\boldsymbol{b}\|_2}. \tag{1.36}$$

可逆性保证解唯一，条件数描述对扰动的敏感性。条件数很大时称为病态。满列秩矩形矩阵也可定义 $\kappa_2(A) = \sigma_1/\sigma_d$，此时 $\kappa_2(A^{\mathsf{T}}A) = \kappa_2(A)^2$。数学秩以严格为零为准，数值秩还需给定尺度和容差。

考虑用一个低维线性子空间重建一组向量。设 $\boldsymbol{z}_i \in \mathbb{R}^d$，$i = 1, \dots, n$ 且 $n \geq 1$。令 $S = n^{-1} \sum_{i=1}^{n} \boldsymbol{z}_i \boldsymbol{z}_i^{\mathsf{T}}$，并令 $U_r \in \mathbb{R}^{d \times r}$ 满足 $U_r^{\mathsf{T}} U_r = I_r$，其中 $1 \leq r \leq d$。矩阵 $U_r U_r^{\mathsf{T}}$ 把每个向量投影到它的列空间。由正交分解与迹的性质，

$$\frac{1}{n} \sum_{i} \| \boldsymbol{z}_i - U_r U_r^{\mathsf{T}} \boldsymbol{z}_i \|_2^2 = \frac{1}{n} \sum_{i} (\| \boldsymbol{z}_i \|_2^2 - \| U_r^{\mathsf{T}} \boldsymbol{z}_i \|_2^2) \tag{1.37}$$

$$= \operatorname{tr}(S) - \operatorname{tr}(U_r^{\mathsf{T}} S U_r). \tag{1.38}$$

这里 $S \in \mathbb{R}^{d \times d}$ 半正定，不要求 $\boldsymbol{z}_i$ 来自随机抽样。若 $\boldsymbol{z}_i$ 是减去样本均值后的向量，则 S 是以 n 为分母的样本协方差矩阵。未中心化时，它是二阶矩矩阵，最优子空间被限制为经过原点。若 S 的特征值按 $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$ 排列，则在全部 r 维子空间上，右端最小值为 $\sum_{j>r} \lambda_j$。令 $\boldsymbol{u}_j$ 为 S 的第 j 个单位特征向量，则保留的迹为 $\sum_j \lambda_j w_j$，其中 $w_j = \| U_r^{\mathsf{T}} \boldsymbol{u}_j \|_2^2$ 表示该特征方向保留的平方投影长度。正交投影保证 $0 \leq w_j \leq 1$ 且 $\sum_j w_j = r$。把权重配置给最大的 r 个特征值可使该迹达到最大值，选择相应特征向量作为 U_r 的列即可实现。若截断位置的特征值相同，最优子空间可能不唯一。

1.5 微积分工具

1.5.1 导数、全微分与链式法则

函数 f 在 x 的导数为 $f'(x) = \lim_{h \to 0} [f(x+h) - f(x)]/h$，前提是极限存在。对 $f : \mathbb{R}^d \to \mathbb{R}$，偏导数只沿一个坐标方向取极限。各偏导数存在并不自动保证全微分存在。若存在 $\boldsymbol{g} \in \mathbb{R}^d$ 使

$$f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \boldsymbol{g}^{\mathsf{T}} \boldsymbol{h} + o(\| \boldsymbol{h} \|_2), \tag{1.39}$$

则 f 在 $\boldsymbol{x}$ 可微。$\boldsymbol{g} = \nabla f(\boldsymbol{x})$ 称为梯度（gradient），分量为各偏导数。小量 $o(\|\boldsymbol{h}\|_2)$ 除以 $\|\boldsymbol{h}\|_2$ 后趋于零。偏导数在邻域内连续是可微的充分条件。

对 $\boldsymbol{f} : \mathbb{R}^d \to \mathbb{R}^m$，雅可比矩阵（Jacobian matrix）为 $D\boldsymbol{f} = (\partial f_i / \partial x_j)_{i,j} \in \mathbb{R}^{m \times d}$。可微时，$\boldsymbol{f}(\boldsymbol{x} + \boldsymbol{h}) = \boldsymbol{f}(\boldsymbol{x}) + D\boldsymbol{f}(\boldsymbol{x}) \boldsymbol{h} + o(\|\boldsymbol{h}\|_2)$。若 $\boldsymbol{g} : \mathbb{R}^m \to \mathbb{R}^k$ 也可微，链式法则（chain rule）给出

$$D(\boldsymbol{g} \circ \boldsymbol{f})(\boldsymbol{x}) = D\boldsymbol{g}(\boldsymbol{f}(\boldsymbol{x})) D\boldsymbol{f}(\boldsymbol{x}) \in \mathbb{R}^{k \times d}. \tag{1.40}$$

当 g 为标量函数时，$\nabla (g \circ \boldsymbol{f}) = (D\boldsymbol{f})^{\mathsf{T}} \nabla g \in \mathbb{R}^d$。

1.5.2 二阶导数与泰勒展开

海森矩阵（Hessian matrix）为 $H_f = (\partial^2 f/\partial x_i \partial x_j)_{i,j} \in \mathbb{R}^{d\times d}$。若二阶偏导数在邻域内连续，混合偏导数可交换，$H_f$ 对称，且二阶泰勒展开（Taylor expansion）为

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\mathsf{T}}\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^{\mathsf{T}} H_f(\boldsymbol{x})\boldsymbol{h} + o(\|\boldsymbol{h}\|_2^2). \tag{1.41}$$

可微函数沿方向 $\boldsymbol{v}$ 的方向导数为 $\nabla f^{\mathsf{T}}\boldsymbol{v}$。梯度非零时，柯西–施瓦茨不等式说明单位方向中的最小方向导数为 $-\|\nabla f\|_2$，由负梯度的单位方向取得。这保证足够小的正位移使函数下降。

定义域内部的可微局部极小点必须满足 $\nabla f = \mathbf{0}$。二阶连续可微时，该点还必须满足 $H_f \succeq 0$。若驻点满足 $H_f \succ 0$，则为严格局部极小点。仅半正定不足以判定极小点。

1.5.3 矩阵微分

对固定 $A \in \mathbb{R}^{d\times d}$、$\boldsymbol{b} \in \mathbb{R}^d$，

$$\nabla_{\boldsymbol{x}}(\boldsymbol{b}^{\mathsf{T}}\boldsymbol{x}) = \boldsymbol{b}, \qquad \nabla_{\boldsymbol{x}}(\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x}) = (A + A^{\mathsf{T}})\boldsymbol{x}. \tag{1.42}$$

第二式由 $d(\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x}) = (d\boldsymbol{x})^{\mathsf{T}}A\boldsymbol{x} + \boldsymbol{x}^{\mathsf{T}}A\,d\boldsymbol{x}$ 得到。A 对称时梯度为 $2A\boldsymbol{x}$。

对固定 $A \in \mathbb{R}^{m\times d}$、$\boldsymbol{b} \in \mathbb{R}^m$，$F(\boldsymbol{x}) = \frac{1}{2}\|A\boldsymbol{x} - \boldsymbol{b}\|_2^2$ 满足

$$dF = (A\boldsymbol{x} - \boldsymbol{b})^{\mathsf{T}}A\,d\boldsymbol{x}, \quad \nabla F = A^{\mathsf{T}}(A\boldsymbol{x} - \boldsymbol{b}), \quad H_F = A^{\mathsf{T}}A. \tag{1.43}$$

梯度为 d 维，海森矩阵为 $d \times d$ 且半正定。

对可微变化的可逆方阵，

$$d(A^{-1}) = -A^{-1}(dA)A^{-1}, \qquad d\log|\det A| = \operatorname{tr}(A^{-1}dA). \tag{1.44}$$

第一式由 $d(AA^{-1}) = 0$ 推得，第二式在可逆矩阵邻域内成立。正定时可写 $\log\det A$。对矩阵函数 $F(A)$，可由 $dF = \operatorname{tr}((\nabla_A F)^{\mathsf{T}}dA)$ 定义同维度的矩阵梯度。

1.5.4 积分与变量替换

若 f 连续且 $F' = f$，微积分基本定理给出 $\int_a^b f(x)\,dx = F(b) - F(a)$。若 u, v 连续可微，分部积分为 $\int_a^b uv'\,dx = [uv]_a^b - \int_a^b u'v\,dx$。

若 $\boldsymbol{x}=\boldsymbol{g}(\boldsymbol{z})$ 为开集之间一一、连续可微且逆也连续可微的变换，则

$$\int_{\mathcal{X}} f(\boldsymbol{x})\,d\boldsymbol{x}=\int_{\mathcal{Z}} f(\boldsymbol{g}(\boldsymbol{z}))\,|\det D\boldsymbol{g}(\boldsymbol{z})|\,d\boldsymbol{z}. \tag{1.45}$$

这里 $\mathcal{X},\mathcal{Z}\subseteq\mathbb{R}^d$，雅可比矩阵为 $d\times d$，要求 f 非负或绝对可积。行列式绝对值是体积因子。非负函数可交换积分次序，这是托内利定理（Tonelli theorem）。绝对可积函数也可交换次序，这是富比尼定理（Fubini theorem）。缺少这些条件时，不能任意交换积分或求和次序。

1.6 概率空间、随机变量与分布

即使输入读数相同，设备下一小时的温度也可能不同。概率模型需要区分可能发生的结果、结果组成的事件，以及事件的概率。先建立这三个对象，才能准确解释条件概率和预测分布。下面的抽象定义统一覆盖离散结果与连续测量，后续计算主要使用质量函数和密度。

1.6.1 事件与概率

概率空间（probability space）是三元组 $(\Omega,\mathcal{F},P)$。Ω 为所有可能结果组成的样本空间。$\mathcal{F}$ 为事件组成的 σ 代数，包含 Ω，对补集与可数并封闭。概率测度 P 定义在 $\mathcal{F}$ 上，满足

$$P(A)\ge 0,\qquad P(\Omega)=1,\qquad P\left(\bigcup_{i=1}^{\infty}A_i\right)=\sum_{i=1}^{\infty}P(A_i) \tag{1.46}$$

最后一式要求 A_i 两两不交。公理蕴含 $P(\varnothing)=0$、$P(A^{\mathrm{c}})=1-P(A)$ 及 $P(A\cup B)=P(A)+P(B)-P(A\cap B)$。

若 $P(B)>0$，条件概率（conditional probability）定义为 $P(A\mid B)=P(A\cap B)/P(B)$。它在 B 内重新归一化。事件 A,B 独立（independent）是指 $P(A\cap B)=P(A)P(B)$。相互独立要求任意有限子集的交事件概率等于相应概率之积，比两两独立更强。

1.6.2 随机变量与分布函数

随机变量（random variable）是可测映射 $X:\Omega\to\mathbb{R}$，即对每个实数 t 都有 $\{X\le t\}\in\mathcal{F}$。分布由 $P_X(B)=P(X\in B)$ 确定，B 为实数上的可测集合。大写 X 表示随机变量，小写 x 表示可能取值。分布函数（cumulative distribution function，CDF）为 $F_X(t)=P(X\le t)$，它单调不减、右连续，在 $t\to-\infty$ 与 $t\to+\infty$ 时分别趋于 0 与 1。区间概率为 $P(a<X\le b)=F_X(b)-F_X(a)$。

随机变量用于表示观测结果的数值化对象。例如，X 可表示某时刻的温度，Y 可表示随后一小时的温度。离散随机变量的取值至多可数，概率质量函数（probability mass function，PMF）为 $p_X(x)=P(X=x)$，满足 $p_X(x)\ge0$ 与 $\sum_x p_X(x)=1$。分布相对于勒贝格测度绝对连续时，存在概率密度函数（probability density function，PDF），满足

$$P(X\in B)=\int_B p_X(x)\,dx,\qquad p_X(x)\ge0,\qquad \int_{\mathbb{R}} p_X(x)\,dx=1. \tag{1.47}$$

这时 $F_X(t)=\int_{-\infty}^{t}p_X(x)\,dx$，几乎处处有 $F_X'=p_X$。密度可大于 1，但单点概率为零。密度量纲是变量量纲的倒数，积分后概率无量纲。一般分布可能有离散或奇异连续部分，不能假定每个分布都有普通密度。

随机向量 $\boldsymbol{X}=(X_1,\dots,X_d)^{\mathsf{T}}$ 是到 $\mathbb{R}^d$ 的可测映射。多维密度相对于 d 维勒贝格测度定义，积分覆盖全部坐标。

1.6.3 联合、边缘、条件与独立

联合分布（joint distribution）描述共同取值。有联合密度 $p(x,y)$ 时，边缘密度（marginal density）为 $p_X(x)=\int p(x,y)\,dy$。离散变量使用求和。无歧义时用 $p(x)$ 代替 $p_X(x)$。

在 $p(x)>0$ 处，条件密度或条件质量函数满足

$$p(x,y)=p(y\mid x)p(x),\qquad p(y\mid x)=\frac{p(x,y)}{p(x)}. \tag{1.48}$$

条件分布在 y 上归一化。连续情形不能将其写成两个单点概率相除。条件分布仅需在 X 的分布下几乎处处定义，$p(x)=0$ 处不由比值确定。多变量链式法则为 $p(x_1,\dots,x_d)=p(x_1)\prod_{j=2}^{d}p(x_j\mid x_1,\dots,x_{j-1})$，在条件分布有定义处使用。

X, Y 独立，是指任意可测集合 B, C 满足 $P(X \in B, Y \in C) = P(X \in B)P(Y \in C)$。有联合密度时，等价于 $p(x,y) = p(x)p(y)$ 几乎处处成立。给定 Z 时条件独立（conditional independence）记为 $X \perp Y \mid Z$，密度形式为

$$p(x, y \mid z) = p(x \mid z)p(y \mid z) \tag{1.49}$$

对 Z 的分布下几乎所有 z 成立。独立与条件独立一般不能互相推出。

1.7 期望、方差与协方差

1.7.1 期望与矩

若 $\mathbb{E}|g(X)| < \infty$，期望（expectation）为

$$\mathbb{E}[g(X)] = \sum_{x} g(x)p_X(x) \quad \text{或} \quad \mathbb{E}[g(X)] = \int g(x)p_X(x)\,dx. \tag{1.50}$$

前式针对离散分布，后式针对有密度的分布。一般定义是对分布测度积分。非负函数允许期望为 $+\infty$，但正负部分均为无穷时不能定义为它们的差。均值为 $\mu = \mathbb{E}X$，k 阶原点矩为 $\mathbb{E}[X^k]$，中心矩为 $\mathbb{E}[(X-\mu)^k]$，均需检查存在条件。

期望具有线性性质，不要求变量独立。若 X, Y 独立且绝对可积，则 $\mathbb{E}[XY] = \mathbb{E}X\mathbb{E}Y$。对凸函数 ϕ，若 X 与 $\phi(X)$ 可积，詹森不等式（Jensen inequality）为 $\phi(\mathbb{E}X) \le \mathbb{E}[\phi(X)]$。

1.7.2 方差与协方差

若 $\mathbb{E}[X^2] < \infty$，方差（variance）与标准差（standard deviation）为

$$\operatorname{Var}(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - \mu^2, \qquad \operatorname{sd}(X) = \sqrt{\operatorname{Var}(X)}. \tag{1.51}$$

方差非负，且为零当且仅当 $X = \mu$ 几乎必然成立。方差量纲为 X 量纲的平方，标准差与 X 同量纲。常数 a, b 满足 $\operatorname{Var}(aX+b) = a^2 \operatorname{Var}(X)$。

若 X, Y 有有限二阶矩，协方差（covariance）为

$$\operatorname{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)], \tag{1.52}$$

$$\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X, Y). \tag{1.53}$$

独立蕴含协方差为零，反向结论一般不成立。两方差均为正时，相关系数（correlation coefficient）为 $\rho_{XY}=\operatorname{Cov}(X,Y)/(\operatorname{sd}(X)\operatorname{sd}(Y))\in[-1,1]$，它无量纲。任一方差为零时，相关系数无定义。

有有限二阶矩的 $\boldsymbol{X}\in\mathbb{R}^d$ 具有均值 $\boldsymbol{\mu}=\mathbb{E}\boldsymbol{X}$ 及协方差矩阵 $\Sigma=\mathbb{E}[(\boldsymbol{X}-\boldsymbol{\mu})(\boldsymbol{X}-\boldsymbol{\mu})^{\mathsf{T}}]\in\mathbb{R}^{d\times d}$。第 (i,j) 个元素为 $\operatorname{Cov}(X_i,X_j)$，且

$$\boldsymbol{v}^{\mathsf{T}}\Sigma\boldsymbol{v}=\mathbb{E}[(\boldsymbol{v}^{\mathsf{T}}(\boldsymbol{X}-\boldsymbol{\mu}))^2]=\operatorname{Var}(\boldsymbol{v}^{\mathsf{T}}\boldsymbol{X})\geq 0. \tag{1.54}$$

此式对任意 $\boldsymbol{v}\in\mathbb{R}^d$ 成立，证明 Σ 对称半正定。它正定当且仅当每个非零线性组合均有正方差。固定 $B\in\mathbb{R}^{m\times d}$、$\boldsymbol{b}\in\mathbb{R}^m$ 时，$\mathbb{E}[B\boldsymbol{X}+\boldsymbol{b}]=B\boldsymbol{\mu}+\boldsymbol{b}$，$\operatorname{Cov}(B\boldsymbol{X}+\boldsymbol{b})=B\Sigma B^{\mathsf{T}}$。

1.7.3 条件期望与全方差

对可积 Y，条件期望 $\mathbb{E}[Y\mid X]$ 是 X 的可积函数，满足对任意有界可测 g 都有 $\mathbb{E}[g(X)\mathbb{E}[Y\mid X]]=\mathbb{E}[g(X)Y]$。它几乎处处唯一。存在条件密度时，$\mu(x)=\mathbb{E}[Y\mid X=x]=\int y p(y\mid x)\,dy$，离散时使用求和。

条件期望具有线性性质，满足塔式法则 $\mathbb{E}[\mathbb{E}[Y\mid X]]=\mathbb{E}Y$。有界可测 g 还满足 $\mathbb{E}[g(X)Y\mid X]=g(X)\mathbb{E}[Y\mid X]$。

若 $\mathbb{E}[Y^2]<\infty$，定义 $\operatorname{Var}(Y\mid X)=\mathbb{E}[(Y-\mathbb{E}[Y\mid X])^2\mid X]$。对任意常数 $a\in\mathbb{R}$，在条件二阶矩有限处展开平方：

$$\begin{aligned}\mathbb{E}[(Y-a)^2\mid X=x]&=\mathbb{E}[(Y-\mu(x))^2\mid X=x]+(\mu(x)-a)^2\\&\quad+2(\mu(x)-a)\mathbb{E}[Y-\mu(x)\mid X=x]\\&=\operatorname{Var}(Y\mid X=x)+(\mu(x)-a)^2.\end{aligned} \tag{1.55}$$

交叉项由条件均值为零而消失，所以条件平方偏差在 $a=\mu(x)$ 处取得唯一最小值，不需要分布形状假设。

将 $Y-\mathbb{E}Y=(Y-\mathbb{E}[Y\mid X])+(\mathbb{E}[Y\mid X]-\mathbb{E}Y)$ 平方并取期望。交叉项先对 X 条件化后为零，故

$$\operatorname{Var}(Y)=\mathbb{E}[\operatorname{Var}(Y\mid X)]+\operatorname{Var}(\mathbb{E}[Y\mid X]). \tag{1.56}$$

这称为全方差公式（law of total variance），要求有限二阶矩。

1.8 常用概率分布

本节给出分布的定义、参数范围与基本性质。质量函数与密度在指定支撑集之外均取零。$X \sim \mathcal{D}$ 表示 X 服从分布 $\mathcal{D}$。

1.8.1 离散分布

伯努利分布（Bernoulli distribution）$X \sim \mathrm{Bernoulli}(\pi)$ 定义在 $\{0,1\}$ 上，$0 \le \pi \le 1$，满足 $P(X=1)=\pi$、$P(X=0)=1-\pi$。均值为 π，方差为 $\pi(1-\pi)$。

二项分布（binomial distribution）$X \sim \mathrm{Binomial}(n,\pi)$ 的质量函数为

$$P(X=k)=\binom{n}{k}\pi^k(1-\pi)^{n-k}, \qquad k=0,\dots,n. \tag{1.57}$$

n 为非负整数，$0 \le \pi \le 1$，端点参数按退化分布理解。均值为 $n\pi$，方差为 $n\pi(1-\pi)$。n 个独立同参数伯努利变量之和服从该分布。

类别分布（categorical distribution）定义在 $\{1,\dots,K\}$ 上，$P(X=j)=\pi_j$，$\pi_j \ge 0$ 且 $\sum_j \pi_j = 1$。多项分布（multinomial distribution）$\boldsymbol{N} \sim \mathrm{Multinomial}(n,\boldsymbol{\pi})$ 定义在非负整数向量 $\boldsymbol{k}$ 且 $\sum_j k_j = n$ 上：

$$P(\boldsymbol{N}=\boldsymbol{k})=\frac{n!}{\prod_{j=1}^{K} k_j!}\prod_{j=1}^{K}\pi_j^{k_j}. \tag{1.58}$$

n 为非负整数，$\boldsymbol{\pi}$ 为类别概率向量，0^0 按 1 处理。均值为 $\mathbb{E}N_j = n\pi_j$，方差为 $n\pi_j(1-\pi_j)$，$i \ne j$ 时协方差为 $-n\pi_i\pi_j$。

泊松分布（Poisson distribution）$X \sim \mathrm{Poisson}(\lambda)$ 为

$$P(X=k)=e^{-\lambda}\frac{\lambda^k}{k!}, \qquad k=0,1,\dots, \quad \lambda>0. \tag{1.59}$$

均值与方差均为 λ。相互独立的泊松变量之和仍为泊松变量，参数为各参数之和。

1.8.2 连续分布

均匀分布（uniform distribution）$X \sim \mathrm{Uniform}(a,b)$ 要求 $a<b$，在 $[a,b]$ 上的密度为 $1/(b-a)$，均值为 $(a+b)/2$，方差为 $(b-a)^2/12$。

指数分布（exponential distribution）$X \sim \mathrm{Exponential}(\lambda)$ 的密度为 $\lambda e^{-\lambda x}$，$x \geq 0$、$\lambda > 0$。均值为 $1/\lambda$，方差为 $1/\lambda^2$。无记忆性质为 $P(X > s+t \mid X > s) = P(X > t)$，$s, t \geq 0$。

伽马分布（gamma distribution）采用形状–率参数化：

$$p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \qquad x > 0, \quad \alpha, \beta > 0. \tag{1.60}$$

$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t}\, dt$ 为伽马函数。均值为 α/β，方差为 α/β^2。若使用尺度参数，尺度为 $1/\beta$，须相应改写公式。

贝塔分布（beta distribution）$X \sim \mathrm{Beta}(\alpha, \beta)$ 的密度为

$$p(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathrm{B}(\alpha, \beta)}, \qquad 0 < x < 1, \quad \alpha, \beta > 0. \tag{1.61}$$

$\mathrm{B}(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha+\beta)$ 为贝塔函数。均值为 $\alpha/(\alpha+\beta)$，方差为 $\alpha\beta/[(\alpha+\beta)^2(\alpha+\beta+1)]$。

狄利克雷分布（Dirichlet distribution）$\boldsymbol{X} \sim \mathrm{Dirichlet}(\alpha_1, \ldots, \alpha_K)$ 要求 $K \geq 2$、$\alpha_j > 0$。在 $x_j > 0$、$\sum_j x_j = 1$ 的单纯形上，以 $x_1, \ldots, x_{K-1}$ 为自由坐标，其密度为

$$p(\boldsymbol{x}) = \frac{\Gamma(\alpha_0)}{\prod_j \Gamma(\alpha_j)} \prod_{j=1}^{K} x_j^{\alpha_j - 1}, \qquad \alpha_0 = \sum_{j=1}^{K} \alpha_j. \tag{1.62}$$

密度相对于自由坐标的 $(K-1)$ 维勒贝格测度定义。均值为 α_j/α_0，方差为 $\alpha_j(\alpha_0 - \alpha_j)/[\alpha_0^2(\alpha_0+1)]$，$i \neq j$ 时协方差为 $-\alpha_i\alpha_j/[\alpha_0^2(\alpha_0+1)]$。

1.8.3 正态分布

正态分布（normal distribution），又称高斯分布（Gaussian distribution），$X \sim \mathcal{N}(\mu, \sigma^2)$ 的密度为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \qquad x \in \mathbb{R}, \quad \mu \in \mathbb{R}, \quad \sigma > 0. \tag{1.63}$$

均值为 μ，方差为 σ^2。标准正态分布的均值为零、方差为一。

多元正态分布 $\boldsymbol{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ 在 $\Sigma \succ 0$ 时具有密度

$$p(\boldsymbol{x}) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathsf{T}} \Sigma^{-1} (\boldsymbol{x}-\boldsymbol{\mu})\right]. \tag{1.64}$$

$\boldsymbol{x},\boldsymbol{\mu}\in\mathbb{R}^d$，$\Sigma\in\mathbb{R}^{d\times d}$ 为协方差矩阵，$|\Sigma|=\det\Sigma>0$。若 $\boldsymbol{Z}$ 的分量为相互独立的标准正态变量，则 $\boldsymbol{\mu}+\Sigma^{1/2}\boldsymbol{Z}$ 具有该分布。固定 $B\in\mathbb{R}^{m\times d}$、$\boldsymbol{b}\in\mathbb{R}^m$ 时，$B\boldsymbol{X}+\boldsymbol{b}\sim\mathcal{N}(B\boldsymbol{\mu}+\boldsymbol{b},B\Sigma B^{\mathsf{T}})$。

允许 $\Sigma\succeq 0$ 时仍可通过线性变换定义退化正态分布，但奇异 Σ 没有 $\mathbb{R}^d$ 上的普通密度，不能使用式(1.64)。联合正态变量的零协方差等价于独立，该等价性不适用于任意分布。

设分块联合正态向量为

$$\begin{pmatrix}\boldsymbol{X}\\ \boldsymbol{Y}\end{pmatrix}\sim\mathcal{N}\left(\begin{pmatrix}\boldsymbol{\mu}_X\\ \boldsymbol{\mu}_Y\end{pmatrix},\begin{pmatrix}\Sigma_{XX}&\Sigma_{XY}\\ \Sigma_{YX}&\Sigma_{YY}\end{pmatrix}\right). \tag{1.65}$$

$\boldsymbol{X}\in\mathbb{R}^d$、$\boldsymbol{Y}\in\mathbb{R}^k$，交叉协方差 $\Sigma_{XY}\in\mathbb{R}^{d\times k}$ 且 $\Sigma_{YX}=\Sigma_{XY}^{\mathsf{T}}$。当 $\Sigma_{XX}\succ 0$ 时，

$$\boldsymbol{Y}\mid\boldsymbol{X}=\boldsymbol{x}\sim\mathcal{N}(\boldsymbol{\mu}_{Y|x},\Sigma_{Y|X}), \tag{1.66}$$

$$\boldsymbol{\mu}_{Y|x}=\boldsymbol{\mu}_Y+\Sigma_{YX}\Sigma_{XX}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_X), \tag{1.67}$$

$$\Sigma_{Y|X}=\Sigma_{YY}-\Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}. \tag{1.68}$$

条件协方差是舒尔补，不依赖 $\boldsymbol{x}$。令 $\boldsymbol{R}=\boldsymbol{Y}-\boldsymbol{\mu}_Y-\Sigma_{YX}\Sigma_{XX}^{-1}(\boldsymbol{X}-\boldsymbol{\mu}_X)$，计算可得 $\operatorname{Cov}(\boldsymbol{R},\boldsymbol{X})=0$。联合正态性使 $\boldsymbol{R}$ 与 $\boldsymbol{X}$ 独立，从而得到上述条件均值与协方差。

1.9 全概率与贝叶斯公式

1.9.1 事件形式

若 B_i 为两两不交、并集为 Ω 的有限或可数事件，且各 $P(B_i)>0$，全概率公式（law of total probability）为

$$P(A)=\sum_i P(A\mid B_i)P(B_i). \tag{1.69}$$

它由 $A=\bigcup_i(A\cap B_i)$ 及可数可加性推出。零概率的 B_i 可直接按 $P(A\cap B_i)=0$ 处理，避免定义零概率事件上的条件概率。当 $P(A)>0$ 时，贝叶斯公式（Bayes' theorem）为

$$P(B_j\mid A)=\frac{P(A\mid B_j)P(B_j)}{\sum_i P(A\mid B_i)P(B_i)}. \tag{1.70}$$

分子是交事件的概率，分母是 $P(A)$，保证结果归一化。

1.9.2 密度形式

设 Θ 与 X 具有联合密度，则

$$p(x)=\int p(x\mid\theta)p(\theta)\,d\theta,\qquad p(\theta\mid x)=\frac{p(x\mid\theta)p(\theta)}{p(x)}. \tag{1.71}$$

离散 Θ 时使用求和。第二式要求 $0<p(x)<\infty$，以几乎处处意义理解。$p(\theta)$ 称为先验分布（prior distribution），$p(\theta\mid x)$ 称为后验分布（posterior distribution）。固定 x 后，将 $p(x\mid\theta)$ 视为 θ 的函数称为似然函数（likelihood function），它不要求在 θ 上积分为一。$p(x)$ 称为边缘似然（marginal likelihood），也称证据（evidence）。先验归一化且分母为正、有限时，公式给出归一化的后验。

1.10 信息量与分布差异

比较概率模型时，需要量化单个分布的不确定性，以及两个分布的差异。前者可以用平均信息量描述，后者既可以比较同一结果的概率，也可以考虑不同结果之间的距离。这几类量的定义和性质不同，下面分别说明。

1.10.1 熵、交叉熵与相对熵

离散分布的熵（entropy）为 $H(p)=-\sum_x p(x)\log p(x)$，交叉熵（cross entropy）为 $H(p,q)=-\sum_x p(x)\log q(x)$。约定 $0\log 0=0$。若 $p(x)>0$ 且 $q(x)=0$，交叉熵为 $+\infty$。自然对数对应的信息单位为奈特（nat）。

库尔贝克–莱布勒散度（Kullback–Leibler divergence，KL 散度），又称相对熵，为

$$\mathrm{KL}(p\|q)=\sum_x p(x)\log\frac{p(x)}{q(x)}. \tag{1.72}$$

采用同样的零值约定。共同基准测度下的密度使用积分。若 p 不相对于 q 绝对连续，散度为 $+\infty$。散度非负，为零当且仅当两分布相同。离散情形由 $-\log u\ge 1-u$ 得到

$$\mathrm{KL}(p\|q)\ge\sum_{p(x)>0}\bigl(p(x)-q(x)\bigr)\ge 0. \tag{1.73}$$

连续情形有相应积分证明。KL 散度一般不对称，不满足度量的全部条件。熵与交叉熵均有限时，展开对数比得到

$$H(p,q) = H(p) + \mathrm{KL}(p\|q), \qquad \mathrm{KL}(p\|q) \geq 0. \tag{1.74}$$

有限性避免未定义的 $\infty - \infty$。连续分布使用微分熵（differential entropy），定义为

$$h(p) = -\int p(x) \log p(x)\, dx. \tag{1.75}$$

这里 p 为相对于所用坐标下勒贝格测度的密度，要求积分有定义。微分熵可为负，并随坐标尺度改变。

多元正态分布在 $\Sigma \succ 0$ 时的微分熵为 $\frac{1}{2}\log((2\pi e)^d|\Sigma|)$。在具有相同均值与正定协方差、相关积分有限的密度中，它具有最大微分熵。令 q 为该正态密度，因 $\log q$ 为常数加二次型，相同矩意味着 $\mathbb{E}_p \log q = \mathbb{E}_q \log q$。于是 $\mathrm{KL}(p\|q) = h(q) - h(p) \geq 0$。

1.10.2 Wasserstein 距离

对有限共同支撑集上的分布 p, q，令 $c(a,b)$ 为支撑集上的度量，$\Gamma(p,q)$ 为边缘分别是 p, q 的联合质量函数集合。一阶瓦瑟斯坦距离（Wasserstein distance）定义为

$$W_1(p,q) = \min_{\gamma \in \Gamma(p,q)} \sum_{a,b} \gamma(a,b) c(a,b). \tag{1.76}$$

约束为 $\gamma(a,b) \geq 0$、$\sum_b \gamma(a,b) = p(a)$、$\sum_a \gamma(a,b) = q(b)$。$\gamma$ 也称为耦合（coupling），规定两个边缘取值之间的共同质量。有限支撑使最小值存在，底层 c 为度量时 W_1 也为度量。一般度量空间上将求和改为对耦合测度积分，将最小值改为下确界，并要求有限一阶矩以保证距离有限。

1.11 期望的参数微分

参数变化时，函数值与分布都可能变化。对 $\theta \in \mathbb{R}^k$，仅对函数求导一般不能给出完整的期望导数：

$$\nabla_\theta \mathbb{E}_{X\sim p_\theta}[f_\theta(X)] \quad \text{一般不能直接写为} \quad \mathbb{E}_{X\sim p_\theta}[\nabla_\theta f_\theta(X)]. \tag{1.77}$$

特殊条件下两者可以相等，该式说明不能无条件交换运算。

设 p_θ 相对于固定测度 ν 具有共同的参数无关支撑集，且 f_θ, p_θ 关于 θ 可微。若在参数的邻域内，$f_\theta p_\theta$ 及其各参数偏导具有可积控制函数，则可由支配收敛定理交换微分与积分：

$$\nabla_\theta \int f_\theta(x) p_\theta(x)\, d\nu(x) = \int [p_\theta(x)\nabla_\theta f_\theta(x) + f_\theta(x)\nabla_\theta p_\theta(x)]\, d\nu(x) \tag{1.78}$$

$$= \mathbb{E}_{p_\theta}[\nabla_\theta f_\theta(X)] + \mathbb{E}_{p_\theta}[f_\theta(X)\nabla_\theta \log p_\theta(X)]. \tag{1.79}$$

第二步另要求共同支撑上密度为正，且各项可积。向量 $\nabla_\theta \log p_\theta(x) \in \mathbb{R}^k$ 称为得分函数（score function），度量固定观测 x 的对数密度怎样随参数变化。将相同的交换条件用于归一化等式 $\int p_\theta\, d\nu = 1$，得到

$$\mathbb{E}_{p_\theta}[\nabla_\theta \log p_\theta(X)] = \mathbf{0}. \tag{1.80}$$

这里 $\mathbf{0} \in \mathbb{R}^k$，说明得分在模型自身分布下的均值为零。支撑集随参数变化时需要处理移动边界，不能直接套用式(1.79)。

1.12 指数族分布

1.12.1 基准测度、自然参数与归一化

指数族（exponential family）通过固定统计量与参数的内积表达密度。设 ν 为固定的 σ 有限基准测度（base measure），$h(x) \geq 0$ 为参数无关的基准项，$T(x) \in \mathbb{R}^k$ 为固定可测函数。σ 有限表示空间可被可数个具有有限测度的集合覆盖。分布写作

$$p_\theta(x) = h(x)\exp\{\theta^{\mathsf{T}} T(x) - A(\theta)\}, \qquad A(\theta) = \log \int h(x) e^{\theta^{\mathsf{T}} T(x)}\, d\nu(x). \tag{1.81}$$

p_θ 为相对于 ν 的密度，$\theta \in \mathbb{R}^k$ 称为自然参数（natural parameter），T 称为充分统计量（sufficient statistic），A 称为对数配分函数（log-partition function）。h 不必积分为一。离散变量可使用计数测度，普通连续密度使用勒贝格测度。也可将 h 吸收到测度 $h\, d\nu$ 中。

自然参数空间为

$$\mathcal{H} = \left\{ \theta \in \mathbb{R}^k : 0 < \int h(x) e^{\theta^{\mathsf{T}} T(x)}\, d\nu(x) < \infty \right\}. \tag{1.82}$$

只有 $\theta \in \mathcal{H}$ 时，密度才可归一化。A 使 $\int p_\theta \, d\nu = 1$，同时描述参数改变时归一化量的变化。共同支撑由 $h(x) > 0$ 确定，要求不随参数变化。

参数集合取为全部 $\mathcal{H}$ 时称为满指数族（full exponential family）。自然参数集合为 $\mathbb{R}^k$ 中的开集时称为正则指数族（regular exponential family）。使用受限参数映射 $\theta = \theta(\eta)$ 时，关于 θ 的导数不能直接当作关于 η 的导数。

1.12.2 充分性与最小表示

统计量的充分性是指给定该统计量后，随机对象的条件分布不再依赖参数。对具有共同支配测度的分布族，因子分解判据将充分性写为 $p_\theta(x) = g_\theta(S(x))b(x)$。式(1.81)具有这一形式，所以 $T(X)$ 对 θ 充分。

若 $X_1, \dots, X_n$ 相互独立且同分布，其联合密度为

$$\prod_{i=1}^{n} p_\theta(x_i) = \left(\prod_{i=1}^{n} h(x_i) \right) \exp\left\{ \theta^{\mathsf{T}} \sum_{i=1}^{n} T(x_i) - n A(\theta) \right\}. \tag{1.83}$$

因此 $\sum_i T(X_i)$ 是联合分布的充分统计量。充分性不保证维度最小，也不保证不同参数对应不同分布。

若不存在非零 $\boldsymbol{a} \in \mathbb{R}^k$ 和常数 b 使 $\boldsymbol{a}^{\mathsf{T}} T(x) = b$ 在测度 $h\,d\nu$ 下几乎处处成立，则称为最小表示（minimal representation）。存在这样的仿射关系时，统计量含有冗余分量，自然参数可沿相应方向改变而不改变分布。

1.12.3 对数配分函数的导数

在自然参数空间内部，要求一阶、二阶微分可移入积分，且相关矩有限。一个足够的局部条件是：在参数的某个邻域内，$h(x)e^{\theta^{\mathsf{T}} T(x)}$ 及其一阶、二阶偏导具有共同的可积控制函数。令 $Z(\theta) = e^{A(\theta)}$，则

$$\frac{\partial A}{\partial \theta_j} = \frac{1}{Z(\theta)} \int T_j(x) h(x) e^{\theta^{\mathsf{T}} T(x)} \, d\nu(x) = \mathbb{E}_\theta[T_j(X)], \tag{1.84}$$

$$\frac{\partial^2 A}{\partial \theta_i \partial \theta_j} = \mathbb{E}_\theta[T_i(X) T_j(X)] - \mathbb{E}_\theta[T_i(X)] \mathbb{E}_\theta[T_j(X)]. \tag{1.85}$$

因此

$$\nabla A(\theta) = \mathbb{E}_\theta[T(X)] \in \mathbb{R}^k, \qquad \nabla^2 A(\theta) = \operatorname{Cov}_\theta(T(X)) \in \mathbb{R}^{k \times k}. \tag{1.86}$$

这些公式将归一化函数的导数与统计量的矩联系起来。海森矩阵半正定，因为 $\boldsymbol{a}^{\mathsf{T}}\nabla^2 A\boldsymbol{a} = \mathrm{Var}_\theta(\boldsymbol{a}^{\mathsf{T}}T(X)) \geq 0$。最小表示下，非零线性组合不能几乎必然为常数，所以在满足上述条件的内部点，海森矩阵正定。

自然参数空间是凸集。对 $\theta_1, \theta_2 \in \mathcal{H}$ 与 $0 < t < 1$，赫尔德不等式（Hölder inequality）给出 $Z(t\theta_1 + (1-t)\theta_2) \leq Z(\theta_1)^t Z(\theta_2)^{1-t}$。取对数可得 A 为凸函数。在最小正则表示下，A 在自然参数空间内部严格凸。边界处导数或矩可能不存在，不能无条件延伸内部结论。

1.12.4 得分与信息矩阵

在上述正则条件下，得分函数为

$$\nabla_\theta \log p_\theta(x) = T(x) - \nabla A(\theta), \tag{1.87}$$

其期望为零。费舍尔信息矩阵（Fisher information matrix）定义为得分的二阶矩：

$$\mathcal{I}(\theta) = \mathbb{E}_\theta\left[(\nabla_\theta \log p_\theta(X))(\nabla_\theta \log p_\theta(X))^{\mathsf{T}}\right] = \nabla^2 A(\theta). \tag{1.88}$$

它为 $k \times k$ 半正定矩阵，最小正则表示下正定。它描述分布相对于自然参数的局部变化。若 $\theta = \theta(\eta)$ 可微，则信息矩阵按 $\mathcal{I}_\eta = (D\theta)^{\mathsf{T}}\mathcal{I}_\theta D\theta$ 变换，矩阵元素依赖参数坐标。

第二章　机器学习的任务、模型与风险

本章摘要。本章定义样本、任务、模型、损失和风险，说明不同损失对应不同预测对象，并讨论正则化、可识别性及预测到决策的边界。

同一段振动记录可以用于判断轴承是否故障，也可以用于预测下一时刻的振幅。两项任务需要不同的标签，预测错误的后果也不同。上一章介绍了计算所需的数学工具。本章先确定要学习的对象，再说明怎样用目标函数比较模型。

输入决定模型能够使用哪些信息，标签规定需要预测什么，损失衡量预测错误的代价。如果三者与实际任务不一致，即使训练目标已经达到最小值，预测结果也可能无法支持维护决策。本章由数据和任务引出模型、损失与风险，再讨论归纳偏置、正则化和任务的可学习性。后续各章将把这些概念用于具体计算。

2.1　样本、任务与预测模型

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

从数据到任务。 数据（data）是对对象、过程或环境的观测记录。一个样本（sample）对应一次定义明确的观测单位。数值特征可记为 $\boldsymbol{x} \in \mathbb{R}^d$，其中 d 为特征个数。监督学习还配有目标标签 y，样本记为 $(\boldsymbol{x}, y)$。观测单位可以是一次设备运行周期、一张图像、一个句子或一段传感器窗口。其划分需要与预测时刻、目标范围和数据可用性一致。

“任务”由输入空间 $\mathcal{X}$、输出空间 $\mathcal{Y}$ 以及评价准则共同决定。输入空间是模型允许接收的对象集合（例如时序数据、图像、文本等），输出空间是允许回答的结果集合，这两个集合先于可学习参数的确定。分类的输出是离散类别，回归的输出是连续数值，预测性维护可能输出剩余寿命，异常检测则可能没有逐样本标签。相同的数据可以支持不同任务。例如，振动信号既可以用于故障分类，也可以用于生

成未来波形或估计设备状态。

输入与标签的配对。 假设每小时读一次温度和振动，把这两项读数排成输入向量：

$$\boldsymbol{x} = (\text{温度}, \text{振动})^{\mathsf{T}} \in \mathbb{R}^2.$$

若标签是下一小时温度 $y \in \mathbb{R}$，任务是回归。若标签改为“未来一天是否故障”的 $y \in \{0, 1\}$，任务就是二分类。

监督学习用已知输入和标签学习对应关系，无监督学习则在没有这些目标标签时寻找输入结构，即发现样本之间的相似性、变量之间的关联等规律。例如，不提供故障标签，仅根据温度和振动把相似的设备记录分组，但这些分组不自动代表正常或故障。

同一数据记录可以用于不同任务，不同任务需要相应的标签或输出定义。训练是利用已有样本调整模型参数。推理是在参数固定后处理新输入，得到预测输出。

模型、参数与预测。 模型规定了允许采用的预测关系。直接给出一个预测值时，可以用确定性模型（deterministic model）表示：

$$f_{\boldsymbol{\theta}} : \mathcal{X} \to \mathcal{Y}, \qquad \boldsymbol{\theta} \in \Theta. \tag{2.1}$$

这里 Θ 是允许的参数取值集合。给定输入 $\boldsymbol{x}$ 和参数 $\boldsymbol{\theta}$，输出为 $\hat{y} = f_{\boldsymbol{\theta}}(\boldsymbol{x})$。模型结构规定函数的形式，参数从这些函数中确定一个具体函数。例如，$f_{w,b}(x) = wx + b$ 规定了直线形式，w 和 b 分别决定斜率和截距。训练利用数据和目标函数选择参数，求解算法决定怎样完成这一选择。

如果还需要描述不同标签的可能性，可以建立概率模型（probabilistic model），输出条件分布 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$。此时模型的直接输出属于分布集合，而非单个标签所在的 $\mathcal{Y}$。在 K 类分类中，输出是 K 个非负且总和为一的概率。在高斯回归中，模型可以给出条件均值和方差。概率分布随后可以转成一个预测值，例如取回归分布的均值，或取概率最大的类别。这种转换会舍去部分不确定性信息。确定性预测也可以表示为集中在单点 $f_{\boldsymbol{\theta}}(\boldsymbol{x})$ 上的退化分布，但它没有表达该点以外的观测波动。

从条件分布得到决策，还需要指定行动及其代价。设 $p = P(Y = 1 \mid \boldsymbol{x})$ 为故障概率，漏报代价为 $C_{\mathrm{FN}} > 0$，误报代价为 $C_{\mathrm{FP}} > 0$，正确决策的代价取零。选择

“不告警”的条件期望代价为 $C_{\mathrm{FN}}p$，选择“告警”的代价为 $C_{\mathrm{FP}}(1-p)$。比较两者得到告警规则

$$p \geq \frac{C_{\mathrm{FP}}}{C_{\mathrm{FP}} + C_{\mathrm{FN}}}. \tag{2.2}$$

等号处两种行动的代价相同，这里约定选择告警。这个阈值只适用于上述两类行动和代价设定。若误报代价为 1、漏报代价为 9，阈值为 0.1，不应固定取 0.5。代价由任务规定，概率模型则需要在适用数据上检验其概率质量。

上述两类表述都直接描述给定输入后的输出，属于判别建模（discriminative modeling）。选择函数形式时，需要考虑输入结构、任务和计算资源。例如，处理图像时可以利用邻近像素的局部关系，处理时间序列时可以利用观测的先后顺序。具体网络结构将在相应章节介绍。

概率建模还可以作用于未观测的状态或未知参数。用潜变量 z 表示设备状态时，可通过 $p_{\boldsymbol{\theta}}(z \mid \boldsymbol{x})$ 和 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}, z)$ 描述预测，再对 z 求和或积分。贝叶斯模型则用后验分布 $p(\boldsymbol{\theta} \mid \mathcal{D})$ 表达观测训练数据后对参数的不确定性。因此，输出是否为概率分布，与参数是否用分布表示，是两个需要分别确定的问题。

生成模型（generative model）描述观测数据的分布。在带标签任务中，它可以建立联合分布 $p_{\boldsymbol{\theta}}(\boldsymbol{x}, y)$。没有标签时，也可以直接建立 $p_{\boldsymbol{\theta}}(\boldsymbol{x})$。联合模型能够通过条件概率得到 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$，也可能用于生成新样本。相比直接建立条件分布，它增加了关于输入如何产生的假设，这些假设同样需要检验。

2.2 损失函数与训练目标

单样本损失与经验风险。 损失函数（loss function）把模型输出和观测标签映射为一个标量，用来规定训练时怎样比较预测。不同损失对应不同的错误代价。回归中常用平方损失：

$$\ell_{\mathrm{sq}}\big(f_{\boldsymbol{\theta}}(\boldsymbol{x}), y\big) = \frac{1}{2}\big(f_{\boldsymbol{\theta}}(\boldsymbol{x}) - y\big)^2. \tag{2.3}$$

这里 $f_{\boldsymbol{\theta}}(\boldsymbol{x})$ 是标量预测，$y \in \mathbb{R}$ 是观测标签。系数 $1/2$ 只影响数值尺度，常用于简化求导。平方会使大误差承担更高损失。如果任务对高估和低估的代价不同，需要改用相应的损失函数。第四章将讨论这些选择。

对训练集 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$，单样本损失的平均值称为经验风险（empirical

risk）：

$$\hat{R}(f_{\boldsymbol{\theta}}) = \frac{1}{n}\sum_{i=1}^{n} \ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i), y_i). \tag{2.4}$$

训练目标函数（objective function）规定训练时需要优化的量。它可以是经验风险，也可以包含正则项。单样本损失定义一次预测的代价，经验风险对训练样本的损失取平均，完整训练目标还可能包含其他惩罚。三者应分别说明。

概率模型可以通过似然构造目标。把参数视为固定未知量时，极大似然估计（Maximum Likelihood Estimation，ML）选择使观测数据似然最大的参数。在给定参数后样本相互独立的联合模型中，有

$$\hat{\boldsymbol{\theta}}_{\mathrm{ML}} = \arg\max_{\boldsymbol{\theta}} \log p_{\boldsymbol{\theta}}(\mathcal{D}) = \arg\max_{\boldsymbol{\theta}} \sum_{i=1}^{n} \log p_{\boldsymbol{\theta}}(\boldsymbol{x}_i, y_i). \tag{2.5}$$

条件模型则使用 $\sum_i \log p_{\boldsymbol{\theta}}(y_i \mid \boldsymbol{x}_i)$。最大化对数似然等价于最小化其负值，称为负对数似然（Negative Log-Likelihood，NLL）。第三章将说明高斯回归的 NLL 为何对应平方误差。

如果为参数指定先验 $p(\boldsymbol{\theta})$，还可以选择后验密度最大的参数，称为最大后验估计（Maximum A Posteriori estimation，MAP）：

$$\hat{\boldsymbol{\theta}}_{\mathrm{MAP}} = \arg\max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} \mid \mathcal{D}) = \arg\max_{\boldsymbol{\theta}} \big[\log p(\mathcal{D} \mid \boldsymbol{\theta}) + \log p(\boldsymbol{\theta})\big]. \tag{2.6}$$

该等式要求后验可归一化。其归一化常数与待比较的参数无关。MAP 使用先验，但结果仍是一个参数点。保留完整后验分布还需要进一步计算。极大似然和 MAP 都可以用于条件模型或联合模型，采用哪一种估计方法与是否建立输入的分布是两个不同的选择。

经验风险与总体风险。 有限样本上的拟合与总体上的预测能力需要分开讨论，经验分布到真实分布的一致收敛是统计学习理论的基础问题之一 [**?**]。设 $(X, Y) \sim P$ 描述部署环境中的输入与标签，$X \in \mathbb{R}^d$，Y 可为实数或类别。总体风险定义为

$$R(f) = \mathbb{E}_{(X,Y)\sim P}[\ell(f(X), Y)]. \tag{2.7}$$

这里的期望针对目标分布 P 下的新样本，要求损失的期望存在。实际通常不知道 P，所以需要用独立评价数据估计风险。若训练样本独立同分布于 P（independent

and identically distributed，i.i.d.），对不依赖这些样本且损失可积的固定函数 f，有 $\mathbb{E}[\hat{R}(f)] = R(f)$。这里的期望针对训练集的重复抽取。若 f 由其他数据训练得到，则可以在给定该函数后，对独立测试集使用相同的论证。测试数据一旦参与模型选择，就不能继续按这种独立性解释测试分数。若损失方差有限，独立性进一步给出

$$\mathrm{Var}(\hat{R}(f)) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(\ell(f(X_i), Y_i)) = \frac{\mathrm{Var}(\ell(f(X), Y))}{n}. \tag{2.8}$$

这解释了平均损失为什么可用于估计风险，也暴露了限制：相邻设备窗口相关时有额外协方差项。f 由同一训练集选择后，上述固定模型的无偏论证不能直接用于其训练误差。验证与测试的必要性由此产生，而不是来自惯例。

训练时通常最小化经验风险，真正希望最小化的却是部署分布上的总体风险。**“过拟合”**的核心表现，是模型在训练集上的经验风险很小，但在未参与训练的新样本上的总体风险仍然较大，因而出现较大的泛化差距。模型容量过大时，它不仅可以学习输入与标签之间可迁移的规律，也可能记住训练样本中的噪声、偶然相关性甚至标签错误。但模型容量过大并不是过拟合的必要条件，训练样本过少、标签噪声较强或反复利用验证集也可能造成过拟合。当训练集有限或含有噪声时，模型记住的细节可能无法在同一分布的新样本中重复出现。若训练集与部署分布不同，则还存在分布偏移问题，不能仅把性能下降归因于过拟合。典型地，训练早期经验风险和总体风险可能同时下降。训练后期经验风险继续下降，而总体风险可能转而上升，因为模型开始更多地拟合训练数据中的偶然性。

2.3 归纳偏置

泛化（generalization）描述模型在未参与训练的新样本上的表现，通常用目标分布上的风险衡量。独立测试集提供的是对该风险的有限样本估计。训练算法直接优化训练目标，加入惩罚后，目标下降甚至不要求经验风险同步下降。因此，需要分别检查优化结果、训练拟合与独立评价结果。

有限训练样本通常无法确定所有新输入处的预测。模型构造和训练算法需要对候选预测关系作出选择，下面讨论这种选择中预先引入的偏好。

模型结构、参数化方式和训练算法会限制能够采用的预测关系，也会使某些解更容易被找到。这些预先引入的限制和偏好称为归纳偏置（inductive bias）。当训

练样本不足以唯一确定预测关系时，归纳偏置提供选择候选解的依据。它能否改善新样本上的表现，取决于这些假设是否适合任务。

例如，对同一图像分类任务，卷积神经网络把局部连接和参数共享写进了模型结构，因此偏好局部模式以及对平移具有一定稳定性的函数。全连接网络则没有这种结构性限制。局部连接与共享参数减少了分别估计每个位置关系的需要。如果这些假设适合任务，有限样本下可能更容易学到可迁移的关系。平移后的输出是否保持不变还取决于边界、池化和后续层，卷积本身不保证整网的平移不变性。

归纳偏置与可解释性有关，但二者不是同一个概念。可解释性讨论人能否理解模型的预测依据。归纳偏置讨论模型在学习时预先接受了哪些结构假设。一个模型可以具有明确的归纳偏置，却仍然难以解释。也可以相对容易解释，但其归纳偏置并不适合当前任务。判断归纳偏置是否良好，关键在于它是否与数据生成过程和任务目标相匹配，并能否在有限样本下缩小训练风险与总体风险之间的差距。

正则化（regularization）提供了加入这种偏好的另一条途径：不一定更换模型结构，而是在训练目标中明确惩罚某些不希望出现的解。其基本形式是

$$\min_{\boldsymbol{\theta}} \ \hat{R}(\boldsymbol{\theta}) + \lambda \Omega(\boldsymbol{\theta}), \qquad \Omega(\boldsymbol{\theta}) = \frac{1}{2}\|\boldsymbol{\theta}\|_2^2. \tag{2.9}$$

第一项 $\hat{R}(\boldsymbol{\theta})$ 是参数 $\boldsymbol{\theta}$ 对应的经验风险，衡量训练集拟合误差。第二项 $\Omega(\boldsymbol{\theta})$ 是惩罚函数，这里用参数范数平方表达对较小系数的偏好。参数范数与函数复杂度的关系依赖特征尺度和参数化方式，因此不能跨模型直接比较范数大小。

系数 $\lambda \geq 0$ 控制惩罚强度。$\lambda = 0$ 时目标只包含经验风险。增大 λ 通常使解的范数减小，同时可能增大训练误差。较小系数有时能降低数据扰动引起的预测波动，但不能保证更接近真实参数。应使用验证数据选择 λ，并用未参与选择的测试数据评价最终预测效果。

例 2.1. 根据温度记录预测下一时刻温度时，若已知相邻时刻通常连续变化，可以采用平滑性假设。若设备存在周期，可以把相应周期特征加入输入。这些选择限制了候选预测关系。只有假设与设备运行条件相符时，这种限制才可能帮助有限样本下的学习。

惩罚目标与复杂度约束。 若希望直接限制惩罚函数的取值，可以先规定复杂度预算 c，得到约束问题

$$\min_{\theta} \hat{R}(\theta) \quad \text{subject to} \quad \Omega(\theta) \le c. \tag{2.10}$$

该问题在 $\Omega(\theta) \le c$ 的可行参数中，选择经验风险最小的参数。预算限制的是选定的 Ω，不能无条件等同于限制任意模型的全部复杂度。

约束问题也可以通过拉格朗日乘子写成

$$L(\theta, \lambda) = \hat{R}(\theta) + \lambda\big(\Omega(\theta) - c\big), \qquad \lambda \ge 0. \tag{2.11}$$

固定 λ 后，$-\lambda c$ 与 θ 无关，不会改变拉格朗日函数关于参数的最优解，剩下的就是惩罚形式 $\hat{R}(\theta) + \lambda\Omega(\theta)$。这里 $c \ge 0$ 规定复杂度上限，$\lambda \ge 0$ 规定单位复杂度的惩罚代价。要让约束问题的解也最小化这个惩罚目标，需要存在相应的最优乘子。对于定义在整个参数空间上的有限连续凸函数，若最优解存在，且有某个参数满足 $\Omega(\theta) < c$，凸对偶理论可以给出这种联系。该结论不要求模型必须线性。对非凸网络，任意约束问题未必都与某个惩罚问题全局等价，λ 与 c 也未必一一对应。

在约束问题的最优点 $\hat{\theta}$ 处，若目标与约束满足相应的凸性条件，可以写出

$$0 \in \partial\hat{R}(\hat{\theta}) + \lambda\partial\Omega(\hat{\theta}), \qquad \Omega(\hat{\theta}) \le c, \qquad \lambda(\Omega(\hat{\theta}) - c) = 0. \tag{2.12}$$

这里还需满足 $\lambda \ge 0$。符号 ∂ 表示凸函数的次梯度集合，它把不可微点处的斜率推广为一组可能的支撑斜率。对于凸函数 g，向量 $\boldsymbol{v} \in \partial g(\theta)$ 意味着对所有 θ' 都有 $g(\theta') \ge g(\theta) + \boldsymbol{v}^{\mathsf{T}}(\theta' - \theta)$。第一个条件表示经验风险与复杂度惩罚的斜率在最优点平衡。最后一个等式是互补条件。若 $\Omega(\hat{\theta}) < c$，互补条件强制 $\lambda = 0$。若 $\Omega(\hat{\theta}) = c$，乘子可以为正，也可以为零，不能仅凭约束取等号断定它改变了最优解。

最后用一维例子看清“收缩”究竟发生了什么。设无正则化时的训练风险为

$$\hat{R}(w) = \frac{1}{2}(w - a)^2, \tag{2.13}$$

其中 a 是只根据训练数据得到的最优估计。它的最小值在 $w = a$ 处，因为此时 w 与 a 完全一致。现在加入平方惩罚，训练目标变为

$$J(w) = \frac{1}{2}(w - a)^2 + \frac{\lambda}{2}w^2. \tag{2.14}$$

第一项希望 w 接近数据给出的估计 a，第二项希望 w 接近零。对 w 求导得到

$$J'(w) = (w - a) + \lambda w. \tag{2.15}$$

令导数为零，得到 $(1 + \lambda)w = a$，因此

$$\hat{w} = \frac{a}{1 + \lambda}. \tag{2.16}$$

由于 $\lambda \geq 0$，有 $|\hat{w}| \leq |a|$。当 $\lambda = 0$ 时不收缩，随着 λ 增大，$\hat{w}$ 逐渐靠近零。这就是“收缩”的含义：正则化不会自动判断某个变量是噪声，也不会直接把所有不重要的系数删掉，而是把参数估计向预先选定的中心（这里是零）拉近。

收缩为什么可能改善总体风险？训练数据中的偶然波动会使无正则化估计 a 在不同训练集之间变化很大，这种变化称为估计的不稳定性或方差。平方惩罚牺牲了一部分对当前训练集的贴合，使估计更稳定。但如果真实系数确实远离零，收缩会带来偏差。因此，在平方预测损失下，收缩需要权衡估计偏差平方与方差。只有相应方差的降低足以抵消偏差平方的增加，才可能降低期望预测风险。验证集用于估计这种取舍，有限验证样本也可能选错 λ。它不是“惩罚越强越好”，也不是“参数越小越接近真实机制”。

模型选择至少同时受四类约束：数据规模与标注质量、任务中的依赖结构、训练与推理资源、错误的业务代价。复杂模型是否值得采用，需要与简单基线比较预测效果及计算成本。除表示能力外，优化方式、参数共享和数据规模也会影响结果，不能仅凭结构更复杂作出判断。后文讨论的序列、视觉和语言模型，实际上是在不同结构约束下对这四个问题的回答。

2.4 任务的可学习性

在选择模型之前，还应先问一个更根本的问题：给定的输入中，是否含有足以预测目标的稳定信息？例如，设输入是风电机组叶片的图像，标签是同一时刻的发电功率。凭借领域知识可以预期，功率还强烈依赖风速、风向、空气密度、机组运行状态和控制策略。一张只反映叶片外观的图像，通常不足以充分决定功率。图像中也许包含结冰、污损或损伤等与功率有关的间接线索，但这种联系必须由数据和机理共同证实，不能因为两个变量出现在同一张数据表中，就假定二者必然存在可用于预测的关系。

训练集上的拟合能力不能单独回答任务是否可从输入中稳定预测。只要模型足够灵活，它就可以把输入空间划分为许多很小的区域，并为每个训练样本建立对应映射。以决策树回归为例，当训练输入彼此可区分，且树的深度、叶节点样本数等不受限制时，树可以把训练样本逐个分到不同叶节点，从而达到零训练误差。分类树也可以达到百分之百训练准确率。这说明模型有能力记住训练样本，却不说明图像中存在对未来功率稳定有效的预测线索。若新图像落入训练时未被充分覆盖的区域，模型只能依赖未经验证的划分和映射，训练集上的完美表现便可能无法迁移到新样本。这正是过拟合的一种典型表现。

从统计角度看，需要检查给定输入 X 后的条件分布 $P(Y \mid X)$ 是否具有可利用的结构，以及这种结构在训练和部署环境之间是否足够稳定。相近输入对应相近的标签分布，是一种可能的结构。连续性、平滑性和低维结构也可以支持对未见样本的预测。但这些条件并不适用于所有任务，判断时还要结合样本覆盖、噪声水平和模型假设。即使存在稳定关系，有限训练数据也未必足以学到它。

现实中的困难在于，输入空间往往高维，且样本真实分布不均匀。有限样本更不可能把整个空间都覆盖。因此，数据中是否存在规律通常不能仅靠观察几个样本来断言。一个有用的直觉是：若相同或非常相近的输入在输入空间的一个小邻域内反复对应差异很大的标签，那么只使用这些输入时就存在不可消除的不确定性。即使知道真实条件分布，也不可能准确预测每一个样本。相反，若 X 能够稳定地缩小 Y 的不确定性，使合适的预测函数在独立新样本上显著优于“不看输入、只预测平均值或多数类”的基线，则该任务具有可学习的信号。这里的“规律”不要求是线性的、显式的，或容易写成公式。它可以是高度非线性的统计关系，但必须能够在新的数据中重复出现。

有限观测只能支持有条件的经验判断，不能保证同一规律在任意未来环境中继续成立。实践中应结合四类检查：首先用领域机理审查输入到标签的路径，确认不是把结果发生之后的信息误当作输入。其次检查标签的测量质量、时间对齐和样本覆盖，避免真实信号被噪声或错误配对淹没。再次在严格隔离的验证集或测试集上，与不使用输入的简单基线比较。最后检验结果是否能跨时间、机组或运行条件复现。若模型只在训练集上优于基线，或一旦按时间、设备划分测试集就失效，更合理的结论通常是现有输入不足、分布发生了变化，或模型只记住了偶然性，而不是急于增加模型复杂度。

训练、部署与反馈。 图2.1将设备记录整理为输入和标签，再由任务确定候选模型与目标。训练数据用于求参数，验证数据用于选择超参数。独立测试完成后，模型才进入部署评价。上线后的错误可以提示下一轮补充数据或重新训练。评价时除了训练损失，还要检查新工况下的表现。概率校准表示在可比较的样本中，预测概率与实际发生频率是否相符。例如，故障概率接近 0.2 的一组样本，其故障比例也应接近 0.2。这需要在足够且适用的评价数据上检验，还不能代替对误报、漏报和推理时延的检查。

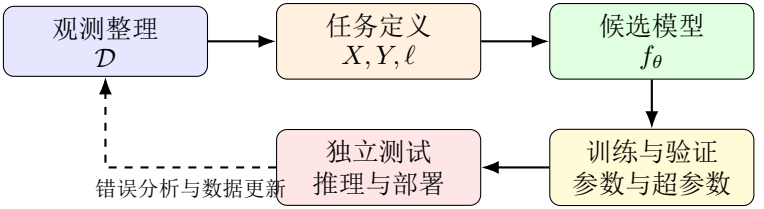


图 2.1: 训练、评价与部署的组织关系。实线箭头表示处理步骤，虚线表示部署后的反馈。观测与任务定义需要相互核对。反馈用于下一轮改进，不能据此反复选择模型后仍把同一测试集视为独立评价数据。

2.5 从问题定义到模型计算

本章确定了输入、标签、模型和训练目标之间的关系。经验风险描述训练数据上的平均损失，总体风险描述目标分布上的预测代价。归纳偏置和正则化能够约束学习，但其效果仍需要独立数据检验。

接下来需要把这些定义用于计算。第三章以线性回归说明怎样组织数据、求出参数，以及怎样用后验分布表达参数不确定性。第四章进一步比较不同任务的损失和评价指标，第五章讨论目标没有直接解或后验难以计算时的求解方法。

辅助学习材料

- **Linear Models**。作者/平台：scikit-learn Developers。英文。官方文档。重点阅读 Ordinary Least Squares、Ridge、Lasso 与 Logistic Regression 小节，配合本章的线性预测、正则化和分类损失理解参数约束与风险最小化。在线

阅读。

- **Cross-validation: evaluating estimator performance**。作者/平台：scikit-learn Developers。英文。官方文档。重点阅读训练/验证/测试划分、交叉验证和数据泄漏说明，帮助把本章的经验风险、部署风险与可复现实验边界落实为流程。在线阅读。

- **损失函数（Loss Function）**。知乎。中文解说。比较平方损失与交叉熵，核对本章预测对象。标题与主题据必应索引，原页受限。在线阅读。

- **损失函数（lossfunction）的全面介绍（简单易懂版）**。CSDN。中文博客。阅读 L1、MSE 与交叉熵说明，比较不同误差的代价。已核对公开页面标题与索引摘要。在线阅读。

- **2021 - 类神经网络训练不起来怎么办 (四) 损失函数 (Loss) 也可能有影响**。李宏毅。bilibili。中文课程。选看第 22 集，对照本章损失与学习目标。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量。已核对目录与计数，未逐帧观看。观看分集。

第三章　线性回归与概率预测

本章摘要。本章以数值回归为共同问题，先由平方损失推导正规方程，区分参数唯一性与数值敏感性。随后讨论矩阵分解求解和参数正则化。在独立同方差高斯观测假设下，极大似然估计与最小二乘具有相同的权重最优解。加入高斯先验后，可以得到最大后验估计和完整权重后验。最后利用核函数转到函数值的联合分布，说明高斯过程怎样区分潜在函数与带噪观测的预测不确定性。

上一章介绍了许多概念，但只知道名称还不足以建立一个模型。例如，输入和标签究竟怎样排成数据？参数怎样从目标函数中求出来？输出一个概率，是否就意味着参数也是随机的？本章沿着“问题形式化、参数估计、贝叶斯线性回归、投影解释”的线索组织推导 [**?**]，但用本书的工业预测任务重新表述这些关系。

我们始终围绕同一个回归问题展开。先把预测写成输入与权重的加权和，再把它看作条件分布的均值，随后用权重的后验分布表达有限数据带来的不确定性，最后不再显式保存有限维权重，而是在函数空间中用协方差函数描述任意输入处的联合不确定性。这样既能看清四种视角之间的联系，也能看清它们对模型结构和计算方式作出的不同选择。

3.1　数据与回归任务

一个带标签样本由输入 $\boldsymbol{x}_i$ 和对应的标签 y_i 组成，其中 i 是样本编号。输入是预测时可用的信息，用 d 个数值特征组成的列向量表示。标签是希望根据这些信息预测的目标量。本章讨论实数值的回归任务，因此

$$\boldsymbol{x}_i = (x_{i1}, \dots, x_{id})^{\mathsf{T}} \in \mathbb{R}^d, \qquad y_i \in \mathbb{R}. \tag{3.1}$$

这里 x_{ij} 表示第 i 个样本的第 j 个特征。标签 y_i 是训练时已经观测到的目标值，模型给出的预测值则记为 $\hat{y}_i$，两者需要区分。标签也可能含有观测噪声，并不一定是完全精确的真值。

将 n 个输入与各自的标签配对，得到训练集

$$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}. \tag{3.2}$$

训练的目的是根据这些已知配对学习从输入到目标的关系，再对新输入预测尚未知的标签。这属于监督学习。对未来量的预测，输入只能包含预测时刻已经可用的信息，未来的目标观测只能作为历史样本的标签，不能提前放入输入。

下一小时温度预测。 在每个历史预测时刻，记录设备当前的温度和振动，并将下一小时实际测得的温度作为标签：

$$\boldsymbol{x}_i = (\text{当前温度}_i, \text{当前振动}_i)^{\mathsf{T}} \in \mathbb{R}^2, \qquad y_i = \text{下一小时温度}_i. \tag{3.3}$$

这个例子中 $d = 2$，每一对 $(\boldsymbol{x}_i, y_i)$ 对应一次历史预测及其后续观测。训练完成后，给出新的当前温度和振动读数，模型便输出对下一小时温度的预测。

模型结构与参数。 回归模型先写成

$$f_{\boldsymbol{w},b}(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b. \tag{3.4}$$

这里 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{w} \in \mathbb{R}^d$ 且 $b \in \mathbb{R}$。“加权求和再加截距”构成模型结构，$\boldsymbol{w}$ 和 b 是要从数据中学习的参数。输入 $\boldsymbol{x}$ 与历史标签 y 属于数据。例如，两个权重为 $0.8, 0.2$、截距为 1 时，预测就是 $0.8x_1 + 0.2x_2 + 1$。训练过程确定这些参数，已经观测到的读数则保持不变。

基函数与输入表示。 更一般地，可先选择 M 个预先规定的基函数（basis functions），把原始输入映射为特征向量

$$\boldsymbol{\phi}(\boldsymbol{x}) = (\phi_1(\boldsymbol{x}), \ldots, \phi_M(\boldsymbol{x}))^{\mathsf{T}}, \qquad f_{\boldsymbol{w}}(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{\phi}(\boldsymbol{x}). \tag{3.5}$$

这时“线性”始终是指 $f_{\boldsymbol{w}}$ 对参数 $\boldsymbol{w}$ 线性，并不要求 ϕ_j 对原始输入线性。对一维温度读数 x，可取 $\boldsymbol{\phi}(x) = (1, x, x^2)^{\mathsf{T}}$，得到二次曲线。对振动窗口，可将均方根、峭度、频带能量或某个频率分量作为不同的 ϕ_j。基函数负责规定模型能够看见和组合什么模式，权重负责根据标签决定这些模式各占多大作用。若基函数由训

练数据本身估计，例如标准化均值、主成分分析（Principal Component Analysis，PCA）投影或特征选择规则，则它们也必须只在训练部分拟合，再应用于验证和测试数据。

给定 n 个输入后，式(3.5)形成设计矩阵 $\Phi \in \mathbb{R}^{n\times M}$，其中 $\Phi_{ij}=\phi_j(\boldsymbol{x}_i)$。从这里开始，统一用 X 表示实际进入线性回归计算的设计矩阵，其列数记为 p。原始特征模型中 $p=d$，基函数模型中 $p=M$。参数向量 $\boldsymbol{w}\in\mathbb{R}^p$，使 $X\boldsymbol{w}\in\mathbb{R}^n$。改变原始特征或加入基函数会改变 X 及 p，最小二乘、岭回归和贝叶斯线性回归仍使用相同的矩阵推导。

以下推导都可以自然包含截距。令增广特征为 $\tilde{\boldsymbol{x}}_i=(\boldsymbol{x}_i^{\mathsf{T}},1)^{\mathsf{T}}$、增广参数为 $\tilde{\boldsymbol{w}}=(\boldsymbol{w}^{\mathsf{T}},b)^{\mathsf{T}}$，则 $\tilde{\boldsymbol{w}}^{\mathsf{T}}\tilde{\boldsymbol{x}}_i=\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i+b$。在设计矩阵中增加一列全为 1 的特征，就能把截距并入参数向量。后文用 X 表示当前模型的设计矩阵，用 p 表示它的列数，故 $X\in\mathbb{R}^{n\times p}$ 且 $\boldsymbol{w}\in\mathbb{R}^p$。若将截距并入参数，$p$ 会比其余特征数多 1。岭惩罚或高斯先验可以对截距采用不同的规则，因此不应自动收缩这一坐标。

3.2 确定性线性预测与参数估计

3.2.1 平方损失与正规方程

本节将进入设计矩阵的特征向量也简记为 $\boldsymbol{x}_i\in\mathbb{R}^p$。使用基函数时，它代表基函数向量，使用截距时则包含常数坐标。给定一组参数，模型直接输出 $\hat{y}_i=\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i$。这里的“确定性”只描述输入和参数固定时输出的状态。真实观测仍可能含有噪声，训练数据改变后参数也会随之改变。

模型已经规定了允许怎样预测，还需要目标函数规定怎样比较预测。选择平方损失

$$\ell_i=\frac{1}{2}(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i-y_i)^2,\qquad \hat{R}(\boldsymbol{w})=\frac{1}{n}\sum_{i=1}^{n}\ell_i. \tag{3.6}$$

单个样本的损失衡量一次预测偏差，经验风险是训练样本损失的平均值。平方让正负偏差不会抵消，也使较大的偏差受到更强惩罚。平方损失体现了我们对错误代价的选择，并非线性模型结构唯一规定的损失。

一个简单的手算例子。 为便于手算，暂时只保留一个输入，取 $(x_1, y_1) = (1, 2)$、$(x_2, y_2) = (2, 3)$，模型为 $\hat{y} = wx$。本章用损失之和写训练目标：

$$J(w) = \frac{1}{2}[(w-2)^2 + (2w-3)^2]. \tag{3.7}$$

求导得到 $J'(w) = (w-2) + 2(2w-3) = 5w - 8$。令导数为零，得到 $\hat{w} = 8/5$，两个预测分别为 1.6 和 3.2。它没有逐点穿过观测，却使总平方误差最小。这给出了从数据、模型和损失求出参数的过程。

最小二乘的矩阵表示。 把每个 $\boldsymbol{x}_i^{\mathsf{T}}$ 排成设计矩阵 $X \in \mathbb{R}^{n \times p}$ 的一行，将标签排成 $\boldsymbol{y} \in \mathbb{R}^n$，则

$$J(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2. \tag{3.8}$$

梯度为 $X^{\mathsf{T}}(X\boldsymbol{w} - \boldsymbol{y})$，令它为零得到**正规方程** (normal equations)

$$X^{\mathsf{T}}X\hat{\boldsymbol{w}} = X^{\mathsf{T}}\boldsymbol{y}. \tag{3.9}$$

当 X 的列线性无关时，$X^{\mathsf{T}}X$ 可逆，最小二乘解唯一。若 X 有零空间方向，不同参数会产生相同的训练预测，这些参数无法由当前设计矩阵区分。特别地，若两列完全相同，训练数据只能确定相应系数的和。这里讨论的是参数在当前训练设计下的可识别性，不能单凭它断定任意更大总体模型中的参数可识别。正规方程也可写成逆矩阵形式，但实际计算通常用矩阵分解求解，而不显式求逆。

这个条件也把样本数与特征数的关系说清楚了。对 $X \in \mathbb{R}^{n \times p}$，$X^{\mathsf{T}}X$ 可逆当且仅当 X 有满列秩，即 $\operatorname{rank}(X) = p$。因此 $n \geq p$ 只是可逆的必要条件，并非充分条件：即使样本数不少于特征数，重复或线性相关的特征列仍会使矩阵不可逆。反过来，若 $n < p$，则

$$\operatorname{rank}(X) \leq n < p. \tag{3.10}$$

于是 X 不可能满列秩，必存在非零向量 $\boldsymbol{v}$ 满足 $X\boldsymbol{v} = \boldsymbol{0}$，从而 $X^{\mathsf{T}}X\boldsymbol{v} = \boldsymbol{0}$。所以 $X^{\mathsf{T}}X$ 必定不可逆。直观地说，参数个数多于训练样本时，仅凭这些样本无法唯一确定每个权重。

解的唯一性与数值敏感性。 正规方程的矩阵不可逆，意味着参数不能由数据唯一确定，并不意味着最小二乘问题无解。若特征列完全共线，或样本数不足以约束所有参数，X 就不满列秩。此时若 $\hat{\boldsymbol{w}}$ 是一个最小二乘解，则对任意满足 $X\boldsymbol{v}=\mathbf{0}$ 的向量 $\boldsymbol{v}$，$\hat{\boldsymbol{w}}+\boldsymbol{v}$ 也给出相同的训练集预测。问题在于数据不能唯一识别参数，而非最小二乘目标没有最优解。可以删除冗余特征、重新参数化，或用穆尔–彭罗斯伪逆 X^{+} 选取最小范数解 $X^{+}\boldsymbol{y}$。

与此同时，更容易被忽略的是：X 满列秩，解在数学上唯一，但特征近似共线，使某些参数方向只受到数据很弱的约束。令 $A=X^{\mathsf{T}}X$，其特征分解为

$$A=Q\,\mathrm{diag}(\mu_1,\dots,\mu_p)Q^{\mathsf{T}},\qquad \mu_j>0,\qquad Q^{\mathsf{T}}Q=I. \tag{3.11}$$

记 Q 的第 j 列为 $\boldsymbol{q}_j$，则

$$A^{-1}=\sum_{j=1}^{p}\frac{1}{\mu_j}\boldsymbol{q}_j\boldsymbol{q}_j^{\mathsf{T}}. \tag{3.12}$$

固定 X，若正规方程的右端 $\boldsymbol{b}=X^{\mathsf{T}}\boldsymbol{y}$ 受到扰动 $\delta\boldsymbol{b}$，参数变化恰好为

$$\delta\boldsymbol{w}=A^{-1}\delta\boldsymbol{b}=\sum_{j=1}^{p}\frac{\boldsymbol{q}_j^{\mathsf{T}}\delta\boldsymbol{b}}{\mu_j}\boldsymbol{q}_j. \tag{3.13}$$

因此，小特征值方向上的右端扰动会被放大 $1/\mu_j$ 倍。标签若发生小扰动 $\delta\boldsymbol{y}$，右端就相应变化为 $\delta\boldsymbol{b}=X^{\mathsf{T}}\delta\boldsymbol{y}$。当矩阵病态时，标签中的小扰动也可能使求出的权重发生很大变化。实际标签通常含有测量误差、记录误差或其他观测噪声，不能把它们当作完全精确的数值。因此，矩阵可逆只保证解唯一，不保证解可靠。病态矩阵会使参数估计对标签噪声敏感。

正规方程的正交投影解释。 所有可由该模型给出的训练集预测向量构成 X 的列空间

$$\mathcal{C}(X)=\{X\boldsymbol{w}:\boldsymbol{w}\in\mathbb{R}^{p}\}\subseteq\mathbb{R}^{n}. \tag{3.14}$$

最小二乘的搜索范围限定在 $\mathcal{C}(X)$：预测向量必须来自这个列空间，而不能在 $\mathbb{R}^{n}$ 中任意选取一个接近 $\boldsymbol{y}$ 的向量。令残差为 $\boldsymbol{r}=\boldsymbol{y}-X\hat{\boldsymbol{w}}$。从预测向量 $X\hat{\boldsymbol{w}}$ 沿列空间中的任意方向 $X\boldsymbol{v}$ 作一个微小移动，平方残差不能在一阶继续下降，因此

$$0=\frac{\mathrm{d}}{\mathrm{d}\epsilon}\frac{1}{2}\|\boldsymbol{r}-\epsilon X\boldsymbol{v}\|_2^2\Big|_{\epsilon=0}=-\boldsymbol{v}^{\mathsf{T}}X^{\mathsf{T}}\boldsymbol{r}\quad\text{对任意}\boldsymbol{v}. \tag{3.15}$$

故 $X^{\mathsf{T}}\boldsymbol{r}=0$，这就是式(3.9)。从几何上看，拟合向量 $X\hat{\boldsymbol{w}}$ 是 $\boldsymbol{y}$ 到列空间的正交投影，残差垂直于每一列特征。若 X 秩不足，不同权重可生成同一个投影向量。因此训练集上的最佳预测唯一，但参数表示未必唯一。选择最小范数解 $X^{+}\boldsymbol{y}$，是在这些同样拟合训练数据的参数中选取一个代表，不改变最优的训练拟合。这里有两个需要分别观察的问题：数据能否唯一确定参数，以及求出的参数对扰动是否稳定。下面先说明实际软件怎样求解这个线性最小二乘问题，再在拟合要求之外加入对参数的偏好，看看它怎样缓解病态情况下参数对标签噪声的敏感性。

3.2.2 最小二乘的数值求解

正规方程给出了一个清晰的数学条件，但它不是计算机实现线性回归时的首选操作流程。若直接写成

$$\hat{\boldsymbol{w}}=(X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\boldsymbol{y}, \tag{3.16}$$

就需要显式构造逆矩阵。实际数值线性代数中通常只需解线性方程组：给定矩阵 A 和右端 $\boldsymbol{b}$，求满足 $A\boldsymbol{w}=\boldsymbol{b}$ 的 $\boldsymbol{w}$，而不计算 A^{-1}。原因有三点：求逆通常需要更多运算和内存。数值误差会被不必要地放大。得到逆矩阵也没有为后续预测提供额外好处。

正规方程的 Cholesky 求解。 当 X 满列秩时，$A=X^{\mathsf{T}}X$ 是对称正定矩阵，可以分解为

$$A=LL^{\mathsf{T}}, \tag{3.17}$$

其中 L 是对角线为正的下三角矩阵。求解正规方程只需依次解两个三角方程：

$$L\boldsymbol{z}=X^{\mathsf{T}}\boldsymbol{y},\qquad L^{\mathsf{T}}\hat{\boldsymbol{w}}=\boldsymbol{z}. \tag{3.18}$$

三角方程可以从前往后、再从后往前代入，整个过程不需要求逆。不过，在二范数下，形成 $X^{\mathsf{T}}X$ 会使条件数严格平方，即 $\kappa_2(X^{\mathsf{T}}X)=\kappa_2(X)^2$。因此，Cholesky 适合规模较小且已经确认数值条件良好的问题，不是普通最小二乘的默认首选。

满列秩问题的 QR 求解。 当 $n\ge p$ 且 X 满列秩时，对 X 作简化 QR 分解

$$X=QR,\qquad Q\in\mathbb{R}^{n\times p},\quad R\in\mathbb{R}^{p\times p},\quad Q^{\mathsf{T}}Q=I_p, \tag{3.19}$$

其中 R 是可逆的上三角矩阵。由最小二乘的正交投影条件，先计算

$$Q^{\mathsf{T}}\boldsymbol{y}, \tag{3.20}$$

再解三角方程

$$R\hat{\boldsymbol{w}} = Q^{\mathsf{T}}\boldsymbol{y}. \tag{3.21}$$

QR 不必显式形成 $X^{\mathsf{T}}X$，所以通常比“先构造正规方程再求解”更稳定。实际库一般使用 Householder 变换，而不是逐列手工构造 Q，因为 Householder 变换能在保持正交性的同时减少舍入误差。

病态或秩不足问题的 SVD 求解。 若特征高度相关、列不满秩，或者需要判断哪些方向实际上由数据支持，可使用奇异值分解

$$X = U\Sigma V^{\mathsf{T}}. \tag{3.22}$$

这里 $U \in \mathbb{R}^{n\times n}$、$V \in \mathbb{R}^{p\times p}$ 且 $\Sigma \in \mathbb{R}^{n\times p}$。若奇异值为 σ_j，数值求解时可使用

$$\hat{\boldsymbol{w}} = V\Sigma^{+}U^{\mathsf{T}}\boldsymbol{y}, \qquad \Sigma^{+}_{jj} = \begin{cases} 1/\sigma_j, & \sigma_j > \text{容差}, \\ 0, & \sigma_j \le \text{容差}. \end{cases} \tag{3.23}$$

若只将零奇异值对应的项置零，该表达式给出原问题的最小范数解。若还截断非零的小奇异值，就改变了估计规则，得到的是截断 SVD 解，未必是原问题的最小二乘解。SVD 的计算成本通常高于 QR，但能直接显示各方向的奇异值，适合诊断病态性和处理秩不足。这里的“容差”是数值判据，不是把小奇异值方向无条件当成真实无关。阈值仍应结合尺度、噪声和验证结果选择。

大规模问题的迭代求解。 当 X 稀疏、样本或特征数量很大时，软件可能不显式存储分解，而使用 LSQR（Least Squares QR，最小二乘 QR）和 LSMR（Least Squares Minimal Residual，最小残差最小二乘）等迭代方法，通过计算 $X\boldsymbol{v}$ 和 $X^{\mathsf{T}}\boldsymbol{u}$ 逐步逼近最小二乘解。若求解对称正定的岭回归系统，也可使用共轭梯度法。迭代法需要设置停止条件，并监控残差、迭代次数和验证集表现。它不是因为“不能求逆”才使用，而是为了避免大规模矩阵分解的时间和内存成本。

岭回归的数值实现。 岭回归的方程为

$$(X^{\mathsf{T}}X + \lambda I)\hat{\boldsymbol{w}}_\lambda = X^{\mathsf{T}}\boldsymbol{y}. \tag{3.24}$$

它可以用 Cholesky 求解，但同样不必显式构造逆矩阵。更稳定的做法是把问题改写为增广最小二乘：

$$\min_{\boldsymbol{w}} \left\| \begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix} \boldsymbol{w} - \begin{bmatrix} \boldsymbol{y} \\ \boldsymbol{0} \end{bmatrix} \right\|_2^2, \tag{3.25}$$

然后直接对增广矩阵使用 QR 或 SVD。若截距不应正则化，只需将对应的 $\sqrt{\lambda}$ 行删除或置为零。

这些方法对应不同的计算条件。普通最小二乘可优先考虑 QR，需要诊断数值秩或处理秩不足时可使用 SVD。已经形成且条件良好的对称正定系统适合 Cholesky，超大规模或稀疏问题则适合相应的迭代法。实现时应调用最小二乘或线性方程求解接口，以避免不必要的显式求逆。求解后还应检查残差 $\|X\hat{\boldsymbol{w}} - \boldsymbol{y}\|_2$、数值秩和验证集误差，不能只因为程序返回了一个向量就认为结果可靠。

3.2.3 参数正则化与变量选择

只追求训练误差小，可能得到对数据扰动敏感的权重。岭回归在平方损失之外加入二次惩罚 [**?**]：

$$J_\lambda(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \frac{\lambda}{2}\|\boldsymbol{w}\|_2^2, \qquad \lambda \geq 0. \tag{3.26}$$

第一项要求解释数据，第二项惩罚权重向量的平方范数。它在拟合效果相近时偏好较小的权重，但其含义依赖特征单位。与前面用伪逆从原有最小二乘解中选取最小范数代表不同，有限强度的岭惩罚改变了优化目标，通常也改变最优的训练拟合。因此，岭惩罚是为了控制参数而引入的建模选择。矩阵不可逆时，可以根据问题目标决定是否采用它。对参数求导，得到

$$(X^{\mathsf{T}}X + \lambda I)\hat{\boldsymbol{w}}_\lambda = X^{\mathsf{T}}\boldsymbol{y}, \tag{3.27}$$

其中 $I = I_p$ 是 $p \times p$ 单位矩阵。只要 $\lambda > 0$ 且所有坐标都受惩罚，这个解就唯一，即使特征列相关也成立。若不惩罚截距，应把 I_p 改成相应坐标为零的对角惩罚矩阵，此时需另行核对唯一性。

岭回归的作用不仅是让矩阵可逆，更是在数据约束薄弱的方向上抑制过大的权重。若所有坐标均受惩罚，$X^{\mathsf{T}}X+\lambda I$ 的特征值为 $\mu_j+\lambda$，求解时相应的放大因子从 $1/\mu_j$ 变为 $1/(\mu_j+\lambda)$，从而减弱小特征值方向上的噪声放大。但它通过改变估计目标换取稳定性，会引入收缩偏差。若截距不受惩罚，上述统一平移所有特征值的结论不直接适用，可先中心化数据，再对特征权重讨论这一结论。

Lasso 的稀疏系数。 Lasso（Least Absolute Shrinkage and Selection Operator，最小绝对收缩与选择算子）使用绝对值惩罚：

$$J_{\text{lasso}}(\boldsymbol{w})=\frac{1}{2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2+\lambda\|\boldsymbol{w}\|_1,\qquad \|\boldsymbol{w}\|_1=\sum_{j=1}^{p}|w_j|. \tag{3.28}$$

ℓ_1 惩罚在零点不可微，其次梯度条件允许某些 w_j 恰好等于零，因此 Lasso 不仅收缩系数，还能产生稀疏模型。它适合特征很多、希望进行变量筛选的场景，但当特征高度相关时，可能任意保留其中一列而丢弃其他列，选择结果会对数据扰动敏感。Lasso 通常不能像岭回归那样通过一个线性方程组直接求解，而使用坐标下降、近端梯度或其他凸优化方法。

弹性网络的组合惩罚。 Elastic Net（弹性网络）同时加入 ℓ_1 和 ℓ_2 惩罚：

$$J_{\text{EN}}(\boldsymbol{w})=\frac{1}{2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2+\lambda_1\|\boldsymbol{w}\|_1+\frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2,\qquad \lambda_1,\lambda_2\ge 0. \tag{3.29}$$

ℓ_1 项鼓励零系数，ℓ_2 项缓解共线特征之间的不稳定性，并倾向于让相关特征成组保留。$\lambda_1=0$ 时退化为岭回归，$\lambda_2=0$ 时退化为 Lasso。两个超参数必须在验证数据上选择，不能只根据训练误差决定。

Group Lasso 的分组选择。 当特征天然分成组，例如一个类别变量展开出的哑变量、同一传感器产生的一组频域特征，可以使用 Group Lasso：

$$J_{\text{group}}(\boldsymbol{w})=\frac{1}{2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2+\lambda\sum_{g=1}^{G}\alpha_g\|\boldsymbol{w}_g\|_2. \tag{3.30}$$

这里 G 是预先规定的组数，各组互不重叠且覆盖全部受惩罚坐标。$\boldsymbol{w}_g$ 是第 g 组系数，$\lambda\ge 0$ 控制总体惩罚强度，$\alpha_g>0$ 是组权重。常取 α_g 为组内系数个数的平

方根，以减轻组大小不同造成的选择偏向。该惩罚倾向于让整组系数同时为零，因此比普通 Lasso 更符合“选择或删除一个特征组”的先验结构。组内若还需要进一步稀疏，可以使用稀疏组 Lasso，同时加入组级 ℓ_2 范数和元素级 ℓ_1 范数。

非凸惩罚与收缩偏差。 Lasso 对较大的系数仍施加线性增长的惩罚，可能把真正重要的系数收缩得过小。SCAD（Smoothly Clipped Absolute Deviation，平滑截断绝对偏差）和 MCP（Minimax Concave Penalty，极小最大凹惩罚）等非凸惩罚会让惩罚对系数的边际增长率在系数较大时逐渐减弱，从而减少收缩偏差：

$$J(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \sum_{j=1}^{p} p_\lambda(|w_j|). \tag{3.31}$$

这里 p_λ 是由非负强度参数 λ 控制的标量惩罚函数，SCAD 和 MCP 还各有形状参数。减弱大系数的收缩可能降低估计偏差，但效果依赖数据与参数选择。目标通常不再凸，求解结果可能依赖初始化，局部最优点也可能不同。

约束式正则化与早停。 惩罚形式也可以改写为约束形式，给定 Lasso 惩罚问题的最优解 $\hat{\boldsymbol{w}}_\lambda$，令 $t = \|\hat{\boldsymbol{w}}_\lambda\|_1$，则该解也最小化对应的约束问题：

$$\min_{\boldsymbol{w}} \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 \quad \text{subject to} \quad \|\boldsymbol{w}\|_1 \le t. \tag{3.32}$$

反向从给定 t 找出对应的 λ 需要适当的最优乘子。多个 λ 可能对应同一个解，因而这两种参数化未必一一对应。在神经网络等迭代优化模型中，限制训练轮数的早停也可产生正则化效果：参数尚未完全拟合训练噪声时停止，相当于限制了模型有效复杂度，但它不是显式的参数范数惩罚，必须通过验证集选择停止时刻。

这些惩罚回应不同的问题。岭回归收缩所有受惩罚系数，主要用于控制薄弱方向上的估计波动。需要删除部分特征时，可以使用 Lasso。相关特征的稀疏选择不稳定时，Elastic Net 再加入二次惩罚。已知特征组需要整体选择时，Group Lasso 按组计算范数。SCAD 和 MCP 则减弱大系数处的边际惩罚，但增加了非凸求解困难。它们的预测效果都需要独立验证，不能根据训练误差或参数是否稀疏直接排序。

处理这类问题时，应区分三个目的：完全共线时，删除冗余列、重新参数化或选取伪逆解，可以处理参数表示不唯一。计算普通最小二乘时，QR 或 SVD 分解

可以避免显式求逆及构造正规方程造成的额外数值误差，但无法消除数据本身的敏感性。若希望降低噪声引起的参数波动，则可依据验证结果选择岭惩罚、截断小奇异值，或补充能区分相关特征的数据。后两类收缩处理改变了估计规则，需要评估稳定性与偏差的取舍。因此，“不可逆”并不自动意味着必须使用岭回归，“已经求出唯一解”也不足以保证估计结果可靠。

在刚才的例子中，$X^{\mathsf{T}}X=5$、$X^{\mathsf{T}}\boldsymbol{y}=8$，因此 $\hat{w}_\lambda=8/(5+\lambda)$。取 $\lambda=3$，权重从 1.6 缩为 1，预测变成 $1,2$。训练误差变大了，但权重也更小了。是否因此更适合新数据，要用未参与拟合的数据检验，不能只凭惩罚项判断。

λ 是控制学习偏好的超参数，而 $\boldsymbol{w}$ 是给定这个偏好后学出的参数。选择 λ 通常需要验证数据。惩罚还受特征单位影响，因此一般先按训练数据的统计量调整特征尺度。若改用平均损失，目标中的相同数值 λ 不再代表同样的惩罚强度：$\hat{R}+\lambda\|\boldsymbol{w}\|^2/2$ 乘以 n 后，对应的求解矩阵是 $X^{\mathsf{T}}X+n\lambda I$。以下推导都沿用损失求和的约定。

3.3 高斯观测模型与极大似然估计

3.3.1 条件分布与似然函数

本节使用设计矩阵的行特征记号。令 $\boldsymbol{x}\in\mathbb{R}^p$ 为一个样本的特征向量，$\boldsymbol{w}\in\mathbb{R}^p$ 为对应参数。若模型已加入截距，常数坐标也包含在该向量中。给定输入后，假设观测在模型均值附近波动：

$$Y=\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}+\varepsilon,\qquad \varepsilon\sim\mathcal{N}(0,\sigma^2),\qquad Y\mid\boldsymbol{x},\boldsymbol{w}\sim\mathcal{N}(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x},\sigma^2). \tag{3.33}$$

这里 $\mathcal{N}$ 表示高斯分布，$\sigma^2>0$ 是噪声方差。随机性放在标签 Y 上。参数 $\boldsymbol{w}$ 和噪声方差 σ^2 都是模型中需要确定的量。为了先看清权重的求解过程，下面先暂时固定 σ^2，随后再对它进行最大似然估计。训练后，点估计模型保存的是确定的 $\hat{\boldsymbol{w}}$ 和 $\hat{\sigma}^2$。

假设给定输入和参数后，各样本的观测噪声相互独立。对第 i 个样本，前面的高斯观测模型给出条件密度

$$p(y_i\mid\boldsymbol{x}_i,\boldsymbol{w})=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(y_i-\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2}{2\sigma^2}\right]. \tag{3.34}$$

其中 y_i 是已经观测到的数值，$\boldsymbol{x}_i$ 是已知输入，$\boldsymbol{w}$ 是待比较的参数。指数中的平方项衡量模型均值 $\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i$ 与标签 y_i 之间的差异。差异越大，该参数对这条观测分配的密度越小。

独立性使得 n 条观测的联合条件密度等于各项密度的乘积。把式(3.34)代入，得到条件似然

$$L(\boldsymbol{w}) = \prod_{i=1}^{n} p(y_i \mid \boldsymbol{x}_i, \boldsymbol{w}) \tag{3.35}$$

$$= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2}{2\sigma^2}\right] \tag{3.36}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2\right]. \tag{3.37}$$

最后一行用了两个基本运算规则：相同的常数相乘得到 $(2\pi\sigma^2)^{-n/2}$，指数函数的乘积等于指数中各项之和。把各样本残差排成向量，注意

$$\sum_{i=1}^{n}(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2 = \|X\boldsymbol{w} - \boldsymbol{y}\|_2^2, \tag{3.38}$$

因此也可以写成

$$L(\boldsymbol{w}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2\right]. \tag{3.39}$$

这里需要区分联合概率密度与似然函数。若把参数 $\boldsymbol{w}$ 固定，把可能出现的标签 $(y_1, \ldots, y_n)$ 看作变量，则

$$p(\boldsymbol{y} \mid X, \boldsymbol{w}) = \prod_{i=1}^{n} p(y_i \mid \boldsymbol{x}_i, \boldsymbol{w}) \tag{3.40}$$

是给定模型参数后，观测数据的联合条件密度。对所有可能的 $\boldsymbol{y}$ 积分，它的总量为 1。而训练时，标签 $\boldsymbol{y}$ 已经观测到，变化的是待估计的参数，于是把同一个表达式看作参数 $\boldsymbol{w}$ 的函数：

$$L(\boldsymbol{w}; \boldsymbol{y}, X) = p(\boldsymbol{y} \mid X, \boldsymbol{w}). \tag{3.41}$$

这就是**“似然函数”**(likelihood function)。它用来比较不同参数对当前数据的解释程度，但不把 $\boldsymbol{w}$ 本身看作随机变量，也不要求似然对 $\boldsymbol{w}$ 积分为 1。因此，联合概

率密度和似然函数可以写成同一个数学表达式，区别在于哪一个量被视为变量，以及概率归一化针对哪个对象。为避免直接处理很小的乘积，通常取对数：

$$\log L(\boldsymbol{w}) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2, \tag{3.42}$$

$$-\log L(\boldsymbol{w}) = \frac{n}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.43}$$

取负号后，最大化似然就等价于最小化“**负对数似然**”（Negative Log-Likelihood）。先固定 σ^2，由于第一项与 $\boldsymbol{w}$ 无关，且 $1/(2\sigma^2)$ 是正常数，关于 $\boldsymbol{w}$ 的最大似然估计等价于最小化平方误差 $\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2$。因此

$$\hat{\boldsymbol{w}}_{\mathrm{ML}} = \arg\min_{\boldsymbol{w}} \|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.44}$$

当 X 满列秩时，它就是正规方程的唯一解。若 X 秩不足，则可用伪逆选取一个最小二乘解。

现在同时估计噪声方差。令

$$\mathrm{SSE}(\boldsymbol{w}) = \|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.45}$$

将 $\boldsymbol{w}$ 固定为某个值，把负对数似然看作 σ^2 的函数：

$$\mathcal{L}(\sigma^2) = \frac{n}{2}\log(2\pi\sigma^2) + \frac{\mathrm{SSE}(\boldsymbol{w})}{2\sigma^2}. \tag{3.46}$$

令 $v=\sigma^2$，对 v 求导得到

$$\frac{\mathrm{d}\mathcal{L}}{\mathrm{d}v} = \frac{n}{2v} - \frac{\mathrm{SSE}(\boldsymbol{w})}{2v^2}. \tag{3.47}$$

令导数为零，并利用 $v>0$，有

$$\hat{v} = \frac{\mathrm{SSE}(\boldsymbol{w})}{n}, \qquad \hat{\sigma}^2(\boldsymbol{w}) = \frac{1}{n}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.48}$$

二阶导数为

$$\frac{\mathrm{d}^2\mathcal{L}}{\mathrm{d}v^2} = -\frac{n}{2v^2} + \frac{\mathrm{SSE}(\boldsymbol{w})}{v^3}. \tag{3.49}$$

当 $\mathrm{SSE}(\boldsymbol{w})>0$ 时，驻点 $\hat{v}=\mathrm{SSE}(\boldsymbol{w})/n$ 位于允许的参数范围内，二阶导数为 $n/(2\hat{v}^2)>0$。一阶导数在该点左侧为负、右侧为正，因此它是负对数似然的全局最小点，也是似然的全局最大点。残差为零的边界情形将在下文单独讨论。

将权重取为最小二乘解 $\hat{\boldsymbol{w}}_{\mathrm{ML}}$，得到联合最大似然估计

$$\boxed{\hat{\sigma}^2_{\mathrm{ML}} = \frac{1}{n}\|X\hat{\boldsymbol{w}}_{\mathrm{ML}} - \boldsymbol{y}\|_2^2}, \qquad \hat{\sigma}_{\mathrm{ML}} = \sqrt{\hat{\sigma}^2_{\mathrm{ML}}}. \tag{3.50}$$

在最优残差平方和严格为正时，这个式子给出训练样本残差平方和的平均值。若最优残差为零，右端只给出边界值，不是 $\sigma^2 > 0$ 范围内存在的最大似然估计。

噪声方差的无偏估计。 最大似然方差估计一般会低估噪声方差。无偏估计（unbiased estimation）要求在相同模型下反复抽取数据时，估计量的期望等于待估计的固定参数。例如，对噪声方差 σ^2，无偏性是 $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$。这里随机变化的是训练数据及由它计算的估计量。

下面在 X 固定、满列秩且 $n > p$ 的条件下，说明为什么无偏方差估计的分母为 $n - p$。p 表示实际估计的系数总数。若包含截距，也要计入。在模型

$$\boldsymbol{y} = X\boldsymbol{w}_0 + \boldsymbol{\varepsilon}, \qquad \mathbb{E}[\boldsymbol{\varepsilon}] = \boldsymbol{0}, \qquad \mathrm{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 I_n \tag{3.51}$$

下，$\boldsymbol{w}_0 \in \mathbb{R}^p$ 表示真实的线性系数，$\boldsymbol{\varepsilon} \in \mathbb{R}^n$ 为误差向量。这里要求线性均值模型正确以及零均值、同方差且不相关的误差，不需要误差服从高斯分布。X 满列秩时，最小二乘拟合向量是

$$X\hat{\boldsymbol{w}}_{\mathrm{ML}} = P_X\boldsymbol{y}, \qquad P_X = X(X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}, \tag{3.52}$$

其中 P_X 是投影到 X 的列空间的矩阵。因此残差为

$$\boldsymbol{e} = \boldsymbol{y} - X\hat{\boldsymbol{w}}_{\mathrm{ML}} = (I_n - P_X)\boldsymbol{y} = (I_n - P_X)\boldsymbol{\varepsilon}. \tag{3.53}$$

这里 $(I_n - P_X)$ 也是投影矩阵，且它的秩为 $n - p$：拟合过程已经用 X 的 p 个独立列方向解释了 p 个自由度，残差只保留其余 $n - p$ 个方向。利用 $\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^{\mathsf{T}}] = \sigma^2 I_n$，有

$$\begin{aligned}
\mathbb{E}[\|\boldsymbol{e}\|_2^2] &= \mathbb{E}[\boldsymbol{\varepsilon}^{\mathsf{T}}(I_n - P_X)\boldsymbol{\varepsilon}] && (3.54)\\
&= \mathrm{tr}\left((I_n - P_X)\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^{\mathsf{T}}]\right) && (3.55)\\
&= \sigma^2\,\mathrm{tr}(I_n - P_X) && (3.56)\\
&= (n - p)\sigma^2. && (3.57)
\end{aligned}$$

因此，将残差平方和除以 $n-p$ 后，其期望正好等于真实噪声方差：

$$\hat{\sigma}^2_{\text{unbiased}} = \frac{\|X\hat{\boldsymbol{w}}_{\text{ML}} - \boldsymbol{y}\|_2^2}{n-p}, \qquad \mathbb{E}[\hat{\sigma}^2_{\text{unbiased}}] = \sigma^2. \tag{3.58}$$

这就是它被称为无偏估计的原因。两种估计的用途不同：$\hat{\sigma}^2_{\text{ML}}$ 用于最大化当前高斯似然，分母为 n。$\hat{\sigma}^2_{\text{unbiased}}$ 用于无偏估计真实噪声方差，分母为剩余自由度 $n-p$。若最小二乘残差为零，例如 $n=p$ 且 X 可逆，似然会随 $\sigma^2 \to 0$ 而无界增大。在本章 $\sigma^2 > 0$ 的参数空间内，此时不存在有限的方差最大似然解，不能把零残差解释为未来观测没有噪声。$n=p$ 时，无偏方差公式的分母也为零，无法使用。实际应用中还需要独立数据或交叉验证检查误差与噪声假设。

平方损失既可以直接作为错误度量，也可以从高斯观测假设推导出来。概率解释还补充了关于观测噪声的具体假设。

训练完成后，若方差也采用点估计，模型输出 $\mathcal{N}(\hat{\boldsymbol{w}}^{\mathsf{T}}\boldsymbol{x}_*, \hat{\sigma}^2)$。若方差预先已知，则保留给定的 σ^2。星号表示新输入。需要一个数值时可取其均值。需要描述观测波动时则保留分布。这里尚未将有限数据导致的参数不确定性纳入预测。

3.4 贝叶斯线性回归

3.4.1 权重的先验与后验

前面两种方法训练后都保存一组参数。只有少量数据时，可能仍有其他权重能够合理解释观测。贝叶斯回归用参数分布保留这种不确定性 [**?**, **?**]。这里把参数写成随机量，是为了表达我们对未知系数的认识。设备的真实系数并不会因此在每次预测时改变。

仍采用高斯观测模型，并为权重指定零均值高斯先验：

$$\boldsymbol{w} \sim \mathcal{N}(\boldsymbol{0}, \tau^2 I), \qquad \boldsymbol{y} \mid X, \boldsymbol{w} \sim \mathcal{N}(X\boldsymbol{w}, \sigma^2 I_n), \tag{3.59}$$

这里先验中的 $I = I_p$，各向同性高斯先验对全部 p 个系数采用相同方差，包括已并入参数的截距。这是下面推导的明确选择。若不希望截距被同样收缩，可以为它指定不同的先验方差。不同单位的特征通常应先调整尺度，再解释共同的权重方差。

其中 $\tau^2 > 0$ 描述先验允许权重偏离零的程度，I_n 是 $n \times n$ 单位矩阵。本章把 τ^2 和 σ^2 都作为给定的超参数，先看清参数分布怎样更新。训练输入 X 作为已知

条件，不对输入的产生过程建模，因此这里仍属于条件判别建模。使用贝叶斯公式本身不会改变这一点。

若权重维数为 p，上述两个高斯分布写成密度分别为

$$p(\boldsymbol{y} \mid X, \boldsymbol{w}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\|\boldsymbol{y} - X\boldsymbol{w}\|_2^2\right], \tag{3.60}$$

$$p(\boldsymbol{w}) = \frac{1}{(2\pi\tau^2)^{p/2}} \exp\left[-\frac{1}{2\tau^2}\|\boldsymbol{w}\|_2^2\right]. \tag{3.61}$$

似然的指数项衡量参数给出的均值与观测标签相差多远。先验的指数项衡量权重离零多远。似然前的系数保证密度对 $\boldsymbol{y}$ 积分为一，先验前的系数保证密度对 $\boldsymbol{w}$ 积分为一。它们在比较不同 $\boldsymbol{w}$ 时看似只是常数，但在写出完整后验或计算模型证据时不能随意丢弃。

将 X 视为已知条件，贝叶斯公式写成

$$p(\boldsymbol{w} \mid \mathcal{D}) = \frac{p(\boldsymbol{y} \mid X, \boldsymbol{w})p(\boldsymbol{w})}{\int p(\boldsymbol{y} \mid X, \boldsymbol{u})p(\boldsymbol{u})\,\mathrm{d}\boldsymbol{u}}. \tag{3.62}$$

分子把数据证据与原有偏好结合，分母保证后验积分为一。先验是看见本次训练标签之前的参数分布，后验是结合这些标签之后的参数分布。后验用概率密度描述许多可能的权重，并为它们赋予不同的可信程度。

3.4.2 最大后验估计与岭回归

若仍希望最终只保存一组权重，可以选择后验密度最大的点，称为最大后验估计（Maximum A Posteriori, MAP）。取负对数并舍去与权重无关的常数，得到

$$\hat{\boldsymbol{w}}_{\mathrm{MAP}} = \arg\min_{\boldsymbol{w}} \left\{ \frac{1}{2\sigma^2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \frac{1}{2\tau^2}\|\boldsymbol{w}\|_2^2 \right\}. \tag{3.63}$$

目标乘以 σ^2 不改变最优点。因此，在本章损失求和的约定下，它就是岭回归，且

$$\lambda = \frac{\sigma^2}{\tau^2}. \tag{3.64}$$

观测噪声越大，数据的相对作用越弱。先验越集中于零，收缩越强。这给出了正则化的一种概率解释：二次惩罚可以来自零均值高斯先验的负对数。仅凭某个惩罚项本身，还不能把模型称为贝叶斯模型。

MAP 使用先验计算后验密度的最大点，最终保存的仍是一个参数向量。若直接把 MAP 权重代入概率模型，就会省略参数不确定性对预测的影响。

3.4.3 高斯后验的配方推导

在线性高斯模型中，式(3.60)与式(3.61)的乘积仍可写成高斯形式。为看清这个结论，先把后验中依赖 $\boldsymbol{w}$ 的指数项展开。忽略暂时与 $\boldsymbol{w}$ 无关的因子，有

$$p(\boldsymbol{w}\mid\mathcal{D})\propto\exp\left\{-\frac{1}{2}\left[\boldsymbol{w}^{\mathsf{T}}(\sigma^{-2}X^{\mathsf{T}}X+\tau^{-2}I)\boldsymbol{w}-2\boldsymbol{w}^{\mathsf{T}}\sigma^{-2}X^{\mathsf{T}}\boldsymbol{y}\right]\right\}. \tag{3.65}$$

定义后验精度矩阵和信息向量

$$\Lambda=\sigma^{-2}X^{\mathsf{T}}X+\tau^{-2}I,\qquad \boldsymbol{h}=\sigma^{-2}X^{\mathsf{T}}\boldsymbol{y}, \tag{3.66}$$

$$S=\Lambda^{-1},\qquad \boldsymbol{m}=S\boldsymbol{h}. \tag{3.67}$$

这里 $\Lambda,S\in\mathbb{R}^{p\times p}$，$\boldsymbol{h},\boldsymbol{m}\in\mathbb{R}^{p}$。$\tau^2>0$ 和 $\sigma^2>0$ 保证 Λ 正定，故即使 X 秩不足，后验协方差 S 仍存在。由于 $\Lambda\boldsymbol{m}=\boldsymbol{h}$，二次项可完成平方：

$$\boldsymbol{w}^{\mathsf{T}}\Lambda\boldsymbol{w}-2\boldsymbol{w}^{\mathsf{T}}\boldsymbol{h}=(\boldsymbol{w}-\boldsymbol{m})^{\mathsf{T}}\Lambda(\boldsymbol{w}-\boldsymbol{m})-\boldsymbol{m}^{\mathsf{T}}\Lambda\boldsymbol{m}. \tag{3.68}$$

最后一项不依赖 $\boldsymbol{w}$，会被贝叶斯公式分母中的证据吸收。于是归一化后的完整后验密度为

$$p(\boldsymbol{w}\mid\mathcal{D})=\frac{1}{(2\pi)^{p/2}|S|^{1/2}}\exp\left[-\frac{1}{2}(\boldsymbol{w}-\boldsymbol{m})^{\mathsf{T}}S^{-1}(\boldsymbol{w}-\boldsymbol{m})\right], \tag{3.69}$$

即 $\boldsymbol{w}\mid\mathcal{D}\sim\mathcal{N}(\boldsymbol{m},S)$。其中 $\boldsymbol{m}$ 是后验均值，S 是后验协方差，描述权重的不确定性及其相互关联。$|S|$ 是协方差矩阵的行列式，归一化系数保证式(3.69)对所有 $\boldsymbol{w}$ 的积分为一。高斯分布的均值恰好也是密度最高点，因此这里 $\boldsymbol{m}=\hat{\boldsymbol{w}}_{\mathrm{MAP}}$。这不表示任意后验的均值与 MAP 都相等。

独立新数据的后验更新。 后验也可作为下一批数据到来之前的先验。这里要求新旧数据在给定共同参数后条件独立，不能把共享未知参数的两批数据无条件当作独立。设已有后验为 $\mathcal{N}(\boldsymbol{m}_0,S_0)$ 且 $S_0\succ 0$。新批次有 n_1 个样本，设计矩阵 $X_1\in\mathbb{R}^{n_1\times p}$、标签 $\boldsymbol{y}_1\in\mathbb{R}^{n_1}$，且噪声仍为 $\mathcal{N}(\boldsymbol{0},\sigma^2I)$，则更新后

$$S_1^{-1}=S_0^{-1}+\sigma^{-2}X_1^{\mathsf{T}}X_1, \tag{3.70}$$

$$\boldsymbol{m}_1=S_1\left(S_0^{-1}\boldsymbol{m}_0+\sigma^{-2}X_1^{\mathsf{T}}\boldsymbol{y}_1\right). \tag{3.71}$$

式(3.70)揭示了独立观测的累积方式：增加的是精度（协方差的逆），方差并不会直接相加。新数据在某个权重方向上的信息由 $X_1^{\mathsf{T}}X_1$ 决定：若 $X_1\boldsymbol{v}=\mathbf{0}$，新数据不直接增加方向 $\boldsymbol{v}$ 的精度。协方差的变化还取决于先验中不同方向的关联，不能仅凭某列是否随样本变化判断方差是否降低。将全部训练数据一次代入，或将它们分批按式(3.70)–(3.71)更新，在模型假设相同且不重复计数的条件下都会得到同一个后验。这个顺序视角也提醒我们，重复复制同一条记录并不能制造独立证据。

仍用两个样本 $(1,2),(2,3)$，取 $\sigma^2=1$、$\tau^2=1/3$。此时 $\lambda=3$，并且

$$S=(5+3)^{-1}=\frac{1}{8},\qquad m=\frac{1}{8}\times 8=1,\qquad w\mid\mathcal{D}\sim\mathcal{N}(1,1/8). \tag{3.72}$$

岭回归与 MAP 只留下 $w=1$。完整后验还留下方差 $1/8$。三者在这个例子中可以给出相同的中心预测，但保存的信息并不相同。

3.4.4 后验预测与方差分解

对新输入 $\boldsymbol{x}_*$，贝叶斯预测要把后验中的各种权重都纳入计算，具体表现为积分：

$$p(y_*\mid\boldsymbol{x}_*,\mathcal{D})=\int p(y_*\mid\boldsymbol{x}_*,\boldsymbol{w})p(\boldsymbol{w}\mid\mathcal{D})\,\mathrm{d}\boldsymbol{w}. \tag{3.73}$$

假设新观测噪声与训练噪声、权重均独立。在给定噪声方差的线性高斯模型中，由第一章的全方差公式可得

$$Y_*\mid\boldsymbol{x}_*,\mathcal{D}\sim\mathcal{N}\big(\boldsymbol{x}_*^{\mathsf{T}}\boldsymbol{m},\ \underbrace{\sigma^2}_{\text{观测噪声}}+\underbrace{\boldsymbol{x}_*^{\mathsf{T}}S\boldsymbol{x}_*}_{\text{参数不确定性}}\big). \tag{3.74}$$

第一项是在给定权重后仍存在的观测波动，第二项是不同合理权重在新输入处产生的预测差异。也可以先看没有观测噪声的线性函数值：它的后验方差只有第二项。前者描述下一次观测本身的不确定性，后者描述我们对均值函数的不确定性，使用时需要区分。

在上述一维例子中，取 $x_*=2$，后验预测的均值为 2，方差为 $1+2^2/8=3/2$。若只代入 MAP 权重，则得到 $\mathcal{N}(2,1)$，省略了额外的 $1/2$。图3.1比较这一位置处的两个条件区间。区间相同的中心来自共同的均值，宽度差异来自是否计入参数方差。

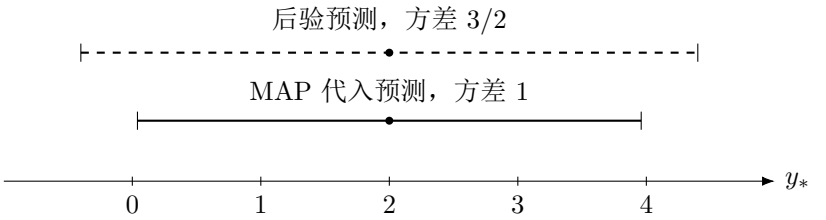


图 3.1: 给定 $x_* = 2$ 及教学算例数据后的观测预测区间。实线为 MAP 代入高斯模型的 2 ± 1.96，虚线为后验预测的 $2 \pm 1.96\sqrt{3/2}$，两者在各自模型下约含 95% 的条件概率。区间描述新观测，不是参数置信区间，也不保证真实部署覆盖率。

本章的线性高斯假设使后验和预测分布都能写成闭式形式，便于看清参数不确定性怎样传递到预测中。更一般的模型可能需要近似推断，后面的贝叶斯章节再讨论这些方法。

3.5 核贝叶斯线性回归与高斯过程

前面的贝叶斯线性回归把不确定性放在有限维权重 $\boldsymbol{w}$ 上。本节恢复 $\boldsymbol{x} \in \mathbb{R}^d$ 表示原始输入，显式写出特征映射 ϕ。一般设计矩阵的列数此前记为 p，本节改用 M 表示特征空间的维数。现在仍然使用相同的高斯权重模型。先用特征函数把原始输入映射到特征空间，再对特征空间中的权重使用高斯先验。特征空间可以取任意有限维，也可以形式上扩展到无穷维。后一个变化会使我们从显式计算权重，转向计算输入之间的核函数，最后引出高斯过程的函数空间视角。经典教材对这条联系有系统介绍 [**?**]。

3.5.1 特征空间中的权重后验

令 $\phi(\boldsymbol{x})$ 表示输入 $\boldsymbol{x}$ 的特征向量。与本章前面式(3.5)相同，函数写成

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}} \phi(\boldsymbol{x}), \qquad \boldsymbol{w} \sim \mathcal{N}(\boldsymbol{0}, \Sigma_p). \tag{3.75}$$

如果 $\phi(\boldsymbol{x})$ 有 M 个分量，$\boldsymbol{w}$ 和 Σ_p 的维度分别是 M 和 $M \times M$。下标 p 沿用先验协方差的记号，不表示矩阵阶数。以下显式使用 Σ_p^{-1} 的权重空间公式要求 $\Sigma_p \succ 0$。半正定但奇异的先验仍能诱导有效核，但应在其支撑子空间推导权重后验，或直接使用后面的核空间公式。给定训练输入后形成特征矩阵 $\Phi \in \mathbb{R}^{n \times M}$，其中第 i 行是

$\phi(\boldsymbol{x}_i)^{\mathsf{T}}$。观测模型仍为

$$\boldsymbol{y} \mid \Phi, \boldsymbol{w} \sim \mathcal{N}(\Phi \boldsymbol{w}, \sigma^2 I_n). \tag{3.76}$$

因此，前面贝叶斯线性回归的后验推导完全保留，只需将 X 换成 Φ：

$$S = \left(\sigma^{-2}\Phi^{\mathsf{T}}\Phi + \Sigma_p^{-1}\right)^{-1}, \tag{3.77}$$

$$\boldsymbol{m} = S\sigma^{-2}\Phi^{\mathsf{T}}\boldsymbol{y}, \tag{3.78}$$

$$\boldsymbol{w} \mid \mathcal{D} \sim \mathcal{N}(\boldsymbol{m}, S). \tag{3.79}$$

对新输入 $\boldsymbol{x}_*$，潜在函数值的后验预测为

$$f(\boldsymbol{x}_*) \mid \boldsymbol{x}_*, \mathcal{D} \sim \mathcal{N}\left(\phi(\boldsymbol{x}_*)^{\mathsf{T}}\boldsymbol{m}, \phi(\boldsymbol{x}_*)^{\mathsf{T}} S \phi(\boldsymbol{x}_*)\right). \tag{3.80}$$

到这里，它仍然只是把原始输入换成了特征表示后的贝叶斯线性回归。

3.5.2 核函数与对偶预测

当 M 很大，直接形成 Φ 并求解 $M \times M$ 的后验系统会变得困难。更重要的是，很多有用的特征映射并没有方便写出的有限维表达式。此时可以观察预测公式中实际出现的量。定义

$$k(\boldsymbol{x}, \boldsymbol{x}') = \phi(\boldsymbol{x})^{\mathsf{T}}\Sigma_p \phi(\boldsymbol{x}'), \qquad K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j). \tag{3.81}$$

k 称为核函数。它把两个输入先映射到特征空间，再计算由先验协方差加权的内积。训练数据与新输入之间的行核向量定义为

$$\boldsymbol{k}_{*X} = [k(\boldsymbol{x}_*, \boldsymbol{x}_1), \ldots, k(\boldsymbol{x}_*, \boldsymbol{x}_n)] \in \mathbb{R}^{1\times n}. \tag{3.82}$$

令 $\boldsymbol{k}_{X*} = \boldsymbol{k}_{*X}^{\mathsf{T}} \in \mathbb{R}^n$。核矩阵 $K = \Phi\Sigma_p\Phi^{\mathsf{T}} \in \mathbb{R}^{n\times n}$ 是训练函数值的先验协方差，$\sigma^2 > 0$ 保证 $K + \sigma^2 I_n$ 正定。利用矩阵恒等式，可以将式(3.80)改写为

$$\mathbb{E}[f(\boldsymbol{x}_*) \mid \mathcal{D}] = \boldsymbol{k}_{*X}(K + \sigma^2 I_n)^{-1}\boldsymbol{y}, \tag{3.83}$$

$$\mathrm{Var}(f(\boldsymbol{x}_*) \mid \mathcal{D}) = k(\boldsymbol{x}_*, \boldsymbol{x}_*) - \boldsymbol{k}_{*X}(K + \sigma^2 I_n)^{-1}\boldsymbol{k}_{X*}. \tag{3.84}$$

这里不再需要显式构造 $\phi(\boldsymbol{x})$ 或保存 $\boldsymbol{w}$。计算从特征空间的 M 个权重转到了训练样本决定的 $n \times n$ 核矩阵。若 $M > n$，这个转换尤其有用。这种利用核值替代显

式特征内积的计算称为核技巧（kernel trick）。它避免逐项构造高维特征，但训练样本很多时仍需处理较大的核矩阵。

以径向基函数（Radial Basis Function，RBF）核为例，取

$$k(\boldsymbol{x}, \boldsymbol{x}') = \alpha^2 \exp\left(-\frac{\|\boldsymbol{x} - \boldsymbol{x}'\|_2^2}{2\ell^2}\right). \tag{3.85}$$

这里 $\alpha > 0$ 决定先验函数值的标准差，$\ell > 0$ 是长度尺度。两个输入距离越远，核值越小，模型就越少把一个位置的观测变化传递到另一个位置。长度尺度小的模型允许函数快速变化，长度尺度大的模型偏好更平滑的函数。这个核具有一个无穷维的特征表示，但实际计算只需要核函数值。有效的实协方差核还必须对称，并使任意有限输入集合形成的矩阵半正定，即对任意向量 $\boldsymbol{a}$ 都有 $\boldsymbol{a}^{\mathsf{T}} K \boldsymbol{a} \geq 0$。

3.5.3 高斯过程的函数分布

前面的推导已经在使用一个事实：对任意输入集合，函数值向量的协方差都由同一个核函数给出。现在把这一事实单独作为模型定义。高斯过程（Gaussian Process，GP）是定义在输入空间上的随机函数。若任取有限个输入 $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$，函数值向量都服从多元高斯分布：

$$\begin{bmatrix} f(\boldsymbol{x}_1) \\ \vdots \\ f(\boldsymbol{x}_n) \end{bmatrix} \sim \mathcal{N}\left(\boldsymbol{m}(X), K(X, X)\right), \qquad K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j). \tag{3.86}$$

由有限维高斯权重模型诱导出的核正是式(3.81)。高斯过程把这个关系推广到不必显式给出有限维特征映射的情形。此后讨论的对象从权重 $\boldsymbol{w}$ 变为函数值 $f(\boldsymbol{x})$，但高斯条件分布的计算形式仍然来自前面已经学过的贝叶斯线性回归。

3.5.4 函数后验与观测预测

仍以回归数据 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$ 为例，假设观测包含独立高斯噪声：

$$f \sim \mathcal{GP}(m, k), \qquad y_i = f(\boldsymbol{x}_i) + \varepsilon_i, \qquad \varepsilon_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2). \tag{3.87}$$

令 $\boldsymbol{m}_X = [m(\boldsymbol{x}_1), \ldots, m(\boldsymbol{x}_n)]^{\mathsf{T}}$，$K_{XX} = K(X, X)$。噪声还假设与潜在函数 f 独立。高斯函数值与独立高斯噪声之和仍为高斯，因此训练标签的边缘分布为

$$\boldsymbol{y} \mid X \sim \mathcal{N}\left(\boldsymbol{m}_X, K_{XX} + \sigma^2 I_n\right). \tag{3.88}$$

这里的 $\sigma^2 I_n$ 只加在观测协方差上，表示每次测量的独立噪声。它不改变潜在函数 f 本身的协方差。与贝叶斯线性回归保存权重后验不同，高斯过程直接对函数值的联合分布进行更新。

设新输入集合 X_* 包含 $n_* \geq 1$ 个输入，记 $K_{*X} = K(X_*, X) \in \mathbb{R}^{n_* \times n}$、$K_{**} = K(X_*, X_*) \in \mathbb{R}^{n_* \times n_*}$ 和 $K_{X*} = K_{*X}^{\mathsf{T}}$。$f_* \in \mathbb{R}^{n_*}$ 是这些位置的潜在函数值，$\boldsymbol{m}_* \in \mathbb{R}^{n_*}$ 是对应的先验均值向量。训练数据与新位置的联合高斯分布为

$$\begin{bmatrix} \boldsymbol{y} \\ f_* \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \boldsymbol{m}_X \\ \boldsymbol{m}_* \end{bmatrix}, \begin{bmatrix} K_{XX} + \sigma^2 I_n & K_{X*} \\ K_{*X} & K_{**} \end{bmatrix} \right). \tag{3.89}$$

对这个联合分布作条件化，得到潜在函数值的后验预测：

$$\boldsymbol{\mu}_* = \boldsymbol{m}_* + K_{*X}(K_{XX} + \sigma^2 I_n)^{-1}(\boldsymbol{y} - \boldsymbol{m}_X), \tag{3.90}$$

$$\Sigma_* = K_{**} - K_{*X}(K_{XX} + \sigma^2 I_n)^{-1} K_{X*}. \tag{3.91}$$

$\boldsymbol{\mu}_*$ 是新位置的函数均值，Σ_* 是对潜在函数值的不确定性。若要预测下一次带噪观测 $\boldsymbol{y}_*$，还要加入观测噪声：

$$\boldsymbol{y}_* \mid X_*, \mathcal{D} \sim \mathcal{N}(\boldsymbol{\mu}_*, \Sigma_* + \sigma^2 I_{n_*}). \tag{3.92}$$

观测点附近通常有更多信息，后验方差会降低，但带噪观测的预测方差仍包含 σ^2。因此，训练点处的函数不确定性和下一次测量的不确定性不能混为一谈。

这些公式也说明了高斯过程回归（Gaussian Process Regression，GPR）的计算代价。训练时需要分解 $n \times n$ 矩阵 $K_{XX} + \sigma^2 I_n$，直接方法的时间复杂度通常为 $O(n^3)$，存储复杂度为 $O(n^2)$。实现时应使用 Cholesky 分解求解线性方程，不显式计算逆矩阵。样本很多时，常用诱导点或其他稀疏高斯过程近似降低代价，但近似会改变计算结果，需要用验证数据检查。

3.5.5 高斯过程回归的适用条件

GPR 适合样本量中小、希望获得平滑函数预测和不确定性估计的回归任务。例如，温度传感器的历史记录不多时，可以用长度尺度表达相近工况下的温度关系，并用后验方差标出数据稀疏区域。核的形式和输入尺度需要结合领域知识及验证结果选择。长度尺度、幅度和噪声方差也可用训练集边缘似然估计，再以独立数

据评价，不能把边缘似然较大解释为部署性能已经得到保证。高斯过程的方差只反映所选核和噪声模型下的统计不确定性，不能自动发现传感器漂移、分布变化或核函数选错等模型错误。高维、大样本任务通常需要特征降维、结构化核或稀疏近似，否则矩阵计算会成为主要限制。

3.6 线性回归中的概念联系

回顾这条线性模型主线，首先要区分几组容易混淆的对象。

- **数据与任务**：输入 $\boldsymbol{x}_i$ 是预测时可用的特征，标签 y_i 是对应的实数目标。在设备温度例子中，当前温度和振动是输入，下一小时温度是标签，任务是回归。
- **结构与参数**：加权求和是结构，权重和截距是参数。线性结构本身就是一种归纳偏置：不允许模型任意改变输入与输出的关系。
- **损失与目标**：平方损失衡量单样本的预测误差。求和后形成训练目标，加入惩罚后则同时考虑拟合和参数偏好。
- **训练与预测**：训练用历史标签求权重或后验。预测将结果用于新输入。点估计下代入固定参数，完整贝叶斯预测则对参数后验积分。高斯过程回归直接利用核矩阵对函数值进行条件化。
- **正则化与先验**：岭惩罚可以在给定高斯似然和高斯先验时解释为 MAP。惩罚强度、先验方差和噪声方差之间的对应依赖目标的尺度约定。
- **经验风险与泛化**：这些计算决定怎样拟合已有样本，不保证新设备、新时段上的表现。验证仍然需要独立于参数拟合的数据。

本章比较了四种模型表达。确定性函数给出单个数值预测。固定参数的高斯观测模型描述标签的条件分布。贝叶斯线性回归将权重后验的不确定性传到预测分布。高斯过程直接描述有限个函数值的联合分布。选择时需要检查任务所需的信息、数据规模与模型假设。

本章只把上一章的判别模型分支具体算了一遍，并没有试图用线性回归代替所有模型类型。生成建模、隐藏变量和无监督学习改变了要描述的对象，需要另作

假设。即使使用参数后验，模型结构和噪声假设也仍可能不适合数据。后验不确定性并不能自动覆盖所有建模错误。

辅助学习材料

- **Linear Models**。scikit-learn Developers。英文官方文档。阅读 Ordinary Least Squares、Ridge 与 Bayesian Regression 小节，对照本章的点预测、惩罚目标与参数不确定性。软件中损失的归一化和超参数记法可能不同，需要先核对定义。在线阅读。

- **Mathematics for Machine Learning**。Deisenroth、Faisal、Ong。英文教材。阅读线性回归相关章节，对照设计矩阵、最大似然估计与贝叶斯回归。书籍网站。

- **Gaussian Processes for Machine Learning**。Rasmussen、Williams。英文教材。阅读协方差函数、后验预测与超参数学习，对照本章的函数空间视角。在线阅读。