

工业数据智能入门指南

Industrial Data Intelligence Group

2026 年 10 月 4 日

目录

第一部分 机器学习的基本语言与完整流程	1
第一章 数学与概率预备知识	3
1.1 为什么需要数学语言	3
1.2 向量、矩阵与几何	3
1.3 微积分与链式法则	4
1.4 概率、条件概率与期望	5
1.5 高斯分布与最大熵	5
1.6 熵、交叉熵与 KL 散度	6
1.7 从几何距离到概率距离	7
1.8 特征值、主方向与降维	8
1.9 微分、积分与期望的对应	9
1.10 数值稳定性	9
1.11 本章小结：看到公式时问什么	9
第二章 机器学习究竟在学习什么	11
2.1 学习对象：数据、任务与模型	11
2.2 训练目标：从预测到可优化问题	12
2.3 训练目标与结构约束	13
2.4 本章小结：学习的对象由规则决定	15
第三章 线性模型与经典学习算法	16
3.1 线性回归与正则化：从几何到稳定性	16
3.2 分类模型与代价敏感决策	18
3.3 非线性模型与无监督结构	19
3.4 工业基线：从可解释模型到复杂模型	21
第四章 从数据到推理的完整流程	23
4.1 数据划分与数据治理	23
4.2 训练、评价、部署与反馈	24

第五章 优化算法与神经网络训练	29
5.1 目标、梯度与参数更新	29
5.2 尺度、信号传播与正则化	32
5.3 训练诊断与实验解释	33
5.4 可复现训练设置	35
5.5 本章小结	35
第六章 泛化、偏差与不确定性	36
6.1 经验风险与真实风险	36
6.2 泛化误差、正则化与分布偏移	37
6.3 本章小结：从误差解释走向证据约束	40
第七章 统计学习理论与模型选择	41
7.1 假设空间与泛化约束	41
7.2 模型选择、校准与不平衡	43
7.3 从统计结论到实验设置	45
7.4 从统计量到决策	46
7.5 本章小结	46
第八章 工业数据工程与实验设计	48
8.1 从原始记录到可学习样本	48
8.2 从数据处理到可信实验	50
8.3 从离线证据到在线系统	51
8.4 案例分析：剩余寿命预测	51
8.5 数据时序、缺失与来源记录的深入分析	52
8.6 实验归因与部署反馈	53
第二部分 贝叶斯机器学习：用概率表达知识与不确定性	55
第九章 贝叶斯机器学习	57
9.1 贝叶斯更新与后验预测	57
9.2 概率图模型：从依赖关系到分布分解	58
9.3 隐马尔科夫模型与状态推断	59
9.4 从局部条件模型到条件随机场	63
9.5 马尔科夫随机场与空间一致性	66
9.6 从共轭模型到近似推断	68
9.7 模型比较与不确定性计算	71
9.8 校准、诊断与工业决策	73

第十章 参数化与非参数化模型	76
10.1 两个概念	76
10.2 核方法、函数空间与计算边界	78
 第三部分 深度学习模型	 83
第十一章 序列建模模型	85
11.1 序列与状态	85
11.2 注意力、Transformer 与长依赖	87
11.3 时间序列预测与状态估计	89
11.4 训练、预测与工业告警	91
第十二章 视觉模型	97
12.1 视觉表示：从卷积骨干到视觉 Transformer	97
12.2 空间输出：检测、分割与多尺度特征	100
12.3 预训练、跨域泛化与工业验收	105
12.4 数据反馈与部署决策	107
第十三章 语言大模型	108
13.1 Token、表示与语言建模	108
13.2 预训练、对齐与推理	110
13.3 检索、工具与安全边界	114
第十四章 多模态模型	118
14.1 不同模态的共同空间	118
14.2 时间对齐、缺失鲁棒性与工业诊断	121
第十五章 深度生成模型	123
15.1 生成建模的目标	123
15.2 对抗学习与可逆密度建模	124
15.3 扩散过程与条件控制	126
15.4 采样、约束与工业可信度	127
第十六章 物理信息神经网络：从稀疏观测重建风场	130
16.1 从函数拟合到受约束逆问题	130
16.2 激光雷达实际观测了什么	131
16.3 风场方程、尺度与物理假设	133
16.4 网络、损失与训练过程	134
16.5 主要变体及其适用条件	136

16.6 风电场案例的验证流程	138
第四部分 从学习方式看数据智能场景	140
第十七章 预训练：构建可复用的数据表示	142
17.1 预训练学到了什么	142
17.2 监督预训练与重建式目标	143
17.3 对比学习：哪些样本应当接近	145
17.4 无负样本学习与表示坍塌	147
17.5 数据组织与领域继续预训练	148
17.6 工业振动信号的完整学习任务设置	149
第十八章 迁移学习	151
18.1 源域知识与目标域风险	151
18.2 实例重加权与分布对齐	152
18.3 预训练、微调与参数高效适配	155
18.4 测试时适配与负迁移	156
第十九章 持续学习	158
19.1 数据流、任务边界与遗忘	158
19.2 经验回放与梯度约束	159
19.3 参数重要性与知识蒸馏	161
19.4 参数隔离、扩展与混合策略	162
19.5 评价矩阵与工业更新规则	163
第二十章 主动学习	165
20.1 查询规则与标注预算	165
20.2 不确定性、委员会与贝叶斯查询	166
20.3 预期风险、梯度变化与多样性	168
20.4 成本、噪声与工业流式变体	170
20.5 算法流程与验收	171
第二十一章 联邦学习	172
21.1 问题定义	172
21.2 联邦优化、隐私与系统约束	174
21.3 联邦诊断案例与验收	176
第二十二章 流形学习	181
22.1 几何假设与邻域构造	181

22.2 线性基线与测地距离	182
22.3 局部重构与谱嵌入	183
22.4 概率邻域可视化	185
22.5 流形正则与工业验证	187
第二十三章 元学习	189
23.1 任务分布与双层目标	189
23.2 度量与关系方法	190
23.3 梯度初始化与一阶变体	192
23.4 学习更新规则与概率适应	194
23.5 跨设备快速适应的完整设置	196

写在前面

本指南面向刚开始接触数据智能、机器学习或深度学习的读者。工业数据智能包括多类任务：预测设备故障或风功率，根据有限观测重建风场，通过缺失值填充恢复不完整数据，定位图像中的缺陷，以及根据手册和工单回答问题。本书以设备维护作为贯穿案例之一，同时结合这些任务介绍数据、模型、优化、推理和不确定性。公式用来说明计算怎样成立，例子用来说明结果会怎样影响现场判断。

本书中的“模型”通常表示从输入到输出的可计算映射；当模型还描述随机性时，则将其写成概率分布。除特别说明外，向量默认为列向量， $\|\cdot\|_2$ 表示欧氏范数， $\mathbb{E}$ 表示期望。

设备维护案例联系了其中几类学习任务：根据运行记录预测未来二十四小时内的故障，利用巡检图像定位缺陷，再结合有效手册和历史工单组织复检依据。这些任务共享设备、时间和证据来源，但并不共享同一种标签。预测未来二十四小时内是否故障，也不等于保证提前二十四小时告警。各章中的数值设置是教学设置，不代表已经完成的工业实验。阅读时应追问：观测在何时可用，目标如何定义，模型保留了什么结构，损失优化了什么，错误如何影响决策，以及系统需要采取什么动作。

因此，本书的章节不是按模型名称组成的目录。前两部分先固定学习对象、数据边界、风险和不确定性；第三部分改变观测结构，分别处理时间、空间、文本、跨模态关系和数据分布，再以风场重建说明物理方程如何参与学习；第四部分改变知识的流动方式，讨论跨设备迁移、跨组织协作以及少样本适应。每次引入新模型时，都应把它放回明确的案例设定中，并与简单基线、信息可用性和部署资源进行比较。

贯穿全书的核心观点是：先把现场能看到的東西和要做的決定說清楚，再談模型。传感器晚到五分鐘，不能當成實時輸入；拆機后才拍到的裂紋照片，不能拿來證明拆機前預警有效；一次誤報會占用檢修人員的時間，一次漏報可能損壞設備。數據、假設、損失、優化和驗證，最終都要對這些具體後果負責。它們不是彼此獨立的技术清單。例如，平方損失既可以解釋為幾何距離，也可以從高斯觀測噪聲推出；正則化既可以看作控制模型複雜度，也可以在適當條件下解釋為先驗。理解這些聯繫，比記住孤立的算法名稱更重要。

閱讀每章時，可以先沿着开篇的幾個問題建立方向：上一章已經解決了什麼，仍留下什麼困難，本章通過增加哪一種假設或結構處理這個困難。進入推导後，應先確認隨機變量與具體觀測、待學習參數與已知常量的區別，再檢查矩陣維度和概率分布

的条件。等式说明在给定假设下严格成立的关系，近似式通常意味着舍弃了某些项、引入了采样或限制了函数族；二者不能混为一谈。遇到较长推导，不必先记结论，可以用一个标量、两个样本或一维高斯分布重算一遍，再回到一般形式。

本书中的数学展开承担三项任务：从问题假设推出目标，从目标推出求解步骤，再从求解结果返回实际含义。因此，得到梯度或闭式解不是讨论的终点，还要追问解是否存在、是否唯一、算法是否能到达它，以及所需假设在工业数据中是否成立。章末的总结段落把这些结论重新放回相应的工业任务，并指出下一章需要改变的条件。读者可以据此区分已经得到证明的结论、依赖模型的解释和仍须通过实验检验的判断。

第一部分

机器学习的基本语言与完整流程

本部分首先给出机器学习的几个重要组成部分：数据、任务、模型、目标、优化、验证和部署。然后分别说明监督学习、无监督学习的假设、目标和评价边界。最后讨论如何在有限样本下分析泛化误差，并把统计假设翻译成可执行的数据规则。读者应看到，机器学习不是一条训练命令，而是一个完整的流程：先明确问题，再选择模型，最后验证结果。

第一章 数学与概率预备知识

本章摘要。本章建立全书共同使用的数学语言。先从向量、矩阵和微积分说明模型如何表示对象、变化与优化，再引入概率、分布和期望，最后解释熵、距离、降维和数值稳定性。阅读顺序对应后文的依赖关系：先能读懂确定性模型，再能处理随机性，最后才能理解贝叶斯推断、深度学习和流形表示中的公式。

本书从数学开始，并不是要求读者先成为数学家，而是要建立一种可核查的阅读习惯：每个运算必须作用在合适的对象上，每个结论必须有成立条件。设备的一组传感器读数先成为向量，多个样本组成矩阵；预测误差成为标量函数，其变化由梯度描述；同一工况下仍会出现不同结果，则需要条件概率。以下工具沿着这条路径出现，而不是彼此孤立的公式表。

可以始终带着同一组设备读数来理解这些工具。把温度和振动画成一个点，是几何表示；调整权重让预测更接近测量值，需要导数；重复运行后读数仍然有波动，就要用概率和期望。先看清每一步输入和输出的维度，再跟着推导计算。后面遇到具体模型时，可以回到这里核对它用了哪些条件。

1.1 为什么需要数学语言

机器学习不是把公式堆在代码旁边，而是用一套精确语言说明四件事：对象是什么，假设是什么，优化什么，以及结果在哪些条件下成立。本章只介绍后文反复使用的工具。读者不必一次记住所有细节，但应能在看到一个公式时识别其输入、输出、随机性与求和范围。

1.2 向量、矩阵与几何

向量 $\mathbf{x} \in \mathbb{R}^d$ 可以表示一个样本，也可以表示参数、梯度或隐状态。内积 $\mathbf{x}^\top \mathbf{y}$ 衡量方向相似性，范数 $\|\mathbf{x}\|_2 = (\sum_j x_j^2)^{1/2}$ 衡量长度。矩阵 $A \in \mathbb{R}^{m \times d}$ 是从 d 维空间到 m 维空间的线性变换。其列空间、零空间和秩分别描述可表达方向、被压缩方向与有效维数。

对称半正定矩阵满足 $\mathbf{v}^\top A \mathbf{v} \geq 0$ 。协方差矩阵必须具有这一性质，因为方差不可能为负。二次型 $\mathbf{v}^\top A \mathbf{v}$ 还可以看作沿方向 $\mathbf{v}$ 观察曲率，这使 Hessian 矩阵成为优化和不确定性分析的核心对象。

维度、投影与半正定性的由来。 若 $A \in \mathbb{R}^{m \times d}$ 、 $\mathbf{x} \in \mathbb{R}^d$ ，则 $(A\mathbf{x})_i = \sum_{j=1}^d A_{ij}x_j$ ，输出有 m 个分量。内积不是不受尺度影响的相似度：将一个向量放大两倍会使内积也放大两倍；只有先归一化，内积才等于夹角余弦。对单位向量 $\mathbf{u}$ ，把 $\mathbf{x}$ 投影到其张成的直线上，需要最小化

$$\|\mathbf{x} - a\mathbf{u}\|_2^2 = \|\mathbf{x}\|_2^2 - 2a\mathbf{u}^\top \mathbf{x} + a^2, \quad (1.1)$$

$$\frac{d}{da} \|\mathbf{x} - a\mathbf{u}\|_2^2 = -2\mathbf{u}^\top \mathbf{x} + 2a = 0. \quad (1.2)$$

由式(1.2)得 $a = \mathbf{u}^\top \mathbf{x}$ ，投影为 $\mathbf{u}\mathbf{u}^\top \mathbf{x}$ ，残差与 $\mathbf{u}$ 正交。若 $\mathbf{u}$ 不是单位向量，系数必须再除以 $\mathbf{u}^\top \mathbf{u}$ 。

设随机向量 $\mathbf{X}$ 有有限二阶矩， $\boldsymbol{\mu} = \mathbb{E}\mathbf{X}$ ，定义 $\Sigma = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \in \mathbb{R}^{d \times d}$ 。对任意 $\mathbf{v} \in \mathbb{R}^d$ ，

$$\mathbf{v}^\top \Sigma \mathbf{v} = \mathbb{E}[(\mathbf{v}^\top (\mathbf{X} - \boldsymbol{\mu}))^2] = \text{Var}(\mathbf{v}^\top \mathbf{X}) \geq 0. \quad (1.3)$$

式(1.3)同时证明了协方差半正定，并说明二次型就是投影后的方差。半正定并不保证可逆：若某个传感器恰好是另一个的两倍，就存在非零方向上的方差为零。

1.3 微积分与链式法则

若标量函数 $J(\boldsymbol{\theta})$ 对参数可微，梯度为

$$\nabla_{\boldsymbol{\theta}} J = \left[\frac{\partial J}{\partial \theta_1}, \dots, \frac{\partial J}{\partial \theta_d} \right]^\top. \quad (1.4)$$

梯度指向函数增长最快的方向，因此 $-\nabla J$ 是局部下降方向。对复合函数 $J(f(\boldsymbol{\theta}))$ ，链式法则给出

$$\frac{\partial J}{\partial \theta_j} = \sum_i \frac{\partial J}{\partial f_i} \frac{\partial f_i}{\partial \theta_j}. \quad (1.5)$$

反向传播正是以高效的图结构方式反复应用链式法则，而不是一种神秘的独立学习规则。

为什么负梯度是局部下降方向。 令 $\mathbf{g} = \nabla J(\boldsymbol{\theta})$ 。可微性给出 $J(\boldsymbol{\theta} + \epsilon \mathbf{v}) = J(\boldsymbol{\theta}) + \epsilon \mathbf{g}^\top \mathbf{v} + o(\epsilon)$ 。在 $\|\mathbf{v}\|_2 = 1$ 的方向中，Cauchy-Schwarz 不等式给出 $\mathbf{g}^\top \mathbf{v} \geq -\|\mathbf{g}\|_2$ ，当 $\mathbf{g} \neq 0$ 时由 $\mathbf{v} = -\mathbf{g}/\|\mathbf{g}\|_2$ 取到等号。这只说明足够小的步长能下降，不保证任意步长都有效，也不保证梯度为零时已经达到最小值。

以 $\mathbf{r} = A\boldsymbol{\theta} - \mathbf{y} \in \mathbb{R}^m$ 和 $J = \frac{1}{2} \mathbf{r}^\top \mathbf{r}$ 为例，微分逐步给出

$$dJ = \mathbf{r}^\top d\mathbf{r} = \mathbf{r}^\top A d\boldsymbol{\theta} = (A^\top \mathbf{r})^\top d\boldsymbol{\theta}, \quad \nabla J = A^\top (A\boldsymbol{\theta} - \mathbf{y}) \in \mathbb{R}^d. \quad (1.6)$$

一般地，若 $\mathbf{f} : \mathbb{R}^d \rightarrow \mathbb{R}^m$ 的 Jacobian 为 $D\mathbf{f} \in \mathbb{R}^{m \times d}$ ，则 $\nabla_{\boldsymbol{\theta}} J = (D\mathbf{f})^\top \nabla_{\mathbf{f}} J$ 。转置把输出空间的误差信号拉回参数空间，维度检查可以帮助发现漏转置和广播错误。

1.4 概率、条件概率与期望

随机变量 X 的分布描述不确定性。联合分布满足乘法法则

$$p(x, y) = p(y | x)p(x), \quad p(y | x) = \frac{p(x, y)}{p(x)}. \quad (1.7)$$

边缘化把未知变量积分掉： $p(x) = \int p(x, y) dy$ 。期望是随机量的加权平均，方差是

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]. \quad (1.8)$$

条件期望 $\mathbb{E}[Y | X]$ 是给定输入后对输出的最佳平方损失预测，这解释了为什么均方误差回归在理想条件下学习条件均值。

条件均值为何最优。 对离散变量使用概率质量，对连续变量使用密度；式(1.7)的条件概率比值只在分母为正处使用，连续情形不是把单点概率相除。假设 $\mathbb{E}[Y^2] < \infty$ ，固定输入 x ，记 $\mu(x) = \mathbb{E}[Y | X = x]$ 。对任意实数预测 a ，把误差拆为 $(Y - \mu) + (\mu - a)$ ，得到

$$\mathbb{E}[(Y - a)^2 | X = x] = \mathbb{E}[(Y - \mu)^2 | X = x] + 2(\mu - a)\mathbb{E}[Y - \mu | X = x] + (\mu - a)^2 \quad (1.9)$$

$$= \text{Var}(Y | X = x) + (\mu(x) - a)^2. \quad (1.10)$$

式(1.10)的第一项与 a 无关，交叉项因条件残差均值为零而消失，所以最优 a 为 $\mu(x)$ 。这不是说有限样本拟合一定得到条件均值，而是说它是无限制平方损失预测的理想目标。

进一步对 X 取期望，并对 $Y - \mathbb{E}Y$ 作同样分解，可得全方差公式

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]). \quad (1.11)$$

式(1.11)将总波动分为给定输入后仍存在的波动，以及不同输入导致的均值变化。缺少关键传感器时，前一项可能很大；仅靠更精细地优化参数无法消除这种信息缺失。

1.5 高斯分布与最大熵

多元高斯分布写作

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]. \quad (1.12)$$

均值决定中心，协方差决定椭球的方向和尺度。给定均值和协方差，高斯分布具有最大的微分熵，因此它常作为“只知道一二阶统计量时不过度添加假设”的基线。

密度公式与最大熵结论的条件。 式(1.12)的普通密度要求 Σ 正定。写 $\Sigma = U\Lambda U^\top$, 令 $\mathbf{z} = \Lambda^{-1/2}U^\top(\mathbf{x} - \boldsymbol{\mu})$, 则指数中的二次型为 $\|\mathbf{z}\|_2^2$, 变量替换的体积因子为 $|\Sigma|^{1/2}$ 。因此它实际上是独立标准正态密度经旋转、伸缩和平移得到的分布。若 Σ 奇异, 概率集中在较低维子空间上, 不能直接套用含 Σ^{-1} 的 d 维密度。

设 q 为具有给定均值和正定协方差的高斯密度, p 为具有相同矩且相关积分有限的另一密度。因为 $\log q$ 只是常数加二次型, 相同的一二阶矩意味着 $\mathbb{E}_p \log q = \mathbb{E}_q \log q$ 。利用下一节证明的Kullback–Leibler divergence (KL)非负性,

$$0 \leq \text{KL}(p\|q) = \int p \log p - \int p \log q = -h(p) + h(q), \quad h(q) = \frac{1}{2} \log((2\pi e)^d |\Sigma|). \quad (1.13)$$

故 $h(p) \leq h(q)$ 。最大熵说的是固定矩约束下不再添加额外分布结构, 并不证明现实数据必为高斯。微分熵还会随坐标单位改变, 不应直接当成离散事件数目。

1.6 熵、交叉熵与 KL 散度

熵的信息度量来自 Shannon 的信息论框架, 相对熵的统计区分意义可追溯到 Kullback 与 Leibler 的工作[98, 59]。以下公式区分随机性、编码代价与分布差异, 三者不能仅因为都使用对数就被视为同一个量。离散分布 p 的熵为 $H(p) = -\sum_x p(x) \log p(x)$ 。用 q 编码来自 p 的数据时, 平均代价是交叉熵 $H(p, q) = -\sum_x p(x) \log q(x)$ 。两者关系为

$$H(p, q) = H(p) + \text{KL}(p\|q), \quad \text{KL}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \geq 0. \quad (1.14)$$

由式(1.14)可知, 最小化交叉熵等价于让预测分布接近真实分布。KL 散度不对称, 选择 $\text{KL}(p\|q)$ 还是 $\text{KL}(q\|p)$ 会带来不同的近似行为, 这一点在变分推断中非常重要。

例 1.1. 若故障类别的真实分布为(0.9, 0.1), 模型给出(0.6, 0.4), 交叉熵会惩罚模型对高概率类别的低估。若模型输出概率而不是只输出类别, 系统还可以根据置信度设置不同告警阈值。

KL非负性与交叉熵分解。 约定 $0 \log 0 = 0$, 若 $p(x) > 0$ 但 $q(x) = 0$, 则KL为无穷大。其余情形利用 $-\log u \geq 1 - u$, 逐项得到

$$\text{KL}(p\|q) = \sum_{p(x)>0} p(x) \left[-\log \frac{q(x)}{p(x)} \right] \geq \sum_{p(x)>0} (p(x) - q(x)) \geq 0. \quad (1.15)$$

等号要求两分布相同。再把 $\log(p/q) = \log p - \log q$ 代回求和, 立即得到 $\text{KL} = H(p, q) - H(p)$ 。训练时真实分布 p 固定, 因而最小化交叉熵与最小化这个方向的KL有相同最优解; 用有限样本平均替代期望后, 还存在采样误差和模型表达能力限制。

1.7 从几何距离到概率距离

机器学习中常见的“距离”并不只有欧氏距离。欧氏距离比较两个向量在坐标空间中的位置，余弦距离比较方向，Mahalanobis 距离则利用协方差修正不同方向的尺度：

$$d_M(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}. \quad (1.16)$$

当某个传感器噪声很大时，沿该方向的差异不应与低噪声方向等量齐观。下面列出几种常见距离。它们比较的对象相同，但对“差异”的理解不同：

$$d_1(x, y) = \|x - y\|_1 = \sum_{j=1}^d |x_j - y_j|, \quad (1.17)$$

$$d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}, \quad (1.18)$$

$$d_p(x, y) = \|x - y\|_p = \left(\sum_{j=1}^d |x_j - y_j|^p \right)^{1/p}, \quad p \geq 1, \quad (1.19)$$

$$d_\infty(x, y) = \|x - y\|_\infty = \max_{1 \leq j \leq d} |x_j - y_j|. \quad (1.20)$$

式(1.17)把各坐标的绝对差直接相加，适合把每个传感器的偏差看成可以分别累积的误差。式(1.18)对较大的单项差异惩罚更重，常用于连续特征经过同尺度处理后的比较。式(1.19)把前两者统一起来： $p = 1$ 得到曼哈顿距离， $p = 2$ 得到欧氏距离；当 p 增大时，最大坐标差异的影响逐渐增强。式(1.20)只关注最不一致的那个坐标，例如设备的多个安全指标中只要有一项超出容许范围，就把该项作为整体差异的代表。

如果只关心方向而不关心向量长度，可以使用余弦相似度及其对应的余弦距离：

$$s_{\cos}(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2}, \quad d_{\cos}(x, y) = 1 - s_{\cos}(x, y), \quad x \neq 0, y \neq 0. \quad (1.21)$$

例如，两台设备的振动频谱一个整体强、一个整体弱，但频率峰的相对分布相似时，余弦距离可能很小，而欧氏距离仍然可能很大。相反，若要比类别、开关状态或字符串中有多少位置不同，可以使用汉明距离：

$$d_H(x, y) = \sum_{j=1}^d \mathbb{1}\{x_j \neq y_j\}, \quad (1.22)$$

它只统计不相同的位置，不表示数值差异的大小，因此不适合直接代替连续传感器变量的欧氏距离。

概率模型中的 KL 散度比较分布而非单个点：

$$\text{KL}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)}, \quad (1.23)$$

它会把概率质量放错位置的代价纳入比较，因此适合描述预测分布与真实分布之间的差异。不过，KL 散度一般不对称，也可能为无穷大。若希望比较两个分布搬运概率质量所需的“距离”，离散情形还可以使用 Wasserstein 距离：

$$W_1(p, q) = \min_{\gamma \in \Gamma(p, q)} \sum_{a, b} \gamma(a, b) c(a, b), \quad (1.24)$$

其中 $\Gamma(p, q)$ 是边缘分布分别为 p 和 q 的联合分布集合， $c(a, b)$ 是把质量从 a 搬到 b 的代价。举例来说，把预测的风速分布从“每秒 8 米”移到“每秒 9 米”，Wasserstein 距离会利用这两个数值相近这一事实；KL 散度则只看概率质量在各个取值上的比例。实际使用哪一种距离，取决于特征的尺度、是否关心方向、是否关心最坏坐标，以及分布取值之间是否有自然的距离。

1.8 特征值、主方向与降维

对称矩阵可以正交对角化： $A = U \Lambda U^T$ 。若 A 是协方差矩阵，特征向量给出数据方差最大的正交方向，特征值给出对应方差。Principal Component Analysis (PCA) 选择前 r 个方向的投影

$$z = U_r^T(x - \bar{x}), \quad \hat{x} = U_r z + \bar{x}. \quad (1.25)$$

它同时可以理解为最大化投影方差，或最小化线性子空间的重构误差。这个双重解释为后文的表示学习和流形学习提供了桥梁。

从白化到PCA的优化证明。 当 Σ 正定，令 $W = \Lambda^{-1/2} U^T$ ，则 $d_M(x, y) = \|W(x - y)\|_2$ 。这是先把各主方向除以其标准差再测欧氏距离；但协方差同时含有信号变化和噪声变化，不能无条件把大方差方向都解释为低质量传感器。样本协方差奇异时可考虑 $\Sigma + \epsilon I$ ，代价是改变了原距离。

对中心化样本 $\mathbf{z}_i = \mathbf{x}_i - \bar{\mathbf{x}} \in \mathbb{R}^d$ ，定义 $S = n^{-1} \sum_i \mathbf{z}_i \mathbf{z}_i^T$ 。单个单位方向 $\mathbf{u}$ 的平均投影平方为 $\mathbf{u}^T S \mathbf{u}$ 。拉格朗日函数 $\mathbf{u}^T S \mathbf{u} - \lambda(\mathbf{u}^T \mathbf{u} - 1)$ 的驻点满足 $S \mathbf{u} = \lambda \mathbf{u}$ ；按特征向量展开 $\mathbf{u}$ 可知该二次型是特征值的加权平均，最大值因此为最大特征值。

对 $U_r \in \mathbb{R}^{d \times r}$ 且 $U_r^T U_r = I_r$ ，投影与残差正交，故

$$\frac{1}{n} \sum_i \|\mathbf{z}_i - U_r U_r^T \mathbf{z}_i\|_2^2 = \frac{1}{n} \sum_i (\|\mathbf{z}_i\|_2^2 - \|U_r^T \mathbf{z}_i\|_2^2) \quad (1.26)$$

$$= \text{tr}(S) - \text{tr}(U_r^T S U_r). \quad (1.27)$$

式(1.27)中， tr 表示对角元素之和。在 S 的特征基中，后一迹是特征值按各方向保留程度的加权和，权重在 $[0, 1]$ 内且总和为 r ，所以保留最大的 r 个特征值达到最大值，最小重构误差为 $\sum_{j>r} \lambda_j$ 。重根时最优基不唯一；大方差也不必与故障标签有关，PCA 最优的是重构，不是分类。

1.9 微分、积分与期望的对应

连续概率密度的积分必须等于一；离散概率则通过求和归一化。对参数化密度 $p_\theta(x)$ ，当分布本身也依赖参数时，采样分布的变化也必须被考虑：

$$\nabla_\theta \mathbb{E}_{x \sim p_\theta} [f_\theta(x)] \neq \mathbb{E}_{x \sim p_\theta} [\nabla_\theta f_\theta(x)]. \quad (1.28)$$

这里有两种变化要一起计算：参数改变后，同一个样本上的函数值会变，抽到各个样本的概率也可能变。普通监督学习通常把训练样本固定，只需处理前一种变化；变分推断中的采样分布也要学习，因此常用重参数化技巧或得分函数估计来处理另一种变化。

把缺少的梯度项补出来。式(1.28)的 $\neq$ 应理解为一般不能直接交换，并非所有函数都严格不等。若积分支撑集不随 θ 变化，密度与函数可微，且存在允许微分与积分交换的可积控制函数，则乘积法则给出

$$\nabla_\theta \int f_\theta(x) p_\theta(x) dx = \int [p_\theta(x) \nabla_\theta f_\theta(x) + f_\theta(x) \nabla_\theta p_\theta(x)] dx \quad (1.29)$$

$$= \mathbb{E}_{p_\theta} [\nabla_\theta f_\theta(X)] + \mathbb{E}_{p_\theta} [f_\theta(X) \nabla_\theta \log p_\theta(X)]. \quad (1.30)$$

式(1.30)的第二项就是采样分布变化的贡献。若可写 $X = \mu + \sigma \varepsilon$ 、 $\varepsilon \sim \mathcal{N}(0, 1)$ 且 $\sigma > 0$ ，也可对固定噪声分布下的 $f_\theta(\mu + \sigma \varepsilon)$ 使用链式法则。若支撑集依赖参数，例如 $X \sim \text{Uniform}(0, \theta)$ ，则还要处理积分边界，不能机械使用式(1.30)。

1.10 数值稳定性

概率模型经常使用对数概率。直接计算 $\exp(a)$ 可能溢出，通常使用

$$\log \sum_i \exp(a_i) = m + \log \sum_i \exp(a_i - m), \quad m = \max_i a_i. \quad (1.31)$$

这就是 log-sum-exp 技巧。softmax 的实现、交叉熵损失和扩散模型中的噪声权重都依赖类似的稳定计算。数值稳定性不是实现细节之外的问题：溢出的 loss 会让优化器得到 NaN，随后整个模型参数都可能失效。

1.11 本章小结：看到公式时问什么

面对一个新公式，先问变量是确定量还是随机量，再问每一项的维度和求和范围；然后检查它是在拟合条件均值、概率分布、几何结构还是约束；最后确认该量在训练和推理阶段是否都可计算。这个检查顺序把符号阅读转化为模型理解。

本章的几条推导可以连起来阅读：投影把逼近误差分解为可表达部分和残差；条件均值把预测误差分解为可约误差和条件波动；KL把交叉熵分解为真实分布自身的

不确定性和模型失配。它们共同提醒读者，优化只能改变目标中的某些项，不能凭空补充缺失的信息，也不能消除模型假设的边界。

下一章把这些运算用到具体任务中：一段振动记录算一个样本，还是一次完整运行算一个样本？要预测平均温度、温度的某个分位数，还是故障概率？这些选择会决定标签和损失，也决定本章的公式该用在哪里。

第二章 机器学习究竟在学习什么

本章摘要。本章定义样本、任务、模型、损失和风险，说明不同损失对应不同预测对象，并讨论正则化、可识别性及预测到决策的边界。

上一章给出了向量、导数和概率的语言，但能计算一个梯度并不意味着已经定义了值得学习的问题。现在需要把设备观测、未来事件和维护动作分开：观测决定模型能看见什么，标签决定它试图回答什么，损失决定怎样的错误更值得避免。三者不一致时，即使训练完全收敛，也可能得到一个回答错误问题的模型。

本章导语。同一段振动记录，可以用来判断轴承是否故障，也可以用来预测下一时刻的振幅。这两个问题需要不同的标签，算错后的后果也不同。本章先把这些差别写清楚，再说明模型中的参数如何通过损失函数学出来。随后讨论正则化、可识别性和部署反馈：为什么训练数据上看起来很好，换一台设备却可能失效？后文介绍各种模型时，都要回到输入、目标和错误代价这几件事。

2.1 学习对象：数据、任务与模型

从数据到任务。数据（data）是对对象、过程或环境的观测记录。一个样本（sample）是一次相对完整的观测，通常记为 $\mathbf{x} \in \mathbb{R}^d$ ；监督学习中还伴随标签 y ，于是样本写为 $(\mathbf{x}, y)$ 。这里的“样本”不是数据表的一行这么简单：一次设备运行周期、一张图像、一个句子或一段传感器窗口都可以成为样本，关键在于它是否对应一个明确的学习单位。

任务由输入空间 $\mathcal{X}$ 、输出空间 $\mathcal{Y}$ 以及评价准则共同决定。分类的输出是离散类别，回归的输出是连续数值，预测性维护可能输出剩余寿命，异常检测则可能没有逐样本标签。相同的数据可以支持不同任务。例如，振动信号既可以用于故障分类，也可以用于生成未来波形或估计设备状态。

模型、参数与预测。模型（model）是带有可调参数的函数族

$$f_{\boldsymbol{\theta}} : \mathcal{X} \rightarrow \mathcal{Y}, \quad \boldsymbol{\theta} \in \Theta. \quad (2.1)$$

给定输入 $\mathbf{x}$ ，确定性模型直接输出 $\hat{y} = f_{\theta}(\mathbf{x})$ 。参数 θ 不是由研究者凭空指定的答案，而是由训练数据和训练目标共同决定的可学习量。模型结构规定了“允许怎样的映射”，参数则规定了“当前采用哪一个映射”。

概率模型输出条件分布 $p_{\theta}(y | \mathbf{x})$ 。分类时可以把它理解为各类别的置信度，回归时则可以同时表示预测均值和噪声大小。确定性输出可以看作概率模型的特殊情形，例如 $p(y | \mathbf{x})$ 集中在单点 $f_{\theta}(\mathbf{x})$ 上。因此，确定性模型与概率模型不是互斥的两个世界，而是表达不确定性程度不同的两种建模方式。

2.2 训练目标：从预测到可优化问题

有限样本上的拟合与总体上的预测能力需要分开讨论，经验分布到真实分布的一致收敛是统计学习理论的基础问题之一[108]。神经网络的反向传播则提供了多层可微模型求梯度的有效途径[90]；求得梯度并不自动保证泛化。

损失函数与训练目标。 损失函数（loss function） $\ell(\hat{y}, y)$ 衡量一次预测的代价。训练集 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 上的经验风险为

$$\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(\mathbf{x}_i), y_i). \quad (2.2)$$

以式(2.2)为依据，最基本的训练目标是 $\arg \min_{\theta} \hat{R}(\theta)$ 。回归常用平方损失 $\frac{1}{2}(\hat{y} - y)^2$ ，分类常用交叉熵

$$\ell_{\text{CE}} = - \sum_{k=1}^K \mathbb{I}[y = k] \log p_{\theta}(y = k | \mathbf{x}). \quad (2.3)$$

损失函数不是“模型好坏”的全部定义。它还必须与实际错误代价、标签质量和部署决策相匹配。工业场景中漏报和误报往往代价不同，单纯追求平均准确率可能掩盖真正重要的风险。

2.2.1 从总体风险到有限样本目标

设 $(X, Y) \sim P$ 描述部署环境中的输入与标签， $X \in \mathbb{R}^d$ ， Y 可为实数或类别。总体风险定义为

$$R(f) = \mathbb{E}_{(X, Y) \sim P}[\ell(f(X), Y)]. \quad (2.4)$$

这里的期望包含尚未观察到的未来样本，因此通常不能直接计算。若训练样本独立同分布于 P ，对一个事先固定且损失可积的 f ，有 $\mathbb{E}[\hat{R}(f)] = R(f)$ 。若损失方差有限，独立性进一步给出

$$\text{Var}(\hat{R}(f)) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(\ell(f(X_i), Y_i)) = \frac{\text{Var}(\ell(f(X), Y))}{n}. \quad (2.5)$$

这解释了平均损失为什么可用于估计风险，也暴露了限制：相邻设备窗口相关时有额外协方差项； f 由同一训练集选择后，上述固定模型的无偏论证不能直接用于其训练误差。验证与测试的必要性由此产生，而不是来自惯例。

2.2.2 损失决定预测对象：均值、中位数与概率

平方损失的条件风险可分解为 $\frac{1}{2} \text{Var}(Y | X = x) + \frac{1}{2}(a - \mathbb{E}[Y | X = x])^2$ ，所以最优点预测是条件均值。若使用绝对值损失，令 $F_x(a) = P(Y \leq a | X = x)$ ；在条件分布连续且期望有限时，

$$\frac{d}{da} \mathbb{E}[|Y - a| | X = x] = P(Y < a | x) - P(Y > a | x) = 2F_x(a) - 1. \quad (2.6)$$

令式(2.6)为零，最优点满足 $F_x(a) = 1/2$ 。有原子概率时应使用左右导数，最优点满足 $P(Y < a | x) \leq 1/2 \leq P(Y \leq a | x)$ ，可能不唯一。

更一般地，令 $0 < \tau < 1$ ，分位数损失为 $\rho_\tau(u) = u(\tau - \mathbb{I}[u < 0])$ ，其中 $u = Y - a$ 。预测偏低时斜率代价为 τ ，偏高时为 $1 - \tau$ ，条件风险对 a 的导数为 $F_x(a) - \tau$ ，于是最优解是条件 τ 分位点。若维护决策特别关心寿命偏高估计，可通过适当分位点表达这种不对称性，但分位点的选择仍须来自真实决策成本。

对 K 类问题，记真实条件概率为 $p_k = P(Y = k | X = x)$ ，预测概率为 $q_k > 0$ ， $\sum_k q_k = 1$ 。条件交叉熵为

$$\mathbb{E}[-\log q_Y | X = x] = -\sum_k p_k \log q_k = H(p) + \text{KL}(p||q). \quad (2.7)$$

因此在可表达真实分布且达到总体最优的理想条件下，交叉熵学习整个条件分布；只以准确率训练则只需找最大概率类别。有限数据下输出在 $[0, 1]$ 内不等于已经校准。

2.3 训练目标与结构约束

正则化与归纳偏置。 当模型足够灵活时，它可能记住训练样本而没有学到可迁移的规律。正则化（regularization）通过在经验风险之外加入偏好来限制解，例如

$$\min_{\theta} \hat{R}(\theta) + \lambda \Omega(\theta), \quad \Omega(\theta) = \frac{1}{2} \|\theta\|_2^2. \quad (2.8)$$

式(2.8)中， λ 控制拟合数据和保持模型简单之间的权衡。权重衰减、数据增强、早停、Dropout和共享参数都可以被理解为不同形式的归纳偏置（inductive bias）：它们把某些解视为更合理，从而在有限数据下提高泛化可能性。

例 2.1. 对于温度传感器预测下一时刻温度，模型并不需要学习所有历史序列到未来数值的任意映射。若已知相邻时刻通常连续变化，可以采用平滑性偏置；若设备存在周期，则可以把周期特征加入输入。模型的“聪明”来自数据，也来自这些合理的限制。

惩罚形式与约束形式如何联系。 也可把偏好写成 $\min_{\theta} \hat{R}(\theta)$ 且 $\Omega(\theta) \leq c$ 。其拉格朗日函数为 $L(\theta, \lambda) = \hat{R}(\theta) + \lambda(\Omega(\theta) - c)$, $\lambda \geq 0$ 。固定 λ 后, 常数 $-\lambda c$ 不影响参数最优解, 便得到惩罚目标。若目标与约束凸并满足适当的严格可行性条件, 最优解可满足

$$0 \in \partial \hat{R}(\hat{\theta}) + \lambda \partial \Omega(\hat{\theta}), \quad \Omega(\hat{\theta}) \leq c, \quad \lambda(\Omega(\hat{\theta}) - c) = 0. \quad (2.9)$$

∂ 是允许不可微凸函数的次梯度集合。互补条件表示: 限制未起作用时乘子可为零; 限制起作用时, 数据拟合的改善必须补偿复杂度增加的代价。非凸网络中不能据此声称任意约束问题都与某个惩罚问题全局等价; λ 与 c 也不必一一对应。

以一维模型、 $\hat{R}(w) = \frac{1}{2}(w - a)^2$ 为例, a 是无正则化估计。加入 $\lambda w^2/2$ 后, 导数为 $(w - a) + \lambda w$, 所以 $\hat{w} = a/(1 + \lambda)$ 。这展示了收缩的具体含义: 不是自动删掉噪声, 而是把所有估计向零拉近。若真实系数远离零, 收缩会引入偏差; 只有减少的不稳定性足够大时, 总预测风险才可能下降。

从训练到部署及反馈。 沿图2.1从采集到上线的路径, 可以依次看四个阶段。先把设备记录整理成输入和标签, 再选择能处理这些输入的模型, 通过训练求出参数, 最后用这些参数预测新记录。上线后的错误又会提示我们补数据、改标签或重新训练。评价时除了训练损失, 还要检查新工况下的表现、概率是否校准、计算是否及时, 以及误报和漏报的后果。后续章节将分别展开这些步骤。




图 2.1: 工业数据智能的训练、部署与反馈: 部署反馈会重新影响数据和任务定义。

学习对象与可识别性。 同一组观测可以对应不同的学习对象。若输入是温度窗口, 目标可以是下一时刻温度、未来一小时最大温度、设备健康分数或故障概率。它们需要不同标签、不同时间边界和不同损失函数。若标签由未来事件定义, 训练样本必须避免使用事件发生之后才出现的信息。

还需区分“可预测”和“可识别”。一个变量可能与故障高度相关, 却只是设备编号的替代变量; 当设备更换后, 相关性就会消失。好的特征不是在固定数据表上有高相关系数, 而是在数据生成机制改变后仍保留任务所需的信息。

确定性预测与概率预测。 平方损失学习条件均值, 绝对值损失学习条件中位数, 分位数损失学习指定分位点。这说明损失函数实际上规定了预测对象。若同一输入对应多个合理输出, 点预测会把它们平均在一起; 概率预测则尝试给出完整条件分布。部署时若动作成本不对称, 还应从预测分布计算决策风险, 而不是直接选择最大概率类别。

可识别性不是相关性的另一个名字。严格地说，参数可识别要求不同参数对应不同的可观测分布；仅讨论确定性预测时，可要求 $f_{\theta}(X) = f_{\theta'}(X)$ 几乎处处成立只能推出 $\theta = \theta'$ 。例如若所有样本均满足 $X_2 = 2X_1$ ，则

$$w_1X_1 + w_2X_2 = (w_1 + 2w_2)X_1. \quad (2.10)$$

数据只能确定组合 $w_1 + 2w_2$ ，无法分别确定两个系数。正则化可以选出某个解，却没有创造额外观测证据。参数不可识别、跨设备相关性失效以及因果关系不可识别是不同问题；它们共同说明准确预测并不自动赋予参数机制解释。

从条件概率推导动作。 令动作 $a \in \{0, 1\}$ 分别表示不告警与告警，正确动作成本暂取零，误报与漏报成本分别为 $c_{FP}, c_{FN} > 0$ 。给定校准到目标环境的故障概率 p ，条件风险为

$$r(1 | x) = c_{FP}(1 - p), \quad r(0 | x) = c_{FN}p. \quad (2.11)$$

比较式(2.11)中的两种风险得到告警条件 $p \geq c_{FP}/(c_{FP} + c_{FN})$ ，等号处两种动作成本相同。若漏报成本是误报的九倍，阈值为0.1而不是0.5。此推导假设动作成本固定且概率对应部署人群；若告警后还会改变故障概率，或维护容量有限，就需要扩展动作与后果模型，不能仅调整一个阈值解决全部问题。

模型选择的四个约束。 模型选择至少同时受四类约束：数据规模与标注质量、任务中的依赖结构、训练与推理资源、错误的业务代价。复杂模型并不自动优于简单模型；它只有在表示了简单模型无法表示的结构时才有必要。后文讨论的序列、视觉和语言模型，实际上是在不同结构约束下对这四个问题的回答。

2.4 本章小结：学习的对象由规则决定

机器学习并非从数据中提取一个与任务无关的唯一答案。输入和标签定义可观察的问题，模型族限定可表达的答案，损失确定希望估计的统计对象，正则化与优化再从有限数据允许的解中作出选择。总体风险与经验风险、预测与解释、概率与动作必须分开，才能判断一个低损失结果到底说明了什么。

下一章用可以手算的经典模型练习这些概念。平方损失怎样导出正规方程，惩罚为什么使系数收缩或变为零，逻辑回归的梯度怎样从交叉熵得到，都将逐步展开。先把简单模型算明白，后面换用复杂模型时，才能说清它解决了哪一种原先解决不了的问题。

第三章 线性模型与经典学习算法

本章摘要。本章从最容易解释的线性模型出发，依次讨论回归、正则化、分类、树模型、集成和无监督学习。主线不是罗列算法，而是观察模型复杂度如何改变几何表示、偏差方差和决策阈值。最后将这些选择放回轴承状态分类案例，为后文的深度模型提供可比较的基线。

上一章把学习写成风险最小化，本章要追问这个表达究竟怎样产生一个能计算的模型。线性模型尤其适合作为第一步：每个参数、每次收缩和每条分类边界都能直接从目标函数中解释。这里的“线性”指对参数线性，输入仍可包含平方项、频带能量或其他人工特征，并不意味着原始物理过程必须线性。

先从温度、振动等特征的加权和开始，看看权重怎样求出、读数相关时又会出什么问题。如果简单的加权和无法区分故障，再考虑树和集成模型；没有标签时，则用聚类探索记录中有哪些相似模式。每换一种方法，都要在相同的数据划分和评价规则下比较。这样才能知道，增加的复杂度究竟解决了什么困难。

3.1 线性回归与正则化：从几何到稳定性

岭回归与 Lasso 分别通过二次惩罚和绝对值惩罚控制估计的不稳定性[41, 105]。本节从这两个目标函数解释收缩与稀疏，而不是把正则化仅当作调参选项。

线性回归的矩阵推导。 给定设计矩阵 $X \in \mathbb{R}^{n \times d}$ 和标签向量 $\mathbf{y}$ ，线性回归最小化

$$J(\mathbf{w}) = \frac{1}{2} \|X\mathbf{w} - \mathbf{y}\|_2^2. \quad (3.1)$$

令式(3.1)的梯度为零可得正规方程

$$X^T X \hat{\mathbf{w}} = X^T \mathbf{y}. \quad (3.2)$$

由式(3.2)，当 $X^T X$ 可逆时， $\hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$ 。实际计算通常使用 QR 分解或奇异值分解，避免显式求逆带来的数值不稳定。

展开目标、检查唯一性。 X 的第 i 行是 $\mathbf{x}_i^T$ ， $\mathbf{y} \in \mathbb{R}^n$ ， $\mathbf{w} \in \mathbb{R}^d$ 。将平方展开，

$$J(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T X^T X \mathbf{w} - \mathbf{w}^T X^T \mathbf{y} + \frac{1}{2} \mathbf{y}^T \mathbf{y}, \quad (3.3)$$

$$\nabla J(\mathbf{w}) = X^T X \mathbf{w} - X^T \mathbf{y}, \quad \nabla^2 J = X^T X. \quad (3.4)$$

因为 $\mathbf{v}^\top X^\top X \mathbf{v} = \|X \mathbf{v}\|_2^2 \geq 0$ ，目标凸，正规方程的任意解都是全局最小值。唯一性要求 X 列满秩，即不存在非零 $\mathbf{v}$ 满足 $X \mathbf{v} = 0$ ；特别地， $d > n$ 时无正则化参数不可能唯一。若秩不足， $X^+ \mathbf{y}$ 给出最小欧氏范数解，所有解可写为 $X^+ \mathbf{y} + \mathbf{v}$ ，其中 $X \mathbf{v} = 0$ 。参数可能不同，但训练点的拟合向量相同。

这里使用误差平方和而非平均值；若改用 $\|X \mathbf{w} - \mathbf{y}\|^2 / (2n)$ ，相同数值的 λ 代表不同惩罚强度，后续闭式解中的 λI 要相应变成 $n \lambda I$ 。比较实现时必须先核对这个约定。

岭回归、Lasso 与 Elastic Net。 岭回归加入二次惩罚：

$$\hat{\mathbf{w}}_{ridge} = \arg \min_{\mathbf{w}} \frac{1}{2} \|X \mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad (3.5)$$

式(3.5)的解为 $(X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$ 。Lasso 使用 L_1 惩罚 $\lambda \|\mathbf{w}\|_1$ ，会产生稀疏解，适用于希望进行特征筛选的场景。正则化牺牲一部分无偏性换取更低方差，超参数必须在验证集上选择。

岭回归如何抑制小奇异值方向。 令 X 的秩为 r ，其紧致奇异值分解为

$$X = U S V^\top, \quad S = \text{diag}(s_1, \dots, s_r), \quad s_j > 0. \quad (3.6)$$

正规方程加入 $\lambda \mathbf{w}$ 后变为

$$(X^\top X + \lambda I) \mathbf{w} = X^\top \mathbf{y}. \quad (3.7)$$

当 $\lambda > 0$ 时矩阵正定，且

$$\hat{\mathbf{w}}_\lambda = \sum_{j=1}^r \frac{s_j}{s_j^2 + \lambda} \mathbf{v}_j \mathbf{u}_j^\top \mathbf{y}. \quad (3.8)$$

最小二乘对应系数 $1/s_j$ ，会放大小奇异值方向的标签扰动；岭回归把它乘以 $s_j^2/(s_j^2 + \lambda)$ ，因而在这些方向收缩最强。若 $\mathbf{y} = X \mathbf{w}_* + \varepsilon$ 、 $\mathbb{E} \varepsilon = 0$ 、 $\text{Cov}(\varepsilon) = \sigma^2 I_n$ 且 X 固定，则

$$\mathbb{E}[\mathbf{v}_j^\top \hat{\mathbf{w}}_\lambda] = \frac{s_j^2}{s_j^2 + \lambda} \mathbf{v}_j^\top \mathbf{w}_*, \quad (3.9)$$

$$\text{Var}(\mathbf{v}_j^\top \hat{\mathbf{w}}_\lambda) = \frac{\sigma^2 s_j^2}{(s_j^2 + \lambda)^2}. \quad (3.10)$$

这明确显示偏差增加而方差减少，不保证每个真实参数与每个 λ 下总误差都降低。截距通常单独估计而不惩罚；此处公式默认无截距或数据已经按训练均值中心化。

Lasso 的零系数从哪里来。 固定其他坐标，记第 j 列为 $\mathbf{x}_j$ ，部分残差为 $\mathbf{r}_j = \mathbf{y} - \sum_{k \neq j} \mathbf{x}_k w_k$ 。关于 w_j 的目标去掉常数后为

$$\frac{1}{2} a_j w_j^2 - c_j w_j + \lambda |w_j|, \quad a_j = \|\mathbf{x}_j\|_2^2, \quad c_j = \mathbf{x}_j^\top \mathbf{r}_j. \quad (3.11)$$

对非零列 $a_j > 0$ ，正半轴驻点为 $(c_j - \lambda)/a_j$ ，负半轴驻点为 $(c_j + \lambda)/a_j$ ；在零点， $\partial|w_j| = [-1, 1]$ ，故零点最优当且仅当 $|c_j| \leq \lambda$ 。合并得到软阈值更新

$$w_j \leftarrow \frac{\text{sign}(c_j)(|c_j| - \lambda)_+}{a_j}, \quad (u)_+ = \max(u, 0). \quad (3.12)$$

零不是四舍五入的结果，而是一个相关性区间的精确最优解。Elastic Net只需把分子阈值改成 $\lambda\alpha$ ，分母改成 $a_j + \lambda(1 - \alpha)$ ；其二次项也帮助缓解共线性下解的不稳定。

3.2 分类模型与代价敏感决策

逻辑回归。 二分类逻辑回归令

$$p(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b), \quad \sigma(a) = \frac{1}{1 + e^{-a}}. \quad (3.13)$$

对数几率满足 $\log[p/(1-p)] = \mathbf{w}^\top \mathbf{x} + b$ ，所以其他特征不变时，第 j 个特征增加一个单位使几率 $p/(1-p)$ 乘以 e^{w_j} 。这不是风险概率之比，也不是因果效应。

上面说明了如何把输入转换为类别概率，但参数还没有确定。接下来需要回答：怎样利用已知标签，让模型给出的概率更符合训练数据？例如，对一个确实发生故障的样本，模型应当给实际标签分配较大的概率。从标签的伯努利分布出发，就可以把这个要求写成训练目标。

从伯努利似然到梯度和Hessian。 把截距并入 $\tilde{x}_i = (\mathbf{x}_i^\top, 1)^\top \in \mathbb{R}^{d+1}$ ，参数记为 $\beta = (\mathbf{w}^\top, b)^\top$ 。令 $a_i = \tilde{x}_i^\top \beta$ 、 $p_i = \sigma(a_i)$ 。由于 $Y_i \in \{0, 1\}$ ，模型给实际标签 y_i 分配的概率为 $p_i^{y_i}(1-p_i)^{1-y_i}$ ：当 $y_i = 1$ 时取 p_i ，当 $y_i = 0$ 时取 $1-p_i$ 。假设给定输入和参数后，各样本的标签条件独立，整个训练集的似然就是这些概率的乘积 $\prod_i p_i^{y_i}(1-p_i)^{1-y_i}$ 。

最大化这个乘积，等价于最小化它的负对数。对数把乘积变成求和，因而每个样本对应一个损失。式(3.14)中的两项负对数之和就是二分类交叉熵；代入 sigmoid 后，可将它改写为关于线性得分 a_i 的表达式，并进一步求导：

$$\ell_i = -y_i \log \sigma(a_i) - (1 - y_i) \log(1 - \sigma(a_i)) = \log(1 + e^{a_i}) - y_i a_i, \quad (3.14)$$

$$\frac{\partial \ell_i}{\partial a_i} = p_i - y_i, \quad \frac{\partial^2 \ell_i}{\partial a_i^2} = p_i(1 - p_i) \geq 0. \quad (3.15)$$

令 $\tilde{X} \in \mathbb{R}^{n \times (d+1)}$ 为增广矩阵，平均损失的梯度与Hessian为

$$\nabla J = \frac{1}{n} \tilde{X}^\top (p - y), \quad \nabla^2 J = \frac{1}{n} \tilde{X}^\top D \tilde{X}, \quad D = \text{diag}(p_i(1 - p_i)). \quad (3.16)$$

这里 $J = \frac{1}{n} \sum_i \ell_i$ 。对任意参数方向 $v \in \mathbb{R}^{d+1}$ ，有

$$v^\top \nabla^2 J v = \frac{1}{n} \sum_i p_i(1 - p_i)(\tilde{x}_i^\top v)^2 \geq 0. \quad (3.17)$$

式(3.17)表明 Hessian 半正定, 说明这个训练目标关于逻辑回归参数 β 是凸的: 若存在局部极小点, 它也是全局极小点。这个结论依赖于得分 a_i 是参数的线性函数, 不能直接推广到以神经网络输出概率的交叉熵目标。但凸性不保证有限最优参数存在: 完全线性可分的数据可通过无限放大分类方向使损失趋近零。正则化、共线性检查和停止条件仍然必要。计算 $\log(1 + e^a)$ 时应使用稳定形式 $\max(a, 0) + \log(1 + e^{-|a|})$ 。

3.3 非线性模型与无监督结构

支持向量机通过间隔约束构造判别边界, 随机森林通过随机化的树集成降低相关性, 梯度提升则逐步拟合损失的下降方向[18, 9, 26]。这些机制的差别决定其适用数据规模、非线性表达与调参方式。

支持向量机: 从距离到间隔目标。 对标签 $y_i \in \{-1, 1\}$, 线性边界 $w^\top x + b = 0$ 到点 x_i 的距离是 $|w^\top x_i + b|/\|w\|_2$ 。同时缩放 w, b 不改变边界, 故在线性可分时可选尺度使最近点满足 $y_i(w^\top x_i + b) = 1$ 。最大化几何间隔 $1/\|w\|_2$ 就等价于

$$\min_{w, b} \frac{1}{2} \|w\|_2^2, \quad y_i(w^\top x_i + b) \geq 1. \quad (3.18)$$

不可分时引入 $\xi_i \geq 0$, 约束改为 $y_i(w^\top x_i + b) \geq 1 - \xi_i$ 并惩罚 $C \sum_i \xi_i$ 。固定 w, b 时最小可行松弛量是 $\xi_i = (1 - y_i(w^\top x_i + b))_+$, 因此得到正则化合页损失。 $C > 0$ 越大越强调训练违约代价; 若使用平均损失, 参数尺度也要调整。核方法把内积换成正半定核 $k(x, x') = \langle \phi(x), \phi(x') \rangle$ 以构造非线性边界, 但分类分数并不直接是概率。

树模型与集成。 决策树通过一系列特征阈值划分输入空间。分类树常用基尼不纯度

$$G(S) = 1 - \sum_{k=1}^K \hat{p}_k^2 \quad (3.19)$$

选择划分。随机森林通过自助采样和随机特征子集降低方差; 梯度提升树则逐步拟合当前残差。树模型适合表格数据和混合类型特征, 通常不需要大规模标准化, 但在高维原始图像和长序列上不如专门的深度结构。

不纯度下降、平均方差与提升方向。 在节点 S 中按经验类别比例独立抽两次标签, 二者不同的概率为 $1 - \sum_k \hat{p}_k^2$, 这给出基尼不纯度的解释。候选划分 $S = S_L \cup S_R$ 的收益必须按子节点大小加权:

$$\Delta G = G(S) - \frac{|S_L|}{|S|} G(S_L) - \frac{|S_R|}{|S|} G(S_R). \quad (3.20)$$

不加权会把一个极小纯节点误当成与大节点等量重要。贪心选择最大收益只优化当前一步, 不保证整棵树全局最优。

对固定输入，若 M 棵树的数值预测各有方差 σ_T^2 且两两相关系数均为 ρ ，则平均预测满足

$$\text{Var} \left(\frac{1}{M} \sum_{m=1}^M T_m \right) = \frac{M\sigma_T^2 + M(M-1)\rho\sigma_T^2}{M^2} = \rho\sigma_T^2 + \frac{1-\rho}{M}\sigma_T^2. \quad (3.21)$$

式(3.21)解释了为什么降低树之间的相关性与增加树数同样重要；它针对数值平均，不能直接当成多数投票分类错误率公式。

梯度提升则令当前预测为 $F_{m-1}(x_i)$ ，拟合伪残差 $r_i = -\partial\ell(y_i, F)/\partial F$ ，用树 h_m 逼近 r_i ，再更新 $F_m = F_{m-1} + \nu\gamma_m h_m$ ，其中 γ_m 可由一维线搜索确定， $0 < \nu \leq 1$ 控制步幅。平方损失下 $r_i = y_i - F_{m-1}(x_i)$ 才是普通残差；伯努利交叉熵以对数几率为 F 时 $r_i = y_i - \sigma(F_{m-1}(x_i))$ 。因此“拟合残差”是负梯度思想在特定损失下的形式。

无监督学习。 K-means最小化类内平方距离

$$\min_{\{\mu_k\}} \sum_{i=1}^n \min_k \|\mathbf{x}_i - \mu_k\|_2^2. \quad (3.22)$$

交替执行“分配最近中心”和“更新中心”会使目标不增，但一般只能得到依赖初始化的稳定划分，不能保证全局最优。PCA寻找最大投影方差方向，等价于求协方差矩阵的主特征向量。工业上聚类可用于设备分群，PCA可用于降噪和可视化，但聚类编号不天然具有物理语义。

K-means的两个更新为什么不增损失。 引入指派变量 $z_i \in \{1, \dots, K\}$ ，目标成为 $Q(z, \mu) = \sum_i \|x_i - \mu_{z_i}\|_2^2$ 。固定中心时，每个 z_i 独立取最近中心就最小化对应项；固定指派时，设 $S_k = \{i : z_i = k\}$ 且非空，则

$$\nabla_{\mu_k} \sum_{i \in S_k} \|x_i - \mu_k\|_2^2 = 2|S_k|\mu_k - 2 \sum_{i \in S_k} x_i = 0, \quad \mu_k = \frac{1}{|S_k|} \sum_{i \in S_k} x_i. \quad (3.23)$$

于是 $Q(z^{t+1}, \mu^{t+1}) \leq Q(z^{t+1}, \mu^t) \leq Q(z^t, \mu^t)$ ，目标非负，故目标值收敛。要保证指派稳定，还需处理距离相同的平局；空簇则必须有明确的重新初始化策略。目标值收敛本身不证明找到了最佳聚类，多次初始化是必要的经验检查。

线性回归的几何解释。 预测向量 $X\mathbf{w}$ 属于设计矩阵的列空间。最小二乘解把标签向量 $\mathbf{y}$ 正交投影到这个子空间，因此残差满足 $X^T(X\hat{\mathbf{w}} - \mathbf{y}) = 0$ 。若特征高度相关，列空间本身可能稳定，但参数坐标并不稳定；这解释了为什么预测误差可以很小而单个回归系数却随数据扰动显著变化。

加入截距时，通常应先对特征中心化，或在设计矩阵中显式加入全一列。对量纲差异很大的变量，标准化不会改变线性预测空间，但会改变正则化对各坐标的相对作用。岭回归的惩罚若直接施加在未标准化变量上，为产生相同幅度的预测变化，数值尺度大的特征只需较小系数，因而往往受到较弱的有效惩罚；这会使单位选择不当地影响模型偏好。

正则化路径与稀疏性。 岭回归把共线特征的系数一起收缩，通常不会精确变为零；Lasso 的 L_1 球有尖角，最优点更容易落在坐标轴上，因此产生稀疏解。Elastic Net 将二者结合：

$$\min_w \frac{1}{2} \|Xw - y\|_2^2 + \lambda \left(\alpha \|w\|_1 + \frac{1 - \alpha}{2} \|w\|_2^2 \right). \quad (3.24)$$

当传感器特征成组相关时，Elastic Net 往往比纯 Lasso 更稳定。稀疏性仍应被解释为建模选择，不应自动等同于因果重要性。

逻辑回归与代价敏感决策。 逻辑回归的线性函数给出对数几率，但真正的停机或告警动作还需要阈值。设误报成本为 c_{FP} 、漏报成本为 c_{FN} ，预测概率为 p ，选择告警的期望成本为 $c_{FP}(1 - p)$ ，不告警的期望成本为 $c_{FN}p$ 。因此阈值应由成本比决定，而不是固定为 0.5。类别权重、阈值调整和概率校准分别作用于训练目标、决策规则和输出解释。

树模型的划分偏差。 决策树递归寻找能最大减少不纯度的划分。若类别极不平衡，基尼下降可能主要反映多数类；若连续变量取值很多，候选切点越多也越容易产生偶然收益。限制最大深度、叶节点最小样本数和使用验证集剪枝，都是控制树复杂度的方式。

随机森林通过样本和特征随机化降低树之间的相关性；梯度提升则让后续树拟合前一阶段的残差。前者通常稳健，后者在表格任务上常有很高的精度，但对学习率、树深和迭代次数敏感。工业建模中应同时报告特征重要性稳定性，避免把一次随机森林的排序当作机制结论。

聚类的验证。 K-means 隐含近似球形、相近尺度和均匀方差的簇假设。高斯混合模型允许不同协方差结构，并给出软归属概率；层次聚类则提供多尺度树状结构。聚类质量可以使用轮廓系数，但真正的工业价值还要看簇是否对应不同工况、维护策略或数据质量。若簇只反映传感器量程差异，聚类结果就不应被解释为设备类型。

3.4 工业基线：从可解释模型到复杂模型

假设从每个振动窗口提取均方根、峭度、峰值因子和频带能量。先用逻辑回归检查这些特征的简单组合是否足够，再用随机森林学习非线性划分，最后尝试让一维卷积网络直接读取波形。如果复杂模型只在随机切分时提高成绩，在留出整台设备测试时反而下降，它可能依赖了设备特有的信号。仅凭这一现象还不能断定原因，需要继续检查工况差异、标签质量和设备特征。轴承分类实验应先固定设备级切分，再依次建立多数类基线、逻辑回归、随机森林和一维卷积模型。每一步记录输入信息、参数量、训练时间、推理延迟和错误类型。这里的端到端模型指直接从输入学习预测结

果、联合优化特征提取与预测部分的模型。若这类模型的提升只出现在同一设备随机切分，而在新设备上消失，应回到特征和划分规则检查，而不是继续增加网络深度。

本章小结。 经典模型的价值不只在于计算便宜，更在于它们把数据、假设和决策之间的关系暴露出来。线性模型提供可解释基线，树模型处理非线性表格关系，聚类 and PCA 探索无标签结构；复杂模型应在这些基线无法表达任务结构时再被引入。

本章推导还表明，不同算法的“最优”并非同一含义：最小二乘是在列空间内最优，正则化是在指定偏好下折中，逻辑回归凸性不保证参数有限，K-means的交替下降也不保证全局最优。解释算法时应同时说明优化对象、成立条件和未解决的部分。

模型已经能算，下一章还要检查喂给它的数据怎样得到。正规方程和梯度都写对了，若输入混入未来记录，或把同一设备的相邻窗口分到训练和测试两边，成绩仍可能过于乐观。因此先写清取哪个时段、哪些设备留作测试，以及预测之后怎样告警，再开始训练。

第四章 从数据到推理的完整流程

本章摘要。本章把前面定义的学习问题与经典模型落实为可执行流程：先定义事件和样本，再划分数据、训练模型、进行推理并评价部署风险。数据治理和时间边界贯穿全章，因为任何后续算法都无法修复样本构造或信息泄漏造成的错误。

前一章说明了模型如何依据目标求解，却有意把设计矩阵当作已经给定。工业任务最容易出错的地方，恰恰发生在矩阵形成之前：一条记录何时进入系统，一个窗口对应哪个未来事件，哪些设备可以出现在训练和测试两侧。这些选择不是附属工程细节，而是在决定风险公式中的样本究竟来自什么分布。

本章会反复检查一个朴素的问题：作出预测的那一刻，这条信息真的已经到手了吗？标准化的均值从哪里算，参数用哪些记录训练，阈值在哪一批数据上选择，都要留下清楚的记录。评价时还要把相邻窗口合并回故障事件：同一次故障连续触发许多条告警，并不等于发现了许多次故障。否则离线分数可能很好看，现场却仍然漏报或频繁打扰检修人员。

4.1 数据划分与数据治理

数据泄漏不仅发生在训练测试样本重叠时，也可能通过预处理、特征选择与标签构造进入整个流程[51]。因此以下划分规则约束的是信息使用过程，而不只是一次随机切分。训练集用于拟合参数，验证集用于选择超参数和比较方案，测试集只在最终报告时使用。若时间顺序具有因果意义，应采用按时间切分，而不是随机打乱。工业数据还需处理缺失、漂移、传感器失真、重复记录与标签延迟。数据清洗不是模型之外的琐事，因为它决定了模型究竟看到了什么分布。

预处理也是需要拟合的模型。 设训练索引为 $\mathcal{T}$ ，第 j 个特征的均值和尺度应只在训练集计算：

$$\hat{\mu}_j = \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} x_{ij}, \quad \hat{s}_j^2 = \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} (x_{ij} - \hat{\mu}_j)^2, \quad z_{ij} = \frac{x_{ij} - \hat{\mu}_j}{\max(\hat{s}_j, \epsilon)}. \quad (4.1)$$

这里 $\epsilon > 0$ 是与该特征单位一致的尺度下限，避免常数列除零；也可明确删除常数列。验证、测试与上线输入都使用同一组训练统计量。其原因可写为函数依赖：最终预测

是 $f_{\hat{\theta}}(T_{\hat{\phi}}(x))$ ，其中 $\hat{\phi} = \text{FitTransform}(\mathcal{D}_{\mathcal{T}})$ 。若用全数据估计 $\hat{\phi}$ ，测试集就参与了模型构造，即使没有使用测试标签，也改变了原定的归纳评估问题。

交叉验证时每折必须重新拟合 $\hat{\phi}$ 与 $\hat{\theta}$ ，而不是先全量标准化再切折。缺失值填补、PCA、异常值阈值和监督特征筛选也属于这条规则；若部署允许使用一批无标签目标数据适配，应将其明确写成另一个评估规则。

4.2 训练、评价、部署与反馈




图 4.1: 工业学习管道中的信息边界。切分、特征生成和标签构造共同决定是否发生泄漏。

图4.1把窗口构造、时间与设备划分和上线反馈连接起来；其中延迟标签返回样本构造环节，而测试集边界限制了模型选择可使用的信息。

贯穿案例的固定设置。 先以“预测未来二十四小时内的设备故障”建立维护流程的预测任务。设备 i 在预测时刻 t 的可用观测记为

$$\mathcal{I}_{i,t} = \{x_{i,s} : s \leq t\} \cup \{m_{i,s} : s \leq t\}, \quad (4.2)$$

其中 s 表示记录进入系统并可查询的时刻，原始采集时刻另行保存； $x_{i,s}$ 表示传感器和控制量， $m_{i,s}$ 表示维护信息。二十四小时故障标签定义为

$$y_{i,t} = \mathbb{I}\{\text{设备 } i \text{ 在 } (t, t + 24\text{h}] \text{ 内发生经确认的故障事件}\}. \quad (4.3)$$

这里的预测时刻、事件发生时刻和记录可用时刻必须分开保存。计划保养并不自动构成故障标签，维修工单只是确认事件的证据来源。若未来二十四小时尚未完整观测，且还没有确认故障，该样本不能直接标为正常。二十四小时是预测时间窗，实际提前量则是故障发生时刻与有效告警时刻之差，需要单独评价。后文的剩余寿命回归、图像定位和维修问答是关联任务，各有标签与指标；共享的是证据可用性原则，而非强行统一输出。

后文比较模型时，都沿用这项任务定义，并逐项记录输入、结构、损失和测试划分。还要写清分数超过多少才告警，传感器缺失时是沿用备用规则还是请人工检查。例如，模型能算出故障概率，并不意味着它已经规定了谁来接收告警、何时安排复检。把这些安排与模型结果分别记录，才能复查成绩差异来自算法还是处理流程。

可用性、标签成熟与时间隔离的形式化。 对记录 r 分别保存采集时间 $e(r)$ 和可用时间 $a(r)$ 。预测时刻 t 、回看长度 $w > 0$ 对应的输入集合应为

$$\mathcal{R}_t = \{r : t - w \leq e(r) \leq t, a(r) \leq t\}, \quad x_t = \text{Aggregate}(\mathcal{R}_t). \quad (4.4)$$

因此仅比较采集时间不够；迟到数据不能反向修正历史在线输入而仍声称是实时评估。可将这一原则理解为 x_t 必须由 t 时刻已经掌握的信息计算出来。

令 $h = 24\text{h}$ ，训练快照截止于 T 。若标签确认最多延迟 δ ，且事件追踪完整，则要求 $t + h + \delta \leq T$ 可保守保证一个二元标签成熟。已确认的早期正例虽可提前得知，但不能把尚未成熟的其余样本直接当负例；只保留这些早期正例又会改变样本分布。若延迟没有确定上界，应该依据逐样本的标签成熟状态筛选，或使用明确处理删失的模型。

若训练预测时刻为 t_a ，验证最早预测时刻为 t_b ，为使训练标签不跨入验证预测期，可要求 $t_a + h < t_b$ 。若还要求原始窗口与标签支撑区间完全不重叠，则由 $[t_a - w, t_a + h]$ 与 $[t_b - w, t_b + h]$ 分离得到更保守条件 $t_a + h < t_b - w$ 。后一条件不是所有滚动预测都必须采用：部署时合理地重用过去观测并不自动泄漏，但会造成统计依赖；应根据要模拟的部署方式选择规则并说明残留相关性。

优化：如何找到参数。 以可微目标 $J(\theta)$ 为例，梯度下降更新为

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} J(\theta_t), \quad (4.5)$$

其中 η_t 是学习率。随机梯度下降用小批量 B_t 近似全量梯度：

$$\theta_{t+1} = \theta_t - \eta_t \frac{1}{|B_t|} \sum_{i \in B_t} \nabla_{\theta} \ell_i(\theta_t). \quad (4.6)$$

动量、Adaptive Moment Estimation (Adam)和学习率调度都改变了优化轨迹，但不改变“依据目标函数更新参数”的基本逻辑。优化收敛并不自动意味着泛化良好，因为训练目标只是有限数据上的代理目标。

推理与部署。 训练完成后冻结参数，在新样本上计算 $f_{\theta}(\mathbf{x})$ 或 $p_{\theta}(y | \mathbf{x})$ 。部署阶段还要考虑延迟、吞吐、内存、量化误差、异常输入和模型更新策略。一个在离线测试集上准确的模型，如果无法在传感器数据到达后的时间约束内完成推理，仍然不是有效的工业系统。

评价指标。 分类可报告准确率、精确率、召回率、 F_1 和Area Under the Receiver Operating Characteristic Curve (ROC-AUC)；回归常用Mean Absolute Error (MAE)与Root Mean Squared Error (RMSE)。概率预测还应检查负对数似然和校准误差。指标必须对应决策目标。例如，安全监测通常优先控制漏报，故不能只使用准确率。报告结果时应同时给出数据划分、随机种子、置信区间或多次运行波动，以区分真实改进和偶然差异。

从混淆矩阵推导指标及其基率依赖。固定阈值后，真正例、假正例、假负例与真负例数量记为 TP, FP, FN, TN 。于是

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2TP}{2TP + FP + FN}. \quad (4.7)$$

式(4.7)中的 F_1 由精确率与召回率的调和平均得到；分母为零时必须预先约定报告方式，不能把无正例设备的指标静默设成满分。

令部署故障比例为 $\pi = P(Y = 1)$ ，真正例率为 $u = P(\hat{Y} = 1 | Y = 1)$ ，假正例率为 $v = P(\hat{Y} = 1 | Y = 0)$ 。由条件概率和全概率公式，

$$P(Y = 1 | \hat{Y} = 1) = \frac{\pi u}{\pi u + (1 - \pi)v}. \quad (4.8)$$

例如 $\pi = 0.01, u = 0.9, v = 0.05$ 时，精确率约为0.154；高召回仍可能伴随大量无效告警。因此在故障比例不同的设备群间，不能只依据同一受试者工作特征（Receiver Operating Characteristic, ROC）工作点推断告警质量。ROC-AUC考察排序，部署动作还需要固定阈值、基率与成本。

窗口误差如何转换为事件指标。设第 e 次故障时间为 τ_e ，要求最小提前量为 $L_{\min}$ ，其中 $0 < L_{\min} \leq h$ 。只有位于 $[\tau_e - h, \tau_e - L_{\min}]$ 的有效告警才算及时命中。定义 a_e 为该区间内按既定合并规则选取的首个有效告警，事件召回率为

$$\frac{\sum_e \mathbb{I}\{a_e \text{ 存在}\}}{\text{可评价故障事件数}}, \quad L_e = \tau_e - a_e. \quad (4.9)$$

未命中事件不能从召回分母移除；仅在命中事件上报告平均提前量也应明确这一条件。必须事先规定同一告警能否匹配多个事件、连续超阈值如何合并、告警冷却时间如何设置。无效告警频率宜用“未匹配告警数/有效监测设备天数”计算，而不是把重复窗口当成独立动作。

误差条为何依赖抽样单位。对固定模型的 n 个独立测试错误指示 $E_i \in \{0, 1\}$ ，若错误率为 q ，则 $\hat{q} = n^{-1} \sum_i E_i$ 且 $\text{Var}(\hat{q}) = q(1 - q)/n$ ，标准误可用 $\sqrt{\hat{q}(1 - \hat{q})/n}$ 估计；小样本或极端比例应使用更合适的区间方法。若同一设备有 m 个窗口，设备间独立、设备内错误指示方差为 σ^2 且两两相关系数为 ρ ，共 G 台设备，则

$$\text{Var}(\bar{E}) = \frac{Gm\sigma^2 + Gm(m - 1)\rho\sigma^2}{(Gm)^2} = \frac{\sigma^2}{Gm} \{1 + (m - 1)\rho\}. \quad (4.10)$$

式(4.10)说明窗口数巨大不代表独立证据同样巨大。可按设备进行成组重采样，时间相关则使用适当的块重采样；重采样方案仍需匹配目标设备总体及依赖结构。多随机种子波动主要衡量训练随机性，不能替代测试抽样的不确定性。

说明 4.1. 一条实用的诊断顺序是：先检查标签和切分，再检查训练与验证曲线，随后检查错误样本，最后才调整模型结构。否则，复杂模型很容易被用来掩盖数据问题。

从原始记录到学习样本。 工业数据通常不是天然的 (x, y) 对，而是多个系统中异步产生的事件。构造样本需要确定实体键、观测时间、预测时间、标签时间和允许使用的信息集合。对预测时刻 t ，输入可写成

$$x_t = \text{Aggregate}\{r_s : s \in [t - w, t]\}, \quad (4.11)$$

标签则由部署时真正关心的未来区间生成。若把 t 之后才产生的维修结果加入 x_t ，离线指标会被人为抬高。

落实到日志时，输入必须同时满足“已经采集”和“已经可用”。维修工单可能在故障发生数小时后才录入，可以事后用于确认标签，却不能被反向放入预测时刻的输入特征。标签审计还要区分故障维修和计划保养，避免模型实际学习维护排班而非故障风险。

该问题至少需要三组切分：按时间向后滚动的验证集、完全留出的后期测试集，以及按设备留出的迁移测试集。训练阶段可以使用窗口统计、频谱特征和最近一次维护信息，但每个特征都要通过时间可用性检查。常见泄漏包括用全周期均值标准化、用故障后的完整轨迹计算斜率、把同一设备的相邻窗口随机分到不同集合，以及使用在全数据上拟合的异常阈值。每项检查都应有一个可失败的单元测试或样本审计报告。

上线验收不应只看 ROC-AUC。系统还要规定每台设备每天最多允许的告警数、最小提前量、连续超阈值窗口数和人工确认时限。传感器断流时，服务应返回“数据不足”状态并触发数据质量工单；模型超时则回退到上一版经过验证的模型或规则基线。这样，模型风险、数据风险和服务风险才能在运行记录中被区分，而不是都表现为一个模糊的“预测错误”。

训练、验证和测试的职责。 训练集回答“参数如何拟合”；验证集回答“在候选方案中如何选择”；测试集回答“在选择完成后能否泛化”。当研究者根据测试集反复改模型时，测试集已经承担验证集职责，最终数字会有乐观偏差。时间序列还应使用滚动验证，设备任务则应按设备分组，避免同一实体的相邻窗口跨越划分边界。

数据管道的可追溯性。 每个特征都应能追溯到原始字段、单位、时间窗口、清洗规则和版本。保存最终矩阵还不够，因为矩阵无法说明它是否使用了未来统计量。建议同时保存样本 Identifier (ID)、设备 ID、预测时间、标签版本、特征生成版本和划分哈希。这样错误样本才可以从模型输出反查到数据源。

评价不等于排序。 准确率和 RMSE 适合比较某些预测任务，却不直接等于业务价值。一个故障检测器可能提高宏平均 F_1 ，却增加大量无效告警；一个回归器可能降低平均误差，却在关键峰值时系统性低估。指标应由决策流程倒推，并报告阈值、事件合并规则、提前量、资源预算和错误成本。

上线前后的差异。 离线评估使用固定数据和批量计算，线上系统还会遇到数据延迟、网络断开、字段缺失、模型版本不一致和标签延迟。部署验收应至少包括正常输入、缺失输入、极值输入、重复输入、乱序输入和服务超时。模型服务失败时必须要有明确回退策略，而不是返回一个未校验的默认预测。

本章小结。 完整流程不是“下载数据、训练模型、报告分数”，而是把现实过程转换为可复现的学习问题，再把模型输出转换为可审计的决策。数据定义、划分规则、损失函数、优化过程、评价指标和部署约束必须互相一致；其中任何一环含糊，后续的精度数字都难以解释。

本章最重要的边界有两条：一是信息边界，任何输入只能使用预测当时已经可获得的证据；二是评价边界，训练、选择和最终检验不能共用同一份证据而不承认选择偏差。标准化统计量、标签成熟规则、事件合并与置信区间都应服从这些边界，不能仅把模型权重当作完整实验。

确定样本、标签和数据用途之后，下一章开始逐步更新参数：先沿计算图求梯度，再检查步长、曲率、初始化、归一化与数值精度。优化器可以帮助降低已经定义好的损失，却不会发现工单录入晚了，也不会替我们纠正训练集和测试集的混用。

第五章 优化算法与神经网络训练

本章摘要。本章解释神经网络如何把损失函数转化为参数更新。叙事依次经过计算图、梯度优化、曲率与尺度、初始化和正则化，最后回到训练故障诊断。这样读者能够把“训练不稳定”定位到目标函数、梯度传播、数值尺度或数据管线，而不是把问题简单归咎于模型容量。

前一章已经固定样本、信息边界和评价规则，本章在这些条件不变的前提下研究求解。我们暂时不问模型能否应对新设备，而先问：损失是否被正确求导，参数是否沿着有效方向移动，信号是否在多层网络中保持可计算的尺度。把这些问题分开，才能避免用增加模型容量掩盖错误梯度，或用延长训练掩盖数值发散。

选好优化器以后，训练仍可能出问题。例如，同一批误差取总和还是取平均，会改变梯度的大小；初始权重过大，信号经过多层后可能迅速放大。下面先推导一步更新什么时候能降低损失，再分析随机梯度、曲率、初始化和归一化怎样影响训练。章末把这些推导用于排查故障，帮助读者决定该查数据、梯度还是学习率。

5.1 目标、梯度与参数更新

随机近似奠定了含噪更新的基础，Adam 则将梯度一阶与二阶矩估计用于自适应更新[85, 54]。算法的更新规则、初始化和偏差校正应一起理解，不能只比较默认学习率。

从目标函数到计算图。 训练目标常写成 $J(\theta) = \frac{1}{n} \sum_i \ell_i(\theta)$ 。神经网络把它实现为多层复合函数，计算过程可以表示为有向无环图。前向传播计算预测值，反向传播按照拓扑逆序计算每个节点对损失的梯度。自动微分系统保存中间激活，因此显存消耗和计算图结构密切相关。

一个两层网络的完整反向传播。 取单样本 $x \in \mathbb{R}^d$ ，隐藏宽度 m ，标量标签 y 。令

$$a = W_1 x + b_1 \in \mathbb{R}^m, \quad h = \phi(a) \in \mathbb{R}^m, \quad \hat{y} = w_2^\top h + b_2, \quad \ell = \frac{1}{2}(\hat{y} - y)^2, \quad (5.1)$$

其中 $W_1 \in \mathbb{R}^{m \times d}$, $b_1, w_2 \in \mathbb{R}^m$, $b_2 \in \mathbb{R}$, ϕ 逐元素作用。先求输出误差 $\delta_2 = \partial \ell / \partial \hat{y} = \hat{y} - y$, 然后逐层应用链式法则:

$$\nabla_{w_2} \ell = \delta_2 h, \quad \partial \ell / \partial b_2 = \delta_2, \quad (5.2)$$

$$\delta_1 = \nabla_a \ell = (w_2 \delta_2) \odot \phi'(a), \quad \nabla_{W_1} \ell = \delta_1 x^\top, \quad \nabla_{b_1} \ell = \delta_1. \quad (5.3)$$

外积 $\delta_1 x^\top$ 恰为 $m \times d$, 与权重形状一致。若同一个中间变量流向多个分支, 反向传播必须把各分支贡献相加; 这正是计算图反向累积的作用。Rectified Linear Unit (ReLU) 在零点不可微, 实际实现选择约定的次梯度, 通常取零。

小批量损失取平均时, 上述梯度也按样本平均; 若误用求和, 更新尺度会随批量线性增大。可在小型平滑测试网络上用中心差分 $[J(\theta + \epsilon v) - J(\theta - \epsilon v)] / (2\epsilon)$ 核对 $\nabla J^\top v$, 但应避开不可微点并固定随机屏蔽, 以免把随机性误判为梯度错误。




图 5.1: 梯度更新沿目标函数的局部下降方向移动; 等高线的狭长形状会造成不同参数方向上的尺度差异。

一阶优化。 图5.1用等高线和更新箭头对照目标的局部形状与参数轨迹, 说明不同方向的尺度会影响步长选择。梯度下降、随机梯度下降和小批量梯度下降的差别在于梯度估计的精度和更新频率。若小批量梯度 $\hat{g}_t$ 满足 $\mathbb{E}[\hat{g}_t] = \nabla J(\theta_t)$, 它虽然带有噪声, 却能降低每次更新的计算成本。噪声有时还会帮助优化器离开尖锐的鞍点。

带动量的更新为

$$v_{t+1} = \beta v_t + \hat{g}_t, \quad (5.4)$$

$$\theta_{t+1} = \theta_t - \eta v_{t+1}. \quad (5.5)$$

Adam分别维护梯度的一阶和二阶指数移动平均:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \hat{g}_t, \quad (5.6)$$

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2) \hat{g}_t \odot \hat{g}_t, \quad (5.7)$$

$$\theta_{t+1} = \theta_t - \eta \frac{m_t / (1 - \beta_1^t)}{\sqrt{s_t / (1 - \beta_2^t) + \epsilon}}. \quad (5.8)$$

其中 $m_0 = s_0 = \mathbf{0}$, $0 \leq \beta_1, \beta_2 < 1$, 分式、平方根和加法均按元素进行, 且 $\epsilon > 0$ 为数值稳定常数。自适应学习率不等同于自动选择超参数, 学习率、权重衰减和批量大小仍需验证。

单步下降需要怎样的学习率。 假设 J 可微且梯度为 L -Lipschitz, 即 $\|\nabla J(u) - \nabla J(v)\|_2 \leq L\|u - v\|_2$ 。沿线段积分, 令 $\Delta = v - u$, 则

$$J(u + \Delta) - J(u) = \int_0^1 \nabla J(u + s\Delta)^\top \Delta ds \quad (5.9)$$

$$\leq \nabla J(u)^\top \Delta + \frac{L}{2} \|\Delta\|_2^2. \quad (5.10)$$

在式(5.10)中代入 $\Delta = -\eta g$ 、 $g = \nabla J(u)$, 得到

$$J(u - \eta g) \leq J(u) - \eta(1 - L\eta/2)\|g\|_2^2. \quad (5.11)$$

所以 $0 < \eta < 2/L$ 且 $g \neq 0$ 时可以保证下降; 常取 $\eta \leq 1/L$ 留出余量。若 J 下有界于 $J_{\inf}$, 取固定 $\eta = 1/L$ 并求和, 得到

$$\min_{0 \leq t < T} \|\nabla J(\theta_t)\|_2^2 \leq \frac{2L(J(\theta_0) - J_{\inf})}{T}. \quad (5.12)$$

这是到近似驻点的保证, 不是非凸情形下到全局最优的保证。ReLU网络并不处处满足这里的光滑假设, 因此该证明是理解步长的基准, 而不能未经检查直接套用到全部网络。

随机梯度下为何不能要求每步下降。 对当前参数条件化, 假设 $\mathbb{E}[\hat{g}_t | \theta_t] = g_t$ 、 $\mathbb{E}[\|\hat{g}_t - g_t\|^2 | \theta_t] \leq \sigma^2/B$ 。因为交叉项的条件期望为零, $\mathbb{E}\|\hat{g}_t\|^2 \leq \|g_t\|^2 + \sigma^2/B$ 。将随机更新代入式(5.10)并取条件期望, 得到

$$\mathbb{E}[J(\theta_{t+1}) | \theta_t] \leq J(\theta_t) - \eta(1 - L\eta/2)\|g_t\|^2 + \frac{L\eta^2\sigma^2}{2B}. \quad (5.13)$$

噪声增加了一个正项: 接近驻点时下降项很小, 固定步长可能在邻域内波动。减小步长或增大批量可以减小这一项, 但各有时间和计算代价。无偏性依赖抽样方式; 非均匀采样若不做相应权重修正, 实际优化的目标可能已经改变。

动量与Adam校正项的来源。 从 $v_0 = 0$ 展开动量得 $v_{t+1} = \sum_{k=0}^t \beta^{t-k} \hat{g}_k$ 。若梯度恒定为 g , 则 $v_{t+1} \rightarrow g/(1 - \beta)$, 说明本章未乘 $(1 - \beta)$ 的动量约定会改变有效更新尺度, 不能与归一化约定共用学习率而不加说明。

同理, $m_t = (1 - \beta_1) \sum_{k=1}^t \beta_1^{t-k} \hat{g}_k$ 。若各步梯度具有同一均值 μ , 则 $\mathbb{E}[m_t] = (1 - \beta_1^t)\mu$, 所以除以 $1 - \beta_1^t$ 可消除零初始化导致的偏低; s_t 的二阶矩校正同理。训练中梯度分布持续变化, 校正并不使整个比值成为某个无偏梯度, 也不自动给出收敛保证。 s_t 估计的是逐坐标二阶原点矩, 而非中心化方差或Hessian。

二阶信息与曲率。 二阶泰勒展开为

$$J(\theta + \Delta) \approx J(\theta) + g^\top \Delta + \frac{1}{2} \Delta^\top H \Delta. \quad (5.14)$$

若 Hessian 正定, Newton 步为 $\Delta = -H^{-1}g$ 。它在接近极小点时可能快速收敛, 但大模型中显式存储和求逆 Hessian 代价过高。拟牛顿法、自然梯度和共轭梯度通过近似曲率获得折中。

Newton步和条件数。 对二次近似 $q(\Delta) = J + g^\top \Delta + \frac{1}{2} \Delta^\top H \Delta$ 求导，得到 $\nabla_\Delta q = g + H\Delta$ ；若 H 正定，唯一最小点满足 $H\Delta = -g$ ，实现上应解线性方程而非显式形成逆矩阵。若 H 不定，二次近似可能无下界，Newton方向也不一定下降；加阻尼 $H + \lambda I$ 使其正定，或使用信赖域限制步幅，是处理这一问题的思路。

对严格凸二次函数 $J(\theta) = \frac{1}{2} \theta^\top H \theta - b^\top \theta$ ，记误差 $e_t = \theta_t - \theta_*$ 。梯度下降给出 $e_{t+1} = (I - \eta H)e_t$ 。在 H 的第 j 个特征方向上，误差乘以 $1 - \eta \lambda_j$ ，所以所有方向稳定要求 $0 < \eta < 2/\lambda_{\max}$ 。当 $\kappa = \lambda_{\max}/\lambda_{\min}$ 很大时，为陡峭方向选的小步长会使平缓方向收敛很慢。这就是标准化与预条件可能加速训练的几何原因。

5.2 尺度、信号传播与正则化

学习率与尺度。 学习率过大导致损失震荡或发散，过小则训练缓慢。预热（warm-up）可在训练初期逐步增大学习率，余弦退火则使学习率平滑下降。不同层的梯度尺度可能相差很大，归一化、残差连接和合理初始化帮助维持稳定的信号传播。

初始化与信号传播。 若网络层的权重方差过大，前向激活和反向梯度会指数放大；若过小，则会逐层衰减。Xavier初始化试图保持线性层输入输出方差相近，He初始化适用于 ReLU 激活。ReLU为 $\max(0, a)$ ，计算简单且正区间梯度稳定，但可能产生永久不激活单元。

正则化技术。 Dropout在训练时随机屏蔽部分激活，相当于在许多子网络上进行参数共享。Batch Normalization对小批量激活进行标准化，Layer Normalization则在单个样本的特征维度上归一化，后者更适合序列模型。早停把验证集性能作为停止信号，实质上限制了有效训练时间。

Dropout的期望保持与噪声代价。 训练时采用保留概率 $q \in (0, 1]$ ，令独立屏蔽变量 $m_j \sim \text{Bernoulli}(q)$ ，倒置Dropout输出 $\tilde{h}_j = m_j h_j / q$ 。条件于激活 h_j ，

$$\mathbb{E}[\tilde{h}_j | h_j] = h_j, \quad \text{Var}(\tilde{h}_j | h_j) = h_j^2(1 - q)/q. \quad (5.15)$$

因此推理时可以直接使用 h_j 而无需再缩放，但非线性网络一般不满足 $\mathbb{E}[f(\tilde{h})] = f(\mathbb{E}\tilde{h})$ ，不能将推理网络称为所有子网络输出的精确平均。保留概率过小会显著增加噪声，是否改善泛化仍须验证。

归一化到底沿哪个维度进行。 以单个通道的一批激活 $a_1, \dots, a_B$ 为例，Batch Normalization计算

$$\mu_B = B^{-1} \sum_i a_i, \quad v_B = B^{-1} \sum_i (a_i - \mu_B)^2, \quad z_i = \gamma \frac{a_i - \mu_B}{\sqrt{v_B + \epsilon}} + \beta. \quad (5.16)$$

标准化部分的批均值为零，批方差为 $v_B/(v_B + \epsilon)$ ，并非严格等于一； γ, β 恢复可学习的尺度和平移。训练输出依赖同批其他样本，推理通常改用训练阶段累计统计量，因而必须切换模式并防止测试数据更新这些统计量。Layer Normalization对一个样本的指定特征轴求均值与方差，不依赖批内其他样本；但选择哪些轴仍取决于张量结构。归一化不是保证泛化的定理，也不能替代输入单位审计。

5.3 训练诊断与实验解释

训练故障诊断。 训练损失不下降时，优先检查标签、损失实现、输入范围、学习率和梯度是否为零。训练损失下降但验证损失上升，通常意味着过拟合或训练测试分布不一致。训练与验证都很差，可能是欠拟合、标签噪声、特征不充分或优化尚未稳定。梯度范数、激活均值和预测熵是有用的中间诊断量。

Algorithm 1 小批量梯度训练的基本流程

Require: 训练集 $\mathcal{D}$ ，初始参数 θ ，学习率 η

- 1: **for** $t = 1, \dots, T$ **do**
 - 2: 从 $\mathcal{D}$ 抽取小批量 B_t
 - 3: 计算 $J_t = |B_t|^{-1} \sum_{i \in B_t} \ell_i(\theta)$
 - 4: 通过反向传播计算 $g_t = \nabla_{\theta} J_t$
 - 5: 更新 $\theta \leftarrow \theta - \eta g_t$
 - 6: 在验证集记录损失和任务指标
 - 7: **end for**
 - 8: **return** 验证性能最好的参数
-

算法框。

损失景观与可辨识度。 参数空间中的不同点可能实现同一个函数。例如隐藏单元交换顺序不会改变网络输出，因而神经网络损失景观存在大量等价参数化。优化器并不是在寻找唯一“真实参数”，而是在这些等价表示中找到一个训练和泛化都可接受的解。观察训练损失下降时，还应检查参数范数、梯度范数和验证性能是否同步改善。

批量大小与梯度噪声。 固定当前参数，设均匀抽取的单样本梯度为 g_i ，总体均值为 $\bar{g}$ ，协方差为 Σ 。独立有放回抽取 B 个梯度时，

$$\text{Cov} \left(B^{-1} \sum_{b=1}^B g_{i_b} \right) = B^{-2} \sum_{b=1}^B \text{Cov}(g_{i_b}) = \Sigma/B. \quad (5.17)$$

若从 $n > 1$ 个固定样本无放回抽取，且 $\Sigma = n^{-1} \sum_i (g_i - \bar{g})(g_i - \bar{g})^T$ ，则结果为 $(n - B)\Sigma/[B(n - 1)]$ ， $B = n$ 时方差为零。这些推导都依赖当前参数下的抽样规则，相关

窗口或有偏抽样需要重新计算。增大批量会降低估计噪声并提高并行效率，却可能减少单位样本带来的更新次数。批量大小改变时，学习率、正则化强度和训练步数也应重新校准；不能只替换 batch size 再比较结果。

动量、Adam 与权重衰减。 动量保留历史方向，能减弱狭长谷底中的来回振荡。Adam 对不同坐标使用自适应尺度，适合稀疏梯度和初期训练，但其自适应归一化不等同于解耦权重衰减。实际实现中应区分把 L_2 项加到梯度里的正则化和直接衰减参数的 AdamW 式更新，因为二者在自适应优化器下并不完全相同。

对普通 Stochastic Gradient Descent (SGD)，把 $\lambda\|\theta\|^2/2$ 加入目标产生更新 $\theta^+ = (1 - \eta\lambda)\theta - \eta g$ ，恰好等于直接衰减。若优化器当前的坐标预条件矩阵为对角阵 D_t ，把正则项加入梯度则得到 $\theta^+ = \theta - \eta D_t g - \eta \lambda D_t \theta$ ；解耦衰减则为 $\theta^+ = (1 - \eta\lambda)\theta - \eta D_t g$ 。前者的收缩强度随坐标尺度变化，后者不随 D_t 变化；在 Adam 中正则项还会进入历史矩估计，差异更进一步。应同时记录衰减公式及哪些参数被排除，如偏置和归一化参数。

反向传播的内存占用。 反向传播需要用到前向计算中的输入、激活和部分中间结果，训练时通常要把它们保存在显存里。激活检查点只保存其中一部分，其余在反向传播时重新计算，代价是多花计算时间。混合精度利用低精度运算提高吞吐，常配合高精度参数副本；是否需要损失缩放 (loss scaling)，还取决于所用数值格式。部署预测通常只做前向计算，因此训练时占用的显存不能直接当作推理需求。

初始化的方差推导。 令预激活 $a = \sum_{j=1}^{n_{in}} w_j x_j$ ，偏置初始为零。假设权重彼此独立、均值为零、方差为 σ_w^2 ，并独立于输入；输入各坐标具有相同二阶矩 $q_x = \mathbb{E}[x_j^2]$ 。交叉项因 $\mathbb{E}[w_j w_k] = 0$ 消失，故

$$\mathbb{E}[a] = 0, \quad \text{Var}(a) = \mathbb{E}[a^2] = \sum_j \mathbb{E}[w_j^2] \mathbb{E}[x_j^2] = n_{in} \sigma_w^2 q_x. \quad (5.18)$$

只有输入均值为零时 q_x 才等于 $\text{Var}(x_j)$ 。若 a 关于零对称且 $h = \max(0, a)$ ，则对称性给出 $\mathbb{E}[h^2] = \frac{1}{2} \mathbb{E}[a^2]$ 。为逐层保持激活二阶矩，要求 $n_{in} \sigma_w^2 / 2 = 1$ ，于是得到 He 方差 $\sigma_w^2 = 2/n_{in}$ 。这里保持的是二阶矩，不是 ReLU 输出的方差，因为 $\mathbb{E}[h]$ 通常大于零。

对近似线性的激活，前向保持尺度要求 $n_{in} \sigma_w^2 \approx 1$ ；反向传播在类似独立近似下要求 $n_{out} \sigma_w^2 \approx 1$ 。当输入输出宽度不同，不能同时精确满足，Xavier 取折中值 $\sigma_w^2 = 2/(n_{in} + n_{out})$ 。训练后权重与激活会相关，因此这是初始化阶段的尺度分析，不是整个训练期的保证。

多层网络的反向梯度含有 Jacobian 乘积 $J_1^T \cdots J_L^T$ ，其范数上界由 $\prod_l \|J_l\|_2$ 控制，解释了逐层放大或衰减的风险。残差映射 $h_{l+1} = h_l + F_l(h_l)$ 的 Jacobian 为 $I + DF_l$ ，提供直接传播通路，但并不保证所有奇异值都接近一。初始化、残差和归一化需要共同检验，不能各自被当作梯度稳定性的充分条件。

训练曲线的诊断矩阵。 若训练和验证损失都高，先检查标签、输入尺度和模型是否欠拟合；若训练损失低而验证损失高，检查正则化、数据切分和分布偏移；若损失下降但任务指标不变，检查指标阈值、标签定义和类别不平衡；若梯度为 NaN，检查学习率、混合精度和数值范围。每种曲线形态对应不同假设，不能用统一的“再训练久一点”处理。

5.4 可复现训练设置

一次训练应固定数据版本、切分文件、模型配置、随机种子、优化器版本和停止规则。保存最佳验证检查点时要记录选择指标和选择时刻，否则重新加载的模型可能不是报告结果对应的模型。多次运行应报告均值和波动，尤其是小数据和元学习任务。

5.5 本章小结

优化是把目标函数转化为参数更新的过程，训练工程则负责让这个过程数值稳定、可诊断、可复现。学习率、批量、初始化、归一化和精度共同决定优化轨迹；它们不能被当作互相独立的旋钮。

从推导看，反向传播回答的是梯度怎样计算，下降引理回答的是在光滑假设下步长何时有效，随机梯度分析回答的是噪声为何留下波动，而初始化分析回答的是多层信号为何会改变尺度。这些结论各有条件：求到驻点不等于全局最优，优化器运行稳定也不等于学到了可迁移的规律。

训练损失已经稳定下降，换一台设备后却可能预测不准。下一章讨论这种泛化问题，分别检查模型复杂度、正则化和数据分布变化。本章让参数更新尽量正确有效；下一章要检验更新得到的模型在未见数据上是否仍然有用。

第六章 泛化、偏差与不确定性

本章摘要。本章回答训练集上的好结果为什么可能在真实设备上失效。先区分经验风险与真实风险，再分析偏差方差、正则化和分布偏移，最后讨论校准与不确定性。核心结论是：泛化不是单分数，而是关于数据范围、错误结构和部署条件的可检验陈述。

上一章的优化方法回答了怎样让训练目标下降，却没有回答下降之后能否相信模型。本章把视角从一次训练转到可能重复采集的数据以及尚未出现的设备：同一个学习算法在不同样本上会得到不同函数，同一个函数在不同工况下也会承担不同风险。理解这两种变化，是区分拟合成功与部署成功的起点。

本章先问模型将用在哪些设备和工况，再分析错误从哪里来，最后讨论什么时候应该告警。偏差-方差分解可以帮助判断：模型是否太简单，训练数据是否太少，或者新设备已经超出了原来的数据范围？它并不意味着所有模型都有同样的误差曲线，正则化也要选择合适强度。读完后，说一个模型“泛化好”，应能具体说明在哪些设备上测过、漏报和误报各有多少，以及结论还需要哪些条件。

6.1 经验风险与真实风险




图 6.1: 经验风险只描述训练分布上的拟合；泛化分析还要面对部署分布、噪声和模型选择过程。

一致收敛与算法稳定性提供了理解泛化的不同途径[108, 8]：前者控制假设空间上的经验误差偏离，后者研究替换训练样本对学习结果的影响。它们给出条件化保证，不意味着任何训练误差小的模型都可靠。训练集上的经验风险为 $\hat{R}(f)$ ，数据分布 $P(X, Y)$ 下的真实风险为

$$R(f) = \mathbb{E}_{(X, Y) \sim P} [\ell(f(X), Y)]. \quad (6.1)$$

泛化间隙 $R(f) - \hat{R}(f)$ 刻画模型在未见样本上的退化。它受样本量、模型容量、噪声、训练过程以及训练测试分布差异共同影响。

偏差-方差分解。 对平方损失，在固定输入 x 处，设独立测试观测为 $Y = f^*(x) + \varepsilon$ ，其中 $f^*(x) = \mathbb{E}[Y | X = x]$ ，噪声在该输入处均值为零、方差有限，且与训练集 D 独立。若训练集随机性导致预测为 $\hat{f}_D(x)$ ，则

$$\mathbb{E}_{D, \varepsilon}[(\hat{f}_D(x) - Y)^2] = \underbrace{(\mathbb{E}_D \hat{f}_D(x) - f^*(x))^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_D[(\hat{f}_D(x) - \mathbb{E}_D \hat{f}_D(x))^2]}_{\text{方差}} + \underbrace{\text{Var}(\varepsilon)}_{\text{不可约噪声}}. \quad (6.2)$$

增大模型容量通常降低近似偏差，却可能增加估计方差。正则化、更多数据和数据增强分别从限制解空间、降低估计不确定性和扩大有效样本的角度改善泛化。

分解为何成立。 记 $m(x) = \mathbb{E}_D \hat{f}_D(x)$ 、 $u = \hat{f}_D(x) - m(x)$ 、 $b = m(x) - f^*(x)$ 。预测误差为 $u + b - \varepsilon$ ，故

$$\mathbb{E}[(u + b - \varepsilon)^2] = \mathbb{E}[u^2] + b^2 + \mathbb{E}[\varepsilon^2] + 2b\mathbb{E}[u] - 2b\mathbb{E}[\varepsilon] - 2\mathbb{E}[u\varepsilon] \quad (6.3)$$

$$= \text{Var}_D(\hat{f}_D(x)) + b^2 + \text{Var}(\varepsilon). \quad (6.4)$$

最后一步分别使用中心化、零均值与测试噪声独立于训练集的假设。再对测试输入 X 积分，就得到总体平方风险的分解；异方差时噪声项应写成 $\mathbb{E}_X[\text{Var}(Y | X)]$ ，而不是一个不随 x 变化的常数。此处的“偏差”是重复采样意义下的系统误差，不等同于某次测试集的平均残差。分类交叉熵不能直接套用这个平方展开；训练、测试有关联时，交叉项也未必为零。

区分抽样误差与环境变化。 令 P 为训练总体、 Q 为部署总体， $\hat{R}_D$ 为训练样本风险，则有精确恒等式

$$R_Q(\hat{f}_D) - \hat{R}_D(\hat{f}_D) = [R_P(\hat{f}_D) - \hat{R}_D(\hat{f}_D)] + [R_Q(\hat{f}_D) - R_P(\hat{f}_D)]. \quad (6.5)$$

式(6.5)的第一项是同分布的样本泛化间隙，第二项是同一函数受到分布变化的影响，两项都可能为负。经典独立同分布泛化界主要控制第一项；再多训练样本也不能自动消除第二项。因此图6.1中的部署退化是广义风险差，报告理论保证时应单独说明是否假设 $P = Q$ 。

6.2 泛化误差、正则化与分布偏移

分布偏移。 当训练分布 $P_{\text{train}}(X, Y)$ 与部署分布 $P_{\text{test}}(X, Y)$ 不同，经典同分布泛化分析不再充分。协变量偏移主要改变 $P(X)$ ，标签偏移主要改变 $P(Y)$ ，概念偏移则改变条件关系 $P(Y | X)$ 。工业设备老化、工况变化和传感器替换都可能造成这些偏移。

正则化的概率解释。 考虑观测模型 $y_i | x_i, \boldsymbol{\theta} \sim \mathcal{N}(f_{\boldsymbol{\theta}}(x_i), \sigma^2)$ 和高斯先验 $p(\boldsymbol{\theta}) = \mathcal{N}(0, \tau^2 I)$ 。忽略与 $\boldsymbol{\theta}$ 无关的常数后，最大后验估计满足

$$\hat{\boldsymbol{\theta}}_{\text{MAP}} = \arg \max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} | \mathcal{D}) \quad (6.6)$$

$$= \arg \min_{\boldsymbol{\theta}} \left\{ \frac{1}{2\sigma^2} \sum_i (y_i - f_{\boldsymbol{\theta}}(x_i))^2 + \frac{1}{2\tau^2} \|\boldsymbol{\theta}\|_2^2 \right\}. \quad (6.7)$$

因此， L_2 正则并非纯粹的数值技巧，它也可以解释为对大参数的先验惩罚。贝叶斯方法进一步保留整个后验分布，而不只保留一个最优解。

正则系数的尺度与收缩方向。 上述推导假定给定参数后各观测独立、噪声方差已知，且 $\boldsymbol{\theta} \in \mathbb{R}^d$ 。似然的乘积取负对数成为残差平方和，先验取负对数成为参数平方范数。若目标采用 $\frac{1}{2n} \sum_i (y_i - f_{\boldsymbol{\theta}}(x_i))^2 + \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2$ ，则乘以 σ^2/n 后可知 $\lambda = \sigma^2/(n\tau^2)$ ；若使用未平均的平方和，系数就不同。

在线性模型 $y = X\boldsymbol{\theta} + \varepsilon$ 中， $X \in \mathbb{R}^{n \times d}$ ，一阶条件给出

$$(X^T X + n\lambda I_d) \hat{\boldsymbol{\theta}} = X^T y. \quad (6.8)$$

写薄奇异值分解 $X = U \text{diag}(s_j) V^T$ ，可得

$$\hat{\boldsymbol{\theta}} = V \text{diag} \left(\frac{s_j}{s_j^2 + n\lambda} \right) U^T y. \quad (6.9)$$

最小二乘中不稳定的 $1/s_j$ 被有界的收缩系数替代，小奇异值方向收缩更多。这会增加偏差，却降低噪声放大。结论依赖特征尺度；标准化必须只用训练数据，截距通常单独处理、不作同样惩罚。参数空间的高斯先验也不保证函数空间中具有相同强度的平滑性。

为什么训练误差不是泛化证据。 经验风险只在已观测样本上计算。一个高容量模型可以在随机标签上达到几乎零训练误差，这说明优化能力和泛化能力是两个不同问题。泛化需要额外假设：训练样本如何产生、测试分布是否相近、模型是否利用了稳定结构，以及实验是否避免了信息泄漏。深度模型出现低训练误差并不矛盾，但必须通过严格划分和外部测试判断其学到的是什么。

泛化误差的来源拆解。 排查测试误差时，可以分别检查近似误差、估计误差、优化误差、标签噪声和分布偏移。这是诊断的分类，不是对任意损失都成立的五项相加公式。模型太简单，可能连训练数据中的规律也表达不了；数据太少，换一批样本就可能学出不同结果；优化不到位，则可能尚未找到当前模型能达到的解。错标工单和新设备工况变化还会带来另外的困难，单纯增加网络深度不能一并解决。

数据增强与有效样本量。 数据增强通过构造保持标签的变换扩大有效训练分布。若变换 T 满足任务不变性，理想关系是 $f(Tx) = f(x)$ ；但工业视觉中的旋转、裁剪和颜色改变未必满足这一关系。增强越强不一定越好：它可能降低训练集与部署分布的差异，也可能删除真正的故障信号。增强策略应按物理成像和传感器机制设计，并在原始测试集上验证。

分布偏移的诊断路径。 先比较输入边缘分布，再比较标签比例，最后检查 $P(Y | X)$ 是否变化。若只有输入统计变化，可能是协变量偏移；若类别先验变化，可能是标签偏移；若相同输入含义改变，则是概念偏移。实际系统往往三者同时存在，因此需要按设备、时间、工况和数据质量分层评估，而不是只计算一个总体距离。

校准与决策风险。 预测概率的校准要求，在所有预测为 p 的样本中，事件发生频率接近 p 。可靠性图、期望校准误差和 Brier score 可用于检查这一点。校准良好的概率仍可能来自错误模型，但未校准的概率无法直接用于成本敏感决策。若漏报成本是误报的十倍，阈值应由期望成本决定，而不是固定取0.5。

协变量偏移下的风险重加权。 设 P 、 Q 分别有训练与部署密度，且 $Q(y | x) = P(y | x)$ ，并要求 Q_X 相对于 P_X 绝对连续：部署中可能出现的输入不能完全没有训练支持。定义 $w(x) = q_X(x)/p_X(x)$ ，则

$$R_Q(f) = \int \ell(f(x), y) q_X(x) p(y | x) dx dy \quad (6.10)$$

$$= \mathbb{E}_P[w(X)\ell(f(X), Y)] \approx \frac{1}{n} \sum_{i=1}^n w(x_i) \ell(f(x_i), y_i). \quad (6.11)$$

对固定 f 和已知权重，最后的平均是无偏估计；但其方差为 $\text{Var}_P(w\ell)/n$ ，极大权重会使估计不稳定。截断权重降低方差却引入偏差。若条件关系已变或支持不重叠，这个恒等式不能作为修复依据；仅检测到输入漂移也不能证明条件关系保持不变。

从概率误差到动作阈值。 设 $Y \in \{0, 1\}$ ， $p(x) = P(Y = 1 | x)$ ；告警但无故障的成本为 $C_{\text{FP}} > 0$ ，不告警但故障的成本为 $C_{\text{FN}} > 0$ ，正确动作成本为零。两个动作的条件风险为

$$r(1 | x) = C_{\text{FP}}(1 - p(x)), \quad r(0 | x) = C_{\text{FN}}p(x). \quad (6.12)$$

比较二者得到告警规则 $p(x) > C_{\text{FP}}/(C_{\text{FP}} + C_{\text{FN}})$ 。这不是普适的维护阈值：复检若每次都收费、动作会改变故障概率，或存在资源约束，就要重写成本矩阵。

概率质量也可由平方评分解释。对报告概率 $q \in [0, 1]$ ，

$$\mathbb{E}[(q - Y)^2 | X = x] = (q - p(x))^2 + p(x)(1 - p(x)). \quad (6.13)$$

由式(6.13)可知, Brier 分数在真实条件概率处最小。常数预测总体故障率也可能总体校准, 却无法区分高低风险设备, 故校准不能替代分辨能力。按分箱检查频率只是有限样本近似, 还受箱宽与少数类数量影响。

泛化边界的诚实表述。 实验只验证了特定数据来源、时间范围、设备集合和标签定义规则下的结论。论文或报告中应明确哪些条件被测试, 哪些条件只是推测。对于分布外样本, 模型可以拒识、输出不确定性或请求人工复核, 但不能把“没有训练数据”自动等同于“模型一定知道自己不知道”。

6.3 本章小结: 从误差解释走向证据约束

本章把“效果不好”拆成了可讨论的不同问题: 有限样本使估计变化, 结构限制产生偏差, 噪声设置可达到的误差下限, 环境变化则可能破坏全部同分布论证。正则化改变的是估计过程, 重加权依赖的是可迁移假设, 校准服务的是概率决策; 三者不能相互替代。实际改进应先定位误差来源, 再选择增加数据、修改模型或调整部署范围。

如果试了很多模型, 只挑误差最低的一个, 它可能只是碰巧适合这批数据。下一章用有限假设空间的统一界解释这种选择偏差, 再介绍交叉验证和设备级区间估计, 帮助判断分数差异是否经得住重新采样。

第七章 统计学习理论与模型选择

本章摘要。本章为模型比较提供统计学习视角。先说明假设空间和容量如何影响泛化界，再讨论结构风险、交叉验证、校准、不平衡数据和置信区间。最后把理论约束转成数据泄漏检查，使模型选择从“哪个分数最高”转向“哪个结论在何种不确定性下成立”。

上一章说明训练误差、抽样误差和分布偏移不是一回事，但现实实验还多了一层选择：研究者会试很多窗口、特征和超参数，再报告其中最好的结果。这时需要控制的不再是某个预先固定函数的误差，而是整个选择过程可能带来的乐观偏差。本章以这个区别为出发点，把统计学习的容量约束与实际验证规则连接起来。

试过许多窗口长度以后再挑最高分，相当于又用数据作了一次选择。若仍用同一批数据报告最终成绩，就可能把偶然的好运当成稳定的提升。理论中的复杂度代价说明这种问题为什么会发生，交叉验证帮助安排有限样本的用途，校准和成本分析则帮助把分数变成告警规则。每一种方法都有适用条件，不能替代对新设备的独立检验。

7.1 假设空间与泛化约束




图 7.1：模型复杂度同时影响拟合误差与估计方差；模型选择的目标是控制真实风险，而不是单独追求训练误差。

图7.1对照训练误差下降与复杂度代价上升的趋势；虚线的折中提醒读者，选模应控制未见样本风险，而非仅追求更低训练误差。

假设空间。 学习算法从假设空间 $\mathcal{H}$ 中选择函数。有限训练集只能约束 $\mathcal{H}$ 在观测点上的行为，因此假设空间越丰富，插值训练数据越容易，但泛化分析也越困难。模型容

量不能简单等同于参数数量，还与参数化方式、数据几何和优化偏置有关。

统一收敛的直观证明。 对固定函数 f ，若损失 $\ell(f(X), Y) \in [0, 1]$ ，Hoeffding不等式给出

$$\Pr(|R(f) - \hat{R}(f)| > \epsilon) \leq 2 \exp(-2n\epsilon^2). \quad (7.1)$$

若 $\mathcal{H}$ 是有限集合，对所有 $f \in \mathcal{H}$ 使用联合界可得

$$\Pr\left(\sup_{f \in \mathcal{H}} |R(f) - \hat{R}(f)| > \epsilon\right) \leq 2|\mathcal{H}| \exp(-2n\epsilon^2). \quad (7.2)$$

这说明样本量需要随假设空间复杂度增加。对无限空间，可用 Vapnik–Chervonenkis (VC) 维、Rademacher复杂度或覆盖数替代 $|\mathcal{H}|$ 。

从概率尾界到样本量。 以上 n 个样本必须独立同分布， $\mathcal{H}$ 应预先固定且非空；平方损失无界时不能不加条件地使用式(7.2)。为看到指数项的来源，令 $Z_i = \ell(f(X_i), Y_i) \in [0, 1]$ 。有界变量的指数矩满足 $\mathbb{E} \exp(t(\mathbb{E} Z_i - Z_i)) \leq \exp(t^2/8)$ ；独立性使指数矩相乘。Markov不等式给出

$$\Pr(R - \hat{R} > \epsilon) \leq \exp(-tn\epsilon + nt^2/8). \quad (7.3)$$

取 $t = 4\epsilon$ 得到单侧 $\exp(-2n\epsilon^2)$ ，对另一侧重复并相加即得双侧界。联合界不要求各函数的误差独立，因此适用于在同一数据上比较的多个模型。

令式(7.2)右端为 $\delta \in (0, 1)$ ，解得以至少 $1 - \delta$ 的概率，对所有 $f \in \mathcal{H}$ 同时成立

$$|R(f) - \hat{R}(f)| \leq b_n, \quad b_n = \sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}. \quad (7.4)$$

若希望误差不超过 ϵ ，充分条件是 $n \geq \log(2|\mathcal{H}|/\delta)/(2\epsilon^2)$ 。这是一条保守的充分保证，不是对具体任务所需数据量的精确预测。

设 $\hat{f}$ 最小化经验风险， $f_{\mathcal{H}}^*$ 最小化类内真实风险，则在式(7.4)对所有函数同时成立的事件上

$$R(\hat{f}) \leq \hat{R}(\hat{f}) + b_n \leq \hat{R}(f_{\mathcal{H}}^*) + b_n \leq R(f_{\mathcal{H}}^*) + 2b_n. \quad (7.5)$$

第一步和第三步都需要同时界；只给预先固定 f 的界无法直接代入数据依赖的 $\hat{f}$ 。若优化仅达到 η 精度，最后再加 η 。相对所有可测函数中最优风险的差还包含类外近似误差，故增大 n 不能弥补错误的函数类。

结构风险最小化。 经验风险最小化只看训练误差，结构风险最小化在一系列嵌套假设空间中选择复杂度。实际的正则化、树深度限制、网络宽度和数据增强都可视为控制有效复杂度的方法。理论上更强的模型仍可能泛化良好，因为优化算法偏爱某些简单或平滑的解。

复杂度惩罚如何随候选类分配。 对预先指定的有限类 $\mathcal{H}_m$ 选择正数 π_m ，满足 $\sum_m \pi_m = 1$ ，将失败概率分配为 $\delta_m = \delta \pi_m$ 。再次使用联合界得到所有类同时有效的

$$b_m = \sqrt{\frac{\log(2|\mathcal{H}_m|/(\delta\pi_m))}{2n}}. \quad (7.6)$$

若在所有 $m, f \in \mathcal{H}_m$ 中最小化 $\hat{R}(f) + b_m$ ，则所选模型 $\tilde{f}$ 满足

$$R(\tilde{f}) \leq \inf_m \inf_{f \in \mathcal{H}_m} \{R(f) + 2b_m\}. \quad (7.7)$$

推导是先用 $R(\tilde{f}) \leq \hat{R}(\tilde{f}) + b_m$ ，再用最小化性质与每个候选比较，最后把候选的经验风险换成真实风险。复杂类要靠真实的拟合改善抵消较大的惩罚，而不是仅靠训练误差获胜。

无限类需要什么替代量。 连续参数类通常有无限多个函数，不能把参数个数代入 $\log |\mathcal{H}|$ 。二分类的增长函数 $\Pi_{\mathcal{H}}(n)$ 计数在 n 个点上最多能实现多少种二元标记；若VC维为 d_{VC} ，则 $n \geq d_{VC} \geq 1$ 时有 $\Pi_{\mathcal{H}}(n) \leq (en/d_{VC})^{d_{VC}}$ 。它衡量可区分的标记，而非参数存储量。

另一个视角是随机符号拟合能力。令损失类 $\mathcal{G} = \{(x, y) \mapsto \ell(f(x), y) : f \in \mathcal{H}\}$ ，独立符号 ϵ_i 等概率为 ± 1 ，定义

$$\mathfrak{R}_n(\mathcal{G}) = \mathbb{E}_{D, \epsilon} \sup_{g \in \mathcal{G}} \frac{1}{n} \sum_i \epsilon_i g(X_i, Y_i). \quad (7.8)$$

引入独立同分布的复制样本 D' 后，用 $R(g) = \mathbb{E}_{D'} \hat{R}_{D'}(g)$ 及上确界的凸性，得到

$$\mathbb{E}_D \sup_g (R(g) - \hat{R}_D(g)) \leq \mathbb{E}_{D, D'} \sup_g \frac{1}{n} \sum_i (g(Z'_i) - g(Z_i)) \quad (7.9)$$

$$\leq 2\mathfrak{R}_n(\mathcal{G}). \quad (7.10)$$

第二步利用样本对可交换性插入随机符号，再将两个上确界分开。这解释了“能拟合纯随机波动”为什么意味着更大的乐观风险。若损失在 $[0, 1]$ 内，替换一个样本使上确界至多改变 $1/n$ ，有界差分集中进一步给出以至少 $1 - \delta$ 的概率， $\sup_g (R - \hat{R}) \leq 2\mathfrak{R}_n(\mathcal{G}) + \sqrt{\log(1/\delta)/(2n)}$ 。这些结论仍依赖独立抽样和适当可测性，并非对重叠窗口的自动保证。

7.2 模型选择、校准与不平衡

模型选择偏差要求把调参与最终评价分离[12]。深度网络校准研究则表明，分类正确率与概率可信度需要分别检验，温度缩放是一种后处理基线[32]。

模型选择与交叉验证。 若数据近似独立同分布， K 折交叉验证将训练集分为 K 份，轮流使用一份验证、其余训练。时间序列必须使用滚动窗口或前向验证，避免未来信息泄漏。超参数搜索也应嵌套在训练数据内部；否则测试集会逐渐变成隐形训练集。

交叉验证估计的是哪个算法。设折索引为 $I_1, \dots, I_K$ ，超参数为 h ， $\hat{f}_h^{(-k)}$ 表示只用第 k 折以外的数据完成预处理和训练后的模型。加权交叉验证风险为

$$\hat{R}_{CV}(h) = \frac{1}{n} \sum_{k=1}^K \sum_{i \in I_k} \ell(\hat{f}_h^{(-k)}(x_i), y_i). \quad (7.11)$$

每个损失的标签没有参与产生该预测，但不同折的训练集重叠，因此这些损失不是独立试验。选 $\hat{h} = \arg \min_h \hat{R}_{CV}(h)$ 后，最小分数有选择偏差：对带噪估计 $\hat{r}_h$ ，总有 $\mathbb{E} \min_h \hat{r}_h \leq \min_h \mathbb{E} \hat{r}_h$ 。搜索越广，越容易挑中有利噪声。

嵌套验证在外层训练集内部完成全部内层选择，再对外层留出样本预测，评估的是“选择加训练”这一完整算法。最后可用所有开发数据重新选择并拟合，但外层分数并非这个最终参数向量的无偏测量。设备切分估计跨设备能力，前向切分估计未来能力；两者对应不同目标，不能由普通随机 K 折替代。

校准与决策。 分类器输出的分数不一定是概率。校准要求在所有预测为 p 的样本中，正例频率接近 p 。可靠性图和 Expected Calibration Error 可用于检查校准。若预测要驱动检修、放行或停机决策，还应定义效用函数 $U(a, y)$ ，最终选择

$$a^*(x) = \arg \max_a \mathbb{E}_{p(y|x, \mathcal{D})}[U(a, y)]. \quad (7.12)$$

这说明“最准确的分类器”不一定产生“最优的行动”。

不平衡与置信区间。 少数类任务应报告每类召回率、宏平均 F_1 和 Area Under the Precision–Recall Curve (PR-AUC)。重采样、类别权重和阈值调整针对的是不同环节，不能混为一谈。性能估计还需要不确定性，可使用自助法在测试样本上重采样得到指标分布。跨设备评估时，设备级重采样比样本级重采样更能反映真实部署波动。

类别权重为何改变概率含义。 令真实条件正例概率为 p ，预测为 q ，正负类权重为 $a, b > 0$ 。固定输入处的加权交叉熵为 $L(q) = -ap \log q - b(1-p) \log(1-q)$ 。求导并令其为零，得到

$$-\frac{ap}{q} + \frac{b(1-p)}{1-q} = 0, \quad q^* = \frac{ap}{ap + b(1-p)}. \quad (7.13)$$

所以加权训练的理想输出一般不再是原始分布的 p 。若模型恰好达到该最优且权重已知，可反解 $p = bq/[a(1-q) + bq]$ ；有限样本和错设模型下还需独立校准。重采样同样可能改变类别先验；它不应与只在预测后调整阈值混为一谈。

精确率也直接受基率影响。若正例比例为 π 、真正率为 u 、假正率为 v ，Bayes公式给出

$$\text{Precision} = \frac{\pi u}{\pi u + (1-\pi)v}. \quad (7.14)$$

即使排序和条件错误率不变，部署正例更稀少时精确率也会下降。跨工况比较精确率–召回率（Precision–Recall, PR）曲线应同时报告基率。

区间与配对比较的抽样单位。 若独立测试单位上的损失 L_i 具有有限方差，均值 $\bar{L}$ 的标准误估计为 $s_L/\sqrt{n}$ ，大样本近似区间为 $\bar{L} \pm 1.96s_L/\sqrt{n}$ 。这只针对固定模型和既定测试分布，不包括训练随机性；稀有事件或小样本时正态近似可能不良。

比较模型A、B时应先在同一测试单位上计算 $d_i = L_{A,i} - L_{B,i}$ ，再估计 $\bar{d}$ 的区间，因为

$$\text{Var}(L_A - L_B) = \text{Var}(L_A) + \text{Var}(L_B) - 2\text{Cov}(L_A, L_B). \quad (7.15)$$

忽略配对会丢失共同设备难度的信息。对 G 台近似独立设备，自助法每次有放回抽取 G 个设备编号，保留所抽设备的全部窗口并重算指标；重复 B 次后取经验分位数作为近似区间。每台等权与每窗口等权是不同的目标，必须在每次重采样中维持原定义。设备数很少、设备之间相关或许多重采样没有正例时，区间本身也不可靠；增加重采样次数不会增加独立设备信息。

7.3 从统计结论到实验设置

数据泄漏清单。 常见泄漏包括：用全数据计算标准化参数，把同一设备的相邻窗口分到训练和测试，利用故障发生后的变量预测故障发生前的状态，以及根据测试集反复选择模型。泄漏往往带来异常漂亮的结果，因此每个实验都应记录切分单位、时间边界、预处理拟合范围和标签生成时刻。

从固定函数到数据依赖的模型选择。 Hoeffding 界直接控制固定函数的经验风险偏差，但实际算法会根据数据选择函数。联合界的作用是同时控制整个假设空间，使“先看数据再选模型”仍有可分析的上界。代价是模型空间越复杂，需要更多样本或更强的结构约束。

容量不是参数数量的同义词。 参数数量相同，网络能表达的函数也未必相同。激活函数、连接方式和参数共享决定函数类，优化路径则影响训练最后选到其中哪些函数。例如卷积在不同位置使用同一组权重，注意力允许相距较远的输入直接交互。分析泛化时，因此还要看函数类、参数范数、分类间隔和算法稳定性，不能仅按参数个数给模型排队。

交叉验证的工程细节。 预处理、特征选择和超参数搜索都必须在每个训练折内部拟合。若先对全体数据做标准化或选择相关特征，再执行交叉验证，验证折的信息已经泄漏。时间序列使用前向验证时，验证窗口必须位于训练窗口之后，必要时在二者之间设置间隔以避免标签窗口重叠。

不平衡、阈值与区间估计。 ROC-AUC 衡量排序能力，PR-AUC 更关注少数正类下的精确率和召回率。阈值改变会改变混淆矩阵，却不改变排序本身。若最终动作依赖

阈值，应报告阈值扫描、成本曲线和置信区间。自助法重采样时，设备级任务应按设备重采样；否则同一设备的多个窗口会让区间过窄。

校准的后处理。 温度缩放在验证集上用一个标量调整 logits，通常保持分类排序但改善概率校准；Platt scaling 和 isotonic regression 适用于不同数据规模与单调性假设。校准模型不能使用测试集反复调参，且分布变化后需要重新检查。对安全告警而言，概率校准和拒识机制常比少数百分点的准确率更重要。

温度缩放的目标与边界。 对 C 类 logits $z_i \in \mathbb{R}^C$ ，在独立校准集上令 $T > 0$ ，定义 $q_{ic}(T) = \exp(z_{ic}/T) / \sum_j \exp(z_{ij}/T)$ ，最小化

$$L(T) = \sum_i \left[-z_{i,y_i}/T + \log \sum_c \exp(z_{ic}/T) \right]. \quad (7.16)$$

取逆温度 $\beta = 1/T$ ，则

$$L'(\beta) = \sum_i \left(\sum_c q_{ic} z_{ic} - z_{i,y_i} \right), \quad (7.17)$$

$$L''(\beta) = \sum_i \text{Var}_{c \sim q_i}(z_{ic}) \geq 0. \quad (7.18)$$

因此这是一个一维凸优化问题（约束 $\beta > 0$ ），可以直接检查边界解。正温度保持每个样本内部的类别次序和最大类别；多分类中不同样本的最大概率排序则未必保持，不能据此保证所有排序指标不变。它只能整体调整尖锐程度，无法修复所有类别和工况上的系统偏差。

二分类可靠性图把样本分入 B_m ，计算箱内预测均值 $\bar{q}_m$ 和事件比例 $\bar{y}_m$ ；常用误差为 $\sum_m (|B_m|/N) |\bar{q}_m - \bar{y}_m|$ 。这是依赖分箱的经验统计量，不是证明条件校准的定理。箱数太少会掩盖局部偏差，太多则产生高方差，应同时报告样本量与可靠性图。

7.4 从统计量到决策

模型输出只是决策系统的一个中间量。若动作集合为 $\mathcal{A}$ ，效用函数为 $U(a, y)$ ，最优动作是期望效用最大的动作。不同部门可能面对不同成本，因此同一个概率模型可以配合不同阈值，而不必为每种成本重新训练。这个分离有助于审计模型能力和业务策略各自的变化。

7.5 本章小结

统计学习提供的是关于数据、模型复杂度和未见样本风险的推理框架。它不能保证某个模型在所有工业分布上有效，却能迫使实验者明确假设空间、验证规则、泄漏风险、不确定性和决策成本。

统一界考虑看过数据以后再选模型的影响，嵌套验证把挑选模型和报告成绩分开，配对比较与设备级区间估计则显示结果会怎样波动。比较平均误差前，要先核对任务、抽样单位和尝试方案的预算是否一致；选择告警阈值时，还要看校准和成本。下一章回到原始记录：如果不知道记录何时可用、标签何时截止、样本来自哪台设备，再严谨的统计计算也无法回答原先的维护问题。

第八章 工业数据工程与实验设计

本章摘要。本章处理模型之前和模型之外的必要问题：数据从哪里来、时间如何对齐、缺失与异常如何解释、实验如何复现以及系统如何验收。本章结合数据生命周期讨论实验设计，是因为不可追溯的数据会使性能提升无法归因，也无法在部署后修复。

前两章要求独立评价、清楚的目标分布和不泄漏的模型选择，但这些条件不会由一条训练命令自动满足。它们首先是数据工程问题：一条温度记录在预测时刻是否已经到达，设备停机究竟是故障还是计划维护，同一运行过程是否被重复算成独立证据。本章把统计假设翻译成可以执行和追溯的数据规则。

表格里的一行数据，往往经过截取窗口、补齐缺失值和匹配工单才得到。每一步都可能改变任务：用停机后的读数补停机前的缺失，就让模型提前看到了未来；把计划维护当成故障，则改错了标签。因此要先确定预测时刻和目标，再决定怎样清洗。最后按当时记录到达的顺序回放，并通过不直接控制设备的影子运行，检查线上是否能得到同样的输入和结果。

8.1 从原始记录到可学习样本




图 8.1: 工业样本的时间边界至少包括事件、采集和可用时刻；预测输入不能回看未来才进入系统的信息。

图8.1将事件发生、采集和系统可用时刻分开，强调构造预测输入时应检查记录何时可查询，而不只是何时产生。

数据生命周期。 工业数据从传感器、控制器、日志系统、工单和实验室检测中产生。一个可学习的数据集必须明确采集时间、设备标识、工况、单位、采样频率、缺失含义和标签来源。数据字典应把“缺失”“零值”“未采集”和“传感器故障”区分开，否则模型会把数据质量问题当作物理规律。

时间对齐与窗口化。 不同传感器的时间戳可能存在时钟偏移、延迟和不同采样频率。对齐时需要选择参考时钟，记录插值方法，并保留原始时间间隔。长度为 L 、步长为 s 的滑动窗口为

$$X_t = [x_{t-L+1}, \dots, x_t], \quad y_t = \text{在未来区间定义的标签}. \quad (8.1)$$

标签必须明确预测时刻和观察截止时刻，避免把未来维修记录泄漏到当前样本。

用信息集合推导合法样本。 设第 j 条记录为 (v_j, e_j, a_j) ，其中 $v_j \in \mathbb{R}^d$ 、 e_j 为事件时刻、 a_j 为该版本首次可用时刻。预测时刻 t 的信息集合记作 $\mathcal{F}_t = \sigma\{(v_j, e_j, a_j) : a_j \leq t\}$ ；合法特征必须由 $\mathcal{F}_t$ 中的记录计算。若使用最近 W 小时的观测，输入为

$$x_t = \phi\{v_j : t - W < e_j \leq t, a_j \leq t\}. \quad (8.2)$$

两个条件缺一不可：事件发生得早，不代表当时已被系统接收。回填的维修结论和修正后的传感器值必须保留版本时间，否则历史回放会读到当时不可见的信息。

定义未来 H 小时内首次目标故障时刻为 T_f ，则 $y_t = \mathbb{I}\{t < T_f \leq t + H\}$ 。阴性标签必须等到 $t + H$ 且完成报告延迟后才能确认；若运行记录提前结束，应标为未确定而非零。在线输入的合法性由 t 判断，训练标签是否成熟则由训练截止时间 c 判断。这是两个不同的时间检查。

对等间隔序列 $x_r \in \mathbb{R}^d$ ，窗口矩阵可约定 $X_t \in \mathbb{R}^{L \times d}$ ，第 r 行为 $x_{t-L+r}^\top$ 。不规则时间序列不能仅用行数代表持续时间，需要同时保留 Δt 或按真实时间区间构造窗口。在线前向填补只使用过去最近值；线性插值若用到了 t 以后的点就违反 $\mathcal{F}_t$ 可测性。

划分间隔由哪些窗口决定。 若训练标签覆盖 $(t, t + H]$ ，而验证从 v 开始，为避免训练标签读取验证时期，至少要求训练样本 $t + H \leq v$ ；这不等于输入完全不重叠。若还要求两组原始输入窗口无交叠，则训练最后时刻与验证首时刻之间要留足 W 的间隔。业务上允许共享已知历史时，可以不要求后一条件，但应明确估计的是同设备未来能力，而非独立设备泛化。间隔长度由信息集合决定，不能机械地设置为某个固定百分比。

缺失值与异常值。 缺失机制可粗略分为完全随机缺失、条件随机缺失和非随机缺失。均值填补简单但会压低方差；前向填补适合连续状态但可能延续故障；模型填补可以利用多变量关系却会引入额外不确定性。建议同时加入缺失指示变量，并对不同缺失机制进行敏感性分析。

异常值不应一律删除。尖峰可能是真实冲击，也可能是通信错误。应区分物理约束异常、统计异常和任务异常，并将修正规则记录为可复现的数据版本。

填补究竟保留了什么。 令 $M = 1$ 表示变量 V 被观测到。完全随机缺失要求 M 与完整数据独立；条件随机缺失允许 M 依赖已观测变量，但给定它们后不再依赖缺失值本身；非随机缺失不满足后者。仅从已有表格一般不能检验最后两种机制的区别，因此需要采集知识或敏感性假设。

设 $M \sim \text{Bernoulli}(r)$ 与 V 独立， $\mathbb{E}V = \mu$ 、 $\text{Var}(V) = \sigma^2$ ，用真实均值填补得到 $\tilde{V} = MV + (1 - M)\mu$ 。则

$$\mathbb{E}\tilde{V} = \mu, \quad \text{Var}(\tilde{V}) = \mathbb{E}[M(V - \mu)^2] = r\sigma^2. \quad (8.3)$$

即使均值完全已知，填补也会把方差压缩，故把填补值当作真实测量会低估不确定性。若用其他已观测变量 Z ，平方损失下的最优点填补为 $g(Z) = \mathbb{E}[V | Z]$ ，因为

$$\mathbb{E}[(V - g(Z))^2 | Z] = \text{Var}(V | Z) + (\mathbb{E}[V | Z] - g(Z))^2. \quad (8.4)$$

点填补只能保留条件均值，不能恢复条件方差。加入缺失掩码和“距上次真实观测的时间”使模型能区分测量与代入，但仍不能识别未观测的非随机缺失机制。所有填补器及均值、尺度都只在训练折拟合，验证和部署仅应用这些参数。

特征工程与表示学习。 旋转机械常用时域统计量、频域能量和包络谱特征；过程数据常用滞后量、变化率、累计量和工况归一化值。特征工程把领域知识写入输入，深度表示学习则从原始信号寻找有用变换。两者可以并行比较，不应预先假定端到端网络一定优于物理启发特征。

从采样信号推导可比特征。 对等间隔实信号 $v_0, \dots, v_{L-1}$ ，采样间隔 Δ 、采样率 $f_s = 1/\Delta$ ，均值和均方根分别为 $\bar{v} = L^{-1} \sum_r v_r$ 、 $v_{\text{rms}} = \sqrt{L^{-1} \sum_r v_r^2}$ 。两者满足 $v_{\text{rms}}^2 = \bar{v}^2 + L^{-1} \sum_r (v_r - \bar{v})^2$ ，所以去均值前后的 Root Mean Square (RMS) 描述不同物理量。

取离散傅里叶变换 $V_k = \sum_{r=0}^{L-1} v_r \exp(-2\pi i k r / L)$ 。离散复指数的正交性给出

$$\sum_{k=0}^{L-1} |V_k|^2 = \sum_{r,s} v_r v_s \sum_k e^{-2\pi i k(r-s)/L} = L \sum_{r=0}^{L-1} v_r^2. \quad (8.5)$$

因此 $L^{-2} \sum_k |V_k|^2$ 与时域均方一致。频带能量可以在目标频率索引上求和，但必须说明是双边频谱还是单边频谱；单边谱除直流和偶数长度时的奈奎斯特特点外要计入共轭频率的能量。频率间隔为 f_s/L ，不是增加零填充后就获得更多物理分辨率。

该计算以等间隔采样为前提，降采样前需低通抑制混叠，有限窗口与加窗会改变谱泄漏和能量归一化。转速变化时固定频带也可能不再跟随故障阶次。这说明特征不是纯数学的列变换，其单位、采样机制和工况含义都属于实验设置。

8.2 从数据处理到可信实验

数据依赖、反馈回路和配置变化会在长期运行中积累系统风险，机器学习系统的技术债务研究对此给出了系统性讨论[94]。以下版本与来源记录要求用于追溯预测依

据，不能只记录模型权重。

实验矩阵。 高质量实验应一次只改变一个主要因素。建议建立实验矩阵，至少包含数据切分、输入窗口、模型、损失、超参数、随机种子、硬件、训练时间、参数量、延迟和评价指标。主结果应包含简单基线、当前方法、消融实验、跨域测试和失败案例。

可复现性。 代码版本、数据版本、环境文件、配置文件和随机种子共同定义一次实验。随机种子不能保证不同硬件完全一致，但可以帮助发现结果是否依赖偶然初始化。日志应保存训练曲线、最佳检查点、验证预测、错误样本和配置哈希。

8.3 从离线证据到在线系统

工业部署的验收指标。 验收不只看离线分数，还应包括从输入到动作可用的总延迟、可用率、告警频率、平均提前量、误停机率、人工复核负担和模型回滚路径。模型上线前应进行影子运行，让模型产生建议但不直接控制设备；通过一段时间验证告警稳定性后，再逐步扩大影响范围。

8.4 案例分析：剩余寿命预测

问题定义与数据边界。 设设备在时刻 t 的观测为 $X_{\leq t}$ ，剩余寿命为 RUL_t 。可以将问题写成点预测 $\hat{r}_t = f_{\theta}(X_{\leq t})$ ，也可以预测条件分布 $p(r | X_{\leq t})$ 。后者能表达不同设备在相同观测下的差异，但评价要同时关注误差、区间覆盖率和提前量。若模型在寿命末期才准确，可能对维护决策没有价值。

寿命标签与删失似然。 设从共同起点计算的失效时间为 T ，记录截止时间为 C ，观测到 $u = \min(T, C)$ 与失效指示 $\delta = \mathbb{1}\{T \leq C\}$ 。对给定特征 x ，模型定义密度 $f_{\theta}(t | x)$ 和生存函数 $S_{\theta}(t | x) = P(T > t | x)$ 。若给定 x 后删失与失效独立，且忽略与 θ 无关的删失机制，则单台设备的似然贡献是

$$L_i(\theta) = f_{\theta}(u_i | x_i)^{\delta_i} S_{\theta}(u_i | x_i)^{1-\delta_i}. \quad (8.6)$$

式(8.6)中，已失效设备贡献准确失效时刻的密度，未失效设备只说明寿命大于 u_i ，因此贡献尾部概率，不能赋予“寿命等于截止时间”的标签。独立设备的负对数似然是 $-\sum_i [\delta_i \log f_{\theta}(u_i | x_i) + (1 - \delta_i) \log S_{\theta}(u_i | x_i)]$ 。

在固定协变量模型中，已运行到 t 仍存活设备，其剩余寿命尾概率为

$$P(T - t > r | T > t, x) = \frac{S_{\theta}(t + r | x)}{S_{\theta}(t | x)}, \quad r \geq 0. \quad (8.7)$$

若均值存在，条件期望剩余寿命等于该尾概率对 r 从零到无穷的积分。这个比值明确体现“已活到当前”的信息。若输入是随时间变化的完整历史，则需要相应动态条件模型，不能把未来传感器值塞进固定 x 。预防性维修可能依赖潜在风险，导致信息性删失；此时独立删失假设应重新检查，单用上述似然会偏差。

8.5 数据时序、缺失与来源记录的深入分析

事件时间与处理时间。 流式系统至少存在事件时间、采集时间和处理时间。事件时间表示物理过程发生的时刻，处理时间表示数据进入计算系统的时刻；网络延迟和缓存会使二者不同。标签窗口应基于事件时间定义，而在线服务的可用性应基于处理时间评估。混淆两者会让回放实验看似可行，实时系统却无法重现。

窗口化的统计代价。 重叠窗口可以增加样本数量，但相邻窗口高度相关，不能把它们当作独立样本计算置信区间。若窗口长度为 L 、步长为 s ，在 $s \ll L$ 时有效样本量远小于窗口数量。设备级切分应在窗口化之前或以设备事件为单位进行，避免同一故障轨迹被拆到多个集合。

有效样本量的计算依据。 设窗口指标 $Z_1, \dots, Z_N$ 弱平稳， $\text{Var}(Z_i) = \sigma_Z^2$ ，滞后 h 相关系数为 ρ_h 。对均值展开协方差和可得

$$\text{Var}(\bar{Z}) = \frac{1}{N^2} \left[N\sigma_Z^2 + 2 \sum_{h=1}^{N-1} (N-h)\sigma_Z^2 \rho_h \right] \quad (8.8)$$

$$= \frac{\sigma_Z^2}{N} \left[1 + 2 \sum_{h=1}^{N-1} (1-h/N)\rho_h \right]. \quad (8.9)$$

把式(8.9)中的括号记为 τ_N ，按独立均值方差定义 $N_{\text{eff}} = N/\tau_N$ 。这是一种针对特定统计量的等效精度，不是数据集固有的唯一属性，也不能只由窗口长度和步长精确确定。正相关常使有效数量下降，负相关则可能相反；非平稳退化序列不能直接套用此估计。实践中以设备或独立运行过程做成组重采样，通常比把相关系数机械外推到无穷更可解释。

缺失机制与敏感性分析。 缺失值本身可能携带信息：传感器在高温时掉线，或维护期间停止采集，都不是完全随机缺失。模型可以使用缺失指示变量，但这也可能学到设备或时间的伪相关。应比较删除、简单填补、模型填补和显式缺失建模，并在不同缺失率下报告性能曲线。

异常检测与修复边界。 统计异常、物理异常和业务异常需要不同处理。一个高振幅冲击可能是故障，也可能是传感器饱和；自动裁剪会消除最有价值的信号。建议同时

保留原始值、质量标记和修正值，让模型或分析者能够区分“观测异常”和“处理异常”。

数据版本与来源记录。 保存一版数据集时，应同时保存它对应的原始文件、转换脚本、特征配置、标签规则和切分清单。数据来源与处理记录指的是这条来路及处理过程。例如看到一个振动均方根字段，应能追查它来自哪台设备、哪段波形，用哪个脚本算出，是否误用了预测之后的记录，以及线上哪个版本读取了它。这样发现错误告警时，才能沿处理过程定位问题，而不只是重新训练一次。

8.6 实验归因与部署反馈

实验矩阵与消融。 主实验应先固定切分和评价规则，再逐项改变模型或特征。消融实验需要回答机制问题，例如去掉频域特征后是否仍能识别故障、去掉缺失掩码后是否对掉线更脆弱、缩短窗口后提前量如何变化。只罗列大量模型名称而没有机制消融，不能说明改进来自何处。

消融中的交互作用与配对。 若同时研究频域特征 A 和缺失掩码 B ，设 r_{ab} 是在相同设备、切分和随机种子设置下的风险， $a, b \in \{0, 1\}$ 表示是否启用。 A 在无 B 时的作用为 $r_{10} - r_{00}$ ，在有 B 时为 $r_{11} - r_{01}$ ，两者之差

$$I_{AB} = r_{11} - r_{01} - r_{10} + r_{00} \quad (8.10)$$

衡量交互作用。因此“一次只改变一个因素”适合局部归因，但不能证明组合收益是两项收益的相加；必要时应使用完整的四种设置。各设置应在同一测试设备上配对比较，并分别报告跨设备与训练种子波动。更多种子只能衡量算法随机性，不能替代更多独立设备。

从窗口告警到事件验收。 设第 e 次故障发生在 T_e ，预先规定有效告警窗口 $[T_e - H, T_e - h]$ ，其中 $h \geq 0$ 为最低操作提前量。若窗口内至少一次合法告警，则该事件记为命中；首个符合规则的告警时刻为 A_e ，提前量为 $T_e - A_e$ 。事件召回率是命中事件数除以可完整评价的故障事件数，而非阳性窗口命中比例。还应规定重复告警合并、静默期和告警到事件的匹配规则。

误报可按单位无故障暴露时间计为 $N_{\text{false}}/E_{\text{normal}}$ ，从而区分运行一小时与运行一千小时的负担。提前量均值若只在命中事件上计算，会遗漏漏检事件，故必须与事件召回率一起报告。服务延迟则应从最新合法观测到动作可用的整个过程测量，不能只报神经网络一次前向传播的时间。

从离线到影子运行。 上线前先回放历史数据，再进行不影响控制回路的影子运行。影子阶段检查数据延迟、字段缺失、告警频率、模型版本和人工反馈。通过验收后才

逐步开放建议或控制权限，并保留回滚阈值。上线监控应同时关注输入漂移、输出漂移、标签后验和服务资源。

本章小结。 工业数据工程把现实过程变成时间边界清楚、版本可追溯、统计依赖可解释的学习样本。模型性能的上限往往由数据管道决定；越复杂的模型，越需要可靠的数据来源与处理记录和部署验收来支撑其结论。

时间集合规定能用什么信息，缺失和删失规定我们究竟观察到了什么，成组评价与配对消融规定改进可以归因到哪里。它们共同完成第一部分的学习任务设置：不再只交付一个拟合函数，而是交付一条从记录到预测再到维护动作的可复核的处理过程。

记录整理正确以后，设备数量有限仍会使故障率和回归系数难以精确估计，当前隐状态也可能有多种解释。下一章用先验、似然和后验描述这些不确定性。输入若混入未来信息，概率推断也无法补救；输入使用正确时，它才有助于判断哪些结论较稳定，哪些还需补充数据或请人复核。

第二部分

贝叶斯机器学习：用概率表达知识与不确定性

前一部分已经规定了输入、标签、时间边界和验收动作，但点预测仍没有说明“这次判断有多可靠”。本部分保持贯穿案例不变，只改变答案的表达方式：先用贝叶斯更新描述有限证据，再比较参数化与非参数化模型如何表达函数不确定性。读者应看到，概率不是给结果加一个置信度装饰，而是改变训练目标、预测输出和维护决策的依据；下一部分将在这些边界上选择更强的表示模型。

第九章 贝叶斯机器学习

本章摘要。本章将点预测扩展为对未知量及其依赖关系的分布表达。先建立贝叶斯更新和后验预测，再用概率图模型描述设备隐状态、观测和相邻标签之间的关系。Hidden Markov Model (HMM)、最大熵马尔科夫模型、Conditional Random Field (CRF) 和马尔科夫随机场分别揭示生成建模、条件建模与局部依赖的不同取舍。在此基础上讨论参数后验的近似计算，最后以校准、敏感性分析和维护决策检验概率是否可信。

前一部分已经固定数据可用时间、预测目标与验证规则。现在假设这些前提都成立，仍然存在一个未解决的问题：少量故障能支持多精确的风险估计，多个解释相近的参数应如何共同参与预测？本章不改变任务，而是把单一答案扩展成对可能答案及其依赖关系的分布。

阅读时可以把未知量分成三类：设备长期的故障倾向属于参数，轴承此刻是否磨损属于隐状态，下一次传感器读数还包含新的随机波动。对状态求和和对参数积分处理的是不同的未知量，决定是否停机还要另外比较动作成本。先从能手算的共轭模型开始，再看链式图模型怎样减少枚举，最后讨论近似计算的误差。使用贝叶斯方法以后，仍要检查假设是否合适、概率是否校准，不能省去验证。

9.1 贝叶斯更新与后验预测

从参数点到参数分布。 贝叶斯建模把未知参数视为随机变量，是概率机器学习的基本表述之一[74, 7]。给定先验 $p(\theta)$ 和似然 $p(\mathcal{D} | \theta)$ ，后验为

$$p(\theta | \mathcal{D}) = \frac{p(\mathcal{D} | \theta)p(\theta)}{p(\mathcal{D})}, \quad p(\mathcal{D}) = \int p(\mathcal{D} | \theta)p(\theta) d\theta. \quad (9.1)$$

先验表达观测数据之前的结构知识，似然描述数据如何由参数生成，后验则是二者结合后的知识状态。

后验预测。 图9.1区分后验更新与预测两个环节：先用数据修正参数分布，再以整个后验而非单个参数点形成新观测的预测。对新输入 x_* ，预测分布需要对参数不确定性积分：

$$p(y_* | x_*, \mathcal{D}) = \int p(y_* | x_*, \theta)p(\theta | \mathcal{D}) d\theta. \quad (9.2)$$




图 9.1: 贝叶斯更新把先验与观测结合为后验，再对参数不确定性积分得到预测分布。

式(9.2)中积分涉及的不确定性包含数据噪声和参数不确定性。前者称为偶然不确定性 (aleatoric uncertainty)，后者称为认知不确定性 (epistemic uncertainty)。当设备出现训练数据未覆盖的工况时，后者尤其值得关注。

更新与预测各用了哪条概率规则。联合分布可分别写成 $p(\theta, \mathcal{D}) = p(\mathcal{D} | \theta)p(\theta)$ 和 $p(\theta | \mathcal{D})p(\mathcal{D})$ ；两式相等并除以正且有限的 $p(\mathcal{D})$ 即得 Bayes 公式。连续观测使用的是密度，不要求单个精确观测有正概率。若数据分批到达且给定 θ 后条件独立，则

$$p(\theta | \mathcal{D}_1, \mathcal{D}_2) \propto p(\mathcal{D}_2 | \theta)p(\theta | \mathcal{D}_1). \quad (9.3)$$

同一条记录只能更新一次；相关窗口若被误当独立批次，会使后验虚假收窄。

后验预测来自全概率公式，再使用 $Y_* \perp \mathcal{D} | (x_*, \theta)$ 。固定设计回归把输入视作已知条件；如果 x_* 的生成机制本身依赖待推断参数，则还应对它的证据更新，不能无条件沿用 $p(\theta | \mathcal{D})$ 。这一细节说明概率公式总是在特定条件结构下成立。

9.2 概率图模型：从依赖关系到分布分解

单个故障率只能回答总体上有多大风险，却不能解释设备如何从正常运行进入退化状态。振动和温度往往共同受某个不可直接观测的状态影响，相邻时刻的状态又存在持续性。概率图模型以节点表示随机变量，以边和局部因子表达依赖结构，将一个庞大的联合分布拆成可以解释和计算的部分[7, 74]。

有向无环图对应贝叶斯网络。若变量集合为 $X_1, \dots, X_m$ ，节点 X_j 的父节点集合记为 $\text{pa}(j)$ ，则

$$p(X_1, \dots, X_m) = \prod_{j=1}^m p(X_j | X_{\text{pa}(j)}). \quad (9.4)$$

没有父节点的变量使用边缘分布。这个分解规定了条件独立假设，而不是仅用箭头描绘相关性。例如，在 $X \leftarrow Z \rightarrow Y$ 中，给定共同原因 Z 后，模型假定 X 与 Y 独立。若 Z 表示设备工况，该假设意味着知道工况后，两个传感器不再提供额外的相互依赖信息。真实设备仍可能存在共享噪声，此时需要修改观测模型。

条件化也可能引入依赖。在碰撞结构 $X \rightarrow Z \leftarrow Y$ 中，路径原本被 Z 阻断，而观测 Z 或其后代可能使 X 与 Y 相关。因而不能简单地认为“给定更多变量总会减少依赖”。一般有向图中的这类关系由 d-separation 判断。图中的方向也不自动具有因果含义，因果解释还需要额外的领域假设或干预证据。

无向图适合表达对称的相容关系，例如相邻表面区域倾向于具有相近状态。因子图则把变量节点与因子节点分开，统一表示 $p(X) \propto \prod_a \psi_a(X_a)$ 。它强调计算所依赖的局部分解，可以表示有向模型，也可以表示无向模型。树上的求和积消息传递能够精确计算边缘概率，最大积用于求最优联合配置；含环图的复杂度则取决于连接结构，不能只按节点数判断。

这里需要分清两类未知量。设备在某一时刻的隐状态属于随机变量推断，转移矩阵和观测分布的参数属于参数学习。概率图模型可以用最大似然估计参数，也可以为参数指定先验并计算后验。因此，“贝叶斯网络”描述图的分解形式，“贝叶斯学习”描述对参数不确定性的处理方式，两者不是同义词。

分解与消息的代数来源。 按有向无环图的拓扑顺序排列变量，概率链式法则先给出 $\prod_j p(X_j | X_1, \dots, X_{j-1})$ ；只有加入“给定父节点后独立于其余先前变量”的假设，才能删去多余条件得到图分解。边因此代表被允许的依赖，不是从链式法则自动推出来的物理事实。

对树形因子图，边缘化要计算 $\sum_{X \setminus X_i} \prod_a \psi_a(X_a)$ 。利用乘法对加法的分配律，把树的一个分支先求和，就得到消息

$$m_{i \rightarrow a}(x_i) = \prod_{b \in N(i) \setminus a} m_{b \rightarrow i}(x_i), \quad (9.5)$$

$$m_{a \rightarrow i}(x_i) = \sum_{x_a \setminus i} \psi_a(x_a) \prod_{j \in N(a) \setminus i} m_{j \rightarrow a}(x_j). \quad (9.6)$$

从叶子向内再向外传递后， $p(x_i) \propto \prod_{a \in N(i)} m_{a \rightarrow i}(x_i)$ 。有限离散状态下这些都是有限和；连续变量则需积分或近似。树上各分支只相交于分隔变量，所以每条证据恰好计算一次；含环时重复传递不再对应这样的独立分支消元。把求和换成最大值并保存取值索引可求最优配置，但不能由最大消息恢复边缘概率。

9.3 隐马尔科夫模型与状态推断

HMM 的前向后向、最优路径与参数估计可参照 Rabiner 的经典教程[78]。下面将这些运算分别对应到在线状态识别、离线诊断和历史数据训练，避免混淆可用信息。

设 $x_{1:T}$ 为一段设备观测， $z_t \in \{1, \dots, K\}$ 为时刻 t 的隐状态。隐马尔科夫模型（HMM）假定状态只依赖上一时刻，且观测在给定当前状态后不再依赖其他状态和观测：

$$p(z_t | z_{1:t-1}) = p(z_t | z_{t-1}), \quad (9.7)$$

$$p(x_t | z_{1:T}, x_{1:t-1}) = p(x_t | z_t). \quad (9.8)$$

记初始概率为 π_k ，转移概率为 $A_{jk} = p(z_t = k | z_{t-1} = j)$ ，观测密度或概率为 $b_k(x) = p(x | z_t = k)$ 。联合分布分解为

$$p(x_{1:T}, z_{1:T}) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^T A_{z_{t-1}, z_t} b_{z_t}(x_t). \quad (9.9)$$

图9.2可以直接读成式(9.9)的联合分布：每个节点贡献一个给定父节点的条件分布，




图 9.2: HMM 的有向图结构（以四个时刻为例）。白色圆为隐状态，蓝色圆为已观测变量；横向箭头表示状态转移，向下箭头表示观测生成。箭头表示概率分解关系，不自动代表因果关系。

首个状态贡献初始分布。给定 z_t 后， x_t 与其他时刻的变量条件独立；但只给定观测而未固定隐状态时，各时刻观测通常仍然相关。图中的向下箭头是模型定义的生成方向，推断时则可以从观测反过来更新隐状态的概率。

每行转移概率之和为一。多通道观测可以用联合高斯分布或混合分布描述，HMM并不要求同一时刻的各传感器通道独立。真正受限制的是跨时刻的依赖：一旦给定状态序列，观测之间便被假定条件独立。

以“正常、退化、故障”三个状态为例，转移矩阵可以表达状态持续性。禁止某条转移必须有物理依据，例如只有在明确排除维修过程的运行片段内，才可能限制故障状态不能直接返回正常。无监督学习得到的三个隐状态也不会自动具有这三个语义，需要通过标注、特征分布或专家检查建立对应关系。

过滤、平滑与最优路径。 在线维护需要 $p(z_t | x_{1:t})$ ，称为过滤；事后分析使用 $p(z_t | x_{1:T})$ ，称为平滑。后者利用未来观测，不能直接作为实时告警的性能。若需要解释整段运行过程，还可以寻找联合概率最大的状态路径。这三个问题的输出不同，即使使用同一个 HMM，也不能混用结果。

直接枚举所有状态路径需要考虑 K^T 种配置。前向算法利用链结构复用公共计算，令 $\alpha_t(k) = p(x_{1:t}, z_t = k)$ ，则

$$\alpha_1(k) = \pi_k b_k(x_1), \quad (9.10)$$

$$\alpha_t(k) = b_k(x_t) \sum_{j=1}^K \alpha_{t-1}(j) A_{jk}, \quad (9.11)$$

$$p(z_t = k \mid x_{1:t}) = \frac{\alpha_t(k)}{\sum_j \alpha_t(j)}. \quad (9.12)$$

最后一时刻的前向量求和即为 $p(x_{1:T})$ 。每步对 K^2 个状态对计算，总复杂度为 $O(TK^2)$ 。长序列中概率连乘会下溢，应逐步缩放或在对数域使用 log-sum-exp，并保留缩放因子以恢复序列似然。

后向量 $\beta_t(j) = p(x_{t+1:T} \mid z_t = j)$ 满足

$$\beta_T(j) = 1, \quad \beta_t(j) = \sum_{k=1}^K A_{jk} b_k(x_{t+1}) \beta_{t+1}(k). \quad (9.13)$$

于是平滑概率为 $\gamma_t(k) = \alpha_t(k) \beta_t(k) / p(x_{1:T})$ 。前向量汇总过去证据，后向量汇总未来证据，这也给出了链式消息传递的具体形式。

Viterbi 算法将前向递推中的求和替换为最大值。在对数域中，

$$\delta_t(k) = \log b_k(x_t) + \max_j \{ \delta_{t-1}(j) + \log A_{jk} \}, \quad \delta_1(k) = \log \pi_k + \log b_k(x_1). \quad (9.14)$$

保存每步最大值对应的前驱，便可从终点回溯路径。逐时刻选择边缘概率最大的状态与 Viterbi 路径通常不同，前者优化逐点分类，后者优化整条路径的联合概率。在存在禁止转移时，逐点选择甚至可能产生不合法路径。

前向后向递推的推导与稳定实现。 固定当前状态 k ，对前驱 j 边缘化：

$$p(x_{1:t}, z_t = k) = \sum_j p(x_t \mid z_t = k) p(z_t = k \mid z_{t-1} = j) p(x_{1:t-1}, z_{t-1} = j) \quad (9.15)$$

$$= b_k(x_t) \sum_j A_{jk} \alpha_{t-1}(j). \quad (9.16)$$

条件独立允许把观测因子提到求和外。相似地，从 z_{t+1} 边缘化得到后向递推；给定 z_t 后过去和未来的观测分离，因此 $\alpha_t(k) \beta_t(k)$ 就是 $p(x_{1:T}, z_t = k)$ 。求和表示保留所有可能路径，Viterbi的最大值则丢弃每个终点下非最优前缀；链结构保证最优前缀可扩展为最优整段路径。

数值上令 $h_{t-1}(j) = p(z_{t-1} = j \mid x_{1:t-1})$ ，计算

$$u_t(k) = b_k(x_t) \sum_j h_{t-1}(j) A_{jk}, \quad c_t = \sum_k u_t(k), \quad h_t(k) = u_t(k) / c_t. \quad (9.17)$$

第一步用 $u_1(k) = \pi_k b_k(x_1)$ 。于是 $c_t = p(x_t | x_{1:t-1})$ 且 $\log p(x_{1:T}) = \sum_t \log c_t$ ；缩放后的后向递推对应除以 c_{t+1} 。若 $c_t = 0$ ，是模型认为证据不可能而非普通下溢，应检查零转移与观测支持。对数域的 $\log \sum_j e^{a_j} = m + \log \sum_j e^{a_j - m}$ ($m = \max_j a_j$) 提供另一种稳定计算。

从隐状态推断到参数学习。 隐状态未标注时，Baum-Welch 算法以 Expectation Maximization (EM) 交替估计状态的后验占用和模型参数。E 步计算 $\gamma_t(j)$ 以及相邻状态的后验概率

$$\xi_t(j, k) = \frac{\alpha_t(j) A_{jk} b_k(x_{t+1}) \beta_{t+1}(k)}{p(x_{1:T})}. \quad (9.18)$$

对一条序列，M 步的转移更新为

$$A_{jk}^{\text{new}} = \frac{\sum_{t=1}^{T-1} \xi_t(j, k)}{\sum_{t=1}^{T-1} \gamma_t(j)}. \quad (9.19)$$

初始分布更新为 $\pi_k^{\text{new}} = \gamma_1(k)$ ，观测分布则按 $\gamma_t(k)$ 进行加权估计。多条独立运行序列需要分别推断后再汇总计数，不能把不同设备的尾部与头部连接成一次状态转移。EM 依赖初始化，只保证在精确 E、M 步下不降低训练似然，不能保证找到全局最优参数。

EM为什么得到期望计数比。 取 $q(z) = p(z | x, \theta^{\text{old}})$ ，由 Jensen 不等式，

$$\log p_\theta(x) \geq \mathbb{E}_q \log p_\theta(x, z) - \mathbb{E}_q \log q(z). \quad (9.20)$$

在旧参数处等号成立；M 步保持 q 固定并提高右端，便不降低观测似然。转移相关部分是 $\sum_{jk} N_{jk} \log A_{jk}$ ，其中 $N_{jk} = \sum_{t < T} \xi_t(j, k)$ 。对每行加入约束乘子 $\lambda_j (\sum_k A_{jk} - 1)$ ，一阶条件 $N_{jk}/A_{jk} + \lambda_j = 0$ 与行和为一给出 $A_{jk} = N_{jk} / \sum_k N_{jk}$ 。又因 $\sum_k \xi_t(j, k) = \gamma_t(j)$ ，便得到前述更新。

若 $x_t \in \mathbb{R}^d$ 且 $b_k = \mathcal{N}(\mu_k, \Sigma_k)$ ，高斯对数密度的加权一阶条件给出

$$\mu_k^{\text{new}} = \frac{\sum_t \gamma_t(k) x_t}{N_k}, \quad \Sigma_k^{\text{new}} = \frac{\sum_t \gamma_t(k) (x_t - \mu_k^{\text{new}})(x_t - \mu_k^{\text{new}})^\top}{N_k}, \quad N_k = \sum_t \gamma_t(k). \quad (9.21)$$

这里 $\mu_k \in \mathbb{R}^d$ 、 $\Sigma_k \in \mathbb{R}^{d \times d}$ 。若状态从未被占用，分母为零，参数不可由本轮数据识别；协方差也可能退化，需预先规定先验、协方差结构或数值下界，而非把无定义更新当作成功训练。约束或近似 M 步需要实际检查目标是否改善。

若状态转移已经观测到，可以为 $A_{j\cdot}$ 设置 Dirichlet 先验，其后验参数等于先验参数加转移计数。状态未知时，转移计数本身也不确定。EM 的期望计数可用于点估计，但将其代入 Dirichlet 分布并不自动得到精确的参数后验，完整贝叶斯学习需要联合处理状态和参数的不确定性。

标准齐次 HMM 的自转移还隐含持续时间假设。若 $A_{kk} < 1$ ，进入状态 k 后停留 d 步的概率为

$$p(D = d | k) = A_{kk}^{d-1}(1 - A_{kk}), \quad d = 1, 2, \dots \quad (9.22)$$

这是一种无记忆的几何分布。若退化持续时间明显集中在某个范围，增加状态数未必是合适修复，隐半马尔科夫模型可以显式描述持续时间。动态贝叶斯网络则允许每个时刻包含多个相互作用的隐变量。线性高斯状态空间模型把离散状态换成连续状态，在相应假设下可用卡尔曼滤波精确计算过滤分布，后续序列章将讨论其动态含义。

9.4 从局部条件模型到条件随机场

最大熵马尔科夫模型与条件随机场分别代表局部条件归一化和全局路径归一化[71, 60]。比较二者的关键是概率质量如何在状态转移间分配，而不是是否使用神经网络提取特征。HMM 同时学习观测如何产生和状态如何演化。当目标仅是识别状态，而输入包含频谱、载荷变化和多个重叠窗口特征时，准确建立 $p(x_t | z_t)$ 可能比分类本身更困难。最大熵马尔科夫模型（Maximum Entropy Markov Model, MEMM）直接对状态转移建模，以对数线性分类器给出

$$p_{\theta}(z_t = k | z_{t-1} = j, x) = \frac{\exp\{\theta^T f(j, k, x, t)\}}{\sum_{k'} \exp\{\theta^T f(j, k', x, t)\}}. \quad (9.23)$$

其中 f 为特征向量， x 表示当前任务允许使用的观测范围。最大熵的名称来自特征期望约束下的条件熵最大化，其解具有上述指数族形式。令 z_0 为固定起始状态，序列条件概率为各步条件概率之积。对于完整标注序列，训练可转化为以真实前驱状态为条件的局部分类；预测时前驱状态未知，仍需进行链上推断。




图 9.3: MEMM 的条件有向结构。灰色节点为固定起始状态，观测同时参与各步局部分类；与 HMM 相比，模型不再使用由状态指向观测的生成边。

图9.3中，每个待预测标签的输入来自前驱标签与已给定观测，因此整条路径概率是这些局部条件概率的乘积。顶部的 x 可以包含任务允许的多个时刻和重叠特征，并不意味着在线任务能够读取未来。横向箭头保留了标签顺序依赖，却没有取消每一步各自归一化的限制；这正是后文标签偏置的结构来源。

最大熵为何导出softmax。 把前驱与可用输入合称上下文 c ，令经验上下文权重为 $\hat{p}(c)$ ，特征 $\phi(c, k) \in \mathbb{R}^p$ 。在归一化约束 $\sum_k q(k | c) = 1$ 及特征期望约束 $\sum_{c,k} \hat{p}(c) q(k | c) \phi(c, k) = \bar{\phi}$ 下，最大化条件熵 $-\sum_{c,k} \hat{p}(c) q(k | c) \log q(k | c)$ 。对 $q(k | c)$ 求拉格朗日一阶条件得到

$$-\log q(k | c) - 1 + \theta^\top \phi(c, k) + \lambda(c) = 0. \quad (9.24)$$

指数化后，归一化消去 $\lambda(c)$ ，即得 $q(k | c) = \exp(\theta^\top \phi(c, k)) / \sum_{k'} \exp(\theta^\top \phi(c, k'))$ 。这要求约束可行；特征完全分离时有限最优权重未必存在，通常以正则化松弛精确矩约束。名称中的熵指这个构造原则，不表示模型输出必须高熵。

MEMM 可以使用相关、重叠的输入特征，不需要描述它们的联合分布，但每个前驱状态都单独归一化，这带来了标签偏置。若某个状态只有一个允许的后继，该转移的条件概率恒为一，无论对应特征得分多低，都不能借助该步降低路径概率。更一般地，后继较少或转移分布较集中的状态可能获得结构性优势。问题来自局部归一化对路径评分的约束，并非简单的类别数量不平衡。

线性链条件随机场（CRF）保留相邻标签依赖，却把归一化放到整条路径上[74]。定义路径得分

$$F_\theta(z, x) = \sum_{t=1}^T \theta^\top f(z_{t-1}, z_t, x, t), \quad (9.25)$$

$$p_\theta(z | x) = \frac{\exp F_\theta(z, x)}{Z_\theta(x)}, \quad (9.26)$$

$$Z_\theta(x) = \sum_{z_{1:T}} \exp F_\theta(z', x). \quad (9.27)$$

图9.4把条件分布写成可逐项检查的乘积：每个方形读取相邻两个标签及观测，输出




图 9.4: 线性链 CRF 的因子图。圆形表示标签，方形表示相邻标签的势函数；实线无方向，表示变量参与因子。蓝色虚线仅表示势函数依赖已给定观测，不是标签图中的随机变量边或生成箭头。

一个非负相容度。固定 z_0 后，第一个因子实际只涉及一个待预测标签。去掉因子节点、将共享因子的标签直接相连，就得到标签的无向链。与 MEMM 不同， ψ_t 不要求对后继标签求和为一，所有因子共同决定路径得分，最后才由一个全局配分函数归一化。

配分函数 $Z_\theta(x)$ 比较所有允许路径的得分。一个只有唯一后继的状态仍然可以获得较低的路径得分，因此消除了 MEMM 局部归一化造成的上述限制。全局归一化并不意味着自动解决标注噪声、分布偏移或特征不足。

对一条标注序列 (x, z) ，带二次正则的负对数条件似然为

$$\mathcal{L}(\theta) = -F_\theta(z, x) + \log Z_\theta(x) + \frac{\lambda}{2} \|\theta\|_2^2. \quad (9.28)$$

其梯度等于模型期望的特征计数减去真实路径的特征计数，再加 $\lambda\theta$ 。这个形式解释了训练为何需要边缘概率：只找出当前最优路径不足以计算配分函数的梯度。在线性链、有限状态和相邻标签因子下，前向后向算法可在 $O(TK^2)$ 时间内计算配分函数和边缘概率，Viterbi 则计算最优路径。

配分函数、边缘概率与梯度的完整联系。 令 $\psi_t(j, k) = \exp\{\theta^\top f(j, k, x, t)\}$ 。固定起点 z_0 ，设置 $a_0(z_0) = 1$ 、其余为零，递推 $a_t(k) = \sum_j a_{t-1}(j) \psi_t(j, k)$ ，则 $Z = \sum_k a_T(k)$ 。后向量 $b_T(k) = 1$ 、 $b_{t-1}(j) = \sum_k \psi_t(j, k) b_t(k)$ 给出边缘

$$p_\theta(z_{t-1} = j, z_t = k \mid x) = \frac{a_{t-1}(j) \psi_t(j, k) b_t(k)}{Z}. \quad (9.29)$$

这些 a, b 是未归一化消息，不是HMM的观测似然参数。定义总特征

$$\Phi(z, x) = \sum_t f(z_{t-1}, z_t, x, t) \in \mathbb{R}^p. \quad (9.30)$$

直接对有限和求导得

$$\nabla_\theta \log Z = \frac{\sum_z e^{\theta^\top \Phi(z, x)} \Phi(z, x)}{Z} = \mathbb{E}_{p_\theta(z|x)} \Phi(z, x), \quad (9.31)$$

$$\nabla_\theta \mathcal{L} = -\Phi(z^{\text{obs}}, x) + \sum_{t,j,k} p_\theta(j, k \mid x) f(j, k, x, t) + \lambda \theta. \quad (9.32)$$

再求导得到 $\nabla^2 \mathcal{L} = \text{Cov}_{p_\theta}(\Phi) + \lambda I_p$ 。因此固定特征的线性CRF目标凸， $\lambda > 0$ 时严格凸；若特征由待训练神经网络产生，这一参数凸性便不再成立。禁止路径可赋零势，但至少必须存在一条合法路径，否则 $Z = 0$ 使条件分布无定义。

神经网络可以提供 CRF 的局部观测得分。例如，令 $s_t(k; x)$ 为编码器输出， B_{jk} 为可学习转移得分，则

$$F_\theta(z, x) = \sum_{t=1}^T s_t(z_t; x) + \sum_{t=2}^T B_{z_{t-1}, z_t}. \quad (9.33)$$

与 HMM 的 A_{jk} 不同， B_{jk} 是未归一化得分，不要求非负或行和为一。Bidirectional Long Short-Term Memory (BiLSTM)-CRF 和 Transformer-CRF 将特征提取交给神经网络，将标签关系交给结构化输出层。双向编码器适合完整记录的离线标注；在线预警必须限制输入和推断范围，或者明确等待未来观测所引入的延迟。即使局部特征只读取过去，对整段序列进行平滑仍可能利用后续证据。

9.5 马尔科夫随机场与空间一致性

图像中的局部相互作用可用 Gibbs 分布和马尔科夫随机场描述, Geman 与 Geman 将这一建模方式用于图像恢复[29]。本节据此解释邻域势函数与能量最小化, 但不把平滑先验当作真实边界的替代。时间链只是一种邻接关系。在缺陷图像或设备网络中, 每个变量可能有多个邻居, 马尔科夫随机场 (Markov Random Field, MRF) 用无向图描述这种依赖。对严格正的分布, 在相应马尔科夫性质下可以按图中的团分解为

$$p(z) = \frac{1}{Z} \prod_{C \in \mathcal{C}} \psi_C(z_C) = \frac{1}{Z} \exp\{-E(z)\}. \quad (9.34)$$

图9.5展示的是一种具体的网格结构, 并非所有 MRF 都必须是网格。此处 z_{rc} 的两个




图 9.5: 四邻域网格上的成对 MRF。每个节点对应一个像素或区域标签, 每条无向边对应一个二元势; 不存在箭头, 并不表示各标签独立, 而是表示相互作用不采用有向生成分解。

下标分别表示行和列。局部马尔科夫性质可写为

$$p(z_{22} \mid z_{\setminus 22}) = p(z_{22} \mid z_{12}, z_{21}, z_{23}, z_{32}), \quad (9.35)$$

其中 $z_{\setminus 22}$ 表示除中心外的全部标签。对于图示的一元和二元势分解, 固定其他标签后, 与 z_{22} 无关的因子在条件概率归一化时相消, 因而

$$p(z_{22} = k \mid z_{\setminus 22}) = \frac{\psi_{22}(k) \prod_{j \in N(22)} \psi_{22,j}(k, z_j)}{\sum_{k'} \psi_{22}(k') \prod_{j \in N(22)} \psi_{22,j}(k', z_j)}. \quad (9.36)$$

这也解释了 Gibbs 采样为何只需读取当前节点的邻居。不过, 局部更新只访问邻域, 并不意味着联合分布能够分解成相互独立的节点分布。若这些势还依赖给定图像 x , 图中的标签邻接关系保持不变, 得到的就是后文讨论的网格 CRF。

团 C 内的节点两两相连, 势函数 ψ_C 表达局部相容程度, 并不是归一化概率。能量 $E(z) = -\sum_C \log \psi_C(z_C)$ 越低, 配置概率越高。配分函数 Z 对全部配置求和, 保证总概率为一。若使用零势函数表达硬约束, 则不能直接套用依赖严格正性的等价结论。

在给定图像 x 的二元缺陷标注中, 可以设置

$$E(z; x) = \sum_i U_i(z_i; x) + \lambda \sum_{(i,j) \in \mathcal{E}} w_{ij}(x) \mathbb{1}\{z_i \neq z_j\}, \quad \lambda, w_{ij}(x) \geq 0. \quad (9.37)$$

一元项 U_i 衡量局部像素证据，二元 Potts 项惩罚邻居标签不一致。相邻区域越相似， w_{ij} 可以越大；跨越明显边界时降低权重，可减轻过度平滑。若直接将分类概率转换成一元负对数得分，这构成条件模型的一种参数化，并不自动成为生成似然。

此时 $p(z | x) \propto \exp\{-E(z; x)\}$ 也是一个 CRF。MRF 强调无向马尔科夫依赖，CRF 强调给定观测后的结构化条件分布，两者不是互斥的模型名单。线性链 CRF 是其中计算特别方便的一类，二维网格 CRF 通常不能直接沿用链式动态规划。

能量中的平滑项可以移除孤立误报，也可能抹掉真实细裂纹，因此应依据缺陷宽度和边界误差选择强度。一般含环图的精确推断可能十分昂贵，变量消元的复杂度随树宽增长。置信传播在树上精确，在含环图上通常只是近似且不保证收敛。均值场以较简单的分布逼近联合依赖，Gibbs 采样则逐变量更新。对于二元、次模的成对能量，图割可求全局最小能量，但这一结论不能推广到任意多类别势函数或边缘概率计算。

表 9.1: 链式与无向图模型的建模对象和计算边界。

模型	建模对象	归一化方式	关键限制
HMM	联合分布 $p(x, z)$	转移与观测局部归一化	观测假设和状态持续时间需检验
MEMM	条件分布 $p(z x)$	每个前驱状态局部归一化	标签偏置影响路径评分
链式 CRF	条件分布 $p(z x)$	所有标签路径全局归一化	训练需计算模型期望
MRF	无向图上的联合分布	全部配置全局归一化	一般图中配分函数和推断困难

表9.1按建模对象、归一化方式和推断边界比较图模型；应先决定需要联合生成还是条件预测，再判断链式动态规划是否适用。

MRF的局部更新与均值场。 对固定其他标签 z_{-i} ，不包含 i 的能量项在条件概率的分子分母中相消，因此

$$p(z_i = k | z_{-i}, x) \propto \exp \left\{ -U_i(k; x) - \lambda \sum_{j:(i,j) \in \mathcal{E}} w_{ij}(x) \mathbb{1}\{k \neq z_j\} \right\}. \quad (9.38)$$

逐点从此分布抽样就是Gibbs更新；若改为取最小局部能量，则变为坐标下降，只能保证能量不增而非全局最优。有限状态、适当遍历性和非周期性下Gibbs链以目标分布为平稳分布，强耦合时仍可能混合极慢。

若用乘积分布 $q(z) = \prod_i q_i(z_i)$ 近似，最小化 $\text{KL}(q||p)$ 等价于最小化以下目标：

$$\mathbb{E}_q E + \sum_i \sum_k q_i(k) \log q_i(k). \quad (9.39)$$

固定其他因子并对 q_i 加归一化乘子求导，可得

$$q_i(k) \propto \exp\{-\mathbb{E}_{q_{-i}} E(k, z_{-i}; x)\} \propto \exp\{-U_i(k; x) - \lambda \sum_j w_{ij}(1 - q_j(k))\}. \quad (9.40)$$

这以邻居概率代替确定标签，但忽略联合相关性；逐坐标精确更新改善变分目标，却不保证找到全局最佳近似。二元成对能量可用图割的关键条件是 $V_{ij}(0,0) + V_{ij}(1,1) \leq V_{ij}(0,1) + V_{ij}(1,0)$ ，非负Potts项满足它。图割解决最大概率配置，不提供配分函数或后验区间。

把图结构带回维护任务。 假设要从一次运行记录中识别正常、退化与故障阶段，可以先用独立分类器建立逐点基线。若预测频繁跳变，HMM 用转移持续性与观测模型共同解释状态；若观测特征复杂而状态标注充分，MEMM 和 CRF 可直接学习条件边界。若任务转为表面缺陷的空间连通区域，则链结构不再适用，需要结合图像邻接关系定义条件随机场。模型变化由输出依赖决定，而非由名称的新旧决定。

这些比较必须使用相同的可用观测、标签定义和设备划分。逐点准确率之外，还应检查状态切换延迟、阶段持续时间误差和关键故障段漏检。离线平滑结果只能与离线结果比较，在线过滤应另报实际延迟。若由隐状态概率推导未来故障风险，还需要定义故障事件与状态的关系，并验证预测时间窗，不能把“当前处于退化状态”的概率直接解释成“未来二十四小时故障”的概率。

上述动态规划在参数给定时可以精确计算链式隐状态分布，但这并不意味着参数已经确定。小样本设备的转移矩阵、观测噪声和条件特征权重仍有估计误差。接下来回到参数层，讨论哪些模型可以解析更新，哪些模型需要近似后验。

9.6 从共轭模型到近似推断

共轭模型与近似推断。 若先验与似然属于共轭族，后验可解析求得。例如，伯努利观测的成功概率 p 取Beta先验 $p \sim \text{Beta}(a, b)$ ，观察到 k 次成功、 $n - k$ 次失败后有

$$p \mid \mathcal{D} \sim \text{Beta}(a + k, b + n - k). \quad (9.41)$$

后验均值为

$$\mathbb{E}[p \mid \mathcal{D}] = \frac{a + k}{a + b + n}. \quad (9.42)$$

式(9.42)将先验均值与样本比例按先验强度和观测数量加权。 $a + b$ 越大，先验影响越强。用于故障率时，这个更新假定各次观测在给定 p 后独立且共享同一事件概率，不能直接把大量重叠时间窗视为独立试验。

Beta更新的归一化与预测。 对 $a, b > 0$ ，先验密度为 $p^{a-1}(1-p)^{b-1}/B(a, b)$ ，其中 $B(a, b) = \int_0^1 u^{a-1}(1-u)^{b-1} du$ 。给定独立伯努利序列，似然正比于 $p^k(1-p)^{n-k}$ ，相乘后指数为 $a + k - 1$ 和 $b + n - k - 1$ ，用 $B(a + k, b + n - k)$ 归一化便得到后验。若观测对象只是计数，似然还有 $\binom{n}{k}$ ，它不依赖 p ，不改变后验。

记 $A = a + k$ 、 $B = b + n - k$ （此处大写 B 为参数，不是 Beta 函数），由归一化积分之比得到

$$\mathbb{E}[p \mid \mathcal{D}] = \frac{A}{A+B}, \quad \text{Var}(p \mid \mathcal{D}) = \frac{AB}{(A+B)^2(A+B+1)}, \quad P(Y_* = 1 \mid \mathcal{D}) = \mathbb{E}[p \mid \mathcal{D}]. \quad (9.43)$$

其中 $\mathbb{E}p = \frac{a+b}{a+b+n} \frac{a}{a+b} + \frac{n}{a+b+n} \frac{k}{n}$ ($n > 0$)，显式给出收缩权重。未来 m 次试验的成功数 K_* 满足

$$P(K_* = r \mid \mathcal{D}) = \binom{m}{r} \frac{B(A+r, B+m-r)}{B(A, B)}, \quad 0 \leq r \leq m. \quad (9.44)$$

这是先对二项分布的未知 p 积分所得，不等同于把后验均值代入二项分布：积分后未来试验通过共享 p 相关，从而保留参数不确定性。

共轭关系也适用于连续参数。考虑 $y = X\beta + \varepsilon$ ，其中 $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ ，先验 $\beta \sim \mathcal{N}(m_0, S_0)$ 。当 σ^2 已知时，贝叶斯线性回归的后验仍为高斯分布，其精度矩阵和均值为

$$S_n^{-1} = S_0^{-1} + \sigma^{-2} X^\top X, \quad (9.45)$$

$$m_n = S_n (S_0^{-1} m_0 + \sigma^{-2} X^\top y). \quad (9.46)$$

先验精度与数据精度相加，说明收缩先验如何稳定共线特征下的小样本回归。对新输入 x_* ，预测均值为 $x_*^\top m_n$ ，预测方差为 $\sigma^2 + x_*^\top S_n x_*$ ，分别包含观测噪声和参数不确定性。

高斯后验的配方步骤。 令 $X \in \mathbb{R}^{n \times d}$ 、 $\beta, m_0 \in \mathbb{R}^d$ 、 $S_0 \in \mathbb{R}^{d \times d}$ 正定， $y \in \mathbb{R}^n$ ，且 $\sigma^2 > 0$ 已知。负对数联合密度中依赖 β 的部分为

$$\frac{1}{2}(\beta - m_0)^\top S_0^{-1}(\beta - m_0) + \frac{1}{2\sigma^2}(y - X\beta)^\top(y - X\beta) \quad (9.47)$$

$$= \frac{1}{2}\beta^\top \Lambda \beta - \beta^\top h + \text{常数} \quad (9.48)$$

$$= \frac{1}{2}(\beta - \Lambda^{-1}h)^\top \Lambda(\beta - \Lambda^{-1}h) + \text{常数}, \quad (9.49)$$

其中 $\Lambda = S_0^{-1} + \sigma^{-2} X^\top X$ 、 $h = S_0^{-1} m_0 + \sigma^{-2} X^\top y$ 。识别高斯指数可得 $S_n = \Lambda^{-1}$ 、 $m_n = S_n h$ 。正定先验使 X 秩不足时后验仍适定；实际通过线性方程求解，不必显式求逆。

新观测为 $Y_* = x_*^\top \beta + \varepsilon_*$ ，其中 $x_* \in \mathbb{R}^d$ 且新噪声独立，因此线性高斯和仍为高斯，均值 $x_*^\top m_n$ 、方差 $x_*^\top S_n x_* + \sigma^2$ 。潜在均值区间只含第一项，观测预测区间包含两项。若噪声尺度未知并为其指定共轭先验，积分后常得到 Student 分布，而非直接沿用已知 σ^2 的高斯结论。

复杂深度模型通常没有解析后验，可采用最大后验估计、Laplace 近似、变分推断或 Markov Chain Monte Carlo (MCMC)。变分推断选择易处理的 $q_\phi(\theta)$ 逼近后验，并最

小化

$$\text{KL}(q_\phi(\boldsymbol{\theta}) \| p(\boldsymbol{\theta} | \mathcal{D})). \quad (9.50)$$

通过证据下界 (Evidence Lower Bound, ELBO) 可写成

$$\log p(\mathcal{D}) \geq \mathbb{E}_{q_\phi}[\log p(\mathcal{D} | \boldsymbol{\theta})] - \text{KL}(q_\phi(\boldsymbol{\theta}) \| p(\boldsymbol{\theta})). \quad (9.51)$$

式(9.51)右端的第一项鼓励解释数据, 第二项控制近似后验偏离先验的程度。

这一优化目标来自恒等式

$$\text{KL}(q_\phi(\boldsymbol{\theta}) \| p(\boldsymbol{\theta} | \mathcal{D})) = \log p(\mathcal{D}) - \text{ELBO}(\phi). \quad (9.52)$$

证据对 ϕ 为常数, 因此最大化 ELBO 等价于最小化所选方向的 KL 散度。均值场近似 $q(\boldsymbol{\theta}) = \prod_j q_j(\theta_j)$ 计算方便, 却忽略参数相关性, 可能低估后验方差。结构化变分分布保留部分依赖, 代价是更复杂的计算。

若变分变量 $z \sim \mathcal{N}(\mu_\phi, \sigma_\phi^2)$, 可写成 $z = \mu_\phi + \sigma_\phi \epsilon$, 其中 $\epsilon \sim \mathcal{N}(0, 1)$ 与 ϕ 无关。重参数化把随机性移到外部噪声, 使 ELBO 的梯度能够通过可微变换估计。离散隐状态则未必具有这种可微表示, 应优先检查是否能像 HMM 那样精确求和, 再考虑松弛或得分函数估计。

ELBO恒等式与可计算梯度。 设 q 在联合密度有支持的区域内, 且所需积分有限。把Bayes公式代入KL定义, 逐项展开为

$$\text{KL}(q \| p(\boldsymbol{\theta} | \mathcal{D})) = \mathbb{E}_q \log q - \mathbb{E}_q \log p(\mathcal{D}, \boldsymbol{\theta}) + \log p(\mathcal{D}), \quad (9.53)$$

$$\text{ELBO}(q) = \mathbb{E}_q \log p(\mathcal{D} | \boldsymbol{\theta}) + \mathbb{E}_q \log p(\boldsymbol{\theta}) - \mathbb{E}_q \log q. \quad (9.54)$$

KL非负给出下界, 等号只在 q 等于真实后验 (几乎处处) 时成立。证据最大并不意味着近似最准确: 若不同模型的变分族表达能力不同, 下界差距还混有近似误差。

对均值场 $q(\boldsymbol{\theta}) = \prod_j q_j(\theta_j)$, 固定其他因子, 把ELBO视为 q_j 的函数并加归一化乘子, 可得

$$\log q_j^*(\theta_j) = \mathbb{E}_{q_{-j}} \log p(\mathcal{D}, \boldsymbol{\theta}) + \text{归一化常数}. \quad (9.55)$$

这给出坐标上升更新的来源: 期望或归一化未必能解析算出。若 $\boldsymbol{\theta} = \boldsymbol{\mu} + \mathbf{s} \odot \boldsymbol{\epsilon}$ 、 $\boldsymbol{\epsilon} \sim \mathcal{N}(0, I_d)$ 、 $s_j > 0$, 在可交换微分与积分的可积条件下,

$$\nabla_{\boldsymbol{\mu}} \mathbb{E}_{\boldsymbol{\epsilon}} h(\boldsymbol{\mu} + \mathbf{s} \odot \boldsymbol{\epsilon}) = \mathbb{E}_{\boldsymbol{\epsilon}} \nabla_{\boldsymbol{\theta}} h(\boldsymbol{\theta}), \quad \partial_{s_j} \mathbb{E}_{\boldsymbol{\epsilon}} h(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\epsilon}} [\partial_{\theta_j} h(\boldsymbol{\theta}) \epsilon_j]. \quad (9.56)$$

正态 q 的熵为 $\frac{1}{2} \sum_j \log(2\pi e s_j^2)$, 其对 s_j 的导数为 $1/s_j$, 与联合对数密度梯度合成完整ELBO梯度。可用 $s_j = \exp(\rho_j)$ 保证正值。采样梯度只近似当前变分目标的梯度, 不能消除变分族的结构偏差。




图 9.6: 贝叶斯更新把先验结构与数据证据结合为后验。

贝叶斯更新的几何直观。 贝叶斯公式不仅是概率比例式，也可以理解为在函数空间中重新分配权重。先验把概率质量放在一组可能的参数上，似然根据参数对观测数据的解释能力重新加权，后验再进行归一化。数据量较小时，先验仍然有明显影响；数据量增加后，似然通常占据主导，但这依赖模型假设没有严重错配。

图9.6将先验与数据证据汇入后验，强调后验结论同时依赖结构假设和观测；检验预测可信度时不能只检查数据拟合。

9.7 模型比较与不确定性计算

从 Maximum A Posteriori (MAP) 到正则化。 最大后验估计最大化

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \log p(\mathcal{D} | \theta) + \log p(\theta). \quad (9.57)$$

以高斯先验 $p(\theta) \propto \exp(-\lambda \|\theta\|_2^2/2)$ 为例，负对数后验等价于经验损失加上 $\lambda \|\theta\|_2^2/2$ 。因此正则化并不是一个与概率建模无关的工程技巧，而是在特定先验下的推断结果。需要注意的是，正则化系数、噪声方差和先验方差之间存在耦合，不能脱离似然尺度解释 λ 。

边际似然与模型比较。 边际似然

$$p(\mathcal{D}) = \int p(\mathcal{D} | \theta) p(\theta) d\theta \quad (9.58)$$

同时惩罚拟合不足和模型过度灵活。它与只比较训练集似然不同，因为参数空间中大量不能解释数据的区域会降低平均证据。实际计算边际似然通常困难，可使用 ELBO、Laplace 近似或信息准则近似。模型比较时还应明确先验是否改变，因为不同先验下的边际似然不具有无条件可比性。

Laplace 近似。 在后验众数 $\hat{\theta}$ 附近，对负对数后验 $U(\theta) = -\log p(\theta | \mathcal{D})$ 做二阶 Taylor 展开：

$$U(\theta) \approx U(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^\top H(\theta - \hat{\theta}), \quad H = \nabla^2 U(\hat{\theta}). \quad (9.59)$$

于是后验近似为 $\mathcal{N}(\hat{\theta}, H^{-1})$ 。该近似在后验近似单峰且局部二次时有效；深度网络存在对称性、多峰和平坦方向时，单个高斯可能严重低估不确定性。

从局部二次式到归一化常数。若 $\hat{\theta} \in \mathbb{R}^d$ 为内部驻点且 H 正定，线性项因梯度为零而消失。指数化二阶式，并用高斯积分

$$\int \exp\{-\frac{1}{2}u^T H u\} du = (2\pi)^{d/2} |H|^{-1/2} \quad (9.60)$$

归一化，便得到协方差 H^{-1} 。若从未归一化密度 $\tilde{p}(\theta) = p(\mathcal{D} | \theta)p(\theta)$ 出发，同样推得

$$\log p(\mathcal{D}) \approx \log \tilde{p}(\hat{\theta}) + \frac{d}{2} \log(2\pi) - \frac{1}{2} \log |H|. \quad (9.61)$$

它同时考虑峰高与峰附近体积，而不是只看最大似然。边界众数、奇异Hessian、多峰或不适当先验会使这一步失效；加入数值阻尼可改善线性代数，却不是证明原后验本来就是该高斯。

MCMC 的接受率直观。 Metropolis-Hastings 从当前状态 θ 提出候选 θ' ，以

$$\alpha = \min \left\{ 1, \frac{p(\theta' | \mathcal{D})q(\theta | \theta')}{p(\theta | \mathcal{D})q(\theta' | \theta)} \right\} \quad (9.62)$$

的概率接受。候选分布步长过小会导致样本高度相关，步长过大则接受率过低。实际诊断不能只看链是否“运行完成”，还应检查 burn-in、有效样本量、自相关和多条链之间的混合。

表 9.2: 贝叶斯推断方法的工程取舍

方法	近似对象	优势	主要风险与适用场景
MAP	后验众数	成本低、易扩展、适合在线更新	忽略参数不确定性，适合作为基线
Laplace	众数附近的高斯曲率	能快速产生局部区间	多峰、对称和非二次后验会导致低估
变分推断	可处理的 $q_\phi(\theta)$	可用随机梯度扩展到大模型	均值场假设常低估相关性和方差
MCMC	后验样本链	理论上逼近目标后验	计算昂贵，必须检查混合和有效样本量

表9.2区分局部近似、变分优化与采样的计算取舍；选用方法时应把其近似误差和诊断要求与后验形状共同考虑。

接受率为何保持目标分布。 记目标密度为 $\pi(\theta)$ 。对不同状态 θ, θ' ，Metropolis-Hastings (MH) 的双向概率流满足

$$\pi(\theta)q(\theta' | \theta)\alpha(\theta, \theta') = \min\{\pi(\theta)q(\theta' | \theta), \pi(\theta')q(\theta | \theta')\} \quad (9.63)$$

$$= \pi(\theta')q(\theta | \theta')\alpha(\theta', \theta). \quad (9.64)$$

这就是细致平衡；拒绝时停留原位使转移核的总概率为一。对当前状态积分可验证 π 不变，且后验的未知证据常数在比值中消去。平稳性不等于有限步已收敛；还需要能到达目标支持、非周期性及相关遍历条件。对称提议可约去 q ，非对称提议遗漏该比值则会改变目标分布。

9.8 校准、诊断与工业决策

不确定性的分解与校准。 预测方差可用全概率方差公式分解：

$$\text{Var}(y_* | x_*, \mathcal{D}) = \mathbb{E}_{p(\theta|\mathcal{D})}[\text{Var}(y_* | x_*, \theta)] + \text{Var}_{p(\theta|\mathcal{D})}[\mathbb{E}(y_* | x_*, \theta)]. \quad (9.65)$$

式(9.65)右端的第一项主要对应观测噪声，第二项对应参数不确定性。模型给出的区间还必须经过覆盖率检查：预测百分之九十区间不应只在训练分布内覆盖百分之六十的真实值。对于工业决策，区间宽度与错误成本同样重要。

全方差公式的推导与估计。 省略给定的 x_* , $\mathcal{D}$ ，记 $m_\theta = \mathbb{E}[Y_* | \theta]$ 、 $m = \mathbb{E}_\theta m_\theta$ ，则 $Y_* - m = (Y_* - m_\theta) + (m_\theta - m)$ 。平方后取期望，交叉项为零，因为 $\mathbb{E}[Y_* - m_\theta | \theta] = 0$ ，从而得到全方差公式。这个分解是在指定模型内的，不包含模型类别错设所遗漏的不确定性。

若有 S 个参数样本，并能计算条件均值 m_s 及方差 v_s ，令 $\bar{m} = S^{-1} \sum_s m_s$ ，则经验混合分布的精确方差为

$$\hat{v} = \frac{1}{S} \sum_s v_s + \frac{1}{S} \sum_s (m_s - \bar{m})^2. \quad (9.66)$$

若目的是无偏估计独立后验样本的均值间方差，第二项可改用 $S-1$ 分母，但这时不再是该有限混合的精确方差。回归区间需从完整预测混合求分位数，不能仅对 m_s 取分位数后声称覆盖有噪声观测。对于重尾或多峰预测， $\bar{m} \pm 1.96\sqrt{\hat{v}}$ 也不一定是95%区间。

贝叶斯方法的常见误用。 使用贝叶斯模型时，可以从结果倒查计算过程。先检查报告的概率与实际发生频率是否相符，再检查陌生工况下模型是否仍然过度自信。后验方差只反映当前模型表达的未知量，模型没有考虑到的故障机制可能根本不会使它增大。先验也应写明来源和尺度；如果近似算法尚未稳定，计算误差甚至可能大于想要估计的参数不确定性。

预测分布的蒙特卡洛近似。 当后验积分无法解析计算时，可从后验得到 S 个样本 $\theta^{(s)}$ ，使用

$$p(y_* | x_*, \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S p(y_* | x_*, \theta^{(s)}). \quad (9.67)$$

注意先平均概率再取最大类别；平均 logits 或平均类别标签一般不等价。对回归，可由每个参数样本产生一条预测，再计算总方差和分位数区间。 S 太小会造成蒙特卡洛噪声，样本相关时有效样本量还会进一步下降。

MCMC 诊断不能省略。 链的轨迹图可以检查是否进入稳定区域，自相关函数衡量样本冗余，有效样本量近似为

$$ESS \approx \frac{S}{1 + 2 \sum_{k \geq 1} \rho_k}. \quad (9.68)$$

多条不同初始状态的链还应比较 $\hat{R}$ 等收敛指标。若链只在后验的一个模式附近游走，表面上的稳定并不代表全局混合良好。工业高维模型通常更偏向近似推断，但这并不意味着可以跳过近似质量和预测覆盖率检查。

Effective Sample Size (ESS)是针对哪个估计量。对平稳链上的标量 $h(\theta^{(s)})$ ，设其方差为 v_h 、滞后相关为 ρ_k ，展开样本均值的协方差和得

$$\text{Var} \left(\frac{1}{S} \sum_s h(\theta^{(s)}) \right) = \frac{v_h}{S} \left[1 + 2 \sum_{k=1}^{S-1} (1 - k/S) \rho_k \right]. \quad (9.69)$$

当相关可求和且链足够长时，匹配独立样本均值的方差便得到前述ESS。不同参数、尾部概率和维护成本函数有不同的自相关，因此不存在适用于所有结论的单一ESS。短链直接相加所有经验相关会很不稳定，需截断或稳定的谱估计；尚未进入平稳区或未跨模式时，这个局部诊断不能证明准确性。

先验敏感性分析。先验选择应通过敏感性分析验证。对故障率、噪声尺度或参数收缩强度使用几组合理先验，比较后验预测和决策是否稳定。若结果对先验极其敏感，说明数据不足、模型可识别性弱，或先验承担了过多结论。此时应增加数据、改进测量或明确报告先验依赖，而不是只选择产生最好结果的先验。

校准、覆盖率与风险。预测区间覆盖率和区间宽度需要同时观察。过宽的区间容易达到覆盖率，却可能没有决策价值；过窄的区间看似精确，却会造成过度自信。对分类概率，可按置信度分箱比较预测概率和经验事件率；对回归区间，可按设备、工况和预测提前量分层检查。校准应在独立验证数据上完成，并在部署漂移后持续监测。

小样本故障率的后验决策。某设备在新工况下运行20次，观察到2次异常。若采用Beta(1, 9)先验，则后验为Beta(3, 27)，后验均值为0.1。直接使用样本比例得到的估计也是0.1，但二者对未来风险的表达不同：后验还包含小样本造成的宽区间。若把“安排人工复检”的成本记为 C_I ，把一次漏检损失记为 C_M ，则当后验异常概率满足

$$p(\text{异常} | \mathcal{D}) C_M > C_I \quad (9.70)$$

时才应触发复检。这样，概率输出通过成本函数转化为动作，而不是凭经验固定一个看似通用的阈值。

该例还说明先验不是隐藏的常数。若先验改为Beta(1, 1)，后验均值变为3/22；两种结果的差异提示当前数据不足以完全决定风险。工程报告应同时给出先验、后验和决策阈值，使不同团队可以复核结论。

回归预测区间的覆盖实验。 假设模型对每台设备输出均值 μ_i 和标准差 σ_i ，构造区间 $[\mu_i - 1.96\sigma_i, \mu_i + 1.96\sigma_i]$ 。在验证集上统计真实值落入区间的比例，并分别按设备、环境温度和预测提前量分组。若整体覆盖率为0.94，但高温工况只有0.71，则总体数字掩盖了局部失效。可以在独立校准集上估计分位数修正因子，再在另一段时间上复验，避免把校准集上的偶然波动误认为改进。

区间宽度也应进入报告。两个模型可能具有相同覆盖率，但一个区间宽得无法指导维护，另一个区间更窄且只在少数工况失效。因而应联合绘制覆盖率、平均区间宽度和漏覆盖成本，并说明校准是否使用了未来数据。

后验预测检查的操作步骤。 后验预测检查不是把训练数据重新拟合一次，而是从后验参数样本生成复制数据 $\tilde{y}$ ，比较 $\tilde{y}$ 与真实数据的统计量。例如可比较均值、方差、极值数量、故障持续时间和相邻残差相关性。若模型能匹配均值却无法产生真实的长尾，说明其似然假设不适合风险评估。工业案例中，检查统计量应优先选择与维护动作相关的量，而不是只选择容易展示的总体误差。

本章小结。 贝叶斯更新表达参数在当前证据下仍有多少不确定性，概率图模型则明确状态、观测和标签之间保留哪些依赖。HMM 建模状态与观测的联合分布，MEMM 和 CRF 直接建模条件状态分布，MRF 将邻接关系推广到一般无向图。结构决定可以使用哪些推断算法，参数学习决定这些算法依据什么概率进行计算。即使推断在数学上精确，错误的观测假设或时间边界仍会使维护决策失效。后验预测检查、覆盖率与先验敏感性因此构成模型使用前的检验，而不是公式推导后的附加说明。

贯穿这些方法的共同步骤是先写联合或条件分布，再利用结构进行求和、积分或近似，最后在实际成本下解释预测。解析解提供清楚的参照，动态规划节省状态枚举，变分与采样处理无法解析的参数积分；各自的适用边界都来自前提，而非算法名称。小样本复检案例中的阈值还隐含复检能消除所计漏检损失的简化假设，若检查不完美或有后续成本，应扩充动作损失再取后验期望。

下一章继续使用概率，但不只给有限个系数设分布，还直接考虑可能的函数。线性高斯后验中用过的配方，将再次用于高斯过程的条件分布；核函数则说明两个输入有多相似、相应的函数值应有多大相关性。读者可以据此比较参数化与非参数化模型的灵活程度、先验假设和计算开销。

第十章 参数化与非参数化模型

本章摘要。本章比较两种表达函数复杂度的方式：参数化模型用有限维参数概括规律，非参数化模型则通过核、邻域或函数分布保留更灵活的形状。高斯过程和核方法贯穿全文，用来说明先验结构、计算代价和小样本性能之间的权衡，并与上一章的贝叶斯推断自然衔接。

上一章用参数后验解释有限证据下的未知规律，但一个分布再精确，也受它所依附的模型结构限制。本章进一步问：一定要先选有限个回归系数再描述函数吗？能否直接规定不同输入处函数值如何共同变化，再由观测决定局部形状？参数化与非参数化的区别，正落在这个结构选择上。

假设要根据转速预测温升，可以先找转速相近的历史记录取平均，这就是近邻方法的直观起点。核方法用相似程度决定记录之间怎样相互影响，高斯过程进一步描述可能的函数及其概率。方法越灵活，越需要考虑样本是否足够、计算是否承受得起。还要分清一个预测数值和一整个预测分布：两个方法给出相同的平均温升，并不意味着它们对预测有同样的把握。

10.1 两个概念

参数化模型用固定维度参数描述分布，例如线性回归 $y = \mathbf{w}^\top x + b + \varepsilon$ 。无论样本数如何增加，参数维度仍由输入维度和模型设计决定。非参数化模型不预先固定同样意义上的有限参数维度，而允许模型复杂度随数据增长，例如 k 近邻、高斯过程和Dirichlet过程模型。

近邻回归：由局部常数假设得到估计。设 $x_i \in \mathbb{R}^d$ 、 $Y_i = f^*(x_i) + \varepsilon_i$ ，给定输入后噪声独立、均值为零且方差为 σ^2 。固定查询 x ，按预先规定距离选出 k 个近邻集合 $N_k(x)$ 。若假设该邻域内函数近似常数 c ，最小化 $\sum_{i \in N_k(x)} (Y_i - c)^2$ 的一阶条件为 $2 \sum_i (c - Y_i) = 0$ ，所以

$$\hat{f}_k(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i. \quad (10.1)$$

给定训练输入，条件偏差为 $k^{-1} \sum_{i \in N_k(x)} f^*(x_i) - f^*(x)$ ，条件方差为 σ^2/k 。若 f^* 为 L_f -Lipschitz函数，近邻最远距离为 $r_k(x)$ ，则

$$|\text{Bias}(x)| \leq L_f r_k(x), \quad \mathbb{E}[(\hat{f}_k(x) - f^*(x))^2 | X] \leq L_f^2 r_k(x)^2 + \sigma^2/k. \quad (10.2)$$

增大 k 降低噪声方差，却扩大邻域偏差。若局部密度为正且规则，典型半径量级为 $(k/n)^{1/d}$ ，平衡两项得到 k 约为 $n^{2/(d+2)}$ 、均方误差量级约为 $n^{-2/(d+2)}$ ；这是基于光滑与密度条件的局部量级论证，而非对任何数据的保证。维度越高，邻域收缩越慢，这就是距离方法的维数困难。分类近邻则平均类别指示以估计局部类别概率。

一致性通常要求 $k \rightarrow \infty$ 且 $k/n \rightarrow 0$ ，并附加分布与正则条件；固定 k 一般保留不可消失的方差。距离尺度、无关特征和跨工况混合都可能破坏局部相似假设。朴素查询需约 $O(nd)$ 距离计算，快速索引在高维也可能失效。




图 10.1: 高斯过程用观测点附近的函数相关性收缩后验方差；远离数据时预测区间通常变宽。

高斯过程示例。 高斯过程（Gaussian process, GP）直接在函数空间上定义先验：任意有限输入集合对应的函数值服从联合高斯分布，记为 $f \sim \mathcal{GP}(m, k)$ 。给定训练输入 X 和观测 $y = f(X) + \varepsilon$ ，其中 $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ ，新点 x_* 的后验均值为

$$\mu_* = m(x_*) + k_*^\top (K + \sigma^2 I)^{-1} (y - m(X)), \quad (10.3)$$

后验方差为

$$\sigma_*^2 = k(x_*, x_*) - k_*^\top (K + \sigma^2 I)^{-1} k_*. \quad (10.4)$$

这里 X 的 n 行分别为训练输入的转置， $y \in \mathbb{R}^n$ 为观测列向量， m 为先验均值函数， $m(X) = [m(x_1), \dots, m(x_n)]^\top$ ， $K_{ij} = k(x_i, x_j)$ ， $k_* = [k(x_1, x_*), \dots, k(x_n, x_*)]^\top$ 。噪声与潜在函数独立。式(10.4)针对潜在函数值 $f(x_*)$ ；若预测含独立同方差噪声的新观测，还需加上 σ^2 。核函数 k 表达“相似输入应有相似函数值”的先验。远离训练样本时，预测方差通常增大，这提供了自然的不确定性信号。

图10.1将观测点、预测曲线与不确定性带放在同一坐标中，提示读者区分均值拟合和区间宽度；远处是否回到先验还取决于所选核的相关结构。

GP后验不是另一个需要记忆的公式。 设 $C = K + \sigma^2 I_n$ ，训练中心化观测 $r = y - m(X)$ ，新点中心化函数值 $g_* = f(x_*) - m(x_*)$ 。GP定义和独立高斯噪声给出

$$\begin{bmatrix} r \\ g_* \end{bmatrix} \sim \mathcal{N} \left(0, \begin{bmatrix} C & k_* \\ k_*^\top & k_{**} \end{bmatrix} \right), \quad k_{**} = k(x_*, x_*). \quad (10.5)$$

构造残差 $u = g_* - k_*^\top C^{-1} r$ ，直接计算 $\text{Cov}(u, r) = k_*^\top - k_*^\top C^{-1} C = 0$ 。联合高斯中不相关意味着独立，且

$$\text{Var}(u) = k_{**} - k_*^\top C^{-1} k_*. \quad (10.6)$$

因此给定 r 时 u 仍为同一零均值高斯，恢复先验均值便得到式(10.3)与式(10.4)。这个证明同时说明减去的项为何非负： C 正定时 $k_*^T C^{-1} k_* \geq 0$ ；整个条件方差非负则由联合协方差的半正定性保证。

对 m 个新点， $K_{X_*} \in \mathbb{R}^{n \times m}$ 、 $K_{**} \in \mathbb{R}^{m \times m}$ ，后验协方差为 $K_{**} - K_{X_*}^T C^{-1} K_{X_*}$ 。各点之间通常相关，不能把多个边际区间当作整条曲线的同时置信带。若核超参数固定，此协方差只依赖输入而不依赖观测值；异常的 y 不会自动增大方差。

$\sigma^2 > 0$ 使半正定 K 对应的 C 正定；无噪声且有重复输入时需处理奇异性。只有当远处 k_* 趋近零时，后验才回到先验均值和先验方差；周期核等结构可能在距离很远时仍高度相关。因此“远离数据更不确定”是常见核下的行为，而非GP定义本身的普适结论。

10.2 核方法、函数空间与计算边界

支持向量机展示了核函数如何把线性判别推广到非线性空间，稀疏高斯过程则以诱导变量降低函数后验近似的计算成本[18, 106]。核化与贝叶斯函数建模可以共享工具，但优化目标和不确定性含义不同。

联系而非对立。 参数化和非参数化并不是“现代”和“传统”的划分。神经网络是有限参数模型，但宽网络和核方法之间存在理论联系；贝叶斯神经网络在有限参数空间上保留后验；核方法则把参数学习转化为函数空间中的推断。真正的选择依据是数据量、计算资源、先验结构、预测任务和对不确定性的要求。

说明 10.1. 当数据量很少而风险可解释性重要时，结构清晰的参数化概率模型往往更合适；当关系复杂且数据充足时，深度参数化模型可以提供更强的表示能力。两者都必须通过验证数据和任务指标检验。

参数模型中的先验结构。 参数化并不意味着没有先验。线性模型假设输入与输出的关系可由有限维方向表达；多项式模型增加曲率；状态空间模型把时间依赖写入转移方程。参数越少通常越容易估计，但若结构假设错误，偏差会成为主要误差来源。选择参数化模型就是选择哪些变化被认为值得显式表达。

核方法的函数空间视角。 核函数 $k(x, x')$ 定义了输入相似性。核岭回归的预测可以写成训练样本核函数的线性组合：

$$f(x) = \sum_{i=1}^n \alpha_i k(x_i, x). \quad (10.7)$$

核技巧把高维特征映射隐含在内积中，但训练通常需要处理 $n \times n$ 核矩阵，样本规模增大时计算和存储成为瓶颈。稀疏近似、随机特征和 inducing points 可以降低这一代价。

什么相似性可以成为核。 合法实值核必须对称，并对任意有限输入和 $a \in \mathbb{R}^n$ 满足 $\sum_{ij} a_i a_j k(x_i, x_j) \geq 0$ ，即Gram矩阵半正定。若 $k(x, x') = \phi(x)^\top \phi(x')$ ，该二次式等于 $\|\sum_i a_i \phi(x_i)\|^2$ ，因此自动满足条件；任意手写距离的负值却不一定是合法核。

平方指数核 $k(x, x') = s_f^2 \exp[-\frac{1}{2} \sum_j (x_j - x'_j)^2 / \ell_j^2]$ 用 $\ell_j > 0$ 控制各维相关长度， $s_f^2 > 0$ 控制函数幅度。长度很大意味着该维变化难以使函数改变，长度很小则允许快速波动。核的非负加权和仍为核，可组合平滑、线性或周期结构，但组合之前应确定各分量对应什么物理变化。

核岭回归的表示与系数求解。 在核对应的再生核Hilbert空间 $\mathcal{H}_k$ 中，再生性质为

$$f(x_i) = \langle f, k(x_i, \cdot) \rangle. \quad (10.8)$$

考虑 $\lambda > 0$ 时的目标

$$J(f) = \frac{1}{2n} \sum_i (y_i - f(x_i))^2 + \frac{\lambda}{2} \|f\|_{\mathcal{H}_k}^2. \quad (10.9)$$

把 f 正交分解为训练核函数张成空间中的 $f_{\parallel}$ 与 $f_{\perp}$ 。再生性质给出 $f_{\perp}(x_i) = 0$ ，故去掉 $f_{\perp}$ 不改变训练拟合，却将范数平方减少 $\|f_{\perp}\|^2$ 。最优解必可写为 $f(\cdot) = \sum_i \alpha_i k(x_i, \cdot)$ ，这就是此处表示结论的推导。

代入后 $J(\alpha) = \|y - K\alpha\|^2 / (2n) + \lambda \alpha^\top K \alpha / 2$ ，梯度条件为 $K[(K + n\lambda I)\alpha - y] = 0$ 。可选稳定解

$$\alpha = (K + n\lambda I_n)^{-1} y. \quad (10.10)$$

若 K 奇异，不能在梯度式中随意约去 K ；但式(10.10)的解仍有效，系数的零空间差异表示同一个函数。正则化保证函数解唯一。零均值GP在 $\sigma^2 = n\lambda$ 时与核岭回归均值相同，但核岭目标本身不定义观测噪声或预测方差，不能直接把两者的不确定性等同。

从有限参数高斯先验得到核。 令 $f(x) = \phi(x)^\top w$ ， $\phi(x) \in \mathbb{R}^p$ 、 $w \sim \mathcal{N}(0, S)$ 。任意有限函数值均为高斯线性变换，协方差为 $k(x, x') = \phi(x)^\top S \phi(x')$ 。令 $\Phi \in \mathbb{R}^{n \times p}$ ，则参数后验给出的均值与函数空间表达相等：

$$(S^{-1} + \sigma^{-2} \Phi^\top \Phi)^{-1} \sigma^{-2} \Phi^\top = S \Phi^\top (\Phi S \Phi^\top + \sigma^2 I)^{-1}. \quad (10.11)$$

在 S 正定时，左右两边同乘左侧精度矩阵即可验证恒等式。它说明有限秩核GP也可有固定有限参数表示；所谓非参数性主要针对可随样本扩展的无限秩函数类，而不是“出现核就绝无有限参数”。

核支持向量机的对偶来源。 对 $y_i \in \{-1, 1\}$ ，软间隔分类在特征空间中求

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i, \quad y_i (\langle w, \phi(x_i) \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \quad (10.12)$$

给两组不等式加入乘子 $\alpha_i, \mu_i \geq 0$ 。对 w, b, ξ_i 的驻点条件分别为 $w = \sum_i \alpha_i y_i \phi(x_i)$ 、 $\sum_i \alpha_i y_i = 0$ 、 $C - \alpha_i - \mu_i = 0$ 。代回拉格朗日函数得

$$\max_{0 \leq \alpha_i \leq C, \sum_i \alpha_i y_i = 0} \sum_i \alpha_i - \frac{1}{2} \sum_{ij} \alpha_i \alpha_j y_i y_j k(x_i, x_j). \quad (10.13)$$

凸性和可行条件使对偶可用于求解；预测得分为 $\sum_i \alpha_i y_i k(x_i, x) + b$ 。若 $0 < \alpha_i < C$ ，互补松弛给出对应样本位于间隔边界，可用于计算 b 。非零系数对应支持向量。间隔得分不是故障概率，仍须单独校准；核矩阵半正定则是凸优化性质的重要前提。

高斯过程的边际似然。 高斯过程不仅给出预测均值，还能通过边际似然选择核参数和噪声尺度：

$$\log p(y | X) = -\frac{1}{2} (y - m(X))^T K_y^{-1} (y - m(X)) - \frac{1}{2} \log |K_y| - \frac{n}{2} \log(2\pi). \quad (10.14)$$

其中 $K_y = K + \sigma^2 I$ ， $|K_y|$ 表示行列式； $m \equiv 0$ 时得到零均值先验的简式。第一项衡量拟合，第二项惩罚过于灵活的函数空间。这个 Occam 因子体现了贝叶斯模型选择中“拟合与复杂度”的统一，但矩阵分解成本通常为 $O(n^3)$ 。

边际似然的积分、导数与数值实现。 由 $f_X \sim \mathcal{N}(m_X, K)$ 及 $y = f_X + \varepsilon$ ，独立高斯相加后 $y \sim \mathcal{N}(m_X, C)$ ， $C = K + \sigma^2 I$ ；把这个 n 维高斯密度取对数就得到式(10.14)。这一步已经积分掉函数值，并不是将最优函数值代入似然。

设超参数为 η ， $r = y - m_X$ 、 $a = C^{-1}r$ 。利用 $d \log |C| = \text{tr}(C^{-1}dC)$ 和 $dC^{-1} = -C^{-1}(dC)C^{-1}$ ，逐项微分得到

$$\frac{\partial \log p(y | X)}{\partial \eta} = \frac{1}{2} \text{tr} \left[(aa^T - C^{-1}) \frac{\partial C}{\partial \eta} \right] + \left(\frac{\partial m_X}{\partial \eta} \right)^T a. \quad (10.15)$$

核长度、幅度和噪声可据此优化，正尺度通常取对数参数化。目标不保证凸，应检查多起点和边界。将超参数估计后固定属于经验贝叶斯，预测区间未包含超参数不确定性；充分贝叶斯做法还要对其后验积分。

数值上分解 $C = LL^T$ ，解 $Lv = r$ 、 $L^T a = v$ ，可计算 $r^T C^{-1} r = v^T v$ 及 $\log |C| = 2 \sum_i \log L_{ii}$ 。预测时解 $Lu = k_*$ ，方差为 $k_{**} - u^T u$ ，无需存储逆矩阵。浮点误差可能出现极小负方差，需结合残差和条件数诊断；不能把显著负值简单截断后忽略错误。训练分解为 $O(n^3)$ 时间、 $O(n^2)$ 存储，单点方差通常需 $O(n^2)$ 求解。

行列式项不是独立的万能复杂度标尺。 若 $C = U \text{diag}(c_j) U^T$ ，中心化边际负对数似然为 $\frac{1}{2} \sum_j [(u_j^T r)^2 / c_j + \log c_j] + \frac{n}{2} \log(2\pi)$ 。增大某方向方差会减小残差惩罚，却增加归一化代价，两项共同决定折中。不能脱离数据与核谱，把行列式项简单解释成参数越多就惩罚越大。

非参数模型的计算边界。 非参数模型可以表达复杂结构，却不代表复杂度无限且没有代价。kNN 的查询成本随样本数增加；核方法受核矩阵限制；高斯过程的后验更新需要处理越来越大的协方差矩阵。实际部署常用近似推断、原型压缩、局部模型或分层采样。

诱导变量如何降低代价。 选 $m \ll n$ 个诱导输入 Z ，令 $u = f(Z) \in \mathbb{R}^m$ 。为简化取零均值， $K_{uu} \in \mathbb{R}^{m \times m}$ 可逆， $K_{Xu} \in \mathbb{R}^{n \times m}$ 。高斯条件公式给出

$$p(f_X | u) = \mathcal{N}(K_{Xu}K_{uu}^{-1}u, K - Q), \quad Q = K_{Xu}K_{uu}^{-1}K_{uX}. \quad (10.16)$$

这里 $K - Q$ 是诱导变量未解释的条件协方差，不能只因为使用低秩表示就断言它为零。取近似联合 $q(f_X, u) = p(f_X | u)q(u)$ ，ELBO 化为 $\mathbb{E}_q \log p(y | f_X) - \text{KL}(q(u) \| p(u))$ 。对高斯噪声，先在 $p(f_X | u)$ 下取期望，得到

$$\mathbb{E}[\log p(y | f_X) | u] = \log \mathcal{N}(y | K_{Xu}K_{uu}^{-1}u, \sigma^2 I) - \frac{\text{tr}(K - Q)}{2\sigma^2}. \quad (10.17)$$

再对自由 $q(u)$ 优化，利用 $\sup_q \{\mathbb{E}_q \log h(u) - \text{KL}(q \| p)\} = \log \int h(u)p(u) du$ ，可得

$$\mathcal{L} = \log \mathcal{N}(y | 0, Q + \sigma^2 I) - \frac{\text{tr}(K - Q)}{2\sigma^2}. \quad (10.18)$$

迹修正惩罚遗漏的函数变异，因此这不是随意用 Q 替换 K 的精确模型。借助低秩恒等式主要成本可降至 $O(nm^2 + m^3)$ 、存储 $O(nm)$ ；诱导点过少或位置不当会遗漏局部故障结构。 $m = n$ 、诱导输入等于训练输入且矩阵适定时， $Q = K$ 恢复精确训练证据。

随机特征的另一路近似。 对适当的平稳正定核，可将核写为频率分布下 $\mathbb{E}_\omega \cos(\omega^\top(x - x'))$ （幅度单独处理）。采样 ω_j 和 $b_j \sim \text{Uniform}(0, 2\pi)$ ，设 $\phi_j(x) = \sqrt{2/m} \cos(\omega_j^\top x + b_j)$ ，由相位积分和独立平均有 $\mathbb{E}[\phi(x)^\top \phi(x')] = k(x, x')$ 。这把核问题变成 m 维线性问题，但有限 m 引入随机近似误差；适用的频率分布由核决定，不能对任意相似性随意采样。

参数化与非参数化的混合。 这些方法也可以组合使用。例如先用神经网络把振动窗口压成低维特征，再用 GP 预测并给出模型内的不确定性。这里若把编码器固定，GP 的区间通常不会自动包含编码器本身的不确定性。另一些任务只需在冻结特征上重新训练线性头，或用状态空间先验约束序列预测。组合前要说明每部分负责什么、哪些误差仍未计入，不能因为接上概率模型就认为整个系统已经校准。

模型选择案例。 小样本温度预测可以从线性回归、核岭回归和高斯过程开始，比较留出设备上的误差、区间覆盖率、训练时间和增量更新成本。若数据规模扩大且输入包含图像或长序列，再考虑深度模型。这个顺序能够先验证任务是否可预测，再决定是否需要更复杂的表示学习。

本章小结。 参数化模型以明确结构换取估计效率和解释性，非参数化模型以更灵活的函数空间换取计算成本。二者不是互斥阵营，关键是让模型复杂度、数据量、先验知识和不确定性需求相互匹配。

从局部常数的近邻估计，到再生核空间的正则解，再到高斯联合分布的条件化，本章展示了三种共享样本信息的机制。核规定哪些输入相关，正则或先验规定允许多大变化，近似方法规定在预算内保留哪些变化；任何一个环节都可能成为偏差来源。相同预测均值不意味着相同概率解释，较宽函数空间也不意味着在未覆盖工况下必然诚实地表达不确定性。

到这里，我们已经从参数分布走到了函数分布。下一章把读数按时间排好：平均温度相同，持续升温 and 持续降温却可能需要不同处理。序列网络、状态空间模型和时间核各有办法利用这种顺序。比较时继续检查它们如何表达依赖、需要多少计算，以及给出的不确定性究竟针对潜在规律还是未来读数。

第三部分

深度学习模型

本部分从维护流程中尚未解决的问题出发。统计特征遗漏演化过程时，需要序列表示；风险分数不能指出缺陷位置时，需要视觉定位；检测结果不足以确定复检步骤时，需要检索有效规程；单路证据含糊时，需要跨模态对齐；真实故障覆盖不足时，才讨论生成数据。后续章节沿用第[四](#)章的信息可用性原则，但分别定义预测、定位、问答和合成的验收对象，不能用一种任务的高分证明另一种任务也有效。

第十一章 序列建模模型

本章摘要。本章围绕一个核心问题展开：如何把历史信息压缩成对未来有用的状态。先介绍 Recurrent Neural Network (RNN)、Long Short-Term Memory (LSTM) 和 Gated Recurrent Unit (GRU) 的递归记忆，再解释注意力与 Transformer 如何改变信息访问路径，随后讨论状态空间滤波、长序列计算、多步预测和异常告警。模型比较最终要检查时间边界、提前量、非平稳性与资源消耗。

窗口统计量可以描述振动强度，却可能抹去冲击出现的顺序。本章由此研究如何表示截至 t 的历史信息。故障概率、剩余寿命和未来轨迹是三种不同输出，后文的分钟级轨迹预测用于说明多步误差，不能与二十四小时故障概率直接比较。递归状态、注意力和状态空间模型的取舍，取决于输出需要保留哪些历史证据。前两章已经区分参数化表示、函数先验和预测不确定性，本章进一步追问：当观测按时间到达时，哪些信息应随状态一起保留下来？一个温度均值相同的窗口，可能对应平稳运行，也可能对应持续升温后骤降；只把窗口当作无序样本，就丢掉了区分这两种过程的依据。因此，序列建模不是在回归器前多加一个时间下标，而是规定历史如何进入当前判断，以及新的观测怎样修正已有判断。

读公式时，先看模型怎样保存历史。递归模型把过去压进一个状态，注意力可以回头读取历史记录，卷积和状态空间模型则按各自的结构传递信息。再看这个状态是否还带有协方差：一组确定数值和一个状态分布，能表达的不确定性不同。最后核对输出到底是什么。预测未来温度曲线、预测故障概率和给当前窗口打异常分数，需要不同的标签，也对应不同的维护动作。

11.1 序列与状态

图11.1中，纵向箭头把当前输入写入状态，横向箭头将历史传到下一时刻，最终预测因而依赖状态保留下来的信息。LSTM 的门控记忆用于改善长时依赖中的信息与梯度传播[40]。与之相对，线性高斯状态估计中的 Kalman 滤波显式传播状态均值和协方差[48]；二者不能因为都有隐状态就被视为相同的推断方法。序列数据 $(x_1, \dots, x_T)$ 具有顺序依赖。状态空间模型用隐状态 h_t 压缩历史信息：

$$h_t = g(h_{t-1}, x_t), \quad p(y_t \mid x_{\leq t}) = p(y_t \mid h_t). \quad (11.1)$$

状态的核心作用不是记住所有历史，而是在给定任务下保留预测未来所需的信息。




图 11.1: 递归序列模型把历史压缩为状态; 状态维度和更新机制决定哪些信息能够持续保留。

递归状态与门控记忆。 最基本的RNN为 $h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$ 。反向传播时, 梯度包含多个 W_h 的乘积, 可能出现梯度消失或爆炸。LSTM通过门控缓解这一问题:

$$i_t = \sigma(W_i x_t + U_i h_{t-1}), \quad f_t = \sigma(W_f x_t + U_f h_{t-1}), \quad (11.2)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1}), \quad \tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1}), \quad (11.3)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t). \quad (11.4)$$

细胞状态提供了更稳定的信息通道。GRU用更少的门实现类似的更新。

门控的必要性可以从训练梯度理解。对简单RNN, 隐藏状态对早期状态的导数包含

$$\frac{\partial h_T}{\partial h_t} = J_T J_{T-1} \cdots J_{t+1}, \quad J_s = \text{diag}(1 - \tanh^2(a_s)) W_h. \quad (11.5)$$

这里 $a_s = W_h h_{s-1} + W_x x_s + b$, Jacobian 的第 (i, j) 项为输出第 i 分量对输入第 j 分量的偏导, 乘法按式中从左到右的顺序执行; 反向传播列梯度时使用这一 Jacobian 的转置。若乘积中的最大奇异值长期小于一, 梯度趋向零; 若大于一, 梯度可能爆炸。梯度裁剪把 g 替换为 $g \min(1, \tau/\|g\|)$, 可以控制爆炸但不能修复长期消失。LSTM的细胞状态通过门 f_t 保留一条近似加法路径, 使信息保存时间由门值控制。

非线性导数 $1 - \tanh^2(a_s)$ 在饱和区域接近零, 因此仅控制循环权重的尺度仍不足以保证长期梯度。对于长流, 可以每 K 步截断计算图以控制训练内存, 前向状态仍可携带更早的信息, 但早期输入不能通过被截断的路径直接贡献梯度。窗口长度与截断长度因而是不同的实验变量。

从单步导数到跨时间反向传播。 设 $x_t \in \mathbb{R}^p$ 、 $h_t \in \mathbb{R}^m$, 于是 $W_x \in \mathbb{R}^{m \times p}$ 、 $W_h \in \mathbb{R}^{m \times m}$ 、 $b \in \mathbb{R}^m$ 。令总损失为 $\mathcal{L} = \sum_{t=1}^T \ell_t(h_t)$, 用列向量 $g_t = \nabla_{h_t} \mathcal{L}$ 表示包含所有后续损失的梯度。链式法则逐步给出

$$g_T = \nabla_{h_T} \ell_T, \quad (11.6)$$

$$g_t = \nabla_{h_t} \ell_t + J_{t+1}^\top g_{t+1}, \quad (11.7)$$

$$g_t = \sum_{s=t}^T (J_s J_{s-1} \cdots J_{t+1})^\top \nabla_{h_s} \ell_s, \quad (11.8)$$

其中 $s = t$ 时空乘积为 I 。再令 $\delta_t = \text{diag}(1 - h_t \odot h_t)g_t$ ，共享权重的梯度不是某一步的梯度，而是所有出现位置的累加：

$$\nabla_{W_h} \mathcal{L} = \sum_{t=1}^T \delta_t h_{t-1}^\top, \quad \nabla_{W_x} \mathcal{L} = \sum_{t=1}^T \delta_t x_t^\top. \quad (11.9)$$

由矩阵范数的次乘性， $\|J_s \cdots J_{t+1}\|_2 \leq \prod_{r=t+1}^s \|J_r\|_2$ 。若每项至多为 $\rho < 1$ ，远期损失传回的上界按 ρ^{s-t} 衰减；若上界大于一，仅意味着可能放大，不能据此断言实际梯度必然爆炸，因为奇异方向会随时间改变。

在LSTM中， $x_t \in \mathbb{R}^p$ ，各门、 $c_t, h_t \in \mathbb{R}^m$ ，所以各 W 为 $m \times p$ 、各 U 为 $m \times m$ ；式(11.2)和式(11.3)省略了可训练偏置。固定门值时，沿细胞状态直接路径有

$$\left. \frac{\partial c_T}{\partial c_t^\top} \right|_{\text{直接路径}} = \text{diag} \left(\prod_{s=t+1}^T f_s \right). \quad (11.10)$$

乘积按元素计算。若某维遗忘门近似恒为 $f \in (0, 1)$ ，经过 k 步保留 f^k ，其衰减到初值 e^{-1} 所需步数为 $-1/\log f$ 。这解释了门值与记忆时间尺度的关系，但不是完整Jacobian：门还通过 h_{t-1} 依赖早期状态，其他路径仍会放大或衰减梯度。门控改善可训练性，不保证无限记忆。

GRU 的参数化。 GRU使用更新门和重置门

$$z_t = \sigma(W_z x_t + U_z h_{t-1}), \quad (11.11)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1}), \quad (11.12)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1})), \quad (11.13)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \quad (11.14)$$

更新门接近零时保留旧状态，接近一时写入候选状态。它比LSTM参数更少，却牺牲了对细粒度记忆通道的独立控制。

11.2 注意力、Transformer 与长依赖

图11.2区分历史键用于匹配、历史值用于输出的两条路径；当前查询通过归一化权重决定读取哪些历史内容。递归模型把全部历史压入有限维状态。当预测需要重新访问某次冲击或某段工况时，这种压缩可能成为瓶颈。注意力改为按当前查询读取历史表示，其缩放点积形式为[109]

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (11.15)$$

直接访问缩短了远距离位置之间的信息路径，但标准全局注意力的计算量随序列长度呈二次增长。Transformer 将多头注意力、位置编码、前馈网络、残差连接和归一化组合起来。因此，从 GRU 转向 Transformer 是以保存和访问历史的成本换取更灵活的信息选择，而非无条件提高预测能力。




图 11.2: 注意力把“压缩全部历史”改为“按查询重新读取历史”，代价是保存和计算位置间的相互作用。

注意力的逐位置解释。 对于第 i 个查询，注意力权重为

$$a_{ij} = \frac{\exp(q_i^T k_j / \sqrt{d_k})}{\sum_{r=1}^T \exp(q_i^T k_r / \sqrt{d_k})}, \quad o_i = \sum_j a_{ij} v_j. \quad (11.16)$$

因此每个输出是值向量的加权平均。查询表示“我现在需要什么”，键表示“我具有什么索引”，值表示“被取出的内容”。多头注意力使用多组投影，让不同头分别学习局部邻接、长距离指代或语义匹配。

缩放、归一化与访问成本的推导。 采用逐行存放位置表示的约定， $X \in \mathbb{R}^{T \times d}$ 、 $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ 、 $W_V \in \mathbb{R}^{d \times d_v}$ ，所以 $Q, K \in \mathbb{R}^{T \times d_k}$ 、 $V \in \mathbb{R}^{T \times d_v}$ 。为理解缩放，暂设 q_i, k_j 的坐标彼此独立、均值为零、方差为一，则

$$\mathbb{E}(q_i^T k_j) = 0, \quad \text{Var}(q_i^T k_j) = \sum_{r=1}^{d_k} \text{Var}(q_{ir} k_{jr}) = d_k. \quad (11.17)$$

因此除以 $\sqrt{d_k}$ 使得分方差约为一，避免维度增加时softmax过早饱和。这是初始化尺度的解释，不是对训练后相关特征的严格分布假设。记缩放得分为 s_{ij} ，由商法则得到

$$\frac{\partial a_{ij}}{\partial s_{ir}} = a_{ij}(\mathbf{1}_{j=r} - a_{ir}). \quad (11.18)$$

当一个权重已接近一时，其余权重及大量导数接近零，模型便难以调整访问对象。softmax使 $a_{ij} \geq 0$ 且 $\sum_j a_{ij} = 1$ ，单头输出因而位于值向量的凸包内；但后续投影、残差和前馈变换不受这个凸包约束。

计算 QK^T 需 $O(T^2 d_k)$ 次标量运算，计算 AV 需 $O(T^2 d_v)$ ；显式保存分数需 $O(T^2)$ 空间。若无位置编码、无遮罩，令 P 为位置置换矩阵，则 $Q' = PQ, K' = PK, V' = PV$ ，有 $A' = PAP^T$ 及 $O' = PO$ 。这叫置换等变，而不是输出不随置换变化；网络本身无法从内容之外识别先后顺序。因果遮罩和位置编码正是为打破这种不足而加入的结构。

位置编码与因果遮罩。 自注意力本身对 token 顺序置换不敏感，必须加入位置信息。正弦位置编码使用不同频率的正余弦函数；可学习位置嵌入直接为每个位置分配向量。因果遮罩令 $j > i$ 的注意力得分为 $-\infty$ ，从而保证第 i 个位置只能使用1到 i 的信息。解码时的 Key-Value (KV) cache 保存已经计算的键和值，使每次生成新 token 不必重复计算全部历史。

11.3 时间序列预测与状态估计

单步预测学习 $p(x_{t+1} | x_{\leq t})$ ，多步预测可递归调用模型，也可一次输出整个未来窗口。递归策略容易累积误差，直接多步预测避免把自身输出反复作为输入，但参数量取决于输出头与共享结构。概率预测可以输出分位数，使用 pinball loss

$$\ell_{\tau}(y, \hat{y}) = \max\{\tau(y - \hat{y}), (\tau - 1)(y - \hat{y})\} \quad (11.19)$$

学习条件分位数，从而形成预测区间。

多步误差为何会积累。 为隔离递归效应，设真实向量状态满足 $x_{t+1} = f_*(x_t) + \eta_{t+1}$ ，预测器递归使用 $\hat{x}_{t+h} = f_{\theta}(\hat{x}_{t+h-1})$ ，初值 $\hat{x}_t = x_t$ 。假设在所考察区域， f_{θ} 为 L -Lipschitz，且 $\|f_{\theta}(x) - f_*(x)\| \leq \delta$ 、 $\|\eta_t\| \leq \epsilon$ 。插入并减去 $f_{\theta}(x_{t+h-1})$ ，可得

$$e_h = \|\hat{x}_{t+h} - x_{t+h}\| \quad (11.20)$$

$$\leq L e_{h-1} + \delta + \epsilon \quad (11.21)$$

$$\leq (\delta + \epsilon) \sum_{j=0}^{h-1} L^j. \quad (11.22)$$

当 $L \neq 1$ 时，上界为 $(\delta + \epsilon)(L^h - 1)/(L - 1)$ ，当 $L = 1$ 时为 $h(\delta + \epsilon)$ 。即便一步拟合误差小，迭代的敏感性仍可能放大误差； $L < 1$ 时该上界则有界。这是有界噪声条件下的示意推导，高斯噪声不能直接使用统一的确定性 ϵ 。直接多输出方法避免反馈自身误差，却不消除未来不可预测性，也不必然需要更多参数，参数量取决于共享骨干和输出头设计。

分位数损失为何学习分位数。 固定历史信息 $\mathcal{F}_t$ ，设未来标量 Y 的条件分布函数为 F ，候选预测为 a ，分位水平 $\tau \in (0, 1)$ 。当分布连续且允许交换微分与积分时，条件期望损失为

$$R(a) = (1 - \tau) \int_{-\infty}^a (a - y) dF(y) + \tau \int_a^{\infty} (y - a) dF(y), \quad (11.23)$$

$$R'(a) = (1 - \tau)F(a) - \tau(1 - F(a)) = F(a) - \tau. \quad (11.24)$$

故最优解满足 $F(a) = \tau$ ；有原子质量时改用次梯度，条件为 $F(a^-) \leq \tau \leq F(a)$ 。上下分位数 $\tau = \alpha/2$ 与 $1 - \alpha/2$ 由此形成名义覆盖率 $1 - \alpha$ 的区间。有限样本、模型失配和分布漂移会破坏实际覆盖率，不同分位数独立训练还可能交叉。每个提前量分别覆盖并不等于整条未来轨迹同时覆盖，后者需要联合分布或额外的同时覆盖校准。

工艺参数异常预警。 可以把设备传感器流切成长度为 T 的窗口，输入过去 T 步，预测未来 H 步的正常轨迹。异常分数可以是预测误差、概率负对数似然或隐状态与正常原型的距离。阈值应在验证集上按告警提前量和误报预算选择，而不能直接取训练误差的某个分位数。

状态空间模型与滤波。 序列模型可以拆成状态转移和观测生成两部分：

$$p(h_t | h_{t-1}, u_t) = \mathcal{N}(Ah_{t-1} + Bu_t, Q), \quad (11.25)$$

$$p(x_t | h_t) = \mathcal{N}(Ch_t, R). \quad (11.26)$$

这里 u_t 可以表示控制量， Q 和 R 分别表示状态演化噪声与观测噪声。卡尔曼滤波先用转移方程预测状态，再用新观测修正预测。深度 RNN 可以看作学习非线性转移函数，但如果忽略观测噪声和状态不确定性，就无法直接给出滤波意义下的置信区间。

从这一统一视角看，现代时间序列模型是在不同位置放置“记忆”和“预测分布”。DeepAR 用自回归 RNN 输出下一时刻分布的参数，适合许多设备共享统计规律的场景；Neural Basis Expansion Analysis for Interpretable Time Series Forecasting (N-BEATS) 用堆叠的前馈块逐步拟合趋势和季节性，能够通过基函数解释预测来源，但需要固定长度窗口。Temporal Convolutional Network (TCN) 用因果空洞卷积并行处理整个窗口，感受野由卷积核和空洞率显式控制，适合高吞吐批处理；若故障信号必须在每个新采样到达时更新，带显式状态的 GRU 或状态空间模型通常更自然。

Transformer 系列则把时间点或时间片看作 token。Informer 使用稀疏概率注意力和序列蒸馏，减少长序列的二次成本；Autoformer 先将序列分解为趋势和季节项，再用自相关机制寻找周期模式；FEDformer 在频域或低秩结构中进行全局建模；PatchTST 把连续时间片切成 patch，以更少 token 保留局部形状，并在规则采样的长预测任务中形成强基线。PatchTST 对缺失时间戳和事件驱动数据并不天然稳健，因此应显式加入时间间隔、缺失掩码和设备身份，而不能直接把图像 Vision Transformer (ViT) 的 patch 机制照搬到所有传感器流。

当序列长度使注意力矩阵无法存储时，结构化状态空间模型提供了另一种计算路径。Structured State Space Sequence Model (S4) 将连续时间状态方程离散化并用结构化参数高效计算长卷积，试图同时获得长记忆和线性复杂度；选择性状态空间模型 Mamba 进一步让输入控制状态更新、遗忘和输出，使模型可以对不同事件选择不同的记忆时间尺度。它们适合超长振动流、日志流和在线扫描，但状态压缩也可能丢失需要精确回看的单次事件。比较 Transformer、TCN、S4 和 Mamba 时，应同时报告短暂冲击的召回、长周期趋势误差、流式延迟、显存和窗口外推能力。

表 11.1: 序列模型路线与工业选择

模型路线	记忆机制	计算与部署特征	更适合的工业问题
LSTM/GRU	显式递归状态与门控	顺序计算，流式更新简单	不规则到达、在线状态跟踪、样本有限
TCN	因果空洞卷积与固定感受野	可并行训练，窗口外推有限	高频批处理、固定提前量预测
Transformer	全局注意力与位置编码	长度平方级注意力，缓存可降低解码重复	长距离依赖、数据量较大、离线分析
PatchTST/Informer patch 或稀疏注意力		减少 token，依赖规则采样假设	长窗口、多变量、规则传感器流
S4/Mamba	结构化或选择性状态空间	线性扫描，适合超长流式输入	长振动流、日志流、低延迟连续监控

表11.1按记忆机制和部署成本比较序列模型，选型时应将流式更新、固定窗口与长历史访问的要求对应到具体工业任务。

多头注意力的张量形状。 设批大小为 B 、序列长度为 T 、模型维度为 d 、头数为 H ，每头维度为 $d_h = d/H$ 。输入形状为 $B \times T \times d$ ，投影后重排为 $B \times H \times T \times d_h$ ，注意力分数形状为 $B \times H \times T \times T$ 。最后一个 $T \times T$ 矩阵解释了长序列的显存瓶颈：即使参数量不大，二次注意力也可能无法处理高频传感器流。




图 11.3: Transformer 编码块的主要信息流。

图11.3沿投影、注意力和前馈变换展示编码路径，虚线则标出绕过注意力子层的残差通路；二者共同形成各位置的输出表示。

位置编码的选择。 绝对位置编码把位置直接加到 token 表示中，简单但长度外推能力有限；相对位置编码直接描述 token 间距离，更适合长度变化；旋转位置编码通过复数相位或二维旋转改变查询和键，使点积携带相对位置信息。选择位置编码时要同时考虑训练长度、部署长度和缓存机制，不能只比较短序列上的损失。

时间序列中的非平稳性。 趋势、季节性、工况切换和传感器老化会使 $p(x_{t+1} | x_{\leq t})$ 随时间变化。差分、归一化、分解和时间特征可以减少非平稳性，但也可能删除故障前的有用趋势。滚动验证比随机交叉验证更适合检验未来性能；模型更新还应区分概念漂移与测量系统改变。

11.4 训练、预测与工业告警

序列模型实验矩阵。 至少应比较：持久性或季节性基线、线性模型、树模型、RNN/TCN 和 Transformer。固定预测提前量后，再改变窗口长度、模型容量和缺失处理。评价不仅包括 MAE 或交叉熵，还应包含延迟、显存、吞吐、异常事件召回率和预测区间覆盖率。只有当复杂模型在关键约束下仍有稳定收益，才说明其结构提供了有效归纳偏置。

以轴承剩余寿命（Remaining Useful Life, RUL）预警为例，首先把原始振动、温度、转速和负载按照设备时钟对齐，并保留每一路的采样时间、缺失标记和传感器版本。随后用设备级而非窗口级划分数据：同一轴承的相邻窗口必须进入同一个集合，测试设备和测试时间段完全留出。输入可以由高频振动的统计量、频谱 patch 和低频

工况变量组成，目标则根据维护流程选择连续 RUL、未来 H 分钟内的失效概率或两者的多任务输出。

训练阶段先比较持久性、线性外推、随机森林和 GRU，再引入 TCN、PatchTST 或 Mamba。所有模型使用相同的预测提前量、相同的训练设备和相同的标准化统计量；对 RUL 回归可以采用 Huber 损失，对失效概率采用加权交叉熵，对预测区间增加分位数损失。若失效事件很少，不能只随机抽取正常窗口，否则模型会在类别先验上获得虚假的高准确率；应按设备和事件构造训练批次，并报告事件级召回与每台设备的误报数。

上线时，模型每分钟更新一次状态，告警状态机可以要求连续三个窗口超过阈值才进入高等级告警；“至少提前20分钟”是依据事后确认的故障时刻验收的目标，不能作为在线状态机已知的触发条件。输入缺失超过五分钟时，系统暂停风险结论并生成数据质量告警；恢复后先执行状态重置或冷启动窗口，避免把长时间缺失后的填充值当作真实趋势。监控面板同时展示预测轨迹、置信区间、模型版本、输入覆盖率和人工确认结果，形成从模型输出到维护动作的可追溯的处理记录。

滤波、平滑与预测。 滤波只使用截至 t 的观测估计 h_t ，平滑则允许使用未来观测修正过去状态。在线故障预警只能使用滤波信息，离线诊断可以使用平滑信息。若把平滑后的状态用于训练在线预警器，模型可能隐式读取未来，导致离线指标偏高。实验报告应明确状态估计使用的信息边界。

卡尔曼滤波的两步更新。 在线线性高斯状态空间模型中，预测步骤为

$$\hat{h}_{t|t-1} = A\hat{h}_{t-1|t-1} + Bu_t, \quad (11.27)$$

$$P_{t|t-1} = AP_{t-1|t-1}A^\top + Q. \quad (11.28)$$

观测到 x_t 后，计算创新 $r_t = x_t - C\hat{h}_{t|t-1}$ 和增益

$$K_t = P_{t|t-1}C^\top(CP_{t|t-1}C^\top + R)^{-1}, \quad (11.29)$$

再更新 $\hat{h}_{t|t} = \hat{h}_{t|t-1} + K_tr_t$ 。创新序列可以用于检测模型失配：若其长期偏离零或自相关显著，说明转移、噪声或传感器模型需要重新估计。

由高斯条件化推导滤波增益。 设 $h_t \in \mathbb{R}^m, x_t \in \mathbb{R}^p, u_t \in \mathbb{R}^q$ ，则 $A \in \mathbb{R}^{m \times m}, B \in \mathbb{R}^{m \times q}, C \in \mathbb{R}^{p \times m}$ ； $Q, P \in \mathbb{R}^{m \times m}, R \in \mathbb{R}^{p \times p}$ 。假设转移噪声与观测噪声均为零均值、跨时间独立，并与先前状态独立。记预测均值和协方差为 m^-, P^- 。线性变换的均值与协方差规则先给出前述预测步骤，再给出联合分布

$$\begin{bmatrix} h_t \\ x_t \end{bmatrix} \Big| x_{<t} \sim \mathcal{N} \left(\begin{bmatrix} m^- \\ Cm^- \end{bmatrix}, \begin{bmatrix} P^- & P^-C^\top \\ CP^- & CP^-C^\top + R \end{bmatrix} \right). \quad (11.30)$$

为看清条件化的来源，令 $e = h_t - m^-$ 、 $r = x_t - Cm^-$ 、 $S = CP^-C^\top + R$ ，并写出修正后的误差 $e^+ = e - Kr$ 。要求它与已经利用的创新不相关，有

$$\text{Cov}(e - Kr, r) = P^-C^\top - KS = 0, \quad K = P^-C^\top S^{-1}. \quad (11.31)$$

联合高斯使不相关等价于独立，因此 $\mathbb{E}(h_t | x_t, x_{<t}) = m^- + Kr$ ，且后验协方差为

$$P^+ = P^- - P^-C^\top S^{-1}CP^- \quad (11.32)$$

$$= (I - KC)P^-(I - KC)^\top + K RK^\top. \quad (11.33)$$

式(11.33)称为Joseph形式，更适合在有限精度计算中保持对称性和半正定性。这里要求 S 可逆，实际实现应解线性方程而非显式求逆。若 $p = m = 1, C = 1$ ，则 $K = P^-/(P^- + R)$ ：观测越噪，修正越小；状态预测越不确定，越相信新观测。在线性高斯且参数正确时， $r^\top S^{-1}r$ 服从自由度为 p 的卡方分布；用它设阈值仍需检查噪声、参数估计与重复告警假设，不能直接把名义尾概率当成事件级误报率。

连续动力学怎样成为离散记忆。 考虑 $\dot{h}(t) = A_c h(t) + B_c u(t)$ 、 $y(t) = Ch(t)$ ，其中 $h \in \mathbb{R}^m$ 、 $u \in \mathbb{R}^q$ ， $A_c \in \mathbb{R}^{m \times m}$ 、 $B_c \in \mathbb{R}^{m \times q}$ 。假定每个长度为 Δ 的采样区间内输入恒定，利用积分因子得到

$$h_t = \bar{A}h_{t-1} + \bar{B}u_t, \quad (11.34)$$

$$\bar{A} = \exp(\Delta A_c), \quad \bar{B} = \int_0^\Delta \exp(sA_c)B_c ds. \quad (11.35)$$

只有 A_c 可逆时，才可把积分写为 $A_c^{-1}(\bar{A} - I)B_c$ ；积分形式始终有效。反复代入递推式得

$$y_t = C\bar{A}^t h_0 + \sum_{j=1}^t C\bar{A}^{t-j}\bar{B}u_j. \quad (11.36)$$

因此固定线性状态模型既可按状态在线扫描，也可按卷积核 $G_k = C\bar{A}^k\bar{B}$ 批量计算。若 A_c 各特征值实部为负，则 $\bar{A}$ 的特征值模小于一，长期记忆稳定衰减，但非正规矩阵仍可能短期放大扰动。S4 利用结构化参数高效表示这样的长核；输入依赖的选择性更新则不再对应同一个固定卷积核，需采用扫描计算。线性时间复杂度通常以状态维度固定为前提，不能忽略状态大小和实现常数。

长序列的计算策略。 Transformer 的二次注意力使高频工业流难以直接处理。常见策略包括下采样、分块、局部注意力、稀疏注意力、线性注意力和层级编码器。下采样降低成本却可能删除短暂故障；局部注意力保留邻域细节却限制远距离依赖；层级模型通过低频状态连接长时间尺度。选择策略应由故障持续时间和提前量决定。

教师强制与部署解码。 teacher forcing 下的交叉熵衡量“给定真实历史时的下一步预测”，并不等于自由运行时的轨迹质量。评估多步预测时应让模型使用自己的历史输出，记录误差随预测步长的增长。对连续值预测，还应区分递归策略中的误差累积和直接多输出策略中的共享表示误差。

非平稳序列的分层验证。 若设备老化导致均值、方差或周期变化，随机切分会把未来状态混入训练。时间滚动验证可以模拟上线过程：用较早区间训练，在后续区间验证，再向前滚动。若存在新设备部署，还应增加设备留出维度。结果应按时间、设备、工况和传感器版本分层，以区分概念漂移和测量系统变化。

异常分数的选择。 预测残差适合发现可预测模式的偏离，负对数似然还会考虑预测方差，隐状态距离适合表示空间中已有正常原型的偏离。三种分数的阈值含义不同：残差阈值依赖量纲，似然阈值依赖概率校准，距离阈值依赖表示几何。可以组合多个分数，但必须在验证集上固定组合规则，不能根据测试事件逐个调阈值。

序列模型的资源消耗。 报告模型时应记录每步延迟、端到端窗口延迟、显存、参数量和吞吐。一个离线速度快的模型，如果等待完整窗口才能输出，可能不满足提前预警要求。流式 RNN 可以逐步更新状态，Transformer 则可能需要缓存和窗口重算。计算预算为序列建模问题的一部分，而非部署阶段才补充的细节。

滚动预测的完整设置。 设传感器以一分钟为间隔采样，使用过去 $T = 120$ 步预测未来 $H = 30$ 步。样本构造应令输入窗口为 $[t - T + 1, t]$ ，标签窗口为 $[t + 1, t + H]$ ，并保证同一故障事件不会同时出现在训练和测试窗口。若窗口高度重叠，随机切分会使相邻片段泄漏到不同集合；更稳妥的做法是按时间块或设备划分，并在块之间留出间隔。

评价时分别计算 $h = 1, 5, 15, 30$ 的误差，观察模型是否只在短提前量有效。若采用递归预测，必须在每一步输入模型自己的预测；若采用直接多输出头，则应说明每个提前量是否共享参数。除 MAE 外，还应报告故障前提前量、告警持续时间和每台设备每天误报数，因为这些量直接决定维护团队的工作量。

从预测到异常告警。 轨迹预测误差只有在真实观测到达后才能计算，不能用未来误差触发当前预警。设 $\hat{x}_{t|t-h}$ 及 $\hat{\sigma}_{t|t-h}$ 是在 $t - h$ 时刻对 t 的预测和标准差。对一个传感器通道，时刻 t 可计算的标准化残差为

$$s_t = \max_{1 \leq h \leq H} \frac{|x_t - \hat{x}_{t|t-h}|}{\hat{\sigma}_{t|t-h} + \epsilon}. \quad (11.37)$$

这个分数检测当前观测相对于历史预测的偏离，不等于未来故障概率。若要提前预警，还需验证偏离与后续故障的关系，或直接训练未来事件概率输出头。为了避免一个瞬时噪声触发告警，可以要求连续 m 个窗口超过阈值，或在事件级别合并相邻告

警。阈值和 m 只能在验证数据上根据漏报成本、误报预算和最小提前量确定。测试集只用于一次性报告，不能在看到故障时间后反复调整规则。

传感器掉线时，要先区分设备真的异常，还是根本没有可靠读数。直接填零可能在曲线上制造一次突变。可以用缺失掩码注明哪些值没测到；若沿用上次读数，还应限制最多沿用多久。长时间缺失应触发数据质量告警，并按预定规则暂停判断或转人工处理。这样才不会把通信故障误报成设备故障。

在线部署检查表。 上线前至少应验证初始状态、窗口边界、时区和时间戳顺序；上线后监控输入缺失率、窗口延迟、预测分布、异常分数和告警确认结果。模型更新时保留旧版本作为影子模型，比较同一批输入上的分数变化。这样可以区分真实工况变化、数据管线故障和模型版本引入的行为改变。

序列模型的基线与消融。 持久性预测 $\hat{x}_{t+h} = x_t$ 是许多连续传感器任务的强基线；具有周期性的过程还应加入季节性复制和线性外推。若深度模型不能稳定超过这些基线，应先检查窗口构造、目标定义和数据泄漏，而不是立即增加层数。消融实验可以依次去掉时间特征、缺失掩码、注意力、残差或多步损失，以判断性能来自真正的结构还是额外的参数量。

不规则采样与时间间隔。 许多工业事件并非严格等间隔。直接把事件编号当作时间步，会把十秒间隔和十分钟间隔视为同样的动态变化。可以显式输入 Δt ，或使用连续时间状态转移；但填补缺失时间点也会改变噪声结构。实验应分别比较规则重采样、时间间隔特征和事件驱动建模，并报告重采样造成的延迟和短时故障损失。

多变量序列的因果边界。 多个传感器之间可能存在同步采集、控制回路和滞后影响。相关性注意力权重不能直接解释为因果关系，因为共同工况变量会同时改变多个通道。若预测目标是控制动作，还应区分可用的外生变量、动作之后才产生的变量和部署时不可获得的维修记录。特征可用性应按时间戳审计，并在数据字典中固定定义。

概率预测的评价。 分位数预测使用 pinball loss，完整分布预测还可以使用连续排序概率得分。评价时既要检查尖锐性，也要检查校准：过宽的预测分布可能轻易覆盖真实值，却没有调度价值。对多步预测，应分别评估每个提前量，并观察区间是否随着预测跨度合理变宽。若预测分布出现不合理的收缩，通常意味着模型忽略了过程噪声或训练目标过度追求均值误差。

本章小结。 窗口统计不足以保留演化顺序时，可以引入递归状态；状态压缩丢失关键历史时，可以改用注意力；历史访问成本过高时，再比较分块、卷积和结构化状态空间。选定表示后，还必须区分未来轨迹、故障概率和已到达观测的异常分数。梯度

乘积说明长记忆为何难以训练，高斯条件化说明新观测为何应按不确定性加权，分位数风险与误差递推则说明多步输出不能只用一步均方误差评价。这些推导共同指向一个原则：表示能访问的信息、训练所优化的风险和上线时真正可计算的量必须一致。

振动曲线可以提示设备发生了变化，但通常不能指出表面裂纹在哪里。下一章转向图像，用卷积、区域匹配和像素分割寻找缺陷位置。数据仍需独立测试，也仍要检查预测时能否取得；不过标签将变为图像类别、检测框或像素标记，因此不能拿定位成绩直接代替未来故障预测的成绩。

第十二章 视觉模型

本章摘要。本章从图像的局部空间结构出发，说明卷积为何形成层级表示、残差为何改善深层优化，再逐步扩展到检测、分割、Vision Transformer 和自监督学习。最后将评价从单张图像分数推进到跨相机、跨批次、拒识和数据追溯，强调视觉模型必须服务于可验收的工业决策。

风险预警告诉维护人员何时需要关注设备，却不能指出缺陷位于哪里。本章转向巡检图像和表面质检：先判断是否存在缺陷，再定位区域，最后估计边界与尺寸。这些任务使用图像级、框级或像素级标签，与未来故障标签不同。拆检后才能获得的照片可以支持离线诊断，却不能直接作为拆检前预警的输入。上一章中，时间顺序决定同一组读数代表稳定运行还是异常演化；本章中，空间关系决定相同的颜色和纹理代表正常表面还是裂纹。把图像展平成无结构向量虽然在数学上可行，却放弃了邻近像素之间的规律和不同位置共享的成像机制。卷积把这种共享写进参数化，注意力则让远离区域按内容交互，两者是在不同数据和资源条件下组织空间证据的方式。

识别“这里有裂纹”和指出裂纹的准确位置，对图像细节的要求不同。下采样能减少计算、扩大观察范围，但一条很细的裂纹也可能随之消失。即使网络能比较图像中相距很远的部件，也无法恢复输入时已经丢掉的细节。因此先确定最小要检出的缺陷有多大、需要输出类别还是位置，再选择分辨率和网络。下面从卷积和感受野推到检测框、像素损失与校准，逐步说明这些选择怎样影响结果。

12.1 视觉表示：从卷积骨干到视觉 Transformer

Residual Network (ResNet) 通过残差连接改变深层网络的优化路径，ViT 将图像块编码为 token 后使用 Transformer[37, 23]。下文从这两种机制比较局部归纳偏置、全局交互和预训练需求。图12.1将共享骨干与三种输出粒度分开：分类使用图像级标签，检测和分割还要求保留位置与边界。图像是具有二维邻域结构的信号。卷积层以局部窗口提取平移共享的特征：

$$z_{i,j,c} = \sum_{u,v,c'} W_{u,v,c',c} x_{i+u,j+v,c'} + b_c. \quad (12.1)$$

共享权重降低参数量，也把局部性作为归纳偏置。堆叠卷积、非线性和下采样后，感受野逐步扩大，表示从边缘、纹理发展到部件和对象。




图 12.1: 视觉系统先由卷积或 Transformer 骨干提取表示，再按标签粒度输出分类、检测或分割结果。

卷积的索引、参数与等变性。 设输入 $X \in \mathbb{R}^{H \times W \times C_{in}}$ ，方形核大小 k ，输出通道数 C_{out} ，步幅 s 、填充 p 、空洞率 d_a 。采用从零开始的空间索引，有

$$Z_{i,j,c} = b_c + \sum_{u,v=0}^{k-1} \sum_{a=1}^{C_{in}} K_{u,v,a,c} X_{si-p+d_a u, sj-p+d_a v, a}, \quad (12.2)$$

越界输入按指定规则填充。这个深度学习中惯称的卷积实际采用互相关索引；若使用数学卷积，只需翻转核。为使最右端采样不超过填充后的输入，需满足 $si + d_a(k-1) \leq H + 2p - 1$ ，因此

$$H_{out} = \left\lfloor \frac{H + 2p - d_a(k-1) - 1}{s} \right\rfloor + 1, \quad (12.3)$$

宽度同理。参数量为 $k^2 C_{in} C_{out} + C_{out}$ ，与图像面积无关；不共享的局部连接则须为每个输出位置另存一组权重。

在无限网格或忽略边界、 $s = 1$ 时，令 $(T_\delta X)_{i,j} = X_{i-\delta_1, j-\delta_2}$ ，直接代入求和式得 $K * (T_\delta X) = T_\delta (K * X)$ 。这就是平移等变性，而不是平移后输出保持不变。步幅 $s > 1$ 时通常仅保留对 s 整数倍平移的对应关系，边界填充还会引入额外差异。图像分类可以通过汇聚追求不变性，定位任务却应保留位置随输入一起移动的关系。

深度可分离卷积先对每个输入通道施加一个空间核，再用逐点矩阵混合通道。忽略偏置，每个输出位置的乘加数由 $k^2 C_{in} C_{out}$ 降为 $k^2 C_{in} + C_{in} C_{out}$ ，比值为 $1/C_{out} + 1/k^2$ 。节省来自结构约束：对固定输入通道，通向各输出通道的空间模板被限制为同一个模板的不同倍数，因此它不等价于任意标准卷积，且实际延迟还受内存访问影响。

卷积骨干的演化可以理解为三个连续问题：如何让网络更深而仍然可优化，如何在有限计算量下提高特征复用，如何让不同尺度的目标都得到足够的空间分辨率。ResNet 通过残差连接 $h_{l+1} = h_l + F_l(h_l)$ 改善深层网络的优化；DenseNet 进一步把前面各层的特征拼接到当前层，使梯度和低层纹理可以直接复用，但显存访问成本更高。MobileNet 使用深度可分离卷积，将标准卷积拆成逐通道空间卷积和 1×1 逐点卷积，计算量近似从 $k^2 C_{in} C_{out}$ 降为 $k^2 C_{in} + C_{in} C_{out}$ ，适合边缘质检；EfficientNet 则联合缩放深度、宽度和输入分辨率，强调在给定算力下平衡三者，而不是单独堆叠层数。

对工业图像而言，骨干网络并不只是分类器的前端。ResNet-18/34 通常适合小数据和低延迟基线，ResNet-50 适合迁移学习的性能-成本折中，ConvNeXt 把大卷积核、归一化和训练策略现代化，在保留卷积局部归纳偏置的同时接近 Transformer 的表示能力。选择骨干时应同时记录参数量、特征图步幅、显存、冻结层数和输入分辨率；同一个“准确率更高”的模型，如果把最小可检缺陷下采样掉，就不适合作为生产模型。

ViT 把图像划分为 $P \times P$ 的 patch，展平后通过线性投影得到 token: $z_i = x_i W_E + e_i^{pos}$ ，再用标准 Transformer 建模全局关系。其优势是任意两个区域可以在少量层数内直接交互，代价是 patch 数量为 $N = HW/P^2$ 时注意力开销近似为 $O(N^2 d)$ ，并且从零训练往往需要更多数据。Swin Transformer 通过窗口注意力和交错移位把复杂度降为局部窗口规模的平方，并通过层级下采样适配检测和分割；当缺陷同时依赖局部纹理和较大范围工件结构时，Swin 或 ConvNeXt 往往比原始 ViT 更自然。

卷积与 Transformer 不是简单的替代关系。卷积提供局部性、平移等变性和较强的数据效率，ViT 提供长距离交互和可扩展的全局建模。工业迁移实验应固定预训练数据、输入分辨率和微调预算，至少比较从零训练、冻结骨干线性探测、全量微调和参数高效微调四种设置，避免把预训练规模或训练预算误认为模型结构的收益。

表 12.1: 视觉模型族谱与工业选型依据

模型族	核心机制	主要优势	典型工业选择依据
ResNet	残差块与层级卷积	优化稳定、预训练模型与工具较完善	小中型数据集、稳定基线、低风险迁移
DenseNet	跨层特征拼接	特征复用充分、参数相对紧凑	纹理细节重要但显存带宽充足
MobileNet/EfficientNet	深度可分离卷积或复合缩放	参数和延迟较低	边缘设备、相机侧实时推理
ConvNeXt	现代化大卷积核骨干	局部先验与表达能力平衡	需要卷积归纳偏置的高性能分类或检测
ViT/Swin	patch 注意力或窗口注意力	全局关系与大规模预训练迁移	长距离结构、充足预训练或多尺度输出

表12.1把结构机制对应到工业资源条件，比较时应区分残差优化、特征复用、边缘计算和长距离交互各自解决的问题。

表示学习的评价。 分类常用top-1准确率，检测常用平均精度，分割常用交并比。工业视觉还应报告跨设备、跨光照、跨批次和少见缺陷的结果。视觉模型的显著性图可以辅助分析，但可视化不等于因果解释，仍需结合遮挡实验、反事实扰动或专家标注验证。

卷积的空间归纳偏置。 卷积核是局部加权模板。平滑核抑制高频噪声，边缘核响应局部变化，多个卷积核共同形成一组可学习滤波器。步幅大于一会降低空间分辨率，空洞卷积在不显著增加参数的情况下扩大感受野。池化提供一定平移鲁棒性，却也可能丢失小缺陷位置，因此检测任务常使用特征金字塔恢复多尺度信息。

残差优化与特征复用。 普通深层网络学习 $H(x)$ ，残差网络学习 $F(x) = H(x) - x$ 。若恒等映射已经足够好，优化器只需令 F 接近零。对残差块 $h_{l+1} = h_l + F_l(h_l)$ ，梯度包含直接项 I ，因此比连续相乘的纯变换更容易沿深层传播。残差连接也成为Transformer和扩散模型的基础组件。

残差梯度不再只有单一路径。 设各层 $h_l \in \mathbb{R}^d$ ，且残差分支 $F_l : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 可微。令 $J_l = \partial F_l / \partial h_l^\top$ ，则

$$\frac{\partial h_{l+1}}{\partial h_l^\top} = I + J_l, \quad (12.4)$$

$$\nabla_{h_l} \mathcal{L} = (I + J_l)^\top \nabla_{h_{l+1}} \mathcal{L}. \quad (12.5)$$

连续两个块的前向Jacobian为 $(I + J_{l+1})(I + J_l) = I + J_l + J_{l+1} + J_{l+1}J_l$ ，包含不经过任何残差分支的恒等项、经过一个分支的项和经过两个分支的项。相比普通网络只有 $J_{l+1}J_l$ ，残差结构允许梯度走较短路径。若 $\|J_l\|_2 \leq \epsilon < 1$ ，则对任意向量 v 有

$$(1 - \epsilon)\|v\|_2 \leq \|(I + J_l)v\|_2 \leq (1 + \epsilon)\|v\|_2. \quad (12.6)$$

小残差分支使单块接近恒等，但多块的上下界仍相乘，所以残差不是绝不消失或爆炸的定理。改变通道或空间尺寸时，要把捷径替换为投影 $S_l h_l$ ，导数变为 $S_l + J_l$ ，此时也不再具有字面上的恒等路径。

图像块与窗口注意力的成本。 假设 H, W 均可被 P 整除，令第 i 个展平图像块为列向量 $x_i \in \mathbb{R}^{P^2 C}$ ，投影矩阵 $E \in \mathbb{R}^{d \times P^2 C}$ ，则 $z_i = E x_i + e_i^{\text{pos}} \in \mathbb{R}^d$ ；前文 $x_i W_E$ 采用的是其转置后的行向量记法。共有 $N = HW/P^2$ 个块， $QK^\top$ 需要 $O(N^2 d)$ 计算。若每个窗口包含 $M \times M$ 个token，共有 N/M^2 个窗口，局部注意力开销为

$$O\left(\frac{N}{M^2}(M^2)^2 d\right) = O(NM^2 d). \quad (12.7)$$

固定 M 时对 N 线性增长，但单层不能直接连接不同窗口，移位窗口用后续层交换边界信息。另一方面，线性patch投影若 $d < P^2 C$ ，其秩最多为 d ，必有非零输入变化被映射为零；这说明不可假定所有细节都保留在token中，却不意味着小于patch的缺陷必然不可见，是否丢失还取决于投影和训练。

12.2 空间输出：检测、分割与多尺度特征

卷积神经网络（Convolutional Neural Network, CNN）可以用于不同粒度的视觉预测。U-Net 的同尺度跳跃连接用于恢复像素级定位，Feature Pyramid Network (FPN) 通过特征金字塔组织多尺度语义，Mask Region-based Convolutional Neural Network (Mask R-CNN) 则在实例检测中增加掩码分支[87, 67, 36]。这些方法解决的是

不同粒度的空间输出，不能仅按网络深度排序。从图像分类转向定位时，高层语义与空间细节之间的矛盾变得直接。高分辨率特征保留小缺陷边界，低分辨率特征提供较大范围的上下文。特征金字塔通过自顶向下路径与横向连接融合不同尺度，因此应先根据缺陷在输入图像中的像素尺寸选择输出层级，再选择检测头。对于 ViT，patch 过大同样可能丢失细缺陷，卷积 stem、重叠 patch 和层级表示可以提供不同折中。小、中、大目标的分层召回有助于区分表示分辨率不足与后续匹配错误。

检测和分割的差异不只是输出张量的形状，而是模型必须建立从候选区域到空间决策的完整机制。两阶段检测器 Faster R-CNN 先由区域建议网络产生候选框，再由感兴趣区域（Region of Interest, RoI）的池化或 RoIAlign 提取每个候选区域的特征并分别分类、回归；它通常具有较高定位质量，但候选区域和多阶段计算会增加延迟。单阶段 You Only Look Once (YOLO)、RetinaNet 和 Fully Convolutional One-Stage Object Detection (FCOS) 直接在密集特征图上预测类别与位置，速度更快，却必须处理大量背景位置和正负样本分配。RetinaNet 的 focal loss

$$\mathcal{L}_{\text{focal}} = -\alpha_t(1 - p_t)^\gamma \log p_t \quad (12.8)$$

其中 t 表示该样本的真实类别， p_t 是模型对真实类别的预测概率， α_t 是该类别的预设权重， $\gamma \geq 0$ 控制对易分类样本的降权。二分类时， p_t 按真实标签在 p 与 $1 - p$ 之间选取。通过降低易分类背景的权重缓解类别不平衡；FCOS 不依赖预设 anchor，直接回归位置到边界的距离，减少 anchor 尺寸和比例的超参数。工业小缺陷任务应比较 anchor-based、anchor-free 和不同输入分辨率，而不能只更换 backbone。

检测框、匹配与定位损失。 检测器为每个候选框输出类别概率和边界框参数。两个框 A, B 的交并比为

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}. \quad (12.9)$$

训练通常由分类损失和定位损失组成。推理时非极大值抑制保留高分框并删除与其重叠过大的框。小缺陷检测需要特别关注输入分辨率、正负样本比例和标注框的一致性。

从几何框到可训练的回归目标。 设参考框中心及宽高为 (a_x, a_y, a_w, a_h) ，真实框为 (g_x, g_y, g_w, g_h) ，宽高均严格为正且使用同一像素坐标系。直接回归像素位移会使大框产生更大尺度的梯度，因此定义无量纲目标

$$t_x^* = \frac{g_x - a_x}{a_w}, \quad t_y^* = \frac{g_y - a_y}{a_h}, \quad t_w^* = \log \frac{g_w}{a_w}, \quad t_h^* = \log \frac{g_h}{a_h}. \quad (12.10)$$

网络输出 $t \in \mathbb{R}^4$ 后，以 $b_x = a_x + a_w t_x, b_y = a_y + a_h t_y, b_w = a_w e^{t_w}, b_h = a_h e^{t_h}$ 解码。中心相对化降低尺度依赖，对数宽高保证解码尺寸为正；但 $\partial b_w / \partial t_w = b_w$ ，极端输出仍可能带来不稳定。

对匹配到真实框的正样本，常用残差 $e = t - t^*$ 的分段损失

$$\rho_\beta(e) = \begin{cases} e^2/(2\beta), & |e| < \beta, \\ |e| - \beta/2, & |e| \geq \beta, \end{cases} \quad \beta > 0. \quad (12.11)$$

其导数在小误差处为 e/β ，大误差处为 $\text{sign}(e)$ ，兼顾局部平滑与异常残差的有界影响。完整损失可写为

$$\mathcal{L} = \frac{1}{N_{\text{cls}}} \sum_i \ell_{\text{cls}}(p_i, y_i) + \frac{\lambda}{\max(1, N_+)} \sum_{i: y_i > 0} \sum_{j \in \{x, y, w, h\}} \rho_\beta(t_{ij} - t_{ij}^*). \quad (12.12)$$

背景样本没有真实框回归目标；分类与定位的归一化方式必须报告，否则相同 λ 可能代表不同梯度比例。

IoU直接比较几何重叠。设两个边长为 a 的正方形仅水平错位 $\delta \in [0, a)$ ，则交集为 $a(a - \delta)$ ，并集为 $a(a + \delta)$ ，所以 $\text{IoU} = (a - \delta)/(a + \delta)$ ，在 $\delta = 0$ 右侧的导数为 $-2/a$ 。这说明相同一像素偏移对小框更加苛刻。不相交框的普通IoU为零，在保持不相交的区域不给出靠近方向，因此实际定位还会结合参数回归或加入外接框、中心距离等项。

焦点损失究竟改变了什么梯度。 对正类样本设logit为 z 、 $p = \sigma(z)$ ，则 $\ell = -\alpha(1 - p)^\gamma \log p$ 。不能只把交叉熵梯度乘以 $(1 - p)^\gamma$ ，因为这个权重本身依赖参数。乘积法则给出

$$\frac{d\ell}{dz} = \alpha\gamma p(1 - p)^\gamma \log p - \alpha(1 - p)^{\gamma+1}. \quad (12.13)$$

令 $p = 1 - \varepsilon$ 并利用 $\log(1 - \varepsilon) \approx -\varepsilon$ ，得梯度约为 $-\alpha(\gamma + 1)\varepsilon^{\gamma+1}$ ；普通交叉熵则约为 $-\alpha\varepsilon$ 。所以易样本梯度以更高阶衰减，困难样本占据更大的相对权重。但标注错误往往也是困难样本，焦点损失不具备自动甄别错误标签的能力，也不能保证输出概率仍然校准。

语义分割、实例分割与 U-Net。 像素级交叉熵适合类别互斥场景，Dice损失

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i p_i y_i + \epsilon}{\sum_i p_i + \sum_i y_i + \epsilon} \quad (12.14)$$

对小目标更友好。U-Net 用逐级下采样的编码器提取语义上下文，再用逐级上采样的解码器恢复空间分辨率，并通过同尺度跳跃连接把编码器中的细粒度特征送入解码器。跳跃连接缓解了下采样造成的边界丢失，但也会把纹理噪声带入输出，因此需要结合标注质量、通道宽度和后处理验证。U-Net++通过重新设计跳跃路径减少编码器与解码器之间的语义鸿沟，DeepLab则以空洞空间金字塔池化扩大多尺度上下文；它们解决的是不同的空间信息瓶颈，不能仅凭网络名称比较优劣。实例分割还要进一步区分相邻目标，Mask R-CNN 在检测框分支之外增加 RoI 级掩码分支。边界质量、缺陷面积误差和漏检区域的连通性可能比平均 IoU 更接近工业验收标准。对关键缺陷，可以使用多个模型或随机增强估计预测波动。

像素似然、Dice与稀疏前景。 设一幅图含 n 个像素，二值标签 $y_i \in \{0, 1\}$ ，模型输出 $p_i = \sigma(z_i)$ 。在给定图像后用逐像素Bernoulli分布作为训练分解，有

$$p(y | X) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}, \quad (12.15)$$

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)], \quad (12.16)$$

$$\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial z_i} = \frac{p_i - y_i}{n}. \quad (12.17)$$

这个似然分解不表示真实裂纹像素相互独立，而是输出头采用的近似。前景极少时，大量背景项会主导平均损失。Dice从集合重叠出发：硬掩码的 $D = 2|A \cap B|/(|A| + |B|)$ ，将预测指示函数换成概率便得到式(12.14)中的软Dice。记 $N = 2 \sum_i p_i y_i + \epsilon$ 、 $D_0 = \sum_i p_i + \sum_i y_i + \epsilon$ ，则

$$\frac{\partial \mathcal{L}_{\text{Dice}}}{\partial p_j} = \frac{N - 2y_j D_0}{D_0^2}, \quad \frac{\partial \mathcal{L}_{\text{Dice}}}{\partial z_j} = \frac{N - 2y_j D_0}{D_0^2} p_j (1 - p_j). \quad (12.18)$$

一个像素的梯度依赖全图预测总量，体现其区域级归一化，而不是各像素独立计分。对无前景图， $N = \epsilon$ ，当预测面积较大时惩罚梯度可能很小；可结合Binary Cross Entropy (BCE)并明确空掩码的评价约定。Dice也不是概率校准目标，因此不应把优化后的 p_i 未经验证就解释为可靠风险概率。

硬掩码下，令 $J = \text{IoU}$ ，由 $|A| + |B| = |A \cup B| + |A \cap B|$ 得到 $D = 2J/(1 + J)$ 。同一对掩码的两个指标单调对应，但先对图像平均再作非线性变换不等价；软Dice与阈值后二值IoU更不能直接替换。边界和拓扑验收正是补充这些面积指标遗漏的信息。

数据增强与标签语义。 裁剪、翻转、颜色扰动和噪声增强应保持标签语义不变。若翻转会改变设备方向，或颜色变化会掩盖真实缺陷，增强反而制造错误先验。增强策略应由物理过程和相机成像条件约束，并通过消融实验验证。

工业检测案例。 对表面缺陷数据，可先建立“人工特征加树模型”和“小型卷积网络”两个基线，再比较预训练视觉编码器。实验应按生产批次或相机划分，报告少数缺陷的召回率和每千张图的误报数。IoU对边界移动的敏感性、正负样本不平衡的来源以及不改变缺陷标签的增强边界，都应作为验收规则的一部分明确记录。

感受野与有效感受野。 理论感受野描述某个深层单元能够访问的输入区域。若连续两层卷积核大小为 k_1, k_2 、步幅为 s_1, s_2 ，感受野可递推为

$$r_2 = r_1 + (k_2 - 1)j_1, \quad j_2 = j_1 s_2, \quad (12.19)$$

其中 j 表示相邻深层单元在原图上的间隔。更一般地，令 $r_0 = j_0 = 1$ ，第 l 层核大小、步幅与空洞率为 k_l, s_l, d_l 。该层最左与最右采样点间隔为 $d_l(k_l - 1)$ 个上一层步距，每个

采样点又覆盖 r_{l-1} 个输入位置，故

$$r_l = r_{l-1} + d_l(k_l - 1)j_{l-1}, \quad j_l = s_l j_{l-1}. \quad (12.20)$$

例如三层 3×3 卷积的步幅依次为1, 2, 1、空洞率均为一，则各层的感受野与步距为

$$(r_1, j_1) = (3, 1),$$

$$(r_2, j_2) = (5, 2),$$

$$(r_3, j_3) = (9, 2).$$

第三层相邻位置在原图相隔两像素，各自理论上覆盖九像素宽的区域。这里计算的是内点的覆盖范围，不保证边界处拥有同样多的真实像素，也不保证这个范围内每个像素都获得显著权重。理论感受野很大不代表所有像素贡献相同，实际梯度通常集中在更小的有效区域。小缺陷任务需要检查下采样是否在进入高层前已经抹去目标。

等变性、池化与空间细节。 理想卷积具有平移等变性：输入平移后，输出特征也相应平移。但边界填充、步幅和池化会破坏严格等变性。池化提供一定不变性，却可能让两个相邻缺陷无法区分。工业视觉中应根据缺陷尺寸选择下采样比例，并在增强实验中单独测试平移、旋转、尺度和光照变化。

归一化层与批次统计。 Batch Normalization 使用批内均值和方差，训练与推理阶段的统计量来源不同；小批量或设备分布高度异质时，估计会很噪。Layer Normalization 按样本内特征归一化，更适合序列和 Transformer。Group Normalization 在视觉小批量训练中常更稳定。归一化不是无害的数值操作，它改变了网络的参数化和对批次组成的依赖。

检测匹配与正样本分配。 检测训练首先要决定预测框与真实框如何匹配。基于交并比（Intersection over Union, IoU）的正负样本分配简单，但小目标和稀疏目标可能没有足够正样本；一对多匹配会导致重复预测，需配合非极大值抑制或集合匹配。定位损失的尺度也影响分类与回归梯度的平衡，应报告损失权重和正样本定义。

分割边界与拓扑。 两个掩码具有相同 IoU，不代表它们对工业决策同样有用。细长裂纹、孔洞和连通结构需要边界距离、连通性和骨架指标。Dice 对小目标友好，但可能忽略边界位置；边界损失可以补充几何信息。训练标签若边缘本身含糊，模型输出精细边界并不一定是更真实的结果。

图12.2对照输入局部窗口与高层特征，突出扩大感受野同时降低空间分辨率的代价；细小缺陷是否被保留须在下采样前后检查。




图 12.2: 卷积网络从局部窗口逐步形成层级表示。

12.3 预训练、跨域泛化与工业验收

标注稀缺时，监督微调并不是唯一选择。Contrastive Language–Image Pretraining (CLIP) 使用大规模图文对比学习把图像和文本映射到共享空间，给定“有裂纹”“无裂纹”或更细的缺陷描述即可进行零样本分类；但工业术语、相机域和细粒度缺陷通常与通用图文语料不同，因此 CLIP 只能作为迁移起点，必须通过领域文本模板、少量标注或 Low-Rank Adaptation (LoRA) 适配校准。Bootstrapping Language–Image Pretraining (BLIP)-2、LLaVA 等视觉语言模型把视觉编码器与语言模型连接起来，适合生成检验报告和解释性问答，但它们的文字流畅性不能替代像素级定位，报告中的缺陷位置仍应由检测器或分割器提供可验证证据。

自监督与视觉表征。 当缺陷标签稀缺时，可以先用无标签图像学习表示。对比学习通过不同增强视图构造正样本，遮挡重建则要求模型恢复被隐藏的 patch。增强必须与工业语义一致：如果随机裁剪会删除缺陷，模型可能学会“正常背景”；如果两种视图来自不同设备，正样本关系也可能并不成立。预训练表示仍需在跨设备测试上验证，而不能只看线性探测分数。

校准与拒识。 高置信度错误在质检系统中尤其危险。可以用温度缩放或保序回归修正分类概率，再根据风险设置拒识区域。拒识不是把困难样本删除，而是将其转交人工或更精细的模型。报告覆盖率–风险曲线可以说明系统在自动处理多少样本时保持怎样的错误水平。

任务边界与模型选择。 分类回答“图像中是否存在某类状态”，检测还要回答“状态位于哪里”，分割则要求逐像素或逐区域描述。任务标签越细，标注成本越高，评价也越依赖边界和拓扑。若业务只需判断是否需要复检，像素级分割未必是最经济的方案；若需要估计裂纹长度和扩展方向，分类分数就不足以支持决策。

检测指标与匹配链。 检测评价先按置信度排序预测框，再依据 IoU 和类别匹配真实框，形成精确率–召回率曲线。平均精度依赖匹配阈值、类别平均方式和置信度排序。

小目标的一个像素偏移可能显著改变 IoU，因此应同时报告按目标尺寸分层的结果。非极大值抑制的阈值也会影响最终告警数量，不能只记录网络训练损失。

正负样本与困难样本。 工业缺陷通常是少数类，检测器会面对大量容易分类的背景位置。焦点损失通过降低易样本权重，把梯度集中到困难样本；类别权重则直接改变不同类别的损失比例。两者都可能提高少数类召回，却也可能放大错误标注和难例噪声。验收时应同时查看每类召回、误报空间分布和人工复核负担。

分割后处理与几何指标。 像素预测之后常需要连通域分析、孔洞填充、形态学操作或面积过滤。后处理可以改善视觉结果，却也可能删除细小真实缺陷。应把后处理规则纳入验证规则，并在不同缺陷尺寸、边界模糊程度和相机分辨率下检查稳定性。对裂纹等细长对象，骨架长度、断裂数和最大偏差可能比单一 Dice 更有解释力。

域偏移与测试时监控。 光照、相机、镜头污染、材料批次和背景工装都会改变输入分布。输入统计监控可以发现均值、对比度和频谱变化，但不能直接证明标签关系改变。部署后应结合少量延迟标签检查分层性能，区分数据质量告警、需要校准的协变量偏移和需要重新标注的概念偏移。

解释工具的证据边界。 梯度显著性、遮挡图和类激活图可以帮助定位模型关注的区域，但高亮处不一定就是导致故障判断的真实原因。例如模型可能看的是裂纹旁边的批次标记。可以分别遮住缺陷、替换背景或只保留缺陷区域，观察输出如何变化，并请专家核对。不过这些图像修改也可能产生不自然的输入，结果应结合跨相机测试解释，不能仅凭一张热力图作因果判断。

视觉系统验收。 验收应覆盖正常样本、已知缺陷、少见缺陷、遮挡、模糊、光照变化、相机切换和未知输入。指标包括缺陷召回、每千张误报、定位偏差、处理延迟、拒识率和人工复核时间。若模型在实验室图像上表现优秀，却无法承受生产线速度和污染条件，就不能视为完成部署。

分层实验设置。 设生产线上有四台相机、六个批次和三类缺陷。训练集可以使用前三台相机的早期批次，验证集使用相同相机的后期批次，测试集则完整留出第四台相机。这样的划分同时检验时间变化和设备迁移。若把所有图像随机打散，来自同一工件的近重复帧可能进入不同集合，检测结果会明显偏乐观。

实验应先建立三个层次的基线：多数类或人工规则基线、冻结预训练编码器的线性头、端到端微调模型。每次只改变一个因素，例如输入分辨率、增强策略、正负样本分配或后处理阈值。除 Mean Average Precision (mAP) 外，报告缺陷级召回、每千张正常图的误报、最小可检缺陷尺寸和单张图延迟。对生产线而言，漏掉一个关键缺陷的代价通常不能由平均准确率代表。

分割结果验收。 对裂纹掩码，先计算 Dice 和 IoU，再计算边界到真实边界的平均距离、最大距离和骨架断裂数。若模型通过扩大预测区域提高召回，IoU 可能下降但安全风险降低；若模型只保留粗主干，Dice 可能尚可，却无法估计裂纹长度。因此验收规则应先由业务定义允许的漏检和过检，再选择指标和阈值。

标注不确定时，可以由多名标注者独立勾画并保留分歧区域。模型在分歧区域给出低置信度并不一定是失败，反而可能提示需要复核。训练、评价和部署中的掩码格式、像素坐标系、缩放方式必须保持一致，否则边界误差会被错误归因于模型。

12.4 数据反馈与部署决策

少样本适配不应只比较准确率。新相机只有少量标注时，可以冻结 ResNet、ConvNeXt、Swin 或 ViT 的大部分编码器，仅更新归一化统计量、分类头或低秩适配参数；也可以使用 CLIP 的文本原型进行零样本筛查，再把高不确定样本交给人工。验证时必须保留未参与适配的批次，并比较全量微调、参数高效微调和直接拒识三种方案。若新域置信度整体下降，拒识率应作为业务容量约束，而不是被隐藏的失败样本比例。

数据处理记录。 每张图像应关联相机编号、镜头、曝光、生产批次、工件编号、标注版本和采集时间。增强后的图像保留原图引用，预测结果记录模型版本和预处理参数。发生误报时，只有根据这些记录回溯，才能判断问题来自光学条件、标注规则、数据切分、模型还是后处理。可追溯性是视觉智能进入生产系统的必要条件。

主动学习与标注预算。 当人工标注昂贵时，可优先选择高不确定性、代表新域或具有高业务价值的图像。只按模型置信度采样可能反复选择相似噪声，因而需要结合特征多样性、设备覆盖和缺陷稀有度。每轮主动学习都应保留固定测试集，记录新增标注数量、类别分布、性能变化和人工时间，才能判断单位标注成本带来的真实收益。

本章小结。 视觉表示的选择应从输出要求出发：分类需要区分状态，检测需要定位区域，分割还要恢复边界。卷积和残差提供层级特征，注意力扩展区域之间的信息交互，预训练则改变这些表示所需的标注预算。最终方案必须同时满足缺陷尺度、跨域可靠性、推理资源和人工复核容量的约束。卷积索引与感受野决定证据是否仍在特征中，残差路径决定这些特征能否有效训练，框回归、焦点损失和Dice则分别改变位置误差、难例与区域重叠的权重。任何一个损失下降都只回答其中一部分问题，不能代替空间匹配、跨相机验证和部署后的复核。

找到裂纹后，还得查这台设备允许多大缺陷、该按哪一版规程复检。图像本身不能回答这些问题，下一章因此讨论语言模型怎样检索和使用手册、工单。生成报告时应保留裂纹坐标、尺寸尺度、拍摄时间和模型版本，不能只用一句“发现异常”替代可复查的检测结果。

第十三章 语言大模型

本章摘要。本章沿着“文本如何变成可预测的序列”这条主线介绍语言大模型。先讲 token、表示和 Transformer，再解释预训练、缩放、监督微调、参数高效适配和解码，最后讨论检索增强、工具调用、评测与风险。这样可以把模型能力、外部知识和系统行为区分开来。

在贯穿案例中，本章不让语言模型直接替代故障预测器，而是处理设备手册、维修记录和告警上下文这类离散证据。它改变的是“如何检索、组织和调用知识”，而不是把事后记录伪装成预测时刻可用的信息；任何维修建议都必须回到原始证据、权限和人工确认。上一章把缺陷落实为空间位置和边界，但维护判断还需要回答“这个型号允许多大偏差”“哪一版条款适用于当前设备”。这些知识并不天然存在于像素或传感器轨迹中，而分散在带条件、例外和有效期的文档里。本章研究的不是让语言流畅性覆盖证据缺口，而是把文本概率模型、外部知识访问和受约束的系统行为分开建模，再考察它们怎样协同。

可以把本章的方法分开理解：预训练学习文本怎样接续，微调和偏好学习调整回答方式，检索则为这次回答找来相关资料。三者不能互相替代。模型即使把句子续得很顺，也可能记错规程；回答即使受人欢迎，也可能漏掉适用条件；放入整本手册，也不保证它读到了关键条款。下面通过似然梯度、低秩更新和偏好概率解释训练，再检查生成答案能否追溯到当前有效的原文。

13.1 Token、表示与语言建模

本章的自注意力结构以 Transformer 为基础[109]。Bidirectional Encoder Representations from Transformers (BERT) 的双向掩码预训练与自回归语言模型采用不同的信息可见性，因而需要分别理解表示与生成目标[20, 10]。文本先经过 tokenizer 转换为 token 序列。语言模型学习

$$p_{\theta}(x_{1:T}) = \prod_{t=1}^T p_{\theta}(x_t \mid x_{<t}), \quad (13.1)$$

训练目标是最小化负对数似然。Transformer 中的 token 表示由词嵌入、位置编码和多层注意力变换得到。

链式分解如何变成可计算的训练目标。设词表大小为 V_{voc} , $x_t \in \{1, \dots, V_{\text{voc}}\}$, 嵌入矩阵 $E \in \mathbb{R}^{V_{\text{voc}} \times d}$ 。由联合概率的乘法公式, 反复展开 $p(x_{1:T}) = p(x_{1:T-1})p(x_T | x_{<T})$ 即可得到式(13.1); 这不要求token独立。以起始符提供第一个位置的条件, 以结束符学习何时停止, 才构成包括长度的序列分布。设因果网络对前缀 $x_{<t}$ 产生 $h_t \in \mathbb{R}^d$, 输出矩阵 $U \in \mathbb{R}^{V_{\text{voc}} \times d}$, 则

$$z_t = Uh_t + b, \quad p_{t,j} = \frac{e^{z_{t,j}}}{\sum_{k=1}^{V_{\text{voc}}} e^{z_{t,k}}}, \quad (13.2)$$

$$\ell_t = -\log p_{t,x_t} = -z_{t,x_t} + \log \sum_k e^{z_{t,k}}, \quad (13.3)$$

$$\frac{\partial \ell_t}{\partial z_{t,j}} = p_{t,j} - \mathbf{1}_{j=x_t}. \quad (13.4)$$

因而梯度把真实token的概率向上推, 把其余概率按当前质量向下推; $\partial \ell_t / \partial h_t = U^\top (p_t - e_{x_t})$ 再经网络反传。数值实现用 $\log \sum_k e^{z_k} = m + \log \sum_k e^{z_k - m}$, 其中 $m = \max_k z_k$, 避免指数溢出。

训练时可一次输入整段右移后的真实token, 并用因果遮罩并行计算所有位置; 第 t 个输出的目标必须是尚未作为该位置可见输入的 x_t , 否则会退化成复制任务。填充位置不计损失, 指令微调还可只对回答位置计损失。归一化应按实际计分token数而非填充后的矩阵大小进行。训练并行并不改变生成时必须逐步追加未知token的事实。

固定同一个输入前缀 c , 设真实条件分布为 $q(\cdot | c)$, 则期望交叉熵分解为

$$-\sum_j q_j \log p_j = -\sum_j q_j \log q_j + \text{KL}(q||p). \quad (13.5)$$

第一个熵项与参数无关, 最大似然因此在可表达范围内逼近训练分布, 而不是直接优化事实核查。语料若反复出现过期条款, 拟合得更好甚至可能增强过期回答的概率。这是外部证据管理不能被预训练规模替代的数学原因。

Tokenizer 在有限词表下平衡覆盖率与序列长度。词表过小会产生较长序列, 词表过大则增加嵌入参数, 并使部分低频 token 缺少训练。设备编号、故障码和单位可能被切成多个片段, 因此语言模型是否能正确复制这些字符串, 需要单独检验。标准注意力的计算量随序列长度呈二次增长, 比较上下文成本时也应记录 token 数, 而非只比较字符数。

自注意力由输入 H 生成查询、键和值:

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V, \quad A = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right), \quad (13.6)$$

其中 d_k 为键的维度。自回归模型令 $M_{ij} = -\infty$ (当 $j > i$), 其余位置为零, 使当前位置不能读取后续 token。多头注意力以不同投影组合上下文, 前馈网络进一步变换表示, 残差连接和归一化控制深层计算。各个头可能学到不同关系, 但不能预先认定某个头必然负责特定语义。

预归一化将归一化放在子层之前，保留较直接的残差梯度路径；后归一化改变了残差输出的尺度。因而 Transformer 是一组可以组合的结构选择，而非唯一固定的网络。理解注意力方向后，才能区分双向表示学习与因果生成的任务边界。




图 13.1: 自回归语言模型的基本计算链条。

图13.1从离散 token 追踪到词表 logits，说明嵌入、因果注意力和前馈变换如何共同产生下一词元的打分，而非直接检索一条既存答案。

13.2 预训练、对齐与推理

图13.2的反馈箭头表示选定 token 被追加到上下文；这使后续分布依赖先前生成结果，也解释了训练并行与推理逐步执行的区别。指令微调和人类反馈训练的典型




图 13.2: 自回归解码的单步迭代：模型先形成词表分布，再把选中的 token 反馈给下一步。

路线可参照 InstructGPT，直接偏好优化则把偏好学习转写为对语言模型的优化目标[76, 80]。LoRA 的低秩参数更新有独立的结构假设[45]，不应与对齐目标混为一谈。语言模型的主要分歧来自预训练任务和注意力方向，而不只是参数规模。BERT 属于 encoder-only 架构，通过双向注意力和 masked language modeling 学习上下文表示，适合分类、序列标注和检索重排序；Generative Pretrained Transformer (GPT)、LLaMA 等 decoder-only 模型使用因果掩码，只根据前文预测下一个 token，天然适合连续生成和工具调用；Text-to-Text Transfer Transformer (T5) 属于 encoder-decoder 架构，

把分类、摘要、问答等任务统一写成文本到文本的条件生成。工业系统应依据输出形式选择架构：需要稳定字段分类时，BERT 类模型更容易校准；需要长文本生成时，GPT/LLaMA 类模型更直接；需要输入输出长度差异明显的转换任务时，T5 类结构可减少提示工程依赖。

decoder-only 模型在第 t 步优化

$$\mathcal{L}_{\text{CLM}} = - \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}), \quad (13.7)$$

而 BERT 的掩码目标只在被遮蔽位置计算损失。两者的训练信号不同，因此不能仅用参数量推断迁移效果。对于设备手册和维修记录，可以先用 encoder 模型做语义检索和事件分类，再用 decoder 模型生成带证据引用的维修建议；这种组合通常比让一个生成模型独立完成所有步骤更容易审计。

当模型容量继续增加时，稀疏混合专家（Mixture-of-Experts, MoE）用路由器为每个 token 选择少数专家：

$$y = \sum_{e \in \mathcal{S}(x)} g_e(x) E_e(x), \quad |\mathcal{S}(x)| \ll E. \quad (13.8)$$

Switch Transformer 采用近似 top-1 路由，降低每个 token 的激活计算；更复杂的 top-2 路由能够提高容量利用，但需要处理专家负载不均和通信开销。MoE 的“总参数量”不等于“单次推理成本”，工业部署必须分别报告总存储、激活参数、路由丢弃率和跨卡通信。

表 13.1: 语言模型架构与工业任务匹配

架构路线	训练与注意力方向	优势	工业任务和风险
BERT 类 only	encoder- 双向掩码建模	表示稳定、分类和检索高效	事件分类、实体抽取、重排序； 不直接生成文本
GPT/LLaMA decoder-only	类 因果下一 token 预测	生成、对话和工具调用自然	报告草拟、脚本生成；需防幻觉 和提示注入
T5 类 decoder	encoder- 条件文本到文本	输入输出长度灵活、任务统一	摘要、规范化和文本转换；部署 链路更复杂
MoE 语言模型	路由器选择少数专家	总容量大而激活成本可控	多领域共享；需监控负载和通信

表13.1将注意力方向和训练任务与工业输出要求对应，提示读者把分类检索、连续生成和条件转换分开选型，并单独核算 MoE 的通信成本。

预训练目标与困惑度。 语言模型的平均负对数似然为

$$\mathcal{L}_{LM} = - \frac{1}{T} \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}). \quad (13.9)$$

困惑度定义为 $\text{PPL} = \exp(\mathcal{L}_{LM})$ ，可以理解为模型在每个位置面对的有效候选数。困惑度适合比较相同 tokenization 和数据分布下的语言模型，但不能单独代表事实性、帮助性或工业任务质量。

缩放、数据质量与模型容量。 模型参数量、训练 token 数和计算预算共同影响性能，但增加规模并不能弥补重复、污染或错误数据。高质量语料需要去重、过滤个人信息、识别模板化文本，并建立训练数据与评测数据的隔离。对于工业语料，还需处理机密信息、专有术语和时间有效性。

近重复文本可能降低训练损失，却不增加新的知识覆盖。若训练语料包含评测问题或答案模板，较低困惑度也不能证明迁移能力。固定计算预算下，应同时记录参数规模、有效 token 数、序列长度、训练步数和去重比例。工业语料还需要保存来源、许可和生效时间，使旧版本规程始终与适用设备绑定。

预训练提供语言分布的基础，监督微调则用示范答案塑造任务行为。上下文学习只改变当前输入条件，不更新参数。偏好优化进一步利用同一提示下的优选与非优选答案调整输出。Reinforcement Learning from Human Feedback (RLHF) 通常训练奖励模型并优化带参考策略约束的目标，Direct Preference Optimization (DPO) 则直接学习相对于参考模型的回答概率比。参考模型提供约束基准，但不保证事实性或原有能力完全保留，仍需独立评价。

监督微调与参数高效适配。 全量微调更新所有参数，成本随模型规模增长。LoRA在权重更新上使用低秩分解

$$W' = W + \frac{\alpha}{r}BA, \quad B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k). \quad (13.10)$$

它只训练 A, B ，便于为不同设备、部门或任务保存轻量适配器。参数高效方法降低存储成本，但多个适配器之间可能产生干扰，需要明确版本和适用域。

对一个 $d \times k$ 矩阵，全量更新需要 dk 个参数，LoRA 仅需 $r(d+k)$ 个，参数节省比例为

$$1 - \frac{r(d+k)}{dk}. \quad (13.11)$$

低秩约束限制更新所在的方向，秩过小可能无法表达目标域变化。因此应同时比较任务效果、可训练参数、训练显存及适配器合并后的推理成本，而不是只比较保存文件的大小。

低秩更新的前向与反向计算。 对单个线性层，令输入 $x \in \mathbb{R}^k$ 、输出 $y \in \mathbb{R}^d$ 、冻结权重 $W \in \mathbb{R}^{d \times k}$ ，并记 $s = \alpha/r$ 。LoRA并非先构造完整更新再相乘，而可按

$$v = Ax \in \mathbb{R}^r, \quad y = Wx + sBv \quad (13.12)$$

计算。若上游梯度为 $g = \nabla_y \mathcal{L} \in \mathbb{R}^d$ ，由微分 $d\mathcal{L} = g^\top dy$ 逐项整理得

$$\nabla_B \mathcal{L} = s g(Ax)^\top, \quad (13.13)$$

$$\nabla_A \mathcal{L} = s B^\top g x^\top, \quad (13.14)$$

$$\nabla_x \mathcal{L} = W^\top g + s A^\top B^\top g. \quad (13.15)$$

即使 W 冻结，反向传播仍可能需要穿过它，且前向激活仍需存储，所以可训练参数减少不等于训练显存按同一比例减少。常用 A 随机初始化、 $B = 0$ ，使初始模型严格等于基座；第一步 $\nabla_A = 0$ 而 ∇_B 一般不为零，随后 B 变化才使 A 获得梯度。若两者都初始化为零，两组梯度都为零，会阻断学习。

更新满足 $\text{rank}(BA) \leq r$ 。若理想全量更新 ΔW_* 的奇异值为 $\sigma_1 \geq \dots \geq \sigma_s$ ，其最佳秩 r 的Frobenius范数近似误差为 $\sum_{j>r} \sigma_j^2$ 的平方根。这解释了低秩假设依赖任务变化是否集中在少数方向，但不意味着实际非凸训练一定找到这个近似。部署时可把 sBA 合并进 W 以消除额外分支，前提是适配器固定且数值格式兼容；动态切换适配器、量化权重与合并精度则需另外验证。

从偏好概率到直接偏好优化。 设提示为 q ，完整回答为 y ，策略为 $\pi_\theta(y | q)$ ，冻结参考策略为 π_{ref} 。假设参考策略在所比较回答上概率为正，先考虑给定 q 的KL正则目标

$$\max_{\pi} \left\{ \sum_y \pi(y | q) r(q, y) - \beta \sum_y \pi(y | q) \log \frac{\pi(y | q)}{\pi_{\text{ref}}(y | q)} \right\}, \quad \beta > 0. \quad (13.16)$$

用乘子 λ 约束 $\sum_y \pi(y | q) = 1$ ，对每个 $\pi(y | q)$ 求导，得到

$$r(q, y) - \beta \left(\log \frac{\pi(y | q)}{\pi_{\text{ref}}(y | q)} + 1 \right) + \lambda = 0. \quad (13.17)$$

归一化后，最优策略为 $\pi^*(y | q) = \pi_{\text{ref}}(y | q) e^{r(q, y)/\beta} / Z(q)$ ，即

$$r(q, y) = \beta \log \frac{\pi^*(y | q)}{\pi_{\text{ref}}(y | q)} + \beta \log Z(q). \quad (13.18)$$

再假设偏好符合Bradley-Terry模型，优选回答 y^+ 胜过 y^- 的概率为 $\sigma(r(q, y^+) - r(q, y^-))$ 。同一提示的 $\log Z(q)$ 相消，用 π_θ 参数化最优策略便得到

$$a_\theta = \beta \left[\log \frac{\pi_\theta(y^+ | q)}{\pi_{\text{ref}}(y^+ | q)} - \log \frac{\pi_\theta(y^- | q)}{\pi_{\text{ref}}(y^- | q)} \right], \quad (13.19)$$

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(q, y^+, y^-)} \log \sigma(a_\theta), \quad (13.20)$$

$$\nabla_\theta \mathcal{L}_{\text{DPO}} = -\beta \sigma(-a_\theta) [\nabla_\theta \log \pi_\theta(y^+ | q) - \nabla_\theta \log \pi_\theta(y^- | q)]. \quad (13.21)$$

回答的对数概率是其token条件对数概率之和，提示本身不计入回答似然。这个目标提高相对于参考模型的偏好差，并非单独保证优选回答的绝对概率上升。偏好噪声、回答长度偏差、策略表达能力和有限离线数据都会破坏理想推导的前提；若标注者偏好自信但错误的答案，目标本身不会自动发现错误。KL约束与偏好数据因而不能替代事实和规程验收。

解码与生成控制。 贪心解码每次选择最大概率 token，束搜索维护多个候选序列，温度采样使用

$$p_{\tau_{\text{dec}}}(x_t = j | x_{<t}) = \frac{\exp(z_{t,j}/\tau_{\text{dec}})}{\sum_{k=1}^{V_{\text{voc}}} \exp(z_{t,k}/\tau_{\text{dec}})}. \quad (13.22)$$

这里 $z_t \in \mathbb{R}^{V_{\text{voc}}}$ 为当前词表 logits, V_{voc} 为词表大小, j 为候选词元编号, $\tau_{\text{dec}} > 0$ 为解码温度, 与序列长度 T 区分。温度越高, 分布越平坦。top- k 和 nucleus sampling 通过截断低概率尾部控制随机性。事实问答和工具调用通常需要低随机性与结构化输出, 创意生成则可以接受更高多样性。

温度、序列概率与缓存的边界。 固定当前 logits, 两个 token 的概率比满足

$$\log \frac{p_\tau(j)}{p_\tau(k)} = \frac{z_j - z_k}{\tau}. \quad (13.23)$$

由式(13.23)可知, $\tau \rightarrow 0^+$ 时概率集中到最大 logit 集合, $\tau \rightarrow \infty$ 时在有限词表上趋于均匀。令 $\mathcal{H}(\tau) = -\sum_j p_\tau(j) \log p_\tau(j)$, 利用 $\mathcal{H} = \log Z - \mathbb{E}_{p_\tau}[z]/\tau$ 及 $d\mathbb{E}[z]/d\tau = -\text{Var}_{p_\tau}(z)/\tau^2$, 得到

$$\frac{d\mathcal{H}}{d\tau} = \frac{\text{Var}_{p_\tau}(z)}{\tau^3} \geq 0. \quad (13.24)$$

温度增加确实增加这个固定前缀下的分布熵, 但不保证生成事实更多样或更正确, 因为后续前缀也随采样改变。top- k 或 top- p 先选择集合 S 再按 $p'(j) = p(j)\mathbf{1}_{j \in S} / \sum_{r \in S} p(r)$ 归一化, 已经改变原始模型分布。

贪心逐步取最大条件概率, 也不等于最大化完整序列概率。例如第一步两条路径概率为 0.6, 0.4, 第二步各自最优续接概率为 0.5, 0.9, 两条最优完整路径概率分别为 0.30, 0.36; 贪心会错过第二条。束搜索只保留有限候选, 也不能保证全局最优, 长度处理和终止规则还会改变比较方式。

设批大小为 B 、层数为 L 、缓存长度为 T 、键值头数为 H_{kv} 、每头维度为 d_h , 每元素占 b 字节, 则仅键和值缓存占用约为

$$M_{\text{KV}} = 2BLTH_{\text{kv}}d_hb. \quad (13.25)$$

单个新查询仍需与 T 个历史键比较, 标准全局注意力的新 token 成本仍随上下文线性增加, 连续生成的累计注意力计算仍可能呈二次增长。缓存节省的是旧键值投影和旧位置的重复计算, 并不把任意长上下文变成常数成本。不同键值头共享方案还会改变缓存与表达能力的折中。

生成时只新增一个 token, KV cache 保存已计算的历史键和值以减少重复计算, 但缓存占用随上下文增长。缓存管理还需保证会话隔离与敏感内容清理。量化可以降低内存开销, 却应在故障码、数值、单位和工具参数上单独验证。低温度和缓存优化只改变生成行为与资源消耗, 不能补足模型缺少的有效规程, 因此还需要外部检索。

13.3 检索、工具与安全边界

检索增强生成将外部检索证据与生成模型结合, Retrieval-Augmented Generation (RAG) 的原始工作给出了知识密集任务中的代表性实现[62]。工业手册检索还需要额外约束版本、生效时间和权限, 这些属于本书的应用规则, 不能由生成模型自身保证。

检索增强生成。 给定查询 q ，检索器返回文档 D_q ，生成器计算 $p(y | q, D_q)$ 。系统误差可分为召回错误、排序错误、上下文理解错误和生成错误。评估时应分别测量检索召回率、引用是否支持答案、答案完整性和拒答质量。检索系统不能把不存在的证据变成可靠事实。

检索得分、训练目标与证据边缘化。 设查询编码器 f_ϕ 与文档编码器 g_ϕ 输出 $\mathbb{R}^d$ 中的非零向量，归一化后得分为 $s_\phi(q, d) = f_\phi(q)^\top g_\phi(d)$ 。给定一个相关文档 d^+ 和候选集合 $\mathcal{C}$ ，对比检索损失为

$$P_\phi(d | q, \mathcal{C}) = \frac{\exp(s_\phi(q, d)/\tau_r)}{\sum_{d' \in \mathcal{C}} \exp(s_\phi(q, d')/\tau_r)}, \quad (13.26)$$

$$\ell_{\text{ret}} = -\log P_\phi(d^+ | q, \mathcal{C}), \quad \tau_r > 0, \quad (13.27)$$

$$\frac{\partial \ell_{\text{ret}}}{\partial s_\phi(q, d)} = \frac{P_\phi(d | q, \mathcal{C}) - \mathbf{1}_{d=d^+}}{\tau_r}. \quad (13.28)$$

按式(13.28)进行梯度下降会把相关文档拉近、候选负例推远，但所得概率仅相对于候选集合归一化，不是文档支持答案的校准概率。同型号不同版本尤其适合作为需要区分的候选，却必须避免把另一份同样有效的证据错误标成负例。权限和有效期先定义可搜索集合 $\mathcal{D}(q)$ ，相似度排序只在这个集合内进行。

为理解检索和生成怎样组合，可把相关文档 d 视为潜变量，写出简化的单文档边缘化模型

$$p(y | q) = \sum_{d \in \mathcal{D}(q)} p_\phi(d | q) p_\theta(y | q, d). \quad (13.29)$$

实际仅取top- K 集合 S_K 。令 $Z_K = \sum_{d \in S_K} p_\phi(d | q)$ ，截断并重新归一化的分布为

$$p_K(y | q) = \frac{1}{Z_K} \sum_{d \in S_K} p_\phi(d | q) p_\theta(y | q, d). \quad (13.30)$$

若 $0 < Z_K < 1$ ，完整分布满足 $p(y | q) = Z_K p_K(y | q) + (1 - Z_K) p_{\text{tail}}(y | q)$ ，故两者对任意回答事件的概率差不超过 $1 - Z_K$ 。这个界解释了截断遗漏的影响，但工业向量得分通常没有给出真实全库后验，因此不能从top- K 分数直接宣称已知 Z_K 。此外，将多个片段拼接到一个提示里与上述单文档混合并不等价，跨段落推理还需要联合证据。

令 E 表示检索上下文包含足够有效证据， A 表示答案正确。全概率公式给出

$$P(A) = P(E)P(A | E) + P(E^c)P(A | E^c). \quad (13.31)$$

证据缺失时模型可能凭已有知识答对，所以一般不能声称正确率必然低于检索召回；但若验收事件要求“正确且由当前有效证据支持”，则它是 E 的子事件，其概率必不超过 $P(E)$ 。这正是分别评价召回、答案正确性和引用支持率的理由。增加 K 可能提高召回，也可能加入冲突或噪声，需要固定上下文预算作分层验证。

工业知识问答应把 RAG 拆成可独立验收的流水线。离线阶段按照设备、部件、工况和有效时间切分手册，保留章节标题、表格关系、版本号和页码；切块时不能把

“警告条件”和“处理步骤”拆到互不相邻的向量中。检索阶段可以先用 Best Matching 25 (BM25) 召回精确故障码，再用向量检索补充语义相近描述，最后由 cross-encoder 重排序。生成阶段要求模型输出答案、证据片段、文档版本和不确定性状态；当证据覆盖不足时，应拒答或请求更多设备上下文。

评估集需要按问题类型分层：直接查表、跨段落组合、版本冲突、过期规程、未登录故障码和恶意提示。对每个问题分别记录检索召回、证据支持率、答案正确率、引用准确率和拒答质量。一个语言模型即使在开放问答上流畅，也可能在版本冲突时选择了旧规程；因此文档有效期和权限过滤必须作为检索条件，而不是依赖生成模型自行判断。

工具调用与评测。 工具调用把模型输出限制为结构化参数，再由外部程序执行查询、计算或控制动作。工业系统应采用白名单工具、参数校验、权限隔离和人工确认。评测集需要覆盖正常任务、边界输入、对抗提示、过时知识和工具失败。困惑度与任务准确率并不等价，LoRA 的参数量优势也必须结合任务迁移效果和推理开销评价。

幻觉、提示注入与安全边界。 幻觉不仅是“模型说错话”，还包括引用不存在、混淆设备型号、把条件性建议表达成确定事实。系统应允许模型在证据不足时拒答，并显示证据覆盖范围。提示注入则利用文档或用户输入改变系统指令；因此检索文本必须被视为不可信数据，工具调用必须通过结构化参数、权限检查和资源范围限制。

大模型评测矩阵。 工业评测应至少包含四个轴：语言能力、任务正确性、证据忠实度和系统可靠性。语言能力可测困惑度或结构化遵循；任务正确性应使用专家标注或可验证程序；证据忠实度检查答案是否被文档支持；系统可靠性则记录延迟、成本、拒答、超时和工具失败。每个轴都应按设备型号、工况、输入长度和缺失信息分层报告。

本章小结。 语言大模型的能力来自token表示、因果建模、规模化训练和对齐过程的共同作用，但这些环节优化的对象不同。最大似然逼近语料分布，LoRA限制可更新的方向，偏好优化调整相对回答倾向，温度与截断改变解码分布，检索则改变当前能够引用的证据。把这些数学对象区分开来，才能判断某项改进究竟降低了什么误差，而不是把更流畅、更受偏好和更可信混为一谈。

工业应用的关键不在于把模型接入界面，而在于建立数据版本、检索证据、工具权限、输出校验和持续评测组成的控制链。本章沿用型号、生效时间和预测时刻的信息边界，使文字答案始终能返回原始来源。对于故障码、量值和复检条件，正确复制与精确引用往往比措辞自然更重要；证据不足时的拒答也是系统输出的一部分。

文字还需要与现场记录对应。“此处裂纹”指图中的哪个区域？“升温后异响”对应哪一段传感器记录？下一章讨论怎样配对、对齐和融合这些输入。即使放进共同的

表示空间，时间戳、坐标和记录质量也要保留；几路观测有矛盾时，应指出矛盾并核查，不能靠一段流畅的描述把它们掩盖过去。

第十四章 多模态模型

本章摘要。本章研究图像、文本、传感器和时间序列如何在同一任务中协同。先区分共同表示空间与真正的信息融合，再讨论对比学习、跨模态注意力、模态缺失和时间对齐，最后建立面向工业数据的评价方式。关键问题不是模态越多越好，而是每个模态是否提供了可对齐、可验证的互补信息。

序列、视觉和语言模型各自提供证据后，还需要判断它们是否描述同一对象和同一阶段。本章先区分共享空间与信息融合，再处理对齐误差和模态缺失。联合诊断的类别标签与预警的未来事件标签必须分别定义；维修结论只有在形成后才能作为诊断证据，不能提前进入预警模型。

把照片和振动记录放在一起之前，先核对设备编号和采集时间。若照片来自维修后，振动来自维修前，直接配成一对就可能教错模型。共同嵌入空间用于寻找匹配记录，跨模态注意力让一种输入读取另一种输入，质量门控则在照片模糊或传感器失真时调整使用程度。这几种办法需要不同的训练数据。后文都用相机与振动联合诊断来说明：多出来的信息帮了什么忙，少一路输入时又该怎么办。

14.1 不同模态的共同空间




图 14.1: 双塔对比学习先把不同模态映射到共同空间，再用配对关系约束表示距离。

图14.1的两路编码先独立计算，再在共同空间比较匹配关系；这种交互位置允许分别缓存表示，却未提供区域级联合推理。CLIP 通过图文对比学习获得可比较表示，BLIP-2 以轻量查询模块连接冻结的视觉与语言模型，Large Language and Vision Assistant (LLaVA) 通过视觉指令微调学习多模态交互[79, 63, 68]。BLIP-2 中的查询变换器称为 Querying Transformer (Q-Former)。三者分别强调对齐、表示连接和指令响应，并非同一损失的规模变化。多模态模型首先要决定“对齐”发生在哪里。CLIP

采用图像编码器 f_v 和文本编码器 f_t 构成双塔结构，经过归一化后以温度参数 τ 计算相似度：

$$s_{ij} = \frac{f_v(v_i)^\top f_t(t_j)}{\tau}. \quad (14.1)$$

批内对比目标让匹配图文相似度高于非匹配组合，因此 CLIP 能把“有裂纹”“轴承外圈剥落”等文本描述映射为分类原型。它的优点是图像和文本编码可以独立缓存，缺点是双塔交互浅，难以表达复杂问答和精确区域关系。

BLIP-2 用冻结视觉编码器、冻结语言模型和轻量 Q-Former 连接二者。Q-Former 通过一组可学习查询从视觉特征中提取与文本任务相关的信息，再投影到语言模型输入空间；这样可以显著减少端到端训练成本，但视觉细节会受查询数量和投影瓶颈限制。LLaVA 类结构则通常把视觉编码器输出经过线性投影后拼接到语言模型上下文中，适合图像问答和报告生成。工业场景应把生成式描述与可定位模型分开验收：语言模型可以组织证据，不能凭文字流畅性证明缺陷确实位于某个像素区域。

对于传感器、图像和文本，常见做法是先分别得到 z_s, z_v, z_t ，再进行加权融合或跨模态注意力。若传感器序列的采样频率远高于图像帧率，可以用时间窗池化、事件 token 或 cross-attention 将高频状态压缩到视觉时间点；若某个模态临时失效，则训练时加入模态 dropout，并让质量门控 g_m 根据缺失率、噪声估计和传感器健康度动态调整贡献。多模态系统的关键不是把向量简单拼接，而是明确每种模态提供何种互补证据。

表 14.1: 多模态模型的交互位置与适用任务

模型路线	交互机制	优势	工业风险与适用任务
CLIP 双塔	图像-文本共享嵌入空间	编码可缓存、零样本分类方便	细粒度定位弱，适合筛查和检索
BLIP-2	Q-Former 从视觉特征提取查询	冻结大模型即可迁移	查询瓶颈可能丢失小缺陷，适合报告草拟
LLaVA 类	视觉 token 投影到语言上下文	问答和多轮解释自然	生成内容需外部证据，不能代替定位器
交叉注意力融合	查询模态读取键值模态	能表达局部、时间和条件关系	计算较重，适合联合诊断与根因分析

表14.1对照共享嵌入、查询瓶颈和跨模态注意力，选型时须把编码成本与所需细粒度关系同时考虑。以“相机图像加主轴振动诊断”为例，先由视觉编码器输出工件区域 token，由时序编码器输出若干转速同步的振动 token，再将维修记录编码为文本证据。模型可以采用两阶段决策：第一阶段用 CLIP 或轻量分类器筛选明显正常与明显异常样本，第二阶段仅对异常候选执行跨模态注意力和根因排序。训练标签应同时包含缺陷类别、严重度、发生时间和证据模态；如果只有最终维修结论，没有记录哪一帧图像或哪段频谱支持结论，模型即使获得较高准确率也难以审计。

联合损失可以写为

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{align}} \mathcal{L}_{\text{InfoNCE}} + \lambda_{\text{miss}} \mathcal{L}_{\text{miss}} + \lambda_{\text{rank}} \mathcal{L}_{\text{rank}}, \quad (14.2)$$

其中分类项约束业务输出，对比项约束共同空间，模态缺失项要求模型在删去某一路输入时仍保持可接受风险，排序项则约束根因候选的相对顺序。权重不能只按数值大

小设置，应根据漏诊代价、人工复核容量和各模态的标签可信度进行敏感性分析。图像、文本、音频和传感器序列具有不同的统计结构。多模态模型通常为每种模态建立编码器 $z_m = f_m(x_m)$ ，再通过共享投影或跨模态注意力交互。对配对图文 (x_i, t_i) ，对比学习可最大化匹配样本相似度：

$$\mathcal{L}_{\text{NCE}} = -\frac{1}{N} \sum_i \log \frac{\exp(s(z_i^x, z_i^t)/\tau)}{\sum_j \exp(s(z_i^x, z_j^t)/\tau)}. \quad (14.3)$$

这里 N 为配对样本数， $i, j = 1, \dots, N$ ， z_i^x 与 z_i^v 均表示第 i 幅图像的单位范数表示， $s(a, b) = a^\top b$ 是不含温度的余弦相似度。因此 $s_{ij} = s(z_i^v, z_j^t)/\tau$ 是已经缩放的对比得分，不能再次除以温度，且 $\tau > 0$ 。

融合方式。 早期融合将原始特征拼接，晚期融合分别预测后再组合，中间融合在表示空间通过 cross-attention 交互。编码器-解码器架构还可以让一个模态条件化另一个模态的生成。工业场景中，时间同步、传感器缺失和模态质量差异往往比网络结构更决定系统效果。

多模态推理。 图像问答、视觉定位和设备状态描述都可看作条件生成。应分别评估感知正确性、跨模态对齐和语言表达，避免只用语言流畅度掩盖视觉判断错误。

对比学习的温度参数。 设图像和文本编码器输出归一化表示 z_i^v, z_i^t ，相似度取余弦相似度。温度 τ 控制 softmax 的尖锐程度：

$$s_{ij} = \frac{(z_i^v)^\top z_j^t}{\tau}. \quad (14.4)$$

小温度会放大正负样本差异，梯度更集中于难负样本，但也可能使训练不稳定。对称的图到文、文到图损失通常比单向损失利用更多配对信息。

跨模态注意力。 以文本为查询、视觉 patch 为键和值时，文本 token 可以选择性读取图像区域：

为说明其计算含义，令 $Q \in \mathbb{R}^{n_t \times d}$ 、 $K \in \mathbb{R}^{n_v \times d}$ 、 $V \in \mathbb{R}^{n_v \times d_v}$ 。矩阵 $QK^\top$ 的第 (a, b) 项是第 a 个文本查询与第 b 个视觉键的内积；除以 $\sqrt{d}$ 是为了在各维独立、方差为一时保持内积方差在可控范围。对每个文本位置 a ，定义

$$\alpha_{ab} = \frac{\exp(q_a^\top k_b / \sqrt{d})}{\sum_{r=1}^{n_v} \exp(q_a^\top k_r / \sqrt{d})}, \quad \sum_b \alpha_{ab} = 1.$$

于是输出第 a 行为 $h'_a = \sum_b \alpha_{ab} v_b$ ，它是视觉值向量的凸组合，而不是一个自动产生定位真值的坐标。若缺陷区域很小， n_v 过小或下采样会使多个区域共享一个 token；若时间掩码错误，注意力仍会在错误窗口内给出看似合理的权重。实际部署应同时检查注意力之外的区域标注、遮挡实验和跨设备稳定性。

$$H'_{\text{text}} = \text{softmax} \left(\frac{Q_{\text{text}} K_{\text{image}}^\top}{\sqrt{d}} \right) V_{\text{image}}. \quad (14.5)$$

此处 $Q_{text} \in \mathbb{R}^{n_t \times d}$ 、 $K_{image} \in \mathbb{R}^{n_v \times d}$ 、 $V_{image} \in \mathbb{R}^{n_v \times d_v}$ ， n_t, n_v 分别为文本与视觉 token 数。各行存放列向量的转置，softmax 沿视觉位置逐行计算，输出为 $n_t \times d_v$ 矩阵。这与简单拼接不同，因为每个文本位置可使用不同的视觉证据。多层交互可以支持图像描述、区域问答和视觉定位，但其对齐质量仍受配对数据噪声影响。

模态缺失与质量加权。 真实工业系统常出现相机被挡、传感器掉线或文本记录晚到。模型应显式接收“这一模态当前是否可用”的掩码 m_m ，并考虑

$$z = \sum_m \frac{m_m \exp(a_m)}{\sum_r m_r \exp(a_r)} z_m. \quad (14.6)$$

其中 m, r 遍历模态， $m_m \in \{0, 1\}$ 表示第 m 个模态是否可用， a_m 为有限的质量得分，各 z_m 须投影到相同维度。式(14.6)要求 $\sum_r m_r > 0$ ；全部缺失时不计算这一比值，而应拒绝输出或调用预先验证的回退流程。训练时进行模态 dropout，能减少模型对某一模态的脆弱依赖，但必须保留真实缺失模式。

14.2 时间对齐、缺失鲁棒性与工业诊断

时间对齐的多模态传感器。 视觉帧、振动窗口和控制指令可能不在同一时间尺度。可以用时间编码、可学习延迟或 cross-attention 在邻近时间段内寻找对应信息。若把未来传感器值错误地对齐到当前图像，离线结果会明显偏高，部署时却失效。因此多模态数据集必须保存采集时间、传输延迟和有效时间区间。

设第 m 种模态在时间窗 $W_i = [t_i^-, t_i^+]$ 内产生输入 $x_i^{(m)}$ ，编码器输出 $z_i^{(m)} \in \mathbb{R}^d$ 。所谓配对，至少应满足设备标识一致、事件窗有足够重叠，并且标签在预测时刻已经可用。若两个模态的有效窗交集为空，将它们强行作为正对会把时间错配当成监督噪声。对于存在未知延迟的系统，可在训练中显式搜索有限延迟集合 Δ ，例如令

$$\text{sim}_i = \max_{\delta \in \Delta} \text{sim}(z_i^{(v)}, z_{i,\delta}^{(s)}),$$

但最大化也可能选择偶然相似的错误事件，因此必须在留出设备和固定延迟范围上验证，而不能把对齐搜索结果直接解释为真实因果延迟。

图像与工艺曲线联合诊断。 视觉编码器提取表面纹理，序列编码器提取温度和压力变化，再用融合层预测缺陷类型与严重程度。消融实验至少包括仅视觉、仅时序、简单拼接和跨模态注意力四种设置。若融合模型只在完整数据上有效，还需报告相机缺失或曲线缺失时的退化曲线。

对齐、融合与协同的区别。 对齐回答“不同模态是否指向同一个对象或事件”，融合回答“如何联合使用这些信息”，协同则进一步要求联合表示在任务上优于任何单




图 14.2: 工业多模态系统中，编码、对齐、融合和任务输出是不同层次。

一模态。三者不能混为一谈：图像和文本可以在共享空间中相近，却未必能完成精确定位；多个传感器可以简单拼接，却没有学到跨模态因果关系。

图14.2将各模态编码器与融合层分开，说明原始输入先形成各自表示，再由对齐与融合环节为诊断或生成提供联合证据。

对称对比损失。 图到文和文到图两个方向都应参与训练。令 $S_{ij} = s_{ij}$ 为已经除以温度的得分矩阵，且 $i, j = 1, \dots, N$ ，则对称损失为

$$\mathcal{L} = \frac{1}{2} \left[-\frac{1}{N} \sum_i \log \frac{e^{S_{ii}}}{\sum_j e^{S_{ij}}} - \frac{1}{N} \sum_i \log \frac{e^{S_{ii}}}{\sum_j e^{S_{ji}}} \right]. \quad (14.7)$$

批次中的负样本并不都是真负样本：两个不同时间的图像可能描述同一设备状态，两个文本也可能共享相同故障原因。因此对比学习需要检查 false negative，并在必要时使用组标签、软标签或难负样本过滤。

模态不平衡与缺失鲁棒性。 某一模态信噪比更高时，模型可能忽略其他模态；训练损失下降并不表示融合真正发生。可以通过模态 dropout、分支独立监督、梯度平衡和质量门控减轻这一问题。测试时应绘制从完整输入到逐模态缺失的性能曲线，并区分随机缺失、连续掉线、延迟到达和系统性遮挡。

时间对齐与事件粒度。 图像帧、振动窗口和控制指令的时间粒度不同。对齐时要明确事件发生时间、采集时间、传输时间和标签确认时间。窗口重叠会增加有效样本数，却也可能把同一故障事件复制到训练和测试两侧。应以事件或设备为单位划分，并在报告中说明窗口长度、步长和允许的预测提前量。

多模态评价。 多模态系统应分别报告单模态基线、简单拼接、注意力融合和缺失模态结果。分类任务可检查跨模态遮挡后的鲁棒性；定位任务需要区域级准确率；生成任务需要事实一致性和证据覆盖率。最重要的消融不是把某一层删掉，而是回答“哪一种模态信息在什么工况下真正改变了决策”。

本章小结。 图像、振动和文字的采集频率不同，质量也不同，还可能缺失。联合使用时，要说明每一路怎样编码、按什么时间和设备配对、相互矛盾时听谁的，以及少一路输入时还能完成什么任务。最后在独立数据上分别测试完整输入和缺失输入，才能判断复杂的融合结构是否真的有帮助。

第十五章 深度生成模型

本章摘要。本章从“学习数据分布而非只学习标签”出发，依次解释变分自编码器、扩散模型及其条件控制，再比较生成质量、覆盖性、可控性和计算代价。ELBO、噪声反演和物理约束把抽象生成目标连接到工业仿真、数据增强和异常样本分析。

在贯穿案例中，生成模型不能通过制造合成故障来改变真实测试集或故障定义。它只回答数据稀缺时能否补充候选样本、恢复缺失观测或模拟退化轨迹；最终价值仍由未见设备上的真实故障召回、误报、校准和物理约束违反率决定。

本章先说明要学习怎样的联合分布或条件分布，再推导相应的训练目标。接下来检查生成样本是否遗漏某些故障类型、是否符合指定工况，以及采样误差有多大。合成样本可以用于训练，但收益要在保持独立的真实设备测试集上检验。生成的裂纹看起来逼真，也不代表现场出现过这种裂纹；真实故障很少时，模型尤其容易把已有猜测反复复制出来。因此每种方法都要说明哪些性质能够从目标函数得到，哪些仍需观测和验证。

15.1 生成建模的目标

生成模型学习数据分布 $p_{\text{data}}(x)$ 或其条件分布 $p(x | c)$ ，因而可以采样、补全、去噪和估计似然。判别模型关注 $p(y | x)$ 或决策边界，生成模型还试图描述输入本身的结构。

变分自编码器。 Variational Autoencoder (VAE)引入潜变量 z ，生成模型为 $p_{\theta}(x, z) = p(z)p_{\theta}(x | z)$ [55]。后验 $p_{\theta}(z | x)$ 通常难以计算，以 $q_{\phi}(z | x)$ 近似。由 KL 分解可得

$$\log p_{\theta}(x) = \mathcal{L}(x) + \text{KL}(q_{\phi}(z | x) \| p_{\theta}(z | x)), \quad (15.1)$$

其中证据下界（ELBO）为

$$\mathcal{L}(x) = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x | z)] - \text{KL}(q_{\phi}(z | x) \| p(z)). \quad (15.2)$$

式(15.2)右端的第一项重构输入，第二项使潜变量分布接近先验。若 $q_{\phi}(z | x) = \mathcal{N}(\mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x)))$ 可用重参数化 $z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon$ 、 $\epsilon \sim \mathcal{N}(0, I)$ 进行反向传播。

这个下界可以从 Jensen 不等式直接得到：

$$\log p_\theta(x) = \log \int q_\phi(z | x) \frac{p_\theta(x, z)}{q_\phi(z | x)} dz \quad (15.3)$$

$$\geq \mathbb{E}_{q_\phi}[\log p_\theta(x, z) - \log q_\phi(z | x)]. \quad (15.4)$$

将联合分布拆为 $p_\theta(x | z)p(z)$ ，就得到重构项减去先验正则项。更完整地说，ELBO 的缺口正是后验近似误差：

$$\log p_\theta(x) - \mathcal{L}(x) = \text{KL}(q_\phi(z | x) \| p_\theta(z | x)) \geq 0. \quad (15.5)$$

因此最大化 ELBO 同时有两个目标：提高观测在生成模型下的解释能力，并让编码器后验逼近真正后验；它并不保证重构误差与工业风险完全一致。若 $x \in \mathbb{R}^D$ 采用独立高斯解码器 $p_\theta(x | z) = \mathcal{N}(\mu_\theta(z), \sigma_x^2 I)$ ，则

$$-\log p_\theta(x | z) = \frac{1}{2\sigma_x^2} \|x - \mu_\theta(z)\|_2^2 + \frac{D}{2} \log(2\pi\sigma_x^2),$$

所以常见均方重构项隐含了同方差、条件独立噪声假设。若裂纹像素、高频冲击或少数故障模式更重要，应显式改变观测模型或评价权重，而不能仅增加潜变量维度。

编码器提供近似后验，解码器给出生成机制，两者通过同一个下界联合训练。对高斯后验和标准正态先验，KL 项可解析计算：

$$\text{KL}(q \| p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1). \quad (15.6)$$

若解码器能绕过潜变量解释数据，或 KL 约束过强，近似后验可能接近先验而不再携带输入信息。KL annealing 和 free bits 可以调整训练，但仍需检查潜变量是否保留故障模式，不能只观察总损失。

15.2 对抗学习与可逆密度建模

Generative Adversarial Network (GAN) 的原始对抗目标与可逆密度模型的变量替换目标具有不同的训练信号[30, 21]。本节比较二者如何定义生成分布，而不把样本锐利程度等同于似然质量。VAE 以可计算的下界换取潜变量推断的便利。若主要目标是采样，可以改用判别器提供训练信号；若需要显式密度，则可以限制变换结构以换取精确的变量替换计算。这两种选择分别引出 GAN 和 Normalizing Flow。

GAN 通过生成器 G 和判别器 D 进行极小极大优化：

$$\min_G \max_D \mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D(G(z))). \quad (15.7)$$

在理想最优判别器下，目标与真实分布和生成分布之间的 Jensen–Shannon 散度（Jensen–Shannon Divergence, JSD）相关。在固定生成分布 p_g 且判别器逐点最优时，对每个 x 令 $a =$

$p_{\text{data}}(x)$ 、 $b = p_g(x)$ ，最大化 $a \log D + b \log(1 - D)$ 的一阶导数为 $a/D - b/(1 - D)$ ，故

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}.$$

代回目标并利用 Jensen–Shannon 散度可得

$$V(D^*, G) = -\log 4 + 2 \text{JSD}(p_{\text{data}} \| p_g),$$

因此理想博弈的全局最优要求 $p_g = p_{\text{data}}$ 。这一步依赖判别器足够强、分布可比较和优化达到平衡；有限样本或支撑集几乎不相交时，理论散度与实际梯度都可能失真。实际交替训练中，判别器过强可能使原始生成器目标的梯度饱和，模式崩溃则使不同噪声产生相似样本。对工业故障而言，少数典型样本逼真却遗漏罕见模式，仍不足以支持数据增强。

流模型使用可微可逆变换 $z = f_\theta(x)$ 把数据映射到简单先验。这里 $x, z \in \mathbb{R}^d$ ， $J_{f_\theta}(x)$ 的第 (i, j) 项为 $\partial f_{\theta,i}(x)/\partial x_j$ ，且其行列式非零：

$$\log p_X(x) = \log p_Z(f_\theta(x)) + \log |\det J_{f_\theta}(x)|. \quad (15.8)$$

推导来自微分体积变换：若 $z = f_\theta(x)$ ，则 $dz = |\det J_f(x)|dx$ ，而概率守恒给出 $p_X(x)dx = p_Z(z)dz$ ，故 $p_X(x) = p_Z(f_\theta(x))|\det J_f(x)|$ 。例如逐维仿射耦合层保持一部分坐标不变，并令另一部分 $y_b = x_b \odot \exp s(x_a) + t(x_a)$ ，其雅可比为三角矩阵，因而 $\log |\det J| = \sum_k s_k(x_a)$ ，同时逆变换可显式计算。可逆性和可计算的 Jacobian 行列式限制了网络设计，也使密度计算无需 VAE 的变分下界。采样时使用逆变换。精确似然只表示对模型分布的精确计算，并不保证该分布符合真实故障机制，更不保证高似然等同于低风险。

表15.1比较的关键是目标与代价是否匹配。需要连续表示时检查 VAE 的压缩损失，需要快速采样时检查 GAN 的模式覆盖，需要密度时检查 Flow 的结构限制。扩散模型则把复杂生成映射分解为多步去噪，后文再推导其训练过程。

表 15.1: 生成模型路线与工业应用边界

模型路线	学习对象	主要优点	工业使用时的关键检查
VAE	潜变量分布与重构似然	潜空间连续、采样稳定	重构是否抹平细裂纹，潜变量是否保留工况
GAN	生成器与判别器的对抗平衡	样本锐利、条件生成直接	模式崩溃、训练不稳定、类别覆盖
Flow	可逆变换与精确似然	可计算密度、逆向映射清晰	可逆结构限制、显存和表达能力
Denoising Diffusion Probabilistic Model (DDPM)/Denoising Diffusion Implicit Model (DDIM)	逐步加噪与反向去噪	条件控制强、覆盖较好	采样步数、异常细节和条件一致性
潜空间扩散	压缩空间中的扩散过程	高分辨率成本较低	编码器压缩损失和生成细节可信度




图 15.1: 扩散模型的时间轴：前向过程逐步破坏结构，反向网络学习在每个噪声尺度恢复结构。

15.3 扩散过程与条件控制

图15.1的实线沿时间增加噪声，反馈箭头则概括学习到的反向恢复路径；训练需覆盖多个噪声尺度，而不是只拟合从末端噪声到样本的一次映射。扩散模型通过逐步加噪和反向去噪构造生成过程[38]。前向过程逐步加入高斯噪声：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t I). \quad (15.9)$$

这里 $t = 1, \dots, T$ 为扩散步， $0 < \beta_t < 1$ 为噪声日程， $x_0 \sim p_{\text{data}}$ 。记 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，则可直接采样

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (15.10)$$

反向网络 $\epsilon_\theta(x_t, t)$ 预测噪声，常用简化目标

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2]. \quad (15.11)$$

此处独立采样 $t \sim \text{Uniform}\{1, \dots, T\}$ 、 $x_0 \sim p_{\text{data}}$ 和 $\epsilon \sim \mathcal{N}(0, I)$ ，再由式(15.10)构造 x_t 。由条件期望的最小均方性质，若网络容量和优化均理想，则

$$\epsilon_\theta^*(x_t, t) = \mathbb{E}[\epsilon | x_t, t].$$

又因 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ ，可由噪声预测得到干净样本估计

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

当 $\bar{\alpha}_t$ 很小时，这个反演会放大预测误差，说明末端高噪声阶段对模型校准和采样数值稳定性尤其敏感。

采样时从高斯噪声开始，按反向时间步逐渐去噪。直观上，模型学习的不是一次性画出样本，而是学习一系列局部的“如何去掉一点噪声”。

扩散模型的后验。 由于前向过程是高斯马尔可夫链，给定 x_0, x_t 的后验仍为高斯：

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(\tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I). \quad (15.12)$$

对 $t = 2, \dots, T$ ，其参数为

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t, \quad (15.13)$$

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t. \quad (15.14)$$

其推导只需把两个高斯因子相乘。由 $q(x_t | x_{t-1}) \propto \exp[-\|x_t - \sqrt{\alpha_t}x_{t-1}\|^2/(2\beta_t)]$ 以及 $q(x_{t-1} | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}x_0, (1 - \bar{\alpha}_{t-1})I)$, 收集关于 x_{t-1} 的二次项, 精度为 $\beta_t^{-1} + (1 - \bar{\alpha}_{t-1})^{-1}$, 所以方差是其倒数 $\tilde{\beta}_t$; 再收集一次项并乘以该方差, 就得到式(15.13)的均值。这说明后验同时利用当前噪声状态 x_t 和原始状态 x_0 。采样时 x_0 未知, 网络必须先由 x_t 估计它或等价地估计噪声, 不能把该后验公式误当作可直接使用的生成器。约定 $\bar{\alpha}_0 = 1$, 则 $t = 1$ 时方差为零, 条件后验退化到已知 x_0 , 不作为非退化高斯参与上述 KL 计算。对 $t \geq 2$, 扩散模型的变分目标包含上述后验与反向模型 $p_\theta(x_{t-1} | x_t)$ 之间的 KL 项。固定反向方差并采用噪声预测参数化后, 这些项可写为带时间步权重的噪声预测误差; 常用简化目标改变了这些权重, 不能与完整变分目标直接等同。采样时无法获得 x_0 , 因此反向模型必须仅根据当前带噪状态和时间步完成预测。噪声预测、 x_0 预测和速度预测是不同参数化, 改变梯度尺度与采样表现, 但共享逐步去噪框架。

条件扩散与引导。 若有条件 c , 网络写为 $\epsilon_\theta(x_t, t, c)$ 。分类器引导使用带噪样本分类器的梯度调整生成方向; 无分类器引导通过训练时随机丢弃条件, 使网络同时学习条件与无条件预测, 再组合为

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \emptyset) + w[\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)]. \quad (15.15)$$

$w = 0$ 对应无条件预测, $w = 1$ 对应原始条件预测, $w > 1$ 进一步加强条件方向。更强引导可能损害多样性或产生伪影, 应在固定采样预算下比较条件满足率和缺陷覆盖。ControlNet 等条件分支可接收边缘、深度或几何信息, 但条件输入并不自动保证生成结果满足物理约束。

Score Matching。 以下 $p_t(x_t) = \int q(x_t | x_0)p_{\text{data}}(x_0) dx_0$ 表示前向带噪边缘密度, 不是反向模型的转移密度。扩散模型也可从各噪声时刻的 score $\nabla_{x_t} \log p_t(x_t)$ 理解。去噪 score matching 估计带噪分布的对数密度梯度, 而不直接计算归一化常数。高斯加噪下, 噪声预测对应的 score 估计为 $-\epsilon_\theta(x_t, t)/\sqrt{1 - \bar{\alpha}_t}$ 。这一估计需与噪声日程共同构成反向随机过程, 或对应的概率流常微分方程, 才能用于分布采样; 单纯沿密度梯度上升会趋向局部高密度区域, 并不保证恢复目标分布的模式比例。这个观点连接了扩散模型、能量模型和随机微分方程。

15.4 采样、约束与工业可信度

DDIM 在与 DDPM 相关的训练目标下改变采样轨迹, 潜空间扩散通过压缩表示降低高分辨率生成成本[101, 86]。无分类器引导与 ControlNet 分别提供条件强度组合和结构条件分支[39, 116], 两者均不能自动保证物理可行性。有了可采样模型, 还不能直接把生成样本当成维护数据。只用正常数据训练的模型可以模仿正常模式, 却没有凭据知道故障长什么样。若要按故障标签或严重度生成, 应有真实故障样本、经过

验证的仿真机制，或能够核查的领域约束。不同用途也要分别验收：补足少数类别要检查模式是否被覆盖，模拟退化要检查时间顺序和工况，指定位置的缺陷图像要检查位置与标注是否一致。

DDIM 与采样加速。 DDPM 使用随机反向过程，需要较多时间步。DDIM 可以构造非马尔可夫的确定性或弱随机采样轨迹，在保留训练目标的同时减少采样步数。步数减少会降低延迟，却可能损害细节和条件一致性，因此应绘制质量-延迟曲线，而不是只报告单一采样配置。

潜空间扩散。 直接在高维像素或原始波形空间扩散成本很高。潜空间扩散先用编码器把输入压缩到 z ，在潜空间去噪，再由解码器重构。压缩比例过大可能删除细微裂纹、冲击脉冲或高频异常，因此工业应用必须比较原空间频谱、边缘和峰值统计，而不能只看重构图像的主观质量。




图 15.2: 扩散模型把生成拆为前向加噪和学习反向去噪。

图15.2把预设加噪机制与可训练的噪声预测网络分开；网络读取带噪状态、时间和条件，采样时再由这些预测逐步恢复样本。

物理约束生成。 工业生成样本必须满足守恒、边界、单调性、频率范围或设备状态转移约束。可以在损失中加入残差惩罚

$$\mathcal{L} = \mathcal{L}_{gen} + \lambda_{phys} \mathbb{E}[\|r(x, c)\|_2^2], \quad (15.16)$$

也可以在采样后投影到可行域。惩罚过弱会产生不可能样本，过强则可能牺牲数据多样性；因此应分别报告真实性、多样性和约束违反率。

记忆、隐私与生成数据。 生成模型可能记住训练集中的罕见记录，尤其在数据量小、重复度高或模型过拟合时。近邻距离、成员推断和重复片段检测可用于筛查记忆风险。差分隐私训练可以降低单个样本的影响，但通常带来质量-隐私权衡。生成数据用于发布或跨机构共享前，应进行去标识、相似样本审计和下游泄漏测试。

生成模型的实验流程。 完整实验应包含训练数据分布、采样配置、随机种子、生成数量、重复检测、专家评价、统计检验和下游任务。对故障生成尤其应使用未参与生成训练的真实故障测试集；否则增强后的模型可能只是在适应合成数据的风格。最有说服力的结论是：在不同随机种子、不同设备和不同故障类型上，真实测试性能都获得稳定改善。

评价应先检查边缘分布、相关性、频谱与缺陷几何，再检查物理约束和条件一致性，最后比较真实数据上的下游结果。Fréchet Inception Distance (FID) 或主观逼真度只覆盖部分属性。对照应至少包括仅真实数据与真实加合成数据，并匹配训练预算；重采样基线可以区分数值效应，打乱合成标签则可作为诊断对照，不能替代有效基线。

新增样本可能复制设备身份和批次标记，也可能改变故障先验比例。因此测试集须保持真实、独立且未参与生成器训练与选择，报告召回、误报和校准，而不只看训练损失。若训练指标上升而真实测试性能下降，应检查覆盖不足、生成伪影和先验变化，不能继续用更多合成数据掩盖问题。

本章小结。 VAE 借助潜空间生成，GAN 通过对抗判别训练，flow 使用可逆变换计算似然，diffusion 逐步去噪得到样本。它们的计算方式不同，生成结果都仍需检查。用于工业任务时，既看样本是否逼真、是否覆盖需要的故障，也检查是否违背物理规律、是否泄露训练记录，最后用独立的真实数据检验下游收益。

第十六章 物理信息神经网络：从稀疏观测重建风场

本章摘要。物理信息神经网络（Physics-Informed Neural Network, PINN）将观测误差、微分方程残差和初边值条件共同用于训练。本章以风电场稀疏多普勒激光雷达测量为例，推导从视线速度到连续风场的逆问题，解释自动微分、尺度处理、约束方式和主要变体，并讨论可辨识性、湍流闭合与独立验证。

风电场中的尾流使下游风机入流速度下降，并改变剪切和载荷。扫描激光雷达能够在远距离取得风速信息，但观测沿有限波束和距离门分布，扫描过程还需要时间。目标因而不是把一个完整风速图输入网络，而是根据不完整、不同步且带有空间平均效应的观测，估计指定时空区域中的速度场。本章给出教学建模设置，不对应已完成的风电场实验，也不预设 PINN 优于传统反演或数值同化。

雷达只沿有限方向测量，却希望得到一片区域的风速，这就是本章逆问题的起点。先用观测算子写清仪器到底测到了什么，再选定重建范围和尺度，把方程、边界与初值写入训练损失。未测到的位置主要依靠这些条件推断，因此方程残差很小，并不保证风场重建准确，还要用独立观测检验。能算出结果、能从数据确定唯一结果、能验证结果是否准确，是三个不同问题。下一章的预训练可以改善初始化或共享表示，但不能补上当前场地缺失的观测与边界约束。

16.1 从函数拟合到受约束逆问题

普通监督回归通过成对样本约束函数值。PINN 进一步用已知方程约束函数在未观测位置的变化方式。设空间坐标为 $\mathbf{x} \in \Omega$ 、时间为 $t \in [0, T]$ ，待求状态为 $\mathbf{q}(\mathbf{x}, t)$ ，控制方程、边界条件和初始条件分别写为

$$\mathcal{N}_\eta[\mathbf{q}](\mathbf{x}, t) = \mathbf{0}, \quad (\mathbf{x}, t) \in \Omega \times (0, T], \quad (16.1)$$

$$\mathcal{B}[\mathbf{q}](\mathbf{x}, t) = \mathbf{b}(\mathbf{x}, t), \quad \mathbf{x} \in \partial\Omega, \quad (16.2)$$

$$\mathbf{q}(\mathbf{x}, 0) = \mathbf{q}_0(\mathbf{x}). \quad (16.3)$$

其中 η 表示方程中的物理参数， $\mathcal{B}$ 可以表示函数值、法向导数或通量。神经网络 $\mathbf{q}_\theta$ 提供一个可微的连续函数近似，训练使其同时符合观测与方程[82, 50]。

正问题在参数和初边值条件给定时求状态。逆问题则由部分观测反推状态、参数或边界输入。稀疏风场重建属于后者：即使只优化网络参数，完整风场也不是直接观测标签。若同时估计入流或有效黏度，还需要检查这些未知量是否能够被现有测量分别识别。增加待估参数会扩大解空间，不会自动提高重建可信度。

配点是用于计算方程残差的时空位置，不需要对应真实风速标签。配点越多通常越能覆盖残差，但它们没有增加独立观测信息。若目标是对区域上的残差平方积分，连续量为

$$\mathcal{J}_f = \frac{1}{|D|} \int_D \|r(\boldsymbol{\xi})\|_2^2 d\boldsymbol{\xi}, \quad D = \Omega \times (0, T),$$

从 $\boldsymbol{\xi}_j \sim \rho$ 独立抽样并用 Monte Carlo 近似时，

$$\hat{\mathcal{J}}_f = \frac{1}{N_f} \sum_{j=1}^{N_f} \frac{\|r(\boldsymbol{\xi}_j)\|_2^2}{|D|\rho(\boldsymbol{\xi}_j)}$$

在 ρ 覆盖 D 且积分有限时无偏。均匀采样时权重为常数；残差自适应采样若不除以 ρ ，就等价于改变了目标积分的空间权重。有限样本下误差还取决于残差方差，局部加可以降低某些区域的方差，却不能创造新的观测约束。即便某个网络在全部配点上满足方程，缺少足够的初边值约束时仍可能存在多个物理解。PINN 将连续问题转化为有限样本上的优化问题，离散残差较小也不等于已证明连续解的存在、唯一性或误差上界。

本章采用坐标网络直接拟合一个时间窗内的风场。它与输入一组工况后直接输出解的神经算子不同：更换场地或边界条件后，普通 PINN 往往需要重新优化。若采用跨工况预训练与适应，则应另行报告预训练数据、适应观测及额外成本。

把逆问题写成算子组合有助于定位信息来源。记 $\mathcal{H}$ 为雷达测量算子、 $\mathcal{N}$ 为方程算子、 $\mathcal{C}$ 为初边值约束，则训练实际上寻找

$$\mathbf{u} \in \{\mathbf{u} : \mathcal{H}\mathbf{u} \approx \mathbf{y}, \mathcal{N}[\mathbf{u}] = 0, \mathcal{C}[\mathbf{u}] = 0\}.$$

观测项缩小的是与仪器一致的解集合，物理项缩小的是满足所选方程的解集合；二者交集为空时，继续增大物理权重只会牺牲观测拟合。这个集合观点解释了为什么配点数量、网络宽度和损失权重都不能单独解决边界错误或观测几何退化。

16.2 激光雷达实际观测了什么

图16.1区分测量算子与微分残差：前者把场映射到可观测量，后者在配点上检验物理约束，二者不能用同一种点值误差替代。设三维速度为 $\mathbf{u} = (u, v, w)^\top$ 。在以东、北、上为轴的局部坐标系中，若方位角 α 从东向北计、仰角为 β ，则视线单位向量为

$$\mathbf{e}(\alpha, \beta) = (\cos \beta \cos \alpha, \cos \beta \sin \alpha, \sin \beta)^\top. \quad (16.4)$$




图 16.1: PINN 的信息路径：观测通过测量算子约束场，微分方程和边界条件在未观测位置提供额外约束。

仪器原始方位角若从北起算，必须先转换。径向速度正负号也应与仪器的朝向或远离约定一致。理想点测量为 $\mathbf{e}^\top \mathbf{u}$ ，而不是速度模长 $\|\mathbf{u}\|_2$ 。

实际距离门对有限探测体积内的速度加权，扫描又可能包含时间平均。以固定位置雷达为例，第 m 次观测可以表示为

$$y_m = \mathcal{H}_m[\mathbf{u}] + \epsilon_m, \quad (16.5)$$

$$\mathcal{H}_m[\mathbf{u}] = \int \int K_m(s, \tau) \mathbf{e}_m(\tau)^\top \mathbf{u}(\mathbf{x}_L + s\mathbf{e}_m(\tau), \tau) ds d\tau, \quad (16.6)$$

$$K_m \geq 0, \quad \int \int K_m(s, \tau) ds d\tau = 1. \quad (16.7)$$

这里 $\mathbf{x}_L$ 为雷达位置， K_m 描述该次观测的距离与时间响应， ϵ_m 包含测量噪声。只有当探测体积和时间窗相对于流场变化足够小时，才可近似为门中心、时间戳处的点投影。激光雷达测风中的体积平均与湍流测量限制可参见相关综述[92]。运动平台还需修正位置、姿态和平台速度，本章先限定为固定平台。

在网络训练中，可用数值求积实现这一观测算子：

$$\hat{y}_m = \sum_{a=1}^{A_m} \omega_{ma} \mathbf{e}_m(t_{ma})^\top \mathbf{u}_\theta(\mathbf{x}_{ma}, t_{ma}), \quad \sum_{a=1}^{A_m} \omega_{ma} = 1. \quad (16.8)$$

因此数据损失应比较 $\hat{y}_m$ 和 y_m ，不能将径向速度直接当作 u 分量标签。求积节点和权重来自测量模型，不是任意增加的训练标签。忽略体积平均时，模型可能以过于平滑的局部风场解释距离门观测，也可能把未分辨的剪切错误归因于噪声。

单条波束在某个位置只提供一个标量约束。若扰动 $\delta \mathbf{u}$ 满足 $\mathbf{e}^\top \delta \mathbf{u} = 0$ ，该观测无法区分扰动前后的速度。多台雷达在近似相同位置和时刻交叉观测时，可以组成

$$\mathbf{y} = E\mathbf{u} + \boldsymbol{\epsilon}, \quad E = \begin{bmatrix} \mathbf{e}_1^\top \\ \vdots \\ \mathbf{e}_J^\top \end{bmatrix}. \quad (16.9)$$

直接恢复三维速度需要 E 满列秩且条件数可接受。更一般地，在局部线性化下，观测对未知参数或场系数 $\vartheta \in \mathbb{R}^P$ 的敏感度矩阵为

$$G = \frac{\partial(\mathcal{H}[\mathbf{u}_\vartheta])}{\partial \vartheta}.$$

若存在非零方向 $\delta\vartheta$ 使 $G\delta\vartheta = 0$ ，则一阶观测对该方向没有辨识能力；若 $G^T R^{-1} G$ 有很小特征值，噪声会被放大为很大的参数不确定性。物理残差和边界会增加额外行，但只有当它们对该方向提供独立敏感度时才改善秩或条件数。因而“物理项降低”不能单独证明参数可辨识。两条独立视线配合已知垂直速度等额外假设，才可能恢复两个水平分量。近乎平行的波束会放大噪声，非同时扫描也不能无条件合并为同一瞬时速度。PINN 借助方程和边界在时空中传播信息，但不能消除由测量几何和未知边界共同造成的不可辨识性。

16.3 风场方程、尺度与物理假设

先考虑恒密度、不可压缩流动。将压力除以密度，记运动学压力为 $\pi = p/\rho$ ，则动量与连续性方程为

$$\nabla \cdot \mathbf{u} = 0, \quad (16.10)$$

$$\partial_t \mathbf{u} + (\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla \pi + \nu \nabla^2 \mathbf{u} + \mathbf{f}. \quad (16.11)$$

其中 ν 为运动黏度， $\mathbf{f}$ 为单位质量外力。重力的静水平衡部分可吸收入压力，科里奥利力、浮力或风机作用则应按目标尺度决定是否保留。忽略这些项属于模型假设，需要与场地、稳定度和观测时间尺度匹配。

对于风机尾流，不能在穿过转子的区域直接假设 $\mathbf{f} = \mathbf{0}$ 却又期望方程解释转子动量抽取。可以用已知运行状态约束的执行器盘体力近似，也可以将重建区域限定在转子外，并提供经过验证的入口或界面条件。如果把任意体力场也交给高容量网络自由拟合，它可能吸收所有动量残差，使物理约束失去辨识作用。

实际稀疏扫描通常无法解析全部湍流尺度。如果目标是时间平均速度 $\bar{\mathbf{u}}$ ，雷诺平均方程包含额外应力：

$$\partial_t \bar{\mathbf{u}} + (\bar{\mathbf{u}} \cdot \nabla) \bar{\mathbf{u}} = -\nabla \bar{\pi} + \nu \nabla^2 \bar{\mathbf{u}} - \nabla \cdot \overline{\mathbf{u}' \mathbf{u}'} + \bar{\mathbf{f}}. \quad (16.12)$$

这里的湍流闭合指用额外的模型假设表示平均流动方程中未确定的湍流应力，使方程可求解。采用涡黏度闭合时，常将黏性与湍流应力合并为 $\nabla \cdot [2(\nu + \nu_t)S]$ ，其中 $S = (\nabla \bar{\mathbf{u}} + \nabla \bar{\mathbf{u}}^T)/2$ ，各向同性湍动能项吸收入修正压力。当 ν_t 随位置变化时，这一散度项不能简化为 $(\nu + \nu_t) \nabla^2 \bar{\mathbf{u}}$ 。估计 ν_t 需要闭合假设、取值约束和额外证据，否则黏度、入流与压力可能互相补偿。

因此应先声明重建对象是瞬时场、滤波场还是平均场，再匹配方程和观测平均尺度。本章后续以已选定的恒定有效黏度模型说明算法，并将其作为需要检验的近似。真实复杂地形、热分层和非平稳尾流可能需要扩展控制方程，不能用较大的物理损失权重弥补遗漏机制。

物理损失之前先进行无量纲化。选取长度 L_0 、速度 U_0 、参考位置 $\mathbf{x}_0$ 和时间 t_0 ，定

义

$$\mathbf{x}^* = (\mathbf{x} - \mathbf{x}_0)/L_0, \quad t^* = (t - t_0)U_0/L_0, \quad (16.13)$$

$$\mathbf{u}^* = \mathbf{u}/U_0, \quad \pi^* = \pi/U_0^2. \quad (16.14)$$

压力还可减去参考值，因为不可压缩动量方程只包含其空间梯度。定义 $\text{Re} = U_0 L_0 / \nu_{\text{eff}}$ 和 $\mathbf{f}^* = L_0 \mathbf{f} / U_0^2$ 后，残差为

$$r_c = \nabla^* \cdot \mathbf{u}_\theta^*, \quad (16.15)$$

$$\mathbf{r}_m = \partial_{t^*} \mathbf{u}_\theta^* + (\mathbf{u}_\theta^* \cdot \nabla^*) \mathbf{u}_\theta^* + \nabla^* \pi_\theta^* - \text{Re}^{-1} \nabla^{*2} \mathbf{u}_\theta^* - \mathbf{f}^*. \quad (16.16)$$

这使不同损失项不再因米、秒与压力的单位而任意改变相对量级。以长度尺度 L_0 和速度尺度 U_0 为例，连续性残差的自然量级是 U_0/L_0 ，动量残差的自然量级是 U_0^2/L_0 ；若直接平方原始残差，动量项相对连续性项会多出 $(U_0)^2$ 的单位和尺度因素。因此应先除以各自参考尺度，或通过 λ_c, λ_m 显式定义无量纲权重。数据项还应按噪声标准差除权，边界项则按边界测量误差和边界采样测度归一化。权重不是越大越“物理”，而是定义了不同证据之间的相对容忍度。

如果输入还被映射到 $[-1, 1]$ ，计算物理导数时必须包含额外缩放的链式法则。例如 $\tilde{x} = 2(x - x_{\min})/(x_{\max} - x_{\min}) - 1$ 时， $\partial_x = 2\partial_{\tilde{x}}/(x_{\max} - x_{\min})$ 。自动微分只对实际计算图求导，无法修正被漏写的尺度变换。

16.4 网络、损失与训练过程

网络以无量纲时空坐标为输入，输出三个速度分量和压力：

$$(u_\theta^*, v_\theta^*, w_\theta^*, \pi_\theta^*) = F_\theta(x^*, y^*, z^*, t^*). \quad (16.17)$$

自动微分对输出关于输入求一阶和二阶导数，再将它们代入式(16.16)。例如第一分量的对流项为 $u^* \partial_{x^*} u^* + v^* \partial_{y^*} u^* + w^* \partial_{z^*} u^*$ 。这与仅对网络参数反向传播不同：优化参数时还需要保留输入导数的计算图，二阶空间导数会显著增加内存与计算开销。

强形式黏性方程需要足够光滑的网络。常用 $\tanh$ 或平滑正弦激活；分段线性的 ReLU 二阶导数几乎处处为零，不适合直接表达这里的经典二阶黏性残差。Fourier 特征可增强高频表示，但过高频率会放大导数并加重优化困难。若输入角度来自雷达元数据，其三角函数只用于观测算子，不应与风场坐标混淆。

若第 m 个径向观测的标准差为 σ_m ，可将数据项写成

$$\mathcal{L}_d = \frac{1}{N_d} \sum_{m=1}^{N_d} \left(\frac{\mathcal{H}_m[\mathbf{u}_\theta] - y_m}{\sigma_m} \right)^2. \quad (16.18)$$

式(16.18)对应独立高斯噪声下的加权最小二乘。距离门或扫描之间具有相关噪声时，应考虑残差协方差及有效样本量，不能把重叠门当作独立证据重复加权。质量控制可

筛除受降水、遮挡或低信噪比影响的观测，阈值应事先固定。离群值较多时可比较 Huber 损失，但稳健损失不能代替错误时间戳或仪器偏差的校准。

在 N_f 个内部配点上计算连续性和动量项，并加入边界、初值与压力规范约束：

$$\mathcal{L}_f = \frac{1}{N_f} \sum_{j=1}^{N_f} [\lambda_c |r_c(\boldsymbol{\xi}_j)|^2 + \lambda_m \|\mathbf{r}_m(\boldsymbol{\xi}_j)\|_2^2], \quad (16.19)$$

$$\mathcal{L} = \lambda_d \mathcal{L}_d + \mathcal{L}_f + \lambda_b \mathcal{L}_b + \lambda_i \mathcal{L}_i + \lambda_g \mathcal{L}_g + \lambda_\eta \mathcal{R}(\boldsymbol{\eta}). \quad (16.20)$$

其中 $\boldsymbol{\xi}_j$ 为无量纲时空坐标， $\mathcal{L}_b$ 和 $\mathcal{L}_i$ 分别是边界、初值误差。压力可加上任意仅随时间变化的函数而不改变动量方程，因此 $\mathcal{L}_g$ 可在每个采样时刻固定一个参考点的压力，或固定空间平均压力。只固定一个时空点不足以消除整个非稳态问题的压力自由度。 $\mathcal{R}$ 用于约束待估物理参数；已知参数时无需这一项。

从残差到参数梯度。 令所有配点、观测和边界条件组成向量 $r(\theta)$ ，并暂时写加权平方损失为

$$\mathcal{L}(\theta) = \frac{1}{2} r(\theta)^\top W r(\theta), \quad W \succeq 0.$$

若 $J_r = \partial r / \partial \theta \in \mathbb{R}^{K \times P}$ ，则逐项链式法则给出

$$\nabla_\theta \mathcal{L} = J_r^\top W r, \quad \nabla_\theta^2 \mathcal{L} \approx J_r^\top W J_r,$$

其中第二式忽略残差对参数的二阶项，是 Gauss-Newton 近似。这里的 J_r 不仅包含 $\partial F_\theta / \partial \theta$ ，还包含例如 $\partial(\partial_x u_\theta) / \partial \theta$ 和 $\partial(\partial_{xx} u_\theta) / \partial \theta$ ；因此自动微分先对输入求导，再对所得残差对参数反向传播。残差很大并不必然产生大更新：若网络在该点对参数的雅可比接近零，梯度仍可能很小，这正是饱和激活和 PINN 病态优化的一个来源。

对一个内部点的动量残差 $r_m = \partial_t u + (u \cdot \nabla) u + \nabla \pi - \nu \nabla^2 u - f$ ，其任意参数 θ_p 的导数为

$$\frac{\partial r_m}{\partial \theta_p} = \partial_t \frac{\partial u}{\partial \theta_p} + \left(\frac{\partial u}{\partial \theta_p} \cdot \nabla \right) u + (u \cdot \nabla) \frac{\partial u}{\partial \theta_p} + \nabla \frac{\partial \pi}{\partial \theta_p} - \nu \nabla^2 \frac{\partial u}{\partial \theta_p}.$$

这说明训练不是只让输出接近标签，而是让网络参数改变后其导数结构也朝残差下降的方向变化。若 ν 也待估，则还要增加 $-\partial_{\theta_p} \nu \nabla^2 u$ 项；遗漏该项会使逆参数梯度错误。

边界条件应来自物理设置，而不是为了降低损失任意补齐。对一阶时间方程，给定初值通常决定时间演化；对含空间二阶导数的黏性方程，还需要足够的空间边界信息。若入口速度、压力和出口通量同时被强行指定而彼此不相容，连续问题本身可能无解。离散训练中，这表现为数据项与边界项的残差不能同时下降；此时调权重只是在两类冲突之间选择，并没有修复问题。相反，边界条件不足会留下零空间：存在不同的 $\mathbf{q}$ 具有相同观测和相同内部残差，却在未约束边界上不同。因此应通过边界类型、数量和独立观测检查唯一性，而不是以网络输出平滑作为证据。上游测风可约束入流，地表可在适用分辨率下采用无滑移或壁面模型，开放边界则需要与流动方向和数值模型相符的条件。粗糙地表附近未被解析时，强行令全部近地网格速度为零会改

变垂直剪切。初始场未知时可以用低维参数化联合估计，并明确先验来源；不能将任意零场当作真实初值。

软约束通过损失惩罚边界误差。对适合的 Dirichlet 条件，也可构造硬约束

$$q_\theta(\boldsymbol{\xi}) = g(\boldsymbol{\xi}) + d(\boldsymbol{\xi})\tilde{q}_\theta(\boldsymbol{\xi}), \quad d|_{\Gamma_D} = 0. \quad (16.21)$$

这里 g 是满足边界值的延拓， d 是适当光滑的消失函数。硬约束消除了该部分边界误差，却要求边界数据相容，并可能改变导数尺度。将含噪测量精确写入硬约束，会把测量误差固定在解中。三维速度也可写成光滑向量势的旋度以自动满足散度为零，但拓扑、边界构造和更高阶导数成本仍需处理。

复合损失存在梯度竞争：数据项可能快速下降，而动量项几乎不变，或者物理项主导更新使网络忽略观测。相关研究分析了 PINN 的梯度病态和训练失败模式[113, 58]。训练应分别跟踪各项残差及参数梯度范数，先检查尺度和方程，再考虑调整权重。自适应权重需要限幅或归一化，不能让难拟合的数据项被持续降权后掩盖模型失配。

Algorithm 2 稀疏激光雷达风场重建的 PINN 训练

Require: 训练扫描、观测算子、可用初边值信息、物理假设与验证扫描

- 1: 固定坐标、符号、时间戳、质量控制和无量纲尺度
 - 2: 初始化坐标网络及有约束的待估参数
 - 3: **for** 每个训练阶段 **do**
 - 4: 采样内部配点、边界点和初值点，保留基础覆盖
 - 5: 用距离门求积计算径向预测与数据损失
 - 6: 自动微分计算连续性、动量及边界残差
 - 7: 按式(16.20)更新参数，记录各项损失和梯度
 - 8: 在验证扫描上检查观测误差，并在独立配点上检查残差
 - 9: **end for**
 - 10: 冻结模型和选择规则，在留出观测与独立仪器上验收
-

Adam 可用于早期优化，随后可在固定配点和确定性目标上尝试 Limited-memory Broyden–Fletcher–Goldfarb–Shanno (L-BFGS)。频繁更换配点会改变后者的目标并影响曲率近似，因此两阶段优化不是无需条件的默认保证。停止规则应结合独立验证误差、残差和预算，而非只看总训练损失。若验证误差持续恶化，应检查边界冲突、噪声模型或欠拟合，不应单纯提高物理权重。

16.5 主要变体及其适用条件

残差自适应采样先在候选点上评估误差，再增加高残差区域的配点。它适合尾流剪切层和局部变化较强的位置，但必须保留全域基础覆盖。高残差也可能来自错误方

程或边界，反复加点不一定能够解决。若原目标是均匀体积积分，按非均匀分布采样后应进行相应的重要性修正，否则训练实际强调了新的空间权重。对独立均匀测试配点的评估可以区分局部拟合与全域改善。

弱形式或变分 PINN 将微分方程乘以测试函数并积分，适当分部积分可降低网络所需的导数阶数[52]。例如对扩散项和在边界为零的测试函数 φ ，有

$$\int_{\Omega} (-\nabla^2 q) \varphi \, d\mathbf{x} = \int_{\Omega} \nabla q \cdot \nabla \varphi \, d\mathbf{x}. \quad (16.22)$$

非零边界测试函数还会产生通量边界项。弱形式减少了直接计算二阶导数的需要，但测试空间和积分精度决定哪些残差能够被检测，不能把少量积分约束视为处处守恒的证明。

区域分解为不同子域训练局部网络，并在交界处约束状态与相应通量。Extended Physics-Informed Neural Network (XPINN) 将这种思路扩展到时空分解[47]。风电场可按风机邻域或尾流区域分区，以改善局部尺度表示并支持并行训练。接口仅匹配速度而忽略压力或应力一致性，仍可能产生动量跳变，分区数量增加也会增加接口优化成本。

时间分窗和因果训练强调先拟合早期状态，再逐步处理后续时间。一个常见的加权思路是令第 k 个时间段的残差权重取

$$a_k = \exp \left(-\gamma \sum_{j < k} \mathcal{L}_{f,j} \right), \quad \gamma > 0. \quad (16.23)$$

早期误差较大时，后续时间段暂时减小权重。使用式(16.23)时应说明是否对权重停止梯度，以及如何逐渐开放后续时间段。权重长期接近零会造成后段完全未学到，必须单独验收每个时间窗。窗口交界还需状态传递，错误初值可能沿时间累积。

逆参数 PINN 将 $\boldsymbol{\eta}$ 与 θ 共同优化。正黏度可通过 $\nu_{\text{eff}} = \nu_{\min} + \log(1 + \exp a)$ 参数化，但正值并不等于物理可辨识。应比较不同初值和先验下的参数稳定性，并分析参数变化是否会被速度或边界补偿。只有参数在独立工况上也能解释观测时，才适合将其解释为物理量，而不仅是有效拟合系数。

贝叶斯 PINN 则为参数或场表示设置先验，以后验表达部分不确定性[114]。形式上可写为

$$p(\theta, \boldsymbol{\eta} \mid \mathbf{y}) \propto p(\mathbf{y} \mid \theta, \boldsymbol{\eta}) p(\text{物理约束} \mid \theta, \boldsymbol{\eta}) p(\theta, \boldsymbol{\eta}). \quad (16.24)$$

将物理残差当作概率因子时，残差尺度也必须建模，不能任意解释成已知测量噪声。多个随机种子训练的集合能揭示部分优化敏感性，但不是严格的后验样本。无论采用哪种区间，都应在独立观测上检查覆盖率，并区分测量噪声、有限观测和方程失配造成的不确定性。

16.6 风电场案例的验证流程

一个可检验的案例应先写清场地、扫描几何和重建时间窗。每条观测至少记录时间戳、雷达位置、波束方向、距离门响应、径向速度和质量标记。风机位置与运行状态用于定义几何或体力，入口信息只能使用任务开始时确实能够得到的测风数据。若扫描覆盖多个高度，可以研究三维重建；若只有近水平的一层扫描，就应把任务限定为二维或准二维，并明确采用了怎样的垂直输运假设，不能据此宣称恢复完整三维湍流。

重建窗口内使用晚于目标时刻的观测属于离线平滑，不能称为实时预测。在线重建只能使用当时已到达的扫描，并计入扫描延迟、质量控制、优化和查询时间。滚动窗口可用上一窗口参数初始化，但要记录跨窗口传递的信息。跨日期或跨风况部署需要独立测试，单窗口拟合成功不代表已经学习到可直接迁移的通用求解器。

数据划分应按完整扫描、连续时间段或独立雷达组织，避免将同一扫描的相邻距离门随机分到训练与测试后夸大泛化。验证集用于选择权重、网络规模和停止时刻，测试观测在选择完成前保持隐藏。已知几何和公共物理方程可以用于测试区域配点，但测试风速及由其反推的边界不能进入训练。应区分窗口内未观测位置的插值重建与新窗口的泛化，两者难度不同。

仅有径向观测时，可以在留出集合 $\mathcal{T}$ 上报告

$$\text{RMSE}_{\text{LOS}} = \sqrt{\frac{1}{|\mathcal{T}|} \sum_{m \in \mathcal{T}} (\mathcal{H}_m[\mathbf{u}_\theta] - y_m)^2}. \quad (16.25)$$

这一指标检验测量空间的一致性，不能证明每个速度分量都准确。若有独立三维风速参考，还应报告各分量误差、风向误差以及按空间区域分组的误差。低风速下风向不稳定，需要事先定义有效风速范围。对有限测点或探测体积，应将预测映射到参考仪器的采样尺度后比较。

合成试验可以从未参与训练的流场参考中模拟波束、距离门平均、扫描顺序和噪声，从而获得全场误差；若训练和参考都使用完全相同的简化方程，试验只检验理想匹配条件。为检查模型失配，还应改变入流、闭合或地形条件。真实试验可使用独立交叉雷达或测风仪器，但应说明其覆盖范围和自身误差。缺少全场真值时，不能用满足所假设方程来替代真实精度证据。

对照至少包括采用相同径向观测算子的无物理网络、适用的正则化反演，以及可获得时的数值模型同化。把已知完整速度分量交给某个基线，却只给 PINN 径向速度，会改变任务条件。所有方法应共享可用观测、边界来源和调参划分，同时报告训练或同化成本、单点查询成本和整个时间窗的交付延迟。

消融可以依次检查连续性约束、动量约束、真实距离门算子和边界信息的作用，并在匹配计算预算下比较。若去掉体积平均后径向误差变化很小而剪切误差增大，说明观测拟合不足以识别局部结构。若增加物理权重降低残差却提高独立观测误差，则应检查方程和边界失配。若更多扫描角度显著降低分量误差，收益可能主要来自观测

几何改善，而不是网络规模。

下游应用还应验收轮毂高度速度、转子面平均入流、尾流亏损与位置等目标，并说明参考上游风速的定义。由稀疏平均场不能直接推断湍流强度或疲劳载荷；这些量需要相应时间分辨率和动力学信息。物理残差应在未参与训练的配点上报告，并辅以控制体净通量等积分检查。所有残差较小仍只是所选模型的一致性证据。

部署时可以联合监测径向创新、分区域物理残差、观测几何和不确定区间。观测大面积缺失、波束几何退化或边界状态超出训练范围时，应扩大不确定性说明并限制输出用途，必要时回退到已验证的测风或同化流程。自动微分能够精确计算网络导数，但不能保证网络代表了真实大气。

本章小结。 PINN 用方程帮助推断稀疏观测之间的风场。使用前要写清雷达的测量方式和重建尺度，再设置方程残差、初值和边界条件。多放一些配点，只是多检查一些位置是否符合方程；增加独立视角的观测，才可能带来新的测量信息。报告结果时应同时说明测量精度、方程与现场的偏差、数据能否确定所求风场，以及计算开销。一张平滑的图和较低的训练损失还不够。

第四部分

从学习方式看数据智能场景

前面各章主要讨论如何用给定数据学习预测器。本部分进一步讨论数据与知识如何被组织：预训练构建可复用的表示，迁移学习处理源域与目标域，持续学习处理按时间到达的变化，主动学习决定哪些样本值得标注，联邦学习处理分散的数据所有权，流形学习利用样本几何，元学习利用任务经验。七章分别给出问题假设、关键算法、变体与工业评价边界，不能用其中一种方法的收益替代另一种设定的验证。

第十七章 预训练：构建可复用的数据表示

本章摘要。预训练通过先行学习任务获得可复用的参数或表示。本章从数据与目标的关系出发，解释监督预训练、掩码与生成式学习、对比学习、无负样本自蒸馏及领域继续预训练。工业振动信号案例用于说明如何选择增强与遮蔽方式，以及如何区分预训练损失下降、表示改善和下游收益。

前面的模型章节回答序列、图像和文本应如何表示，上一章进一步让物理方程参与学习：当标签不足时，已知规律可以约束候选解。然而，不是所有设备都有足够准确的控制方程，许多可利用的知识只隐含在历史观测中。本章由此转向另一条路线：在目标故障标签不足时，能否先利用历史数据学习可复用结构，再用有限标签建立预测器？预训练的价值在于可复用性，其监督信号可以来自人工标签，也可以来自数据本身。它不等同于无监督学习，更不要求模型一定具有很大规模。

理解这条路线，需要区分三个并不等价的问题：辅助任务能否被完成，表示是否保留了任务需要的信息，有限标签能否把这些信息转成可靠判断。重构波形可以依靠平滑性，对比学习可以依靠设备身份，而故障诊断可能恰恰需要低能量的短时冲击。因此，本章不以罗列预训练模型为主线，而是逐步追问学习信号要求模型保留什么、丢弃什么：先由似然与重构解释预测目标，再由正负样本关系解释不变性，最后分析不使用负样本时如何避免所有表示趋同。贯穿这些方法的观点是，预训练目标是一种关于有用结构的假设，必须由独立的下游任务检验。

读完本章，可以按三个问题检查自己的方案：哪些历史记录允许参与训练，遮住的部分是否太容易猜中，模型是否把不同输入都编码成了相近的结果。例如波形补得很平滑，却丢掉短时冲击，就未必有利于故障诊断。下一章继续讨论拿到预训练参数以后，哪些可以保留，哪些需要用新设备的数据重新调整。

17.1 预训练学到了什么

图17.1把无标签预训练与下游评估连成反馈路径，强调辅助任务学到的表示须通过独立故障任务检验，而不能只用预训练损失验收。设预训练数据为 $\mathcal{D}_{\text{pre}}$ ，编码器




图 17.1: 预训练的价值由下游任务检验: 辅助目标下降并不自动意味着故障相关信息被保留。

为 f_θ , 与预训练目标配套的预测头为 g_ϕ 。一般训练形式为

$$(\theta_0, \phi_0) = \arg \min_{\theta, \phi} \mathbb{E}_{x \sim \mathcal{D}_{\text{pre}}} \mathbb{E}_{\omega \sim P_\omega} \ell_{\text{pre}}(g_\phi(f_\theta(v_\omega(x))), s_\omega(x)). \quad (17.1)$$

其中 ω 控制裁剪、遮蔽或目标构造, $v_\omega(x)$ 为模型输入, $s_\omega(x)$ 为学习目标。监督分类时目标来自人工标签, 自监督任务则由样本结构构造目标, 例如被遮蔽的片段或同一样本的另一视图。预训练完成后可保留编码器、丢弃辅助头, 再接入目标任务头 h_ψ 。

若冻结 θ_0 只训练线性 h_ψ , 检验的是该表示中的线性可分信息; 全量微调则同时检验初始化能否支持适应。两者可能产生不同排序。模型也可能保留了设备编号和工况, 却没有保留故障机理, 因此预训练损失不能直接用作表示质量指标。下一章讨论微调、参数高效适配与域对齐, 本章重点是初始化产生之前的学习过程。

预训练数据不一定与下游任务同分布。通用图像表示可能提供边缘和纹理结构, 但工业细裂纹要求保留更细的空间信息; 自然语言模型能够学习句法, 却未必知道某台设备的有效规程。数据规模、任务相关性和目标设计共同决定迁移潜力, 增加其中一项不能保证补偿另一项的缺失。

17.2 监督预训练与重建式目标

监督预训练利用较大源数据集的标签训练骨干, 例如图像分类网络中的交叉熵目标[37]:

$$\mathcal{L}_{\text{sup}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\theta, \phi}(y_i | x_i). \quad (17.2)$$

随后保留骨干并替换分类头。源标签可以来自其他设备或相关任务, 但其类别定义决定了哪些差异受到强调。只以设备类别预训练, 可能更容易区分传感器安装位置而不是早期故障。弱标签和伪标签能扩大覆盖, 却需要单独处理标签噪声, 不能把它们等同于准确人工标注。

自编码器从压缩表示重构输入, 去噪自编码器则从受扰动输入 $\tilde{x}$ 恢复原始 x [110]:

$$\mathcal{L}_{\text{denoise}} = \mathbb{E}_{x \sim \mathcal{D}_{\text{pre}}} \mathbb{E}_{\tilde{x} \sim q(\cdot | x)} \|g_\phi(f_\theta(\tilde{x})) - x\|_2^2. \quad (17.3)$$

扰动机制决定模型需要恢复什么。噪声过小可能只要求近似恒等映射, 噪声过大可能使恢复目标含糊。重构均方误差倾向于优先解释高能量成分, 低幅值但诊断价值较高的冲击不一定受到足够重视。频谱或多尺度损失可以改变关注点, 但要明确引入的频段先验, 避免利用测试故障选择损失。

17.2.1 从条件似然理解重构为何产生平滑结果

把一个窗口展平为 $x \in \mathbb{R}^D$ ，令 $u = \tilde{x}$ 表示受扰动观测，编码器输出 $f_\theta(u) \in \mathbb{R}^d$ ，解码器输出 $m_{\theta,\phi}(u) \in \mathbb{R}^D$ 。若建模假设为

$$p_{\theta,\phi}(x | u) = \mathcal{N}(x; m_{\theta,\phi}(u), \sigma^2 I_D), \quad (17.4)$$

则单个样本的负对数似然是

$$-\log p(x | u) = \frac{D}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \|x - m_{\theta,\phi}(u)\|_2^2. \quad (17.5)$$

只有在 σ^2 固定时，最大似然才等价于普通均方误差最小化；若同时学习方差，就不能丢弃对数方差项。不同通道单位差异很大时，采用对角协方差 Σ 会得到 $(x-m)^\top \Sigma^{-1}(x-m)$ ，即按噪声尺度加权的误差。这样的权重表达的是可靠性或尺度假设，不能任意解释为故障重要性。

进一步令 $m^*(u) = \mathbb{E}[X | U = u]$ ，对任意候选重构 a 展开平方：

$$\mathbb{E}[\|X - a\|^2 | u] = \mathbb{E}[\|X - m^* + m^* - a\|^2 | u] \quad (17.6)$$

$$= \mathbb{E}[\|X - m^*\|^2 | u] + \|m^* - a\|^2. \quad (17.7)$$

式(17.7)中交叉项消失，是因为 $\mathbb{E}[X - m^* | u] = 0$ 。因此无限容量、总体风险最优的平方误差预测器输出条件均值。假如遮蔽区的冲击可能出现在两个不同位置，条件均值可能在两处各产生半个冲击，虽然平均误差最小，却不是任何一次真实波形。这不是单纯增加网络容量就能解决的问题；需要缩短遮蔽区、加入可靠上下文，或用能表达多峰条件分布的预测头。

17.2.2 遮蔽任务与因果预测的边界

掩码建模只显示部分输入，并预测被遮蔽区域。令 M 为目标位置集合、 V 为可见位置集合，可写为

$$\mathcal{L}_{\text{mask}} = \mathbb{E}_{x,M} \frac{1}{|M|} \sum_{j \in M} \ell(\hat{x}_j(x_V, M), x_j). \quad (17.8)$$

离散词元通常采用交叉熵，连续图像块或信号片段可采用重构误差。BERT 使用掩码语言建模，MAE 则以可见图像块训练编码器，并由轻量解码器重构被遮蔽块[20, 34]。MAE 的编码器只处理可见块，减少了高遮蔽率下的编码开销；解码器仍需接收位置信息与遮蔽标记。不能仅按遮蔽比例推断所有架构都具有相同节省。

这里假定输入由 L 个元素或片段组成，每个连续片段 $x_j \in \mathbb{R}^p$ ， $M \subset \{1, \dots, L\}$ 非空， V 为其补集；解码器需为每个 $j \in M$ 输出同维预测。若采用逐位置条件分布 $q_{\theta,\phi}(x_j | x_V, M)$ ，掩码损失就是条件负对数似然之和。逐位置相加相当于用条件独立输出头拟合各位置的边缘分布，不表示真实被遮蔽片段给定可见输入后必然独立；若要生成相互协调的一整段，还需联合或自回归解码器。 $1/|M|$ 避免遮蔽更多位置时仅因项数增加而提高损失，但它不会消除不同遮蔽难度带来的梯度差异。

离散监督分类和掩码词元分类共享交叉熵结构。令真实条件分布为 $r(k | u)$ 、预测为 $p(k | u)$ ，则 $-\sum_k r_k \log p_k = H(r) + \text{KL}(r \| p)$ 。固定输入条件下，总体最优预测应匹配 r ；有限标签训练以单个类别指示向量代替未知 r 。因此监督预训练强调源标签可区分的信息，掩码训练强调由上下文可预测的信息，二者都没有数学理由自动保留与自身目标无关的下游细节。

独立随机点遮蔽可能被局部平滑插值轻易解决。时间序列可使用连续片段遮蔽、跨通道遮蔽或多尺度遮蔽，以迫使模型利用更长上下文。遮蔽过长又可能使目标不可预测，网络只能输出条件平均。应根据信号周期、传感器耦合与任务时间尺度选择策略，并检查模型是否只是复制相邻样本。

自回归预训练预测给定过去的下一个元素，目标为

$$\mathcal{L}_{\text{AR}} = -\mathbb{E}_x \sum_{j=1}^L \log p_\theta(x_j | x_{<j}). \quad (17.9)$$

该目标来自联合分布的链式分解 $p_\theta(x_1, \dots, x_L) = \prod_{j=1}^L p_\theta(x_j | x_{<j})$ ；取负对数将连乘转为求和，不要求序列元素相互独立。训练时使用真实前缀计算条件似然，而生成时使用模型已生成的前缀，两者输入分布可能不同。对总体数据分布 P ，期望负对数似然等于 $H(P) + \text{KL}(P \| P_\theta)$ ；模型族足够表达且优化达到总体最优时，才有匹配数据分布的解释。有限数据、有限上下文或模型失配下，即便整体似然改善，稀有故障的条件概率也可能仍很差。对文本这是下一词元预测，对连续信号需要明确预测分布或回归损失。双向掩码表示可以利用目标位置两侧上下文，自回归表示受因果边界约束。在线故障预测若采用窗口表示，应保证窗口中没有预测时刻之后的数据，不能因任务名称为自监督就忽略时间泄漏。

17.3 对比学习：哪些样本应当接近

对比学习用正样本对定义应保留的一致性，用负样本提供区分信号。A Simple Framework for Contrastive Learning of Visual Representations (SimCLR) 对一个批次中的每个样本独立增强两次，经编码器与投影头得到归一化表示 z_i [14]。对锚点 i 及其正样本 j ，损失为

$$\ell_{i,j} = -\log \frac{\exp(z_i^\top z_j / \tau)}{\sum_{k \neq i} \exp(z_i^\top z_k / \tau)}, \quad \tau > 0. \quad (17.10)$$

含 B 个原始样本的批次产生 $2B$ 个视图。分母含一个正样本和 $2B - 2$ 个负样本，训练对两个方向求平均。投影头使对比目标作用于专门的空间，下游任务常使用投影前的编码器表示。温度 τ 改变相似度差异对梯度的影响，较小温度强调难区分样本，也可能放大假负样本的影响。

把对比损失展开为一个分类问题。设投影前表示为 $h_i \in \mathbb{R}^d$ ，投影后归一化向量为 $z_i \in \mathbb{R}^m$ ， $\|z_i\|_2 = 1$ 。固定锚点 i 时，其余 $2B - 1$ 个视图构成候选集合。令 $s_{ik} =$

$z_i^\top z_k$ 及

$$q_{ik} = \frac{e^{s_{ik}/\tau}}{\sum_{l \neq i} e^{s_{il}/\tau}}. \quad (17.11)$$

任务就是从候选中识别真正配对的视图 j 。把 $\ell_{i,j} = -s_{ij}/\tau + \log \sum_{k \neq i} e^{s_{ik}/\tau}$ 逐项求导，有

$$\frac{\partial \ell_{i,j}}{\partial s_{ik}} = \frac{1}{\tau} (q_{ik} - \mathbf{1}[k = j]), \quad \nabla_{z_i} \ell_{i,j} = \frac{1}{\tau} \left(\sum_{k \neq i} q_{ik} z_k - z_j \right). \quad (17.12)$$

这里第二式暂把其他向量视为常量；完整批次梯度还包含 z_i 作为别的锚点的候选时收到的梯度。下降方向拉近正样本并远离概率加权的候选均值，而非均匀排斥每个负样本。若未归一化投影为 u_i ，还需乘归一化雅可比 $(I - z_i z_i^\top) / \|u_i\|_2$ ，不能把单位球面上的变量当成任意自由向量。

这个推导解释了温度的两个作用：显式的 $1/\tau$ 改变梯度尺度，softmax 又把权重集中到最相似候选。因此减小温度不只是“加大学习率”。当一个高相似负样本实际属于同类故障时，它会得到很大的排斥权重。另一方面，若所有 z 完全相等，则 $q_{ik} = 1/(2B - 1)$ ，损失为 $\log(2B - 1)$ ，没有完成配对识别；但对称构型仍可能有退化驻点，不能仅从负样本存在推断优化必然成功。

大批次可以提供更多负样本，但增加内存成本。Momentum Contrast (MoCo) 使用键队列复用近期表示，并用动量编码器降低队列中新旧表示的不一致[35]。若查询编码器参数为 θ_q 、键编码器参数为 θ_k ，则

$$\theta_k \leftarrow \mu \theta_k + (1 - \mu) \theta_q, \quad 0 \leq \mu < 1. \quad (17.13)$$

查询分支通过梯度更新，键分支按指数移动平均更新，当前键入队并移除最旧键。队列增大并不总有益：分布变化较快时，陈旧键可能形成不合适的比较对象。

正样本定义比损失名称更重要。图像颜色扰动可以弱化照明差异，但在变色故障中颜色本身就是标签信息。振动信号的强幅值归一化可能删除故障严重度，时间伸缩可能改变与转速相关的频率结构。只有在目标任务对某种变化确实不敏感时，才应训练这种不变性。状态变化对应的敏感方向应保留，而不是一律压缩。

同一故障的两个不同记录可能被当作负样本，造成假负样本排斥。监督对比学习利用已有类别标签为一个锚点构造多个正样本[53]，但其适用范围由标签覆盖决定。工业采样还应控制设备和批次：若一个批次中每台设备只出现一种工况，模型可能靠设备身份完成对比任务，而非学习可迁移的状态表示。

跨模态对比预训练将同步波形、图像或文本对齐。CLIP 使用图像与文本的双向批次对比目标[79]，其思想可以扩展到工业配对数据，但工单时间不一定等于故障发生时间，粗糙配对会引入错误正样本。跨模态目标学到的是给定配对规则下的关联，不会自动建立因果对应。

17.4 无负样本学习与表示坍塌

如果只令两个增强视图的表示接近，所有输入都映射到同一个常量也能使距离为零，这称为表示坍塌。Bootstrap Your Own Latent (BYOL) 通过在线编码器、预测头和移动平均目标编码器构成不对称训练[31]。用 sg 表示停止梯度，归一化后的预测与目标分别为 $\bar{q}_\theta$ 和 $\bar{z}_\xi$ ，则一个方向的损失为

$$\ell_{\text{BYOL}} = \|\bar{q}_\theta(v_1) - \text{sg}(\bar{z}_\xi(v_2))\|_2^2, \quad \xi \leftarrow \mu\xi + (1 - \mu)\theta. \quad (17.14)$$

实际训练交换视图后再平均。这里 θ 和 ξ 表示两分支中对应编码与投影模块的参数，在线预测头单独通过梯度更新。停止梯度和移动平均控制目标变化，并不使任意网络与任意数据增强都自动免于坍塌。

Simple Siamese (SimSiam) 去掉移动平均目标更新，使用共享编码器、预测头和停止梯度构造更简洁的孪生学习[16]。Self-Distillation with No Labels (DINO) 则让学生匹配教师在不同裁剪视图上的概率输出，并以移动平均教师、输出中心化和温度锐化调节目标分布[11]。这些方法的教师通常来自学生训练轨迹，而不是额外人工标签，因此属于自蒸馏。训练中要检查特征方差、有效秩和样本间距离，不能只看两个分支越来越一致。

另一类方法直接约束表示统计量。VICReg 组合视图一致性、各维方差下限和非对角协方差惩罚[3]：

$$\mathcal{L} = \lambda_s \mathcal{L}_{\text{inv}} + \lambda_v \mathcal{L}_{\text{var}} + \lambda_c \mathcal{L}_{\text{cov}}. \quad (17.15)$$

对中心化批次表示 $Z \in \mathbb{R}^{B \times d}$ ，协方差为 $C = Z^\top Z / (B - 1)$ ，协方差项惩罚 C 的非对角元素平方，方差项则惩罚标准差低于给定阈值的维度。两项通常分别作用于两个视图分支。它以显式统计约束抑制常量表示和维度冗余，但小批次统计不稳定，低相关性也不保证所有维度都具有诊断意义。

停止梯度和统计约束究竟改变了什么。 对单位向量 q, z ， $\|q - z\|^2 = 2 - 2q^\top z$ ，所以 BYOL 的距离最小化也在最大化方向一致性。若目标 z 停止梯度，单次更新只改变在线分支，而目标编码器通过移动平均间接改变。把动量递推展开，得到

$$\xi_t = \mu^t \xi_0 + (1 - \mu) \sum_{s=1}^t \mu^{t-s} \theta_s. \quad (17.16)$$

教师因此是历史学生的指数加权组合：较大的 μ 平滑噪声，也增加对新分布的响应延迟。停止梯度不是修改距离的数值，而是修改计算图的导数路径；它与预测头、归一化和优化共同作用，单独的常量映射依然能让一致性项为零。

为了明确 VICReg 如何额外排斥这个解，令未中心化批次表示为 $Z^{(a)} \in \mathbb{R}^{B \times d}$ 、

$a \in \{1, 2\}$, $B > 1$, 中心化后协方差为 $C^{(a)}$ 。一组明确的损失约定是

$$\mathcal{L}_{\text{inv}} = \frac{1}{B} \sum_{i=1}^B \|z_i^{(1)} - z_i^{(2)}\|_2^2, \quad (17.17)$$

$$\mathcal{L}_{\text{var}} = \frac{1}{2d} \sum_{a=1}^2 \sum_{j=1}^d \max\{0, \gamma - \sqrt{C_{jj}^{(a)} + \epsilon}\}, \quad (17.18)$$

$$\mathcal{L}_{\text{cov}} = \frac{1}{2d} \sum_{a=1}^2 \sum_{j \neq k} (C_{jk}^{(a)})^2. \quad (17.19)$$

这里 $\gamma > \sqrt{\epsilon} > 0$ 规定标准差下限。常量表示使一致性和协方差项都为零，却令每一维方差惩罚严格为正；所有维度复制同一个变化信号能够通过方差检查，却会产生很大的非对角协方差。这说明两种统计惩罚分别针对无变化和重复编码，缺一不可。不过 $\text{rank}(C) \leq \min(d, B-1)$ ，当 $d > B-1$ 时不可能在一个批次内同时达到全维正方差与严格零非对角协方差。损失权重是在这些目标间折中，而不是保证有限批次出现理想白化表示。

无负样本方法避免了显式的负样本队列或大规模两两比较，却仍依赖增强、架构和优化。对比、蒸馏与重建可以组合，但新增目标会引入权重与梯度冲突。应先验证单一目标，再判断组合是否保留了不同的有效信息，而不是因目标数量增加就推断表示更通用。

17.5 数据组织与领域继续预训练

预训练数据应登记来源、设备、时间、工况和使用许可。没有标签不等于可以随意使用：历史记录可能含有机密信息，也可能已经包含后续测试期的数据。对连续波形，应先按设备或时间段划分，再切窗口；否则同一段波形的重叠片段会落入不同集合，让表示看起来比实际更好。归一化统计和滤波参数也只能用规则允许的数据估计。

领域继续预训练在已有参数上使用领域数据延续学习。领域自适应预训练与任务相关语料预训练在语言任务中已有系统研究[33]。对工业波形，相应思路是在通用信号表示上使用目标设备族的历史无标签数据，但应区分部署前可用历史与未来测试期数据。使用无标签测试输入属于不同的信息使用规则，不能悄悄并入普通归纳评估。

只使用狭窄领域数据继续训练可能遗忘通用能力，也可能过拟合设备身份。可比较较小学习率、较短训练、混合原始数据或限制可训练参数等策略。若采用数据混合，可令来源 s 以概率 q_s 被采样， $\sum_s q_s = 1$ 。按样本量取 q_s 使大来源占主导，均衡来源则会重复小数据集；两者改变了优化分布，需要记录而不能仅报告总样本数。

固定算力预算下，模型规模、有效样本量、输入长度和训练步数存在取舍。遮蔽率改变任务难度和部分架构的计算量，队列长度改变负样本覆盖，继续训练改变历史知识的保留。比较时应记录实际处理样本或词元数、去重比例、训练时间与峰值显

存。跨领域缩放规律不能直接当作当前工业数据的性能承诺。

预训练产物应同时保存模型、输入规范、数据来源和训练截止时间。投影头是否保留、归一化层统计是否更新、通道顺序如何定义，都会影响复用结果。所谓冻结编码器还应说明是否固定归一化运行统计，否则无参数梯度更新也可能改变模型行为。预训练模型版本应与适用设备和数据使用规则绑定。

17.6 工业振动信号的完整学习任务设置

考虑利用多个设备的历史振动记录预训练编码器，再以有限故障标签进行诊断。首先限定预测对象：窗口状态分类、未来故障预测和故障严重度回归需要保留的信息不同。本例以窗口状态分类为教学任务，输入为窗口内多通道波形及允许获得的运行条件，不假定已有实验结果。

按设备划分预训练与下游评估范围，再按连续记录或运行批次组织窗口。跨设备泛化试验中，测试设备的无标签记录也不进入预训练；若研究目标设备无标签适应，则另设一组明确允许该信息的规则。故障状态标签只能来自可核查记录，不能将未标注窗口全部视为正常。

掩码方案可将波形分成连续片段，只向编码器显示可见片段，再预测被遮蔽片段。对比方案可使用不改变窗口状态的裁剪和经过幅值校准的小噪声，增强幅度在训练与验证范围内选择。若裁剪可能移除唯一故障冲击，两视图便不再可靠共享状态，应限制裁剪或改用其他目标。转速变化明显时，可以在明确的工况条件下比较，避免把转速差异一律当作应消除的干扰。

Algorithm 3 工业信号预训练与下游表示评价

Require: 按设备和时间划分的数据、预训练目标、有限下游标签

- 1: 固定允许使用的数据、窗口边界、归一化与增强规则
- 2: 初始化编码器及预训练辅助头
- 3: **for** 每个预训练批次 **do**
- 4: 按设备和工况采样窗口，生成掩码或增强视图
- 5: 计算选定的重建、对比或自蒸馏损失
- 6: 更新在线参数，并按算法更新教师或队列
- 7: 监测目标损失、表示方差和不同来源的训练贡献
- 8: **end for**
- 9: 在固定标签子集上训练线性探测头，并单独进行微调对照
- 10: 用验证集选择配置，冻结选择后在独立测试集上评价

对照应包括随机初始化、适用的监督预训练，以及在相同数据范围下的代表性自监督目标。线性探测与全量微调分别报告，至少在多个标签预算下绘制学习曲线，比较每类故障召回、宏平均指标、误报及校准。若使用同一个预训练模型服务多个任

务，可另外报告摊销成本，但不能把预训练计算完全隐藏。

消融应保持数据和计算条件尽量一致。例如固定编码器比较随机点遮蔽与连续片段遮蔽，检验收益是否来自更长上下文；固定增强比较是否使用投影头，检验下游表示与训练目标空间的区别；固定预训练样本量比较来源混合，检验模型是否依赖某个设备族。注意单纯匹配训练轮数不一定匹配算力，尤其是不同遮蔽编码和对比批次设置之间。

预训练损失下降但线性探测不改善，可能说明任务主要学到了插值或身份线索。线性探测改善而微调收益消失，则需检查标签量、适应策略和优化预算。某些设备收益明显、另一些退化时，应报告子群差异，而非只用平均分掩盖负迁移。表示可视化只提供诊断线索，不能代替独立分类或预测评价。

本章小结。 预训练的设计由三件事共同决定：哪些数据可以使用、什么变化应当保持一致、什么信息必须保留。监督目标利用已有标签，掩码与生成目标恢复缺失或后续内容，对比目标定义样本关系，自蒸馏和统计约束抑制表示退化。这些目标的数学结构对应不同偏好：平方误差输出条件均值，对比交叉熵放大难区分候选的作用，停止梯度改变优化路径，方差与协方差项分别约束常量坍塌和维度重复。理解这些偏好，比记住某个模型名称更有助于判断故障信息会不会被保留。

判断预训练是否有用，要在独立任务上给出相同标签预算，再比较线性探测或微调后的结果。报告中应写清用了哪些历史数据，怎样增强或遮蔽，表示有没有退化，以及故障识别究竟改善多少。辅助损失下降只能说明辅助任务学得更好。下一章接着检查这些表示换到新设备后是否仍适用，并讨论重加权、表示对齐、参数适配和负迁移。

第十八章 迁移学习

本章摘要。迁移学习利用已有数据、表示或参数降低目标任务的学习成本。本章先区分任务变化与分布偏移，再从风险重加权、表示对齐和参数适配推导主要算法，最后讨论测试时适配与负迁移。选择依据是哪些假设仍成立，而不是预训练模型有多大。

上一章把大量历史观测压缩成一个可复用的编码器，但“可复用”只是潜力，不是新设备上的性能承诺。旧相机学到的边缘结构可能仍然有用，照明统计可能需要更新，而不同产品的缺陷定义甚至可能不再相同。本章因此从参数初始化走向目标风险：不是询问源模型有多强，而是询问源数据中的哪些关系在目标环境中仍成立。

这里存在三种不同的干预。若预测关系不变而采样频率改变，可重加权样本；若不同观测方式背后存在共享语义，可尝试对齐表示；若目标任务需要新的决策规则，则必须更新分类头或部分骨干。三种干预对应不同假设，不能把它们看成可互换的技巧。本章先推导风险如何从源分布转换到目标分布，再解释统计对齐与域对抗到底消除了什么差异，随后讨论有限标签与计算预算下的参数适配，并用负迁移说明这些方法的边界。

假设两台相机的图像颜色变得更接近了，还要检查裂纹和正常纹理是否仍能区分。对齐指标下降，只说明某种分布差异缩小，不能直接说明目标设备上的故障更容易识别。章末再考虑连续更新：用新设备数据改好模型后，旧设备上的故障还能不能识别？下一章的持续学习就从这里开始。

18.1 源域知识与目标域风险




图 18.1: 迁移学习的核心是把源域知识送入目标域，同时检验哪些分布或任务假设仍然成立。

图18.1将源域知识、适配过程和目标域评价分开；共享参数并不意味着分布相同，目标域验证必须检验迁移后是否降低了实际风险。设源域与目标域联合分布分别为 $P_s(X, Y)$ 与 $P_t(X, Y)$ ，目标是降低 $R_t(f) = \mathbb{E}_{P_t} \ell(f(X), Y)$ 。迁移学习允许域或任务发生变化，领域自适应通常保持预测任务并处理域差异，领域泛化则要求在训练时未见的域上工作[77]。新相机质检可保持缺陷类别不变，跨产品迁移却可能改变标签空间；二者不能使用同一适配规则。

协变量偏移假定 $P_s(Y | X) = P_t(Y | X)$ 而输入边缘分布变化；标签偏移假定 $P_s(X | Y) = P_t(X | Y)$ 而类别比例变化；概念变化则涉及预测关系本身。实际数据可能同时存在多种变化。仅观察无标签目标输入通常无法确定标签机制是否改变，因此无监督适配不能替代目标标签审核。

18.2 实例重加权与分布对齐

重要性加权。 在协变量偏移且目标分布支撑被源分布覆盖时，目标风险可写为

$$R_t(f) = \mathbb{E}_{P_s} [w(X) \ell(f(X), Y)], \quad w(x) = \frac{p_t(x)}{p_s(x)}. \quad (18.1)$$

先用源、目标输入估计密度比，再最小化加权源域损失。核均值匹配直接使加权源域特征均值接近目标均值，避免分别估计高维密度[46]。若用域分类器估计比值，必须校正训练时源、目标样本的先验比例。大权重会使少数样本主导梯度，截断权重可以降低方差但引入偏差。有效样本量 $(\sum_i w_i)^2 / \sum_i w_i^2$ 可用于判断加权是否退化。

风险恒等式、密度比估计与方差。 以离散标签和连续输入为例，协变量偏移要求对目标几乎处处的 x ，两域条件分布相同，且 $p_t(x) > 0$ 时 $p_s(x) > 0$ 。于是

$$R_t(f) = \int \sum_y \ell(f(x), y) p_t(y | x) p_t(x) dx \quad (18.2)$$

$$= \int \sum_y \ell(f(x), y) p_s(y | x) p_s(x) \frac{p_t(x)}{p_s(x)} dx. \quad (18.3)$$

式(18.3)才是可从源标签估计的量。支撑覆盖不是技术性装饰：源域从未出现的输入区域没有标签项可重用，任何有限权重都不能补上这部分风险。

令域指示 $D = 1$ 表示目标，域分类器训练混合中的先验为 π_t 与 $\pi_s = 1 - \pi_t$ ，其校准输出为 $q(x) = P(D = 1 | x)$ 。由贝叶斯公式

$$\frac{q(x)}{1 - q(x)} = \frac{\pi_t p_t(x)}{\pi_s p_s(x)}, \quad w(x) = \frac{\pi_s}{\pi_t} \frac{q(x)}{1 - q(x)}. \quad (18.4)$$

若训练时人为平衡两域，先验就是该平衡采样的比例，而不是原始数据库大小的比例。 q 接近1使估计非常不稳定；高域分类准确率此时可能表明重叠不足，而不是重加权更可靠。

对独立源样本，使用真实权重的估计 $\hat{R} = n_s^{-1} \sum_i w_i \ell_i$ 在可积时无偏；有限方差时其方差为 $\text{Var}_s(w\ell)/n_s$ 。若截断为 $\bar{w} = \min(w, c)$ ，且 $0 \leq \ell \leq L_{\max}$ ，则

$$0 \leq R_t - \mathbb{E}_s[\bar{w}\ell] = \mathbb{E}_s[(w - c)_+\ell] \leq L_{\max} \mathbb{E}_s[(w - c)_+]. \quad (18.5)$$

这显式展示了截断的偏差来源。自归一化估计 $\sum_i w_i \ell_i / \sum_i w_i$ 也通常具有有限样本偏差，但可改善数值稳定性。有效样本量来自归一化权重 $\alpha_i = w_i / \sum_j w_j$ 的 $1 / \sum_i \alpha_i^2$ ：全部相等时为 n_s ，一个样本几乎占全重时接近1；它是权重集中的诊断量，不是所有损失下精确的独立样本数。

标签偏移下，权重改为类别先验比 $p_t(y)/p_s(y)$ 。这个结论来自 $p_t(x, y) = p_s(x | y)p_t(y) = p_s(x, y)p_t(y)/p_s(y)$ ，要求目标出现的类别在源域具有正概率。若希望从无标签目标数据估计先验，可先固定一个分类器，定义源验证集上的混淆矩阵 $C_{ky} = P_s(\hat{Y} = k | Y = y)$ 。标签偏移意味着该矩阵在目标域不变，目标预测类别频率 $\mu_k = P_t(\hat{Y} = k)$ 满足 $\mu = C\pi_t$ ，其中 $\pi_t \in \mathbb{R}^K$ 是目标类别先验。可在 $\pi_t \geq 0$ 、 $\mathbf{1}^\top \pi_t = 1$ 约束下拟合这个线性关系。矩阵列若近似相同，分类器不能区分类别，先验反演便病态；若 $P(X | Y)$ 也改变，则关系本身失效。它不能直接与协变量偏移权重互换。若目标域出现源域从未包含的故障，仅靠重加权不能产生缺失的类别证据。

Maximum Mean Discrepancy (MMD) 与 Correlation Alignment (CORAL)。

深度适配网络在特征 $z = F_\theta(x)$ 上同时优化源域监督损失和域差异[69]：

$$\mathcal{L} = \mathcal{L}_s + \lambda \left\| \frac{1}{n_s} \sum_i \varphi(z_i^s) - \frac{1}{n_t} \sum_j \varphi(z_j^t) \right\|_{\mathcal{H}}^2. \quad (18.6)$$

核技巧将平方范数展开为源源、目标目标和源目标三组核值，无需显式构造 φ 。训练时从两域抽取批次，计算分类与对齐损失，再共同更新编码器。核带宽决定比较的尺度，多核 MMD 组合不同带宽以减少对单一尺度的依赖。

核均值差的实际计算。 设 $k(u, v) = \langle \varphi(u), \varphi(v) \rangle_{\mathcal{H}}$ 为正定核， $z \in \mathbb{R}^d$ 。将式(18.6)中的平方范数按 $\|a - b\|^2 = \langle a, a \rangle + \langle b, b \rangle - 2\langle a, b \rangle$ 展开，得到

$$\widehat{\text{MMD}}_b^2 = \frac{1}{n_s^2} \sum_{i, i'} k(z_i^s, z_{i'}^s) + \frac{1}{n_t^2} \sum_{j, j'} k(z_j^t, z_{j'}^t) \quad (18.7)$$

$$- \frac{2}{n_s n_t} \sum_{i, j} k(z_i^s, z_j^t). \quad (18.8)$$

这是含对角项的非负、有偏估计。若两域样本分别独立同分布且 $n_s, n_t > 1$ ，去掉前两项中相同下标的配对，并将分母换为 $n_s(n_s - 1)$ 和 $n_t(n_t - 1)$ ，可得到总体平方 MMD 的无偏估计；后者有限样本下可能为负，不能误认为程序必定出错。采用特征核时，总体 MMD 为零可以识别分布相同；线性核只检查均值相同。无论采用哪种核，比较对象都是 $P_s(Z)$ 与 $P_t(Z)$ ，并没有自动检查 $P_s(Y | Z)$ 与 $P_t(Y | Z)$ 。

CORAL 对齐二阶统计量[102]:

$$\mathcal{L}_{\text{CORAL}} = \frac{1}{4d^2} \|C_s - C_t\|_F^2, \quad (18.9)$$

其中 C_s, C_t 为 d 维表示的批次协方差。具体地, 把样本按行写成 $Z_s \in \mathbb{R}^{n_s \times d}$, 令 $H_s = I_{n_s} - \mathbf{1}\mathbf{1}^\top/n_s$, 则 $C_s = Z_s^\top H_s Z_s / (n_s - 1)$, 目标域同理。由于 $C_s - C_t$ 对称, 矩阵微分给出

$$\nabla_{Z_s} \mathcal{L}_{\text{CORAL}} = \frac{H_s Z_s (C_s - C_t)}{d^2 (n_s - 1)}. \quad (18.10)$$

可见梯度来自中心化表示与协方差差异的乘积, 源、目标均值本身不在该损失中; 如果还需均值对齐, 应另行添加对应项。 $n_s = 1$ 时样本协方差未定义, 小批次下秩至多为 $n_s - 1$, 也解释了协方差估计为何依赖批次组织。它计算直接, 但小批次协方差不稳定, 而且二阶一致不代表类别条件分布一致。MMD 与 CORAL 都可能把不同类别拉近; 存在目标标签时应检查类条件结构, 使用伪标签时则需控制错误对齐的累积。

域对抗适配。 Domain-Adversarial Neural Network (DANN) 用域判别器 D 识别表示来自哪一个域[28]。若域损失为交叉熵, 目标写为

$$\min_{F,C} \max_D \mathcal{L}_s(C(F(x_s)), y_s) - \lambda \mathcal{L}_d(D(F(x)), d). \quad (18.11)$$

域判别器最小化自己的交叉熵, 编码器通过梯度反转最大化该损失, 同时维持源域分类能力。实现时不能将两个模块都沿同一符号更新。域准确率接近随机只是对齐的诊断信号, 并非目标分类正确的证据; 特征全部坍缩也可使域不可区分。

域不可区分为何不是语义正确。 为了看清目标的符号, 采用等域权重的域损失

$$\mathcal{L}_d = -\mathbb{E}_s \log(1 - D(Z)) - \mathbb{E}_t \log D(Z). \quad (18.12)$$

固定编码器, 在具有特征密度的情况下, 对每个 z 逐点最小化, 得到 $D^*(z) = p_t(z)/(p_s(z) + p_t(z))$ 。代回可得

$$\min_D \mathcal{L}_d = \log 4 - 2 \text{JS}(P_s^Z \| P_t^Z), \quad (18.13)$$

其中 $\text{JS}(P \| Q) = \frac{1}{2} \text{KL}(P \| M) + \frac{1}{2} \text{KL}(Q \| M)$, $M = (P + Q)/2$ 。因此在判别器充分优化这一理想条件下, 编码器最大化域损失相当于减小特征边缘分布差异。若实现中再把两域损失除以2, 常数和系数也相应减半, 方向不变。

但令两域特征都均匀取 $-1, +1$, 源域标签满足 $Y = \mathbf{1}[Z = 1]$, 目标域却满足 $Y = \mathbf{1}[Z = -1]$ 。两域特征分布完全相同, 任何域判别器都只能猜测, 而源分类器在目标域全部判错。这个反例说明真正需要的是可共享的预测关系, 而不只是看不出设备来源。二分类的零一风险可用理论形式

$$R_t(h) \leq R_s(h) + \frac{1}{2} d_{\mathcal{H}\Delta\mathcal{H}}(P_s^X, P_t^X) + \lambda^*, \quad \lambda^* = \min_{h \in \mathcal{H}} (R_s(h) + R_t(h)) \quad (18.14)$$

理解这一点：差异量定义为 $2 \sup_{h, h' \in \mathcal{H}} |P_s(h \neq h') - P_t(h \neq h')|$ ，检查假设对在两域的分歧概率； λ^* 则表达同一分类器同时做好两个域的可能性。这是总体风险界，有限样本估计还需要复杂度误差项；域对抗损失也不等于这个差异量的精确值。对齐可以降低某种域差异，却不能从无标签输入中证明 λ^* 很小。

条件对齐将类别预测纳入域判别输入，以区分同一域中的不同语义。多源适配对不同源域分别估计可信度，避免样本最多的源主导目标；部分域适配需降低源域独有类别的权重，开放集适配则必须识别目标域未知类别。这些变体改变的是标签空间假设，不能只通过调大域对齐系数实现。

18.3 预训练、微调与参数高效适配

第十七章讨论如何从预训练数据构造可复用表示，本节转向已有表示如何适应目标任务。预训练提供初始化，但目标任务仍决定哪些层需要改变。线性探测冻结编码器只训练头，可检验原表示是否已具有判别性；逐层解冻先调整高层，再判断低层滤波是否需要变化；全量微调自由度最大，也更容易在少量目标样本上过拟合。比较时应固定目标标签量、预训练来源与超参数搜索预算。

Adapter 在冻结骨干中插入低维瓶颈。对输入表示 h ，一个残差适配器可写为 $h' = h + W_{up}\sigma(W_{down}h)$ ，只训练新增参数[43]。LoRA 则令权重更新 $\Delta W = BA$ ，以秩 r 限制更新自由度[45]。二者都降低每个目标域的存储开销，但低秩不意味着任何域变化都能被表达。提示学习优化输入或中间层的提示向量，适合保持基础模型不变的条件化使用；其可迁移性仍取决于基础模型是否理解目标语义。

低秩更新的维度、梯度与容量。 令冻结的线性层为 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$ ，输入 $x \in \mathbb{R}^{d_{in}}$ 。LoRA 使用 $A \in \mathbb{R}^{r \times d_{in}}$ 、 $B \in \mathbb{R}^{d_{out} \times r}$ 及尺度 $s = \alpha/r$ ，输出为

$$y = (W_0 + sBA)x. \quad (18.15)$$

可训练参数由 $d_{out}d_{in}$ 降为 $r(d_{out} + d_{in})$ ，更新秩不超过 r 。若 $G = \partial \mathcal{L} / \partial W_{eff}$ ，矩阵链式法则给出

$$\nabla_B \mathcal{L} = sGA^\top, \quad \nabla_A \mathcal{L} = sB^\top G. \quad (18.16)$$

这解释了常见的随机初始化 A 、零初始化 B ：初始 $BA = 0$ 保证原输出不变，同时 B 可以收到非零梯度；若两者都初始化为零，则两条梯度都为零，低秩分支无法启动。假如理想全量更新 ΔW^* 的奇异值为 $\sigma_1 \geq \sigma_2 \geq \dots$ ，最佳秩 r 矩阵近似的平方 Frobenius 误差为 $\sum_{j>r} \sigma_j^2$ 。因此低秩适配隐含的是有用更新可被少数方向近似，而非原权重本身低秩；该矩阵逼近结论也不等于网络任务风险的误差界。

对 Adapter，若 $h \in \mathbb{R}^d$ 、瓶颈宽度为 r ，则 $W_{down} \in \mathbb{R}^{r \times d}$ 、 $W_{up} \in \mathbb{R}^{d \times r}$ ，忽略偏置时有 $2dr$ 个参数。它的非线性瓶颈通常不能像单个线性 LoRA 更新那样直接合并进原权重。选择应同时看可表达变化、路由和推理限制，而不只看参数比率。

参数量、训练显存与推理开销应分别报告。冻结权重仍可能需要存储用于反向传播的激活；多个 Adapter 需要路由规则，LoRA 合并则需要确认目标域选择是否明确。不能把参数高效方法自动视为持续学习算法：若所有域共享并反复覆盖同一个低秩更新，仍会遗忘旧域。

18.4 测试时适配与负迁移

测试时适配只使用部署输入调整有限参数。Tent 最小化预测熵，并在其设定下更新归一化层仿射参数[112]：

$$\min_{\eta} \frac{1}{|B|} \sum_{x \in B} \left[- \sum_k p_{\eta}(k | x) \log p_{\eta}(k | x) \right]. \quad (18.17)$$

先保留训练好的模型，按部署批次计算熵，再对允许更新的参数执行梯度步。低熵可能是正确判断，也可能是错误自信。类别极不平衡、批次很小或流中含未知故障时，熵最小化可能将预测推向单一类别。逐批重置与持续累积更新是不同规则，必须明确是否保留适配状态。

熵下降为什么会强化错误。 令类别 logits 为 $a \in \mathbb{R}^K$ 、 $p = \text{softmax}(a)$ 。由 $\partial p_k / \partial a_j = p_k(\mathbf{1}[k=j] - p_j)$ ，可逐项得到

$$\frac{\partial H(p)}{\partial a_j} = -p_j(\log p_j + H(p)). \quad (18.18)$$

二分类时令 $p = \sigma(a)$ ，则 $dH/da = p(1-p) \log((1-p)/p)$ 。若 $p > 1/2$ ，梯度下降会继续增大 a 和 p ；若 $p < 1/2$ 则进一步压低 p 。没有标签参与时，这个更新没有能力识别当前偏向是否正确，只会强化已有偏向。熵适配因而依赖初始预测大体可信、低密度区域适合作决策边界等额外条件。应限制步数和漂移幅度，保留重置机制，并使用独立监测数据检验校准与少数类召回；这些操作降低风险，但仍不能构成无标签正确性保证。

负迁移指相对于合适的无迁移基线，使用源知识反而提高目标风险。应比较从零训练、线性探测、全量微调和轻量适配，并绘制随目标标签量变化的学习曲线。领域自适应理论中的分布差异项之外，还存在源、目标任务能否被同一假设同时解释的误差项[6]；只减小域差异并不足够。

换了新相机后，先查清楚是亮度、镜头和噪声变了，还是“什么算缺陷”的定义变了。前一类问题可以先试归一化适配和线性探测；后一类问题需要重新核对标签。若规则允许，可以用新相机的无标签图像做适配，但测试标签只能留到最终评价。报告各类缺陷召回、未知输入拒识、校准、训练成本和发生负迁移的设备组。若还要长期维护旧相机能力，就需要下一章的持续学习机制。

本章小结。 迁移学习依次回答源知识是否相关、分布差异能否被估计、哪些参数应更新。重加权改变样本贡献，成立前提是正确的偏移假设和支撑覆盖；分布对齐改变表示，却必须额外保护类别语义；微调和低秩适配改变预测器，其容量与标签预算应匹配。测试时熵下降进一步说明，没有标签的自洽改进可能只是错误自信。所有路线都需要目标域证据与无迁移基线，不能以对齐损失下降代替目标风险下降。

实际选方法时，先核对新旧数据的标签含义是否相同，再看目标设备有多少标签、能否使用它的无标签记录，最后选择足够解决问题的适配办法。如果系统仍需服务旧相机，更新后就要一起复测；新相机得分提高、旧相机却明显退步，不能算整个更新任务已经完成。下一章据此讨论持续学习：数据不断到来时，怎样学习新情况、保留旧能力，并控制存储和计算开销。

第十九章 持续学习

本章摘要。持续学习把更新过程放到时间轴上，同时约束新知识获取、旧知识保持和资源增长。本章从增量设置出发，推导回放、梯度约束、参数正则和知识蒸馏，再比较隔离与扩展方法。评价对象是整个学习轨迹，而非最后一个任务。

上一章研究如何借助源知识降低一个目标域的风险。实际系统却往往没有永久不变的“最终目标域”：新相机、新工况和新故障按时间到达，上一轮的目标域很快又成为需要保护的历史域。如果每次适应都只考核最新数据，系统可能一边发布更好的新版本，一边失去识别旧故障的能力。本章将学习对象从一个最终模型改为一串带资源约束的更新过程。

持续学习并非要求所有参数永远不变，而是要求区分有益的知识修正与不必要的历史破坏。旧数据能否保留、推理时是否知道任务身份、类别是否持续增加，会直接改变可用算法和评价标准。本章先说明回放如何近似历史风险，再从损失的局部变化推出梯度约束，从后验近似推出参数重要性惩罚，并解释蒸馏和参数隔离分别保留了什么。它们共同处理稳定性与可塑性的张力，但保护对象并不相同：样本风险、局部方向、参数邻域和可调用模块不能互相替代。

每次更新以后，都要重新测一遍仍需服务的旧设备，记录哪些故障开始漏检。只看最后一个阶段的总分，会看不到中途丢失的能力。另一个实际困难是，新到的记录往往还没有标签，专家不可能逐条检查。下一章的主动学习讨论怎样挑选优先标注的记录，再把得到的标签交给更新算法。

19.1 数据流、任务边界与遗忘




图 19.1: 持续学习沿数据流更新模型；新任务的可塑性与旧任务的稳定性形成直接张力。

图19.1沿任务流展示更新过程，并将旧知识保持与新任务适应并列；评价更新效果时须同时检查历史任务和当前任务，不能只看新数据损失。设数据依次到达 $\mathcal{D}_1, \dots, \mathcal{D}_T$ ，学习第 t 阶段时通常无法完整访问历史数据。直接在新数据上继续优化会改变共享参数，旧分布风险可能增加，这就是灾难性遗忘的典型表现。持续学习的核心矛盾是可塑性与稳定性，而非单纯限制更新幅度[19]。

任务增量通常在推理时提供任务身份，可选择相应输出头；类增量要求在已出现的所有类别中统一预测，测试时不提供任务身份；域增量通常保持标签空间而改变输入分布。类增量训练可以有已知阶段边界，不能把它与无边界数据流混为一谈。任务无关的在线持续学习进一步要求算法自行处理连续到达的数据，标签还可能延迟。

19.2 经验回放与梯度约束

有限缓存如何近似历史风险。 经验回放保存大小为 M 的缓存 $\mathcal{B}$ ，每次从当前数据与缓存分别采样：

$$\mathcal{L}_t = \frac{1}{|B_t|} \sum_{(x,y) \in B_t} \ell_\theta(x,y) + \lambda \frac{1}{|B_m|} \sum_{(x,y) \in B_m} \ell_\theta(x,y). \quad (19.1)$$

先混合计算梯度并更新模型，再按既定策略更新缓存。蓄水池采样在观察到第 $n > M$ 个样本时，以 M/n 概率将其放入缓存，并均匀替换一个槽位，使历史每个样本有相同保留概率。类别均衡缓存则改变采样目标，保障少数类但不再保持原始频率。iCaRL使用代表样本与蒸馏维护类增量表示，并以类均值进行预测[84]。

缓存无偏性与风险权重不是同一件事。 设此前共观察到 n 个样本且缓存容量为 $M \leq n$ 。蓄水池采样的等概率性质可由归纳法证明：第 n 个新样本的入选概率是 M/n ；任一旧样本在 $n-1$ 时刻位于缓存的概率为 $M/(n-1)$ ，本轮被替换的条件概率为 $(M/n)(1/M) = 1/n$ 。所以它本轮后仍在缓存的概率为

$$\frac{M}{n-1} \left(1 - \frac{1}{n}\right) = \frac{M}{n}. \quad (19.2)$$

初始 $n = M$ 时所有样本都被保留，归纳因此成立。对固定参数 θ ，缓存平均损失对采样随机性取期望等于历史经验平均损失：

$$\mathbb{E}_{\mathcal{B}} \left[\frac{1}{M} \sum_{i \in \mathcal{B}} \ell_\theta(x_i, y_i) \right] = \frac{1}{M} \sum_{i=1}^n \frac{M}{n} \ell_\theta(x_i, y_i) = \frac{1}{n} \sum_{i=1}^n \ell_\theta(x_i, y_i). \quad (19.3)$$

这是固定函数的抽性质，不表示在同一缓存上反复优化后，所选模型的缓存分数仍是无偏泛化估计；模型会适应缓存，所以还需要固定的历史测试集。

此外，式(19.1)的训练目标除以 $1 + \lambda$ 后对应新数据权重 $1/(1 + \lambda)$ 与历史权重 $\lambda/(1 + \lambda)$ 。若真要拟合所有已见样本的等权经验风险，当前阶段有 n_t 个样本、历史有 n_{old} 个样本时，应取 $\lambda = n_{old}/n_t$ ，并确保两侧批次各自代表相应经验分布。固定 λ 实际是在

规定新旧风险的政策权重，而不是自动复现全历史训练。对逐渐变化的设备，近期分布优先也许更合理，但必须说明这是主动选择的目标。

缓存按样本数公平并不等于按字节公平：原图、压缩特征与 logits 占用不同。特征回放节省空间，却依赖编码器版本兼容；生成回放用生成器代替原样本，但生成器本身也会遗忘，偏差可能逐阶段累积[99]。保存合成样本也不能自动免除隐私审计。

Gradient Episodic Memory (GEM) 与 A-GEM。 GEM 将当前梯度 g 投影为与旧任务梯度 g_k 不冲突的方向[70]：

$$\min_{\tilde{g}} \frac{1}{2} \|\tilde{g} - g\|_2^2, \quad \tilde{g}^\top g_k \geq 0 \quad \text{对所有旧任务 } k. \quad (19.4)$$

因为梯度下降的旧损失一阶变化约为 $-\eta g_k^\top \tilde{g}$ ，该约束限制局部增损，而非保证有限步后的旧风险不升。A-GEM 用回放批次的平均参考梯度 g_r 替代全部约束[13]。若 $g^\top g_r < 0$ 且 $\|g_r\| > 0$ ，投影为

$$\tilde{g} = g - \frac{g^\top g_r}{\|g_r\|_2^2} g_r; \quad (19.5)$$

否则保留原梯度。它降低计算开销，但只约束平均回放方向，少数旧任务仍可能受损。

从约束优化推出投影及其步长限制。 令参数维度为 p ， $g, g_r, \tilde{g} \in \mathbb{R}^p$ 。单个约束的拉格朗日函数为

$$\mathcal{J}(\tilde{g}, \alpha) = \frac{1}{2} \|\tilde{g} - g\|^2 - \alpha g_r^\top \tilde{g}, \quad \alpha \geq 0. \quad (19.6)$$

驻点条件给出 $\tilde{g} = g + \alpha g_r$ 。当 $g^\top g_r \geq 0$ 时约束已满足， $\alpha = 0$ ；否则最优点位于边界 $g_r^\top \tilde{g} = 0$ ，故 $\alpha = -g_r^\top g / \|g_r\|^2$ ，代入即得 A-GEM 公式。若 $g_r = 0$ ，该一阶约束没有信息，不应执行除法。对于多个旧任务，把梯度写成矩阵 $G = [g_1, \dots, g_K] \in \mathbb{R}^{p \times K}$ ，同样有 $\tilde{g} = g + G\alpha$ ，对偶问题成为

$$\min_{\alpha \geq 0} \frac{1}{2} \alpha^\top G^\top G \alpha + \alpha^\top G^\top g. \quad (19.7)$$

这把高维参数空间中的投影转换为以旧任务数为变量数的二次规划，但需要计算和保存参考梯度。

即使投影精确，有限步长仍可能增加旧损失。若旧损失梯度为 L_k -Lipschitz，则

$$\mathcal{L}_k(\theta - \eta \tilde{g}) \leq \mathcal{L}_k(\theta) - \eta g_k^\top \tilde{g} + \frac{1}{2} L_k \eta^2 \|\tilde{g}\|^2. \quad (19.8)$$

约束仅保证一次项不为正；当内积恰好为零时，二次项仍允许增损。当内积严格为正且梯度确实来自该损失时， $\eta \leq 2g_k^\top \tilde{g} / (L_k \|\tilde{g}\|^2)$ 才给出这个上界下的非增条件。实际使用的是小缓存梯度，既有抽样误差又有曲率误差，因此仍须检查历史风险。若优化器再对投影梯度施加动量或自适应预条件，实际更新方向也可能不再满足约束；约束应针对实际步向量解释。

19.3 参数重要性与知识蒸馏

Elastic Weight Consolidation (EWC) 及其在线变体。EWC 将旧任务后验在最优参数附近近似为对角二次项[56]:

$$\mathcal{L}_t(\theta) = \mathcal{L}_{new}(\theta) + \frac{\lambda}{2} \sum_j F_j(\theta_j - \theta_j^*)^2, \quad F_j \approx \frac{1}{N} \sum_n [\partial_{\theta_j} \log p_{\theta^*}(y_n | x_n)]^2. \quad (19.9)$$

先训练旧阶段、保存 θ^* 并估计 F ，再在新阶段加入惩罚。经验 Fisher 使用观测标签，和对模型预测分布取期望的 Fisher 并不完全相同。对角近似忽略参数耦合，旧任务局部曲率也未必能描述大范围更新风险。在线变体将历史重要性按衰减系数累积为一个统计量，控制内存，但衰减速度决定更早知识被保留多少。

从贝叶斯递推到对角二次保护。若给定参数后各阶段数据条件独立，后验满足

$$p(\theta | \mathcal{D}_{1:t}) \propto p(\mathcal{D}_t | \theta)p(\theta | \mathcal{D}_{1:t-1}). \quad (19.10)$$

对旧后验的负对数 $V(\theta)$ 在局部极小点 θ^* 二阶展开，若梯度为零，有

$$V(\theta) \approx V(\theta^*) + \frac{1}{2}(\theta - \theta^*)^\top H(\theta - \theta^*), \quad H = \nabla^2 V(\theta^*). \quad (19.11)$$

这里 $H \in \mathbb{R}^{p \times p}$ ，完整存储需要 $O(p^2)$ 。EWC 用似然 Fisher 的对角近似作为局部精度信息，忽略参数间相关性后只需 $O(p)$ 存储。模型 Fisher 的定义为

$$F = \mathbb{E}_X \mathbb{E}_{Y \sim p_{\theta^*}(\cdot | X)} [s(X, Y)s(X, Y)^\top], \quad s = \nabla_{\theta} \log p_{\theta^*}(Y | X). \quad (19.12)$$

在可交换微分和积分等正则条件下，模型分布内的 Fisher 等于负对数似然 Hessian 的期望；把模型标签换为观测标签得到的是经验 Fisher，不必等于实际损失 Hessian。若新损失采用样本平均而旧后验来自样本似然之和，还要计入样本量尺度；实践中的 λ 同时承担尺度转换与保持强度调节，不能把任意 λ 都当作精确贝叶斯更新。

二次惩罚对第 j 个参数的梯度为 $\lambda F_j(\theta_j - \theta_j^*)$ 。在单个坐标上，若新目标局部为 $\frac{1}{2}a(\theta_j - b)^2$ ， $a > 0$ ，则合并后的极小点为

$$\theta_j^{new} = \frac{ab + \lambda F_j \theta_j^*}{a + \lambda F_j}. \quad (19.13)$$

这明确展示了折中：新证据曲率 a 越强，参数越靠近 b ；旧重要性越强，越靠近 θ_j^* 。但两个参数可能需要协同移动才能不改变旧函数，对角惩罚看不到这种安全方向。在线累积 $\bar{F}_t = \rho \bar{F}_{t-1} + F_t$ 还应同时说明锚点如何重置；把多阶段局部曲率压缩到最新锚点，是进一步近似，不等于保留所有历史后验。

Synaptic Intelligence 沿训练轨迹累计参数更新对损失下降的贡献，再按总位移归一化估计重要性[115]。例如令一次参数增量为 $\Delta \theta_j^{(s)}$ 、更新前梯度为 $g_j^{(s)}$ ，可累计 $\omega_j = \sum_s -g_j^{(s)} \Delta \theta_j^{(s)}$ ，再以 $\Omega_j = \max(0, \omega_j) / ((\theta_j^{end} - \theta_j^{start})^2 + \epsilon)$ 作为非负重要性的一种实现

约定。分子来自一阶损失下降的逐坐标贡献，分母避免仅因坐标位移较大就给出高重要性； $\epsilon > 0$ 防止小位移导致数值爆炸。噪声、动量和坐标间耦合会使逐坐标贡献不稳定，因此需记录截断与累积约定。它与 EWC 的区别是使用优化路径而非阶段末的 Fisher。两者都可能在任务冲突较强时过度限制可塑性，因此要同时报告新任务学习不足与旧任务遗忘。

输出蒸馏与特征保持。 Learning without Forgetting 保存旧模型输出，在新数据上约束新模型[66]：

$$\mathcal{L} = \mathcal{L}_{new} + \lambda \tau^2 \mathbb{E}_x \text{KL}(p_{old}^{(\tau)}(\cdot | x) \| p_{\theta}^{(\tau)}(\cdot | x)). \quad (19.14)$$

温度 τ 软化类别概率，旧教师应停止梯度更新。蒸馏只能约束所观察输入上的行为；若新输入不覆盖旧分布，保持这些输出不保证保持旧任务。类增量场景还需统一输出空间并处理新旧类别的偏置。特征蒸馏可约束中间表示，但应明确对齐层、距离和容量，否则会阻碍必要的表示变化。

蒸馏温度、梯度缩放与类增量缺口。 令旧教师与新学生在相同 K 个旧类别上的 logits 分别为 $u, v \in \mathbb{R}^K$ ， $p_k = \text{softmax}(u/\tau)_k$ 、 $q_k = \text{softmax}(v/\tau)_k$ 。停止教师梯度后， $\text{KL}(p \| q) = \sum_k p_k \log p_k - \sum_k p_k \log q_k$ 中的第一项为常数，所以

$$\frac{\partial \text{KL}(p \| q)}{\partial v_j} = \frac{q_j - p_j}{\tau}, \quad \frac{\partial [\tau^2 \text{KL}(p \| q)]}{\partial v_j} = \tau(q_j - p_j). \quad (19.15)$$

较高温度下，令 $\bar{u} = K^{-1} \sum_k u_k$ 、 $\bar{v}$ 同理，有 $p_k \approx K^{-1} + (u_k - \bar{u})/(K\tau)$ ，故 $q_k - p_k$ 本身约为 $1/\tau$ 量级。乘 τ^2 使高温近似下的梯度尺度不至于随温度平方衰减，主要约束中心化 logits 的相对差异；它不是对所有温度都精确保持梯度范数。

类增量时必须说明 softmax 的归一化范围。如果只在旧类别上归一化，蒸馏保存旧类之间的相对关系，却不控制它们与新类之间的整体偏移；如果在全部类别归一化并把教师对新类概率设为零，就会额外压低新类概率，可能与新任务监督冲突。回放样本、分类校准和权重调节可以缓解，但不能省略这个输出空间选择。

特征保持也有明确几何假设：若教师特征 $h_o \in \mathbb{R}^{d_o}$ 、学生特征 $h_n \in \mathbb{R}^{d_n}$ 维度不同，应通过映射 $P \in \mathbb{R}^{d_o \times d_n}$ 再比较 $\|Ph_n - h_o\|^2$ ，或比较关系结构；直接相减没有定义。可训练的 P 可能吸收一部分变化，过强的逐点保持则会限制新任务需要的表示重组。

19.4 参数隔离、扩展与混合策略

Progressive Networks 为新任务增加网络列，并通过横向连接复用旧表示，旧参数冻结以避免直接覆盖[91]。代价是参数随任务增长，并依赖任务路由。掩码方法为不同任务选择不同参数子集，容量耗尽后仍需要压缩或扩展。Adapter 和 LoRA 可以成为隔离模块，但只有旧模块被冻结且路由可靠时，才提供对应的保持机制。

冻结模块只有在它实际被调用时才保护输出。设路由器为 $r(x)$ 、旧任务 i 的固定专家为 f_i ，最终预测为 $f_{r(x)}(x)$ 。对零一损失，记错误路由概率为 ϵ_r ，旧专家单独使用时风险为 R_i ，则由事件的并集界有 $R_{system,i} \leq \epsilon_r + R_i$ 。即使 R_i 完全不变，路由错误也足以损坏系统性能；若另有共享归一化统计或公共前处理被更新，冻结专家权重甚至不保证 f_i 这一函数不变。增加 T 个每个含 P_0 参数的专家通常需 $O(TP_0)$ 存储，隔离是在保持与资源之间交换，不是免费消除遗忘。

回放、蒸馏和隔离并不互斥。可用小缓存维持真实旧分布，用蒸馏保留相对类别信息，再通过新模块吸收变化。比较混合算法时必须同时限制缓存、模型参数、教师副本与训练计算，避免用更大资源获得的收益被误认为算法优势。

19.5 评价矩阵与工业更新规则

定义 $A_{t,i}$ 为学习完阶段 t 后在任务 i 固定测试集上的性能，行对应学习时间，列对应测试任务。最终平均性能和平均遗忘为

$$ACC = \frac{1}{T} \sum_{i=1}^T A_{T,i}, \quad F = \frac{1}{T-1} \sum_{i=1}^{T-1} \left(\max_{i \leq t < T} A_{t,i} - A_{T,i} \right). \quad (19.16)$$

遗忘量可以为负，表示最终性能超过此前最佳值；若采用截断为零的定义，应显式声明。后向迁移为

$$BWT = \frac{1}{T-1} \sum_{i=1}^{T-1} (A_{T,i} - A_{i,i}). \quad (19.17)$$

前向迁移可比较学习任务 i 之前的 $A_{i-1,i}$ 与未迁移基线，但仅在输出空间与任务可访问性允许该测试时有意义[70]。类增量应同时测试所有已见类别，不能利用真实任务身份缩小候选集合。

这些指标中的 A 默认越大越好，例如准确率或召回；若填入损失，需要相应反转差分方向。遗忘与后向迁移并不相反等价：若某旧任务初学得分为0.70，中期最高为0.90，最终为0.80，它的后向迁移为+0.10，但从历史最佳计算的遗忘仍为0.10。数值仅为解释定义的教学例。只报告最终平均性能可能同时掩盖某旧域崩溃与某新域改善，因此应保留完整矩阵、最差子群指标和新阶段初学性能；没有学会旧任务的模型也可能表现为“几乎不遗忘”。当 $T = 1$ 时，含 $T - 1$ 分母的指标不定义。

新相机按周接入时，应提前为每台相机固定测试集，每次更新后都在这些集合上填写评价矩阵。缓存不能混入测试样本，超参数也不能看到未来阶段的结果后反复修改。线上流程应先用当前模型预测，等工单或复检标签到达后再学习，并记录标签延迟、漂移响应时间、每阶段训练时长和累计存储。旧相机或安全关键缺陷一旦超过风险阈值，应回滚到已验收版本，而不是自动覆盖生产模型。

本章小结。 回放重建历史风险，梯度约束限制局部干扰，参数正则保存重要方向，蒸馏保存所观察输入上的函数行为，隔离减少共享参数冲突。这些保护机制各有缺

口：缓存未必覆盖稀有旧故障，一阶约束不控制有限步长曲率，对角重要性忽略参数耦合，新输入上的蒸馏不保证旧输入行为，冻结模块还依赖正确路由。没有一种方法能够脱离任务身份、历史访问和资源预算单独比较。

持续学习要逐阶段记录新旧任务的成绩。先列出仍需识别的设备和故障，再选择保留历史样本、约束重要参数，或保存独立模块。同时检查新任务是否学会：完全不更新当然不会因更新而遗忘，但也可能一直学不会新故障。现场还会受标注速度限制。回放与正则化解决拿到标签以后怎样更新，下一章的主动学习则决定有限的专家时间先花在哪些记录上。

第二十章 主动学习

本章摘要。主动学习在有限标注预算下选择最有价值的查询。本章从候选池与标注者的交互规则出发，比较不确定性、委员会分歧、预期模型变化和批量多样性，再讨论成本、噪声与流式查询。核心不是找到最难的样本，而是使下一次标注改善部署风险。

上一章讨论在新数据到来后如何更新而不遗忘，但这通常默认训练所需标签能够取得。工业现场中，更稀缺的资源可能是能够判断裂纹性质、核对工单因果或识别异常波形的专家时间。面对成千上万条未标注记录，更新算法之前还有一个决策：先看哪一条，为什么值得看，得到答案后能够改变什么？本章把这种决策本身纳入学习过程。

主动学习不是把最难样本交给专家，而是在当前信息和预算下选择预期有用的观测。模型拿不准可能源于知识不足，也可能源于输入本身无法判读；两个都很有价值的单点放在同一批次中，也可能提供重复信息。因此，本章依次区分预测不确定性与可减少的不确定性，推导标签带来的信息增益和预期风险变化，再用几何覆盖与梯度表示处理批量冗余，最后把费用、标注错误和抽样偏差纳入查询与标注流程。

获取函数给记录排出的次序，只是在估计先标哪一条可能更有帮助。它的分数再高，也要通过实际标注和重新训练来检验。比较方法时应给它们相同的总预算，并计入专家核对、返工和等待时间，再看哪一种更快减少漏报与误报。如果记录分散在不能交换原始数据的工厂中，还需要安排各处怎样共同训练，这就是下一章联邦学习的问题。

20.1 查询规则与标注预算

图20.1的反馈路径说明查询与训练相互影响：获取函数选择待标注样本，新标签改变模型，也改变下一轮的查询分布。设已标注集为 L ，未标注池为 U ，标注成本为 $c(x)$ ，总预算为 B 。每轮训练模型，按获取函数 $a(x; L)$ 选择查询集 $Q \subset U$ ，获取标签后更新 $L \leftarrow L \cup \{(x, y) : x \in Q\}$ 、 $U \leftarrow U \setminus Q$ 。查询满足 $\sum_{x \in Q} c(x) \leq B_{\text{remaining}}$ 。获取函数是对未来收益的近似，不是测试集上的真实增益[96]。

池式主动学习可比较整个 U ；流式方法只能对到达样本决定查询或跳过；查询合成允许模型构造新输入，但工业中未必存在可由专家可靠判读的合成波形。无论采用




图 20.1: 池式主动学习在每轮用获取函数分配有限标注预算，再用新标签更新模型和下一轮查询。

哪种设定，测试集都不属于候选池。初始化标签过少时，模型置信度尚不可靠，因此随机或分层覆盖的种子集十分重要。

20.2 不确定性、委员会与贝叶斯查询

最小置信度、间隔与熵。 设模型类别概率按大小排列为 $p_{(1)}(x) \geq p_{(2)}(x)$ 。常见获取函数为

$$a_{LC}(x) = 1 - p_{(1)}(x), \quad a_{margin}(x) = -(p_{(1)}(x) - p_{(2)}(x)), \quad (20.1)$$

$$a_H(x) = -\sum_k p_k(x) \log p_k(x). \quad (20.2)$$

三者均选择得分较大的样本。最小置信度只看最大类别，间隔看前两类竞争，熵考虑全部概率。多分类下它们并不等价。Lewis 与 Gale 的不确定性采样工作展示了基于当前分类器选择标注对象的基本思想[61]。

何时这些分数等价，何时不等价。 对二分类，记 $p = P(Y = 1 | x)$ ，则最小置信度为 $\min(p, 1 - p)$ ，负间隔为 $-|2p - 1|$ ，熵为 $h(p) = -p \log p - (1 - p) \log(1 - p)$ 。在 $0 < p < 1/2$ 时， $h'(p) = \log((1 - p)/p) > 0$ ，三者都随 p 靠近 $1/2$ 而增加，故产生相同排序。多分类没有这个结论。例如两个候选概率为 $(0.50, 0.49, 0.01)$ 与 $(0.50, 0.25, 0.25)$ ，最小置信度相同，间隔优先选前者，熵却优先选后者；前者突出两类决策竞争，后者突出整体分散程度。这里及下文取自然对数，约定 $0 \log 0 = 0$ 。

边界附近可能有可学习样本，也可能是永久模糊的记录、传感器损坏或标签定义冲突。反复查询后一类样本会消耗预算却不减少模型不确定性。应按设备与工况审计获取分数，并检查模型校准，而不是默认低置信度必有高信息价值。

Query-by-Committee。 委员会方法训练多个与当前数据相容的预测器，选择其分歧最大的样本[97]。若有 M 个成员，类别投票比例为 $v_k(x)$ ，投票熵为 $-\sum_k v_k \log v_k$ 。也可用成员概率分布到平均预测的 KL 散度。Bootstrap、不同初始化或后验样本可形成委员会，但高度相关的成员会低估分歧，毫无约束的弱模型则可能制造无效分歧。

Bayesian Active Learning by Disagreement (BALD) 与联合批量查询。 BALD 选择标签与模型参数间条件互信息最大的输入[44]:

$$a_{BALD}(x) = H[\mathbb{E}_{p(\theta|L)} p(y | x, \theta)] - \mathbb{E}_{p(\theta|L)} H[p(y | x, \theta)]. \quad (20.3)$$

第一项是总体预测熵，第二项扣除各模型自身仍有的不确定性。用 M 次后验近似采样计算类别概率、先平均再取熵，并减去逐次熵的平均。它试图区分认知不确定性与数据歧义，但效果取决于后验近似。Monte Carlo (MC) dropout 是一种近似手段，不是精确贝叶斯采样[27]。

从后验信息增益推出 BALD。 固定已标注集 L 和候选 x ，把参数 Θ 看成后验随机变量、标签 Y 看成尚未观测的离散变量。理想查询的信息价值是观察标签后后验改变多少:

$$I(Y; \Theta | x, L) = \mathbb{E}_{Y|x, L} \text{KL}(p(\theta | L, x, Y) || p(\theta | L)) \quad (20.4)$$

$$= \mathbb{E}_{\Theta|L} \sum_y p(y | x, \Theta) \log \frac{p(y | x, \Theta)}{p(y | x, L)} \quad (20.5)$$

$$= H[p(y | x, L)] - \mathbb{E}_{\Theta|L} H[p(y | x, \Theta)]. \quad (20.6)$$

从式(20.4)到式(20.5)使用贝叶斯公式 $p(\theta | L, x, y)/p(\theta | L) = p(y | x, \theta)/p(y | x, L)$ ，这里采用条件预测模型并将候选 x 作为固定设计。互信息非负且至多为 $\log K$ ，其中 K 为类别数，因为条件熵非负且 K 类熵至多为 $\log K$ 。

取 M 个后验近似样本，令 $p^{(m)} \in \mathbb{R}^K$ 为其预测、 $\bar{p} = M^{-1} \sum_m p^{(m)}$ ，则估计为

$$\hat{I} = H(\bar{p}) - \frac{1}{M} \sum_m H(p^{(m)}) = \frac{1}{M} \sum_m \text{KL}(p^{(m)} || \bar{p}). \quad (20.7)$$

最后一个等式也说明概率委员会分歧与 BALD 的联系，但普通随机初始化委员会未必代表后验。二分类中，若每个模型都输出 $(1/2, 1/2)$ ，预测熵为 $\log 2$ 而互信息为零：再看标签未必能解决输入本身歧义。若一半模型输出 $(1, 0)$ 、另一半输出 $(0, 1)$ ，平均预测同样为 $(1/2, 1/2)$ ，但每个模型熵为零，互信息达到 $\log 2$ ：标签可以区分两组假设。这是两种不确定性的理想示例，不保证近似后验能在真实数据中正确区分它们。

逐点取 BALD 前若干名可能选出几乎相同的相邻窗口。BatchBALD 对一批标签与参数的联合互信息进行近似优化，考虑查询间冗余[57]。批量规模增加使联合计算更困难，因此应报告候选池大小、后验采样次数和获取时间。

对查询批次 $Q = \{x_1, \dots, x_b\}$ ，若给定参数后标签条件独立，联合信息增益可写为

$$I(Y_Q; \Theta | L) = H(Y_Q | L) - \sum_{j=1}^b \mathbb{E}_{\Theta|L} H(Y_j | x_j, \Theta). \quad (20.8)$$

不能把第一项换成单点熵之和，因为对参数积分后各标签往往相关。两点时，条件独立假设给出 $I(Y_1, Y_2; \Theta) = I(Y_1; \Theta) + I(Y_2; \Theta) - I(Y_1, Y_2)$ ，省略的条件均为固定输入

与 L 。这正是冗余扣除：两条记录若几乎回答同一个参数问题，单点相加会重复计算收益。联合标签空间有 K^b 种配置，直接枚举随批量指数增长，所以近似采样和贪心批量构造是计算折中，而不是改变查询目标。

20.3 预期风险、梯度变化与多样性

预期误差减少。 理想查询希望标注后风险下降。由于未知 y ，可按当前预测枚举候选标签并模拟更新[89]：

$$a_{EER}(x) = \hat{R}(\theta) - \sum_y p_\theta(y | x) \hat{R}(\theta_{L \cup \{(x,y)\}}). \quad (20.9)$$

风险代理只能在训练侧保留集或规定的无标签代理上计算，不能使用最终测试标签。每个候选、每个标签都重训代价很高，可用少量梯度步近似，但近似可能误判长期收益。若当前模型给真实类别极低概率，预期收益也可能被低估。

一次梯度更新能否预测风险收益。 令 $\theta \in \mathbb{R}^p$ ，候选标签为 y 时的梯度为 $g_y(x) = \nabla_\theta \ell(x, y)$ ，模拟一步 $\theta'_y = \theta - \eta g_y$ 。若风险代理 $\hat{R}$ 二阶可微，在当前参数处梯度为 r 、Hessian 为 H ，则

$$\hat{R}(\theta) - \hat{R}(\theta'_y) \approx \eta r^\top g_y - \frac{\eta^2}{2} g_y^\top H g_y. \quad (20.10)$$

所以有效更新取决于方向对齐和曲率，并非只取决于 $\|g_y\|$ 。若代理风险在当前模型处已近驻点，一阶项很小，大梯度甚至可能主要增加二阶风险。

还有一个容易忽略的抵消现象。对交叉熵 $\ell = -\log p_\theta(y | x)$ ，若用同一个当前模型对未知标签求平均，则

$$\sum_y p_\theta(y | x) g_y(x) = - \sum_y \nabla_\theta p_\theta(y | x) = -\nabla_\theta 1 = 0. \quad (20.11)$$

因此简单的一步、固定代理风险、一阶近似组合会给所有候选零平均收益；它不是完整 Expected Error Reduction (EER) 的替代。完整重训会改变最优解、后验或风险估计，高阶项也不会一般消失。这个结果解释了为什么预期梯度长度使用范数的平均，而不是平均梯度的范数，二者由三角不等式并不相同。

预期梯度长度以 $\sum_y p_\theta(y | x) \|\nabla_\theta \ell(x, y)\|$ 估计模型变化。较大梯度说明会产生较大更新，却不保证更新方向有益，异常值可能占据排名前列。

Core-set 与 Batch Active Learning by Diverse Gradient Embeddings (BADGE)。

Core-set 在表示空间选择覆盖候选池的样本[95]：

$$\min_{Q \subseteq U: |Q|=b} \max_{x \in U} \min_{z \in L_X \cup Q} \|f(x) - f(z)\|_2. \quad (20.12)$$

这里 $L_X = \{x : (x, y) \in L\}$ 为已标注集的输入集合, b 为本轮查询数, f 为当前特征编码器。这样距离比较的两端都是输入, 而不是将带标签样本对与输入混合。常用贪心近似每次选离已选中心最远的点, 并更新所有候选的最短距离。它鼓励覆盖, 但若表示由背景或设备身份主导, 就会覆盖无关差异; 极端离群点也可能被优先选择。

覆盖半径为什么有意义, 又为什么不够。 记当前已选中心集合为 S , 所有候选到中心的最近距离为 $d_S(x)$ 。贪心最远点步骤选择 $x^* = \arg \max_x d_S(x)$, 随后仅需更新 $d_{S \cup \{x^*\}}(x) = \min\{d_S(x), \|f(x) - f(x^*)\|\}$, 而不必每轮重新比较所有中心。在固定度量、等成本、中心从候选中选取的离散覆盖问题中, 最远点策略有经典的两倍半径近似解释: 若最终半径超过最优半径的两倍, 依次选出的点和最终最远点必须彼此相距超过该值; 但最优的 b 个新增半径球无法容纳 $b + 1$ 个这样的点, 因为同一球内任意两点的距离至多为两倍半径。已有固定中心时, 这些点也不可能由已有中心在最优半径内覆盖, 故相同计数逻辑仍成立。

这个结论只保证几何覆盖。若条件期望损失 $\bar{\ell}(z) = \mathbb{E}[\ell \mid Z = z]$ 在表示空间是 L -Lipschitz, 则 $|\bar{\ell}(z) - \bar{\ell}(z_c)| \leq L\|z - z_c\|$, 覆盖半径 r 才能被解释为至多 Lr 的局部损失差异控制; 但故障边界可能不平滑, 表示可能遗漏关键变量, 而且一个中心标签不等于精确的条件期望损失。因此几何近似保证不能直接改写为标注后分类风险保证。

BADGE 将不确定性与多样性放到最后一层的梯度表示中[2]。先取预测概率最大的类别为伪标签, 再计算各类别的梯度块:

$$\hat{y} = \arg \max_k p_k(x), \quad g_k(x) = (p_k(x) - \mathbf{1}[k = \hat{y}])h(x), \quad (20.13)$$

其中 $h(x)$ 是分类头输入。拼接各类梯度后, 用类似 k -means++ 的距离采样选择一批点。梯度长度反映当前预测的不确定性, 梯度方向帮助减少冗余。该方法不需要候选真实标签, 但依赖伪标签与当前表示质量。

梯度嵌入为何同时包含置信度与方向。 令线性分类头 $W \in \mathbb{R}^{K \times d}$ 、特征 $h(x) \in \mathbb{R}^d$, logits 为 Wh , 概率为 p 。对标签 y , 交叉熵梯度为

$$\nabla_W \ell = (p - e_y)h^\top \in \mathbb{R}^{K \times d}, \quad (20.14)$$

其中 e_y 为第 y 个标准基向量。逐行展平这张矩阵得到 Kd 维嵌入, 便得到式(20.13)中的 g_k 。其范数满足

$$\|g(x)\|_2^2 = \|p - e_{\hat{y}}\|_2^2 \|h(x)\|_2^2. \quad (20.15)$$

若预测接近某个确定类别, 第一个因子接近零; 若多个类别竞争, 则残差通常更大。但第二个因子也会影响长度, 所以不能把它当作纯粹的概率不确定性。两个样本的梯度内积为 $(p - e_{\hat{y}})^\top (p' - e_{\hat{y}'}) h^\top h'$: 类别竞争结构与特征相似性共同决定方向。

类似 k -means++ 的选择在已有中心集合 S 下, 以 $D(x)^2 / \sum_{u \in U} D(u)^2$ 抽取新中心, 其中 $D(x) = \min_{z \in S} \|g(x) - g(z)\|$ 。这既避免单纯选取最大梯度的一簇近重复样本, 又

保留随机探索。若所有剩余距离为零，需要采用明确的随机或去重回退规则，不能除以零。它是在梯度空间中寻找代表性，并不保证伪标签正确或最终风险最小。

20.4 成本、噪声与工业流式变体

等成本预算下按获取分数排序即可形成简单策略；成本差异明显时，可用 $a(x)/c(x)$ 作启发式，或直接求带预算约束的批量选择。比值排序不是一般情况下的最优解。长工单、复杂图像与短波形的标注时间不同，应使用专家分钟数或费用，而不只用样本数比较。

若先把收益近似为可加的 $a_i \geq 0$ ，批量选择就是 $\max_{q_i \in \{0,1\}} \sum_i q_i a_i$ ，约束 $\sum_i q_i c_i \leq B$ 。比值排序解的是可分割背包的思想，而样本标签不可分割。例如预算为10，一个候选成本6、收益12，另外两个各成本5、收益9；按比值会先选第一个而得到12，选后两个却得到18。数值只是算法反例，不是实验结果。实际批量收益还因冗余不满足可加性，故应把多样性和成本联合考虑。

多标注者场景还需选择由谁标注，并允许“不确定”或“无法判读”。对高风险少数故障可配置双人复核；对重复分歧应先修改标签定义。密度加权可以降低孤立噪声的优先级，但也可能排斥真正罕见的新故障，因此应保留随机探索和新颖性审核预算。

流式方法可在 $a(x_t) > \tau_t$ 时查询，并根据剩余预算调整阈值。漂移后旧阈值可能失效，不能仅依赖过去的分数分布。持续学习决定如何更新模型，主动学习决定获取哪些标签，二者可联合但应分别消融。查询高不确定样本产生选择偏差，性能监测仍需要独立的代表性抽样，不能直接用已查询数据的准确率估计上线风险。

查询偏差与代表性监测。 设一个固定候选总体有 N 个样本， $S_i \in \{0,1\}$ 表示是否被查询，已知边际入选概率为 $\pi_i > 0$ 。对预先固定的评估器，若损失为 ℓ_i ，则逆概率估计

$$\hat{R}_{IPW} = \frac{1}{N} \sum_{i=1}^N \frac{S_i \ell_i}{\pi_i}, \quad \mathbb{E}[\hat{R}_{IPW}] = \frac{1}{N} \sum_{i=1}^N \ell_i \quad (20.16)$$

利用的是 $\mathbb{E}S_i = \pi_i$ 。查询越少的区域权重越大，故方差可能很高；确定性只选最高分时，未入选样本 $\pi_i = 0$ ，无法作此修正。自适应多轮查询的条件概率还依赖历史，最终入选概率不能随意替换为某轮的查询概率；同一批查询标签又参与训练时，固定评估器的无偏论证也不再直接适用。

一个可操作的补充是将部分预算留给概率探索：每轮候选数为 $|U|$ 时，按 $q_t(x) = (1 - \epsilon)q_{a,t}(x) + \epsilon/|U|$ 查询， $0 < \epsilon \leq 1$ ，并记录当轮概率与历史状态。这保证当轮每个候选有非零机会，却不自动保证精确最终风险估计。最清晰的验收仍是保留不参与获取排序和训练的代表性监测样本，其成本应计入整体标注预算，而不是被当作免费信息。

标注噪声还会改变信息价值。若标注者 a 的混淆矩阵为 $T_{ky}^{(a)} = P(\tilde{Y} = k \mid Y = y, a)$ ，并假定给定真实标签后错误与 x, θ 无关，则观测标签预测为 $p(\tilde{y} = k \mid x, \theta, a) = \sum_y T_{ky}^{(a)} p(y \mid x, \theta)$ 。查询信息增益应针对实际收到的 $\tilde{Y}$ 计算，而非假设完美的 Y 。矩阵本身未知、错误随图像质量变化或多人错误相关时，需要审核样本和更细模型；简单多数投票不能消除共同误判。

20.5 算法流程与验收

在巡检图像标注中，可以先按设备划分候选池和固定测试集，再从训练池取一批共同的初始样本。每轮用相同训练预算更新模型，给候选图像打获取分数，去掉连续拍摄的近重复图像后送专家标注，同时记录标签、耗时、费用和拒标原因。新标签加入训练集后再开始下一轮，不能把本轮查询结果提前用于本轮的分数计算。

比较随机、分层随机、不确定性和一种多样性方法，绘制真实测试召回随累计标注成本的曲线。重复不同种子集与查询随机种子，同时报告获取耗时、训练耗时、少数故障覆盖和失败查询比例。主动学习只有在同等总成本下提高真实风险表现时才有价值；节省标签却需要无法承受的反复重训，并非完整收益。

本章小结。 主动学习把标签视为需要分配的资源。不确定性寻找尚未确定的判断，BALD 进一步区分模型间分歧与单模型仍有的歧义，联合信息增益扣除批量冗余，预期风险方法直接考虑更新后的收益，而几何覆盖与梯度嵌入提供较便宜的批量代理。它们各自近似不同对象，因此获得得分不能跨方法直接解释为真实收益；大梯度不一定有益，高熵不一定可学，远距离也不一定对应新故障。

模型会判断错，专家也可能标错，同一批查询还可能重复，所以选样策略必须连同费用一起检验。上线效果应在独立且有代表性的数据上估计，不能只用主动挑出的难例测试。与持续学习结合时，可以分别替换选样方法和更新方法，查清收益来自哪里。如果多个工厂无法汇集原始记录，还要安排本地计算、更新通信与聚合。下一章讨论这种联邦协作；标签缺失、选择偏差和历史遗忘仍需各自处理。


第二十一章 联邦学习

本章摘要。本章把“数据不能集中”作为约束，重新审视训练、通信、隐私和公平性。先定义联邦优化与非独立同分布，再分析 Federated Averaging (FedAvg)、本地更新、差分隐私、安全聚合和个性化方法，最后回到系统延迟、参与方差异和攻击面。联邦学习解决的是数据协作边界，不会自动解决统计偏差。

上一章主动学习讨论把有限标注预算花在哪些样本上，隐含的问题是所选样本能否进入同一个学习流程。本章进一步撤去数据可集中这一便利条件：不同工厂或设备群既可能具有不同工况，也可能不能把原始记录汇集到同一处。故障预测目标没有改变，改变的是谁持有数据、谁计算梯度，以及谁能够观察更新。

假设几家工厂不能交换原始记录，但希望一起改进故障模型。首先要决定大工厂是否因样本多而占更大权重，再看各厂独立训练多步以后，更新为什么可能朝不同方向走。通信中断、设备掉线和更新中泄露的信息，也都要考虑。本章从加权经验风险推导 FedAvg，再解释近端项、控制变量和个性化方法。评价时既看平均成绩，也看表现最差的工厂，并记录通信成本和隐私预算。原始数据留在本地，并不自动保证上传的更新安全。

21.1 问题定义



双向通信：下发模型、回传更新；服务器按权重聚合

图 21.1: 联邦学习的基本循环。原始数据留在客户端，服务器只接收模型参数或更新。

图21.1区分本地数据路径与服务器聚合路径；客户端在原始记录上训练，服务器通过汇总更新协调模型，而不是集中收集训练样本。FedAvg 通过客户端本地更新与服务器加权聚合实现分散训练[73]。Federated Proximal Optimization (FedProx) 加入

近端约束, Stochastic Controlled Averaging for Federated Learning (SCAFFOLD) 使用控制变量校正客户端漂移[64, 49]; 它们改变优化机制, 并不单独提供隐私保证。联邦学习在多个客户端保留本地数据, 仅交换模型更新。客户端 k 有目标 $F_k(\theta)$ 和权重 p_k , 全局目标为

$$\min_{\theta} F(\theta) = \sum_{k=1}^K p_k F_k(\theta). \quad (21.1)$$

FedAvg在每轮下发全局参数, 客户端执行若干步本地 SGD, 再按样本量聚合:

$$\theta^{t+1} = \sum_{k=1}^K p_k \theta_k^{t+1}. \quad (21.2)$$

21.1.1 权重、抽样与集中式基线

设参数 $\theta \in \mathbb{R}^d$, 客户端 k 持有 n_k 个样本, 且

$$F_k(\theta) = \frac{1}{n_k} \sum_{i=1}^{n_k} \ell(\theta; x_{ki}, y_{ki}), \quad p_k \geq 0, \quad \sum_k p_k = 1. \quad (21.3)$$

取 $p_k = n_k / \sum_j n_j$ 得到所有样本等权的经验风险; 取 $p_k = 1/K$ 得到所有工厂等权的风险。二者不是实现上的可互换选项: 一家拥有大量正常记录的大工厂, 在第一种目标中可能压过数据稀少但故障代价高的小工厂。权重应先由业务目标定义, 而不是由方便上传的数据量事后决定。

若所有客户端参与且只做一步全梯度下降, 则

$$\sum_k p_k (\theta^t - \eta \nabla F_k(\theta^t)) = \theta^t - \eta \sum_k p_k \nabla F_k(\theta^t) \quad (21.4)$$

$$= \theta^t - \eta \nabla F(\theta^t). \quad (21.5)$$

式(21.5)表明, 这个特例与集中式全梯度更新严格相同。若使用随机梯度 g_k , 需要条件无偏性 $\mathbb{E}[g_k | \theta^t] = \nabla F_k(\theta^t)$ 才有期望意义上的相同; 模型中的随机状态、归一化统计量等还应采用相容的处理方式。

部分参与使权重问题更复杂。令 $I_k^t \in \{0, 1\}$ 表示是否参与, 已知参与概率 $\pi_k > 0$, 则在更新与抽样条件相容时,

$$\hat{g}^t = \sum_k I_k^t \frac{p_k}{\pi_k} g_k^t, \quad \mathbb{E}[\hat{g}^t | \theta^t] = \nabla F(\theta^t). \quad (21.6)$$

式(21.6)中的期望等式来自 $\mathbb{E}[I_k^t] = \pi_k$ 。这种逆概率校正不要求各客户端独立入选, 但小 π_k 会放大方差。常用的参与集合内重新归一化权重是随机比值, 通常不能声称对原目标严格无偏。如果网络故障与设备状态相关, 又没有可靠参与概率, 仅靠增加训练轮数不能恢复缺失工厂的代表性。

21.2 联邦优化、隐私与系统约束

非独立同分布与通信。 当 $P_k(X, Y)$ 不同, 本地更新方向可能冲突, 客户端数量、参与率和本地步数会影响收敛。通信压缩、个性化联邦学习和聚类联邦学习分别处理带宽、客户端差异和多群体结构。服务器不能直接看到原始数据, 但更新仍可能泄露信息, 因此需要安全聚合、差分隐私或加密协议。这里的协议指参与方之间明确规定的消息交换和计算步骤。

评价与边界。 联邦系统应报告全局性能、最差客户端性能、通信轮数、隐私预算与掉线鲁棒性。联邦学习解决的是数据不能集中这一约束, 并不会自动解决标签偏差、恶意客户端或模型公平性问题。

表 21.1: 联邦学习方法的约束匹配

方法	主要修正对象	额外代价	适用边界
FedAvg	基本全局聚合	本地漂移未被显式校正	分布接近、通信受限的基线
FedProx	客户端更新偏离	近端系数和局部适应之间需调节	非 Independent and Identically Distributed (IID) 与算力异构
SCAFFOLD	系统性梯度漂移	控制变量存储和同步	客户端长期参与、通信可承受
个性化联邦	客户端条件差异	共享层与本地层的划分	工厂、设备或人群差异明显
安全聚合与 Differential Privacy (DP)	更新可见性和样本影响	密码学开销或噪声导致效用下降	需要隐私保证的跨组织协作

表21.1将联邦方法与数据异质性、通信及个性化约束对应; 比较方法时须先确定主要瓶颈, 不能仅按聚合后平均精度选型。

FedAvg的本地更新。 客户端 k 从全局参数 θ^t 开始执行 E 步本地更新:

$$\theta_{k,e+1}^t = \theta_{k,e}^t - \eta \nabla F_k(\theta_{k,e}^t), \quad \theta_{k,0}^t = \theta^t. \quad (21.7)$$

服务器聚合 $\theta^{t+1} = \sum_k p_k \theta_{k,E}^t$ 。当各客户端数据同分布且目标函数平滑时, 增加本地步数可减少通信; 非 IID 情况下, 本地漂移会使聚合方向偏离全局梯度。

从本地多步展开看漂移来源。 先考虑全参与、确定性梯度与共同步长, 以免将抽样噪声和漂移混在一起。把 E 步递推求和可得

$$\theta^{t+1} - \theta^t = -\eta \sum_k p_k \sum_{e=0}^{E-1} \nabla F_k(\theta_{k,e}^t) \quad (21.8)$$

$$= -\eta E \nabla F(\theta^t) - \eta R_t, \quad (21.9)$$

$$R_t = \sum_k p_k \sum_{e=0}^{E-1} [\nabla F_k(\theta_{k,e}^t) - \nabla F_k(\theta^t)]. \quad (21.10)$$

这里 $R_t \in \mathbb{R}^d$ 就是相对于固定起点梯度的累计偏离。假设各 F_k 梯度为 L -Lipschitz, 且本轮轨迹上 $\|\nabla F_k\| \leq G$, 由三角不等式有

$$\|\theta_{k,e}^t - \theta^t\| \leq \eta e G, \quad \|R_t\| \leq L\eta G \frac{E(E-1)}{2}. \quad (21.11)$$

于是参数误差上界为 $L\eta^2 GE(E-1)/2$ 。这不是完整收敛定理, 也未区分同分布曲率与异质性; 它明确说明: 少通信带来的多步本地训练会累积偏离, 而不是无代价地模拟集中式梯度。

异质性可用 $\zeta^2(\theta) = \sum_k p_k \|\nabla F_k(\theta) - \nabla F(\theta)\|^2$ 描述。全局最优点上 $\nabla F = 0$ 并不要求各 $\nabla F_k = 0$, 因此本地继续优化仍可能把参数拉向不同方向。一个可直接核算的例子是 $F_k(\theta) = a_k(\theta - b_k)^2/2$, 其中 $\theta \in \mathbb{R}$ 、 $a_k > 0$ 。递推给出

$$\theta_{k,E} = b_k + (1 - \eta a_k)^E (\theta^t - b_k). \quad (21.12)$$

当 $|1 - \eta a_k| < 1$ 且 $E \rightarrow \infty$, 聚合趋于 $\sum_k p_k b_k$, 但全局最优点是 $\sum_k p_k a_k b_k / \sum_k p_k a_k$ 。除特殊情形外二者不同; 本地模型各自训练得更充分, 不代表全局模型更接近目标最优点。

隐私的三个层次。 数据不上传不等于隐私完好。更新可能通过梯度反演暴露样本特征, 恶意客户端可能投毒, 服务器也可能推断客户端属性。安全聚合保护服务器免于看到单个更新; 差分隐私在更新上加入噪声, 提供形式化的 (ϵ, δ) 保证; 鲁棒聚合则针对异常更新, 但不能自动提供隐私。

个性化联邦学习。 全局模型适合共享规律, 个性化模型允许客户端保留本地参数:

$$\theta_k = \theta_{shared} + \theta_{k,local}. \quad (21.13)$$

共享层、个性化头、元学习初始化和客户端聚类是常见路线。工业设备差异很大时, 追求一个平均最优模型可能不如学习一组有结构的个性化模型。

个性化目标为什么需要耦合。 仅写 $\theta_k = \theta_{shared} + \theta_{k,local}$ 还没有定义算法, 因为给共享参数加一个向量、给每个本地参数减去同一向量不会改变预测。一个明确的软共享目标是

$$\min_{\theta, \{v_k\}} \sum_k p_k \left[F_k(v_k) + \frac{\lambda}{2} \|v_k - \theta\|^2 \right], \quad \theta, v_k \in \mathbb{R}^d, \quad \lambda > 0. \quad (21.14)$$

固定 θ , 各客户端独立优化其正则化风险; 固定 v_k , 对 θ 求导得到 $\lambda \sum_k p_k (\theta - v_k) = 0$, 故 $\theta = \sum_k p_k v_k$ 。这一交替过程把共享信息理解为各个个性化参数的参照, 而不是强迫它们完全相同。 λ 很大时接近共享模型, 很小时接近独立训练, 但数据少的客户端可能因此过拟合。这里的 v_k 是长期保留的个性化模型, 与 FedProx 中每轮重置的局部变量不同。

若不同工厂的输出标签或传感器结构并不相同，可令共享编码器为 f_θ 、本地头为 h_{ψ_k} ，优化 $\sum_k p_k F_k(\theta, \psi_k)$ 。此时只能聚合语义和维度一致的共享参数，不能把不同类别顺序的分类头逐坐标平均。对从未参与的新工厂，还必须规定支持样本和本地适应步骤；这个问题将在元学习章进一步展开。

通信和系统约束。 量化、稀疏化、低秩更新和客户端选择降低通信量。实际系统还面对带宽波动、设备掉线、异构算力和更新延迟。实验应记录每轮参与客户端数、有效样本量、字节数、端侧训练时间和掉线率，而不能只报告最终准确率。

压缩误差与误差反馈。 设待上传差分 $u_k \in \mathbb{R}^d$ ，压缩器 Q 可返回量化值或稀疏向量。若 $\mathbb{E}[Q(u) | u] = u$ 且 $\mathbb{E}\|Q(u) - u\|^2 \leq \omega \|u\|^2$ ，压缩不改变条件均值，却增加更新方差；确定性的最大幅度稀疏化通常不满足无偏性。误差反馈保存残差 r_k^t ，令

$$s_k^t = Q(u_k^t + r_k^t), \quad r_k^{t+1} = u_k^t + r_k^t - s_k^t. \quad (21.15)$$

由此 $s_k^t = u_k^t + r_k^t - r_k^{t+1}$ ，对轮次求和后中间残差相消： $\sum_{t=0}^{T-1} s_k^t = \sum_{t=0}^{T-1} u_k^t + r_k^0 - r_k^T$ 。它解释了为何未发送信息可以延后补偿，但残差有界及收敛仍需压缩器和目标的额外条件。长期掉线、状态丢失或模型版本变化都可能破坏这种补偿；稀疏上传还要计入索引字节，不能只数非零数值。

21.3 联邦诊断案例与验收

将不同工厂作为客户端，训练共享的故障表征和个性化的告警头。一轮 FedAvg 与集中式梯度下降的差异来自本地多步更新和客户端数据权重；安全聚合只能隐藏单个更新，不能防止模型投毒，因此验收还应约束最差客户端性能、异常更新比例和通信失败后的恢复行为。

一轮联邦训练的完整过程。 服务器首先选择客户端子集并发送当前模型。客户端在本地数据上训练若干步，计算更新后上传参数或差分；服务器按样本量或其他权重聚合，再将新模型发送给下一轮。这个过程的关键不是“把 SGD 分散执行”这么简单，而是每轮参与者、数据量、本地步数和网络状态都会改变优化轨迹。

图21.2展开一轮下发、本地训练和回传聚合的关系；客户端计算与通信构成不同成本，且回传更新本身仍可能包含敏感信息。

客户端漂移与 FedProx。 非 IID 数据下，本地目标的最优方向可能不同。客户端执行过多本地步数后，更新会远离全局模型，聚合后产生客户端漂移。FedProx 在本地目标中加入近端项：

$$\min_{\theta} F_k(\theta) + \frac{\mu}{2} \|\theta - \theta^t\|_2^2. \quad (21.16)$$




图 21.2: 联邦学习的服务器-客户端循环；原始数据留在客户端，但更新仍需保护。

近端系数限制本地模型偏离服务器模型的幅度，适合数据和算力差异较大的系统，但过大的 μ 会降低本地适应能力。

对该目标求梯度，本地第 e 步为

$$\theta_{k,e+1} = \theta_{k,e} - \eta[\nabla F_k(\theta_{k,e}) + \mu(\theta_{k,e} - \theta^t)]. \quad (21.17)$$

起点 $\theta_{k,0} = \theta^t$ 处近端梯度为零，所以第一步与 FedAvg 相同；它主要约束之后的偏离。对二次目标 $F_k(v) = \frac{1}{2}(v - b_k)^\top A_k(v - b_k)$ ，其中 $A_k \in \mathbb{R}^{d \times d}$ 对称半正定、 $\mu > 0$ ，驻点方程为 $(A_k + \mu I)v = A_k b_k + \mu \theta^t$ ，从而

$$v - \theta^t = -(A_k + \mu I)^{-1} \nabla F_k(\theta^t). \quad (21.18)$$

沿 A_k 的特征方向，位移被 $1/(a + \mu)$ 缩放，展示了近端项如何抑制偏离。对非凸神经网络，近端项不自动使目标凸；若 Hessian 特征值下界为 $-\rho$ ，只有 $\mu > \rho$ 才足以使该区域的正则化 Hessian 正定。实际内层通常仅近似求解，应同时报告本地停止准则，而非默认获得精确极小点。

控制变量与 SCAFFOLD。 SCAFFOLD 为服务器和客户端维护控制变量，用于估计并校正本地更新中的系统性偏差。其思想是把“客户端自身的梯度偏移”和“当前模型真正的全局下降方向”区分开。该方法通常以额外状态和通信为代价改善非 IID 收敛，实验时必须报告控制变量的存储和同步开销。

具体地，设 $c, c_k \in \mathbb{R}^d$ 分别估计全局和本地梯度方向，本地更新改为

$$v_{k,e+1} = v_{k,e} - \eta(g_k(v_{k,e}) - c_k + c), \quad v_{k,0} = \theta^t. \quad (21.19)$$

若在同一参考点 $c_k = \nabla F_k(\theta^t)$ 、 $c = \sum_k p_k c_k$ ，则第一步修正方向的条件期望恰为 $\nabla F(\theta^t)$ ，不再随客户端改变。后续各本地点不同，校正并不意味着始终拥有精确全局梯度。一种固定 E, η 的控制变量更新为

$$c_k^{new} = c_k - c + \frac{\theta^t - v_{k,E}}{E\eta} = \frac{1}{E} \sum_{e=0}^{E-1} g_k(v_{k,e}). \quad (21.20)$$

第二个等号由本地递推求和得到，说明新控制变量代表本轮沿轨迹的平均梯度。若维护加权关系 $c = \sum_k p_k c_k$ ，服务器应更新 $c^{new} = c + \sum_{k \in S_t} p_k (c_k^{new} - c_k)$ ，未参与者保留旧状态。经典均匀客户端设定取 $p_k = 1/K$ ；不同权重、服务器步长和参与方案需要配套实现，不能混用聚合规则。陈旧控制变量以及额外的 d 维上传，是该方法的实际代价。

差分隐私与隐私预算。 必须先指定保护单位。样本级邻接表示训练集仅相差一条记录；客户端级邻接表示相差一个客户端的全部贡献。单样本梯度裁剪通常用于样本级保护，不能直接称为客户端级保护。随机机制 M 满足 (ϵ, δ) 差分隐私，是指任意相邻数据集 D, D' 和可测输出事件 A 都有

$$\Pr[M(D) \in A] \leq e^\epsilon \Pr[M(D') \in A] + \delta. \quad (21.21)$$

它约束观察结果因一单位数据变化而改变的程度，不是“攻击一定失败”的概率声明。

以客户端级发布为例，先把每个上传向量 $u_k \in \mathbb{R}^d$ 裁剪为

$$\bar{u}_k = u_k \min\{1, C/\|u_k\|_2\}, \quad M = \frac{1}{m} \left(\sum_k \bar{u}_k + \xi \right), \quad \xi \sim \mathcal{N}(0, \sigma^2 C^2 I_d), \quad (21.22)$$

其中零向量保持为零， m 是固定公开归一化常数，缺席贡献以零计。加入或删除一个客户端时，和的 ℓ_2 敏感度至多为 C ；替换一个客户端时由三角不等式得到 $2C$ 。因此两种邻接定义不可使用相同敏感度而不作说明。对一次发布、加入删除邻接、 $0 < \epsilon < 1$ ，经典高斯机制的一个充分条件是 $\sigma \geq \sqrt{2 \log(1.25/\delta)}/\epsilon$ ；该式是保守校准条件，不是多轮训练的最终预算。

除以 m 后，敏感度与噪声标准差同时缩小，不能据此声称隐私自动增强。裁剪把过大更新的影响截断，也引入偏差；噪声期望为零，但其平均平方范数为 $d\sigma^2 C^2/m^2$ ，高维、少参与者时可能明显损害效用。若服务器先看到未扰动单个更新，再在总和上加噪声，则保证针对发布结果的观察者，而不保护客户端免受该服务器观察；必须明确可信聚合者，或使用安全聚合与按约定步骤进行的分布式噪声生成。

对于自适应的 T 轮发布，基本组合给出 $\epsilon_{tot} \leq \sum_t \epsilon_t$ 、 $\delta_{tot} \leq \sum_t \delta_t$ 。实际可用更紧的隐私会计，但需声明抽样方式、采样率、噪声乘子、邻接定义和会计方法。抽样放大结论依赖抽样独立性及可见信息，不能对按故障分数挑选客户端的过程直接套用均匀抽样公式。

安全聚合与攻击面。 安全聚合使服务器只能看到聚合结果，不能直接读取单个客户端更新，但它不能防止恶意客户端上传投毒或后门更新。鲁棒聚合可以按坐标中位数、截断均值或相似性筛除异常，却可能误伤来自真实少数群体的正常更新。安全性需要从服务器、客户端、通信通道和模型输出四个方面分别分析。

安全聚合为何能只显露总和。 下面只用代数说明掩码抵消，不把它当作可直接部署的完整密码协议。设更新经约定量化后为有限域 $\mathbb{F}_q^d$ 上的向量 u_k ，每对客户端共享随机掩码 r_{kj} ，并约定 $r_{jk} = -r_{kj}$ 。客户端发送

$$\tilde{u}_k = u_k + \sum_{j \neq k} r_{kj}, \quad \sum_k \tilde{u}_k = \sum_k u_k + \sum_{k < j} (r_{kj} + r_{jk}) = \sum_k u_k. \quad (21.23)$$

掩码在总和中抵消，单个带掩码消息却不直接等于原更新。实际协议还需要认证、密钥协商、门限恢复及串谋假设；若某客户端掉线，它对应的掩码未必成对抵消，需要恢复机制，且不能同时恢复足以解开其原始贡献的全部秘密。量化范围和模数还要防止解码溢出。

服务器得到总和仍可能通过参与集合差分或很小的聚合组推断贡献，因此还需最小聚合规模、查询限制及必要的差分隐私。另一个根本冲突是：坐标中位数不是总和的函数，服务器若只能获得总和，就不能直接执行基于单个更新的筛选。安全聚合与鲁棒聚合必须联合设计，而不是把两个算法名称并列便认为两项保证同时成立。

掉线、异构与公平性。 慢客户端会拖延同步，掉线客户端可能造成样本代表性变化；按样本量加权又可能让大客户端压过小群体。评价时应报告平均性能、最差客户端、不同客户端规模区间和掉线条件下的性能。对于工业多工厂系统，公平性不仅是统计指标，也关系到不同工厂是否都能获得足够的故障检测能力。

在多工厂轴承诊断中，可把工厂、产线或设备群定义为客户端。首先固定一个不参与训练的跨工厂测试集，并在每轮记录参与客户端、样本量、本地步数、上传字节数和训练时长。随后构造三种非 IID 情形：不同工厂故障比例不同、不同工厂只观测部分类别、不同工厂的相机或传感器分布不同。FedAvg、FedProx、SCAFFOLD 和个性化头应使用相同总通信预算比较，同时报告全局平均、宏平均、最差工厂和各类故障召回。

隐私验收不能只检查原始文件是否离开工厂。应分别测试更新反演、成员推断、恶意客户端投毒和服务端串谋；对差分隐私记录每轮裁剪、噪声和累计 (ϵ, δ) ，对安全聚合记录阈值、掉线恢复和密钥失效行为。若加入噪声后小工厂的少数故障召回显著下降，平均准确率可能仍然稳定，但系统已经产生了不公平的风险分配，因此最差客户端和少数类指标必须进入停止条件。

本章小结。 联邦学习要求数据留在各工厂，但这不会替我们决定应该最小化哪一种风险。所有工厂各做一步、再按样本聚合时，FedAvg 可还原集中式梯度；每个工厂本地走多步后，各自停在不同位置，聚合方向就会产生偏差。FedProx 用近端项限制本地模型离开全局模型太远，SCAFFOLD 用控制变量修正客户端漂移，个性化方法则允许不同工厂保留不同的预测头。它们解决的不是同一个优化问题，不能只按通信轮数或平均准确率排顺序。

隐私与可靠性同样必须拆开：安全聚合限制单个更新的可见性，差分隐私限制单个保护单位对发布分布的影响，鲁棒聚合处理异常贡献。有效系统还要在掉线、少数

故障和最差工厂上通过验收。本章的基本立场不是尽可能多地分散计算，而是在可说明的统计目标、信任边界与资源预算之间选择可执行的协作方式。

能够共同训练以后，还要检查怎样衡量样本相似性。高维读数距离近，可能只是温度量纲较大，不一定代表故障相似。下一章的流形学习研究局部邻近关系能否反映转速、负载等少量变化因素。理解这些关系，也有助于判断联邦学习中所谓相似工厂究竟是工况相似，还是仅仅表示中的数值接近。

第二十二章 流形学习

本章摘要。流形学习假定高维观测由少量连续因素控制。本章从线性子空间基线出发，分别推导保持测地距离、局部重构和图平滑的算法，再讨论 t-distributed Stochastic Neighbor Embedding (t-SNE)、Uniform Manifold Approximation and Projection (UMAP) 与流形正则化。低维图形只是一种表示，不能直接证明故障类别可分。

上一章解决了数据分散时如何协同训练，却没有保证传递给模型的距离和表示本身合理。相同故障在不同转速下可能相距很远，不同故障也可能因传感器尺度相似而靠得很近。本章把问题从“数据在哪里”转向“数据之间什么关系应被保留”：如果观测的高维变化主要由少量连续因素驱动，能否在低维坐标中保留对判断有用的结构？

把许多传感器读数画到平面上，可以有不同的画法。PCA 尽量保留线性重构能力，Isometric Mapping (Isomap) 保留沿邻域图行走的距离，Locally Linear Embedding (LLE) 保留局部重构关系，谱方法关注图上的平滑变化；概率可视化更重视谁与谁相邻，并不保证远处两点的距离准确。本章分别推导这些目标。看图时还要问：聚在一起的是同一种故障，还是同一种转速？换一台设备后，这种表示是否仍有助于识别故障？

22.1 几何假设与邻域构造




图 22.1: 流形学习把高维观测看作嵌入空间中的低维结构；邻域大小决定局部几何是否可靠。

图22.1用曲线上的邻域说明局部距离与整体嵌入形状的区别；邻域过大会跨越不同局部区域，过小则可能使几何估计缺乏样本支持。设 $x = g(z) + \epsilon \in \mathbb{R}^d$, $z \in \mathbb{R}^r$ 且 $r \ll d$, g 在局部光滑。目标可以是恢复坐标、保持邻域或改善预测，这三者不

是同一个优化问题。不同载荷、转速和传感器尺度会改变距离；先按训练数据确定标准化和度量，再构造 k 近邻或半径邻域图。

邻域太小会使图断裂，太大会跨越流形折叠形成捷径。互为近邻与并集近邻的连通性不同，应记录图的连通分量和边长分布。故障突变可能跨越不连续机制，不能因为原始欧氏距离近就强迫标签平滑。

22.2 线性基线与测地距离

PCA 与核 PCA。 对中心化数据矩阵 $X \in \mathbb{R}^{n \times d}$ ，PCA 求

$$\min_{V^T V = I} \|X - XVV^T\|_F^2, \quad (22.1)$$

其解由 $X^T X$ 的主特征向量组成。坐标为 $Z = XV$ ，截断奇异值分解可避免显式构造大协方差矩阵。高方差方向不一定携带故障信息，低方异常可能被截断。核 PCA 在核矩阵上中心化后求特征向量，允许非线性表示，但需要选择核与处理新样本映射[93]。

PCA 的重构推导与尺度选择。 令 $V \in \mathbb{R}^{d \times r}$ 列正交， $P = VV^T$ 满足 $P^2 = P = P^T$ 。因此

$$\|X - XP\|_F^2 = \text{tr}[(I - P)X^T X(I - P)] \quad (22.2)$$

$$= \text{tr}(X^T X) - \text{tr}(V^T X^T X V). \quad (22.3)$$

最小化重构误差等价于最大化最后的迹。设 $X^T X = U\Lambda U^T$ ，特征值降序排列，把 V 展开到 U 基底后，每个特征方向的被保留权重介于 0 与 1，且总和为 r ；最大值于是为前 r 个特征值之和。若 $X = U_X \Sigma V_X^T$ ，坐标为 $XV_{X,r} = U_{X,r} \Sigma_r$ ，最小误差为被舍弃奇异值平方之和。这也说明为何投影坐标有 r 列，而不是把样本特征向量直接当作载荷矩阵。

中心化均值和标准差仅由训练数据估计，新样本先做同样变换，再计算 $z = V^T(x - \bar{x})$ 。只中心化的 PCA 偏重数值方差大的传感器，标准化后的 PCA 则赋予低方差传感器更大相对权重；二者都不是天然正确。重特征值对应的基底可以旋转，不能把单条主轴的符号或方向变化解释成物理机制变化。

核 PCA 的特征空间与新样本坐标。 设正半定核 $k(x, x') = \langle \varphi(x), \varphi(x') \rangle$ ， $K_{ij} = k(x_i, x_j)$ ， $K \in \mathbb{R}^{n \times n}$ 。特征空间中心化对应 $K_c = HKH$ ，其中 $H = I - \mathbf{1}\mathbf{1}^T/n$ 。若 $K_c v_j = \lambda_j v_j$ 、 $\|v_j\| = 1$ 且 $\lambda_j > 0$ ，则单位主轴为

$$w_j = \frac{1}{\sqrt{\lambda_j}} \sum_i (v_j)_i [\varphi(x_i) - \bar{\varphi}], \quad z_{ij} = \sqrt{\lambda_j} (v_j)_i. \quad (22.4)$$

归一化来自 $\|w_j\|^2 = v_j^T K_c v_j / \lambda_j = 1$ 。对新样本 x ，先形成交叉核向量

$$(k_c(x))_i = k(x_i, x) - \frac{1}{n} \sum_a k(x_a, x) - \frac{1}{n} \sum_b K_{ib} + \frac{1}{n^2} \sum_{a,b} K_{ab}, \quad (22.5)$$

再计算 $z_j(x) = v_j^\top k_c(x) / \sqrt{\lambda_j}$ 。新点必须使用训练均值，不能单独重新中心化。极小特征值会放大数值误差，核宽度会改变整个几何；核空间中的好重构也不等于可以唯一还原原始传感器读数。

Isomap。 Isomap 用邻域图最短路径距离 D_{ij} 近似测地距离，再执行经典多维尺度分析[104]:

$$H = I - \frac{1}{n} \mathbf{1}\mathbf{1}^\top, \quad B = -\frac{1}{2} H D^{\circ 2} H, \quad Z = U_r \Lambda_r^{1/2}. \quad (22.6)$$

$D^{\circ 2}$ 表示逐元素平方， U_r, Λ_r 取正的主特征对。算法依次构图、计算最短路径、双中心化和谱分解。图断裂时路径距离无穷，不能直接进入 Multidimensional Scaling (MDS)；跨流形捷径则会系统性缩短距离。负特征值提示估计距离不能完全对应欧氏嵌入，不应直接对其开平方。

双中心化为什么把距离变成内积。 暂设 D_{ij} 确实来自中心化坐标 $Z \in \mathbb{R}^{n \times r}$ ，即 $Z^\top \mathbf{1} = 0$ 。令 $B = ZZ^\top$ 、 $b_i = B_{ii}$ ，平方距离展开为

$$D_{ij}^2 = B_{ii} + B_{jj} - 2B_{ij}, \quad D^{\circ 2} = b\mathbf{1}^\top + \mathbf{1}b^\top - 2B. \quad (22.7)$$

由于 $H\mathbf{1} = 0$ 且 $HBH = B$ ，左右乘 H 便得到 $B = -HD^{\circ 2}H/2$ 。因此谱分解不是无来由的步骤，而是在从距离反求坐标内积。若 B 半正定，保留前 r 个正特征对得到 $Z = U_r \Lambda_r^{1/2}$ ；坐标只确定到正交旋转，中心化则固定了平移自由度。

图最短路径得到的距离未必能精确嵌入欧氏空间。截断谱解最小化的是秩约束下的 Gram 矩阵误差 $\|B - ZZ^\top\|_F^2$ ，不是一般意义下的 $\sum_{ij} (D_{ij} - \|z_i - z_j\|)^2$ 。即便图构造正确，球面等具有内在曲率的流形也不能被无失真地摊平成同维欧氏平面。Isomap 尤其依赖采样足够密、邻域不跨越折叠以及测地结构近似可展平；“存在低维流形”本身还不足以保证成功。

经典实现需要存储 $n \times n$ 距离矩阵。Landmark 变体仅用部分代表点近似全局几何，降低计算和存储，但代表点必须覆盖各工况；选择失衡会遗漏少数状态。

22.3 局部重构与谱嵌入

LLE。 局部线性嵌入先固定每个样本的邻居，求局部重构权重[88]:

$$\min_W \sum_i \left\| x_i - \sum_{j \in \mathcal{N}_i} W_{ij} x_j \right\|_2^2, \quad \sum_j W_{ij} = 1. \quad (22.8)$$

和为一的约束使权重对整体平移不变。邻域协方差奇异时需加小的对角正则。固定 W 后，再求

$$\min_Z \|(I - W)Z\|_F^2, \quad Z^\top \mathbf{1} = 0, \quad Z^\top Z = I. \quad (22.9)$$

取 $(I - W)^\top(I - W)$ 最小非平凡特征值对应向量。第一步保留局部重构关系，第二步避免坐标全部坍塌。噪声、采样密度变化或过大的邻域会破坏局部线性假设。Hessian LLE 与局部切空间对齐等变体改变局部几何估计，并非仅更换一个可视化参数[22, 117]。

LLE 的两个约束优化如何求解。 对点 i 设邻居数为 m_i ，把差向量组成 $A_i = [x_j - x_i]_{j \in \mathcal{N}_i} \in \mathbb{R}^{d \times m_i}$ ，局部权重 $w_i \in \mathbb{R}^{m_i}$ 。利用 $\mathbf{1}^\top w_i = 1$ ，重构误差化为 $\|A_i w_i\|^2 = w_i^\top C_i w_i$ ，其中 $C_i = A_i^\top A_i$ 。拉格朗日函数取

$$\mathcal{J}(w_i, \nu) = w_i^\top C_i w_i - 2\nu(\mathbf{1}^\top w_i - 1). \quad (22.10)$$

驻点满足 $C_i w_i = \nu \mathbf{1}$ ，故当 C_i 可逆时

$$w_i = \frac{C_i^{-1} \mathbf{1}}{\mathbf{1}^\top C_i^{-1} \mathbf{1}}. \quad (22.11)$$

实现应求解线性系统而非显式求逆。若邻居近似落在低维切平面， C_i 很容易奇异，可用 $C_i + \gamma I$ 、 $\gamma > 0$ 替代。正则化提高稳定性，但同时改变重构关系。权重允许为负，LLE 的权重矩阵不是随机游走概率矩阵。

第二步设 $M = (I - W)^\top(I - W) \in \mathbb{R}^{n \times n}$ 。因 $W\mathbf{1} = \mathbf{1}$ ，有 $M\mathbf{1} = 0$ ，不加约束时 $Z = 0$ 就是平凡最优解。约束 $Z^\top Z = I$ 固定尺度、 $Z^\top \mathbf{1} = 0$ 排除常数方向；Rayleigh 商最小化给出其余最小特征值对应向量。若零空间不止一维，还需诊断连通分量或重构退化，不能机械删除一个特征向量就结束。

对新点可以在训练点中求同样的和为一重构权重，并令 $z(x) = \sum_j w_j(x) z_j$ 。这是一种已声明的邻域插值规则，不是重新求解训练谱问题。它在已覆盖的局部区域有意义，但无法可靠外推到新工况形成的流形分支。

拉普拉斯特征映射。 取对称非负邻接权 W_{ij} ，例如邻域内的高斯核权重；令 $D_{ii} = \sum_j W_{ij}$ 、 $L = D - W$ 。拉普拉斯特征映射最小化[4]

$$\frac{1}{2} \sum_{i,j} W_{ij} \|z_i - z_j\|_2^2 = \text{tr}(Z^\top L Z), \quad Z^\top D Z = I. \quad (22.12)$$

排除常数方向后求 $Lv = \lambda Dv$ 。图断裂会产生多个零特征值，因此非平凡方向的选择必须结合连通性。归一化拉普拉斯使用 $D^{-1/2} L D^{-1/2}$ ，对孤立节点需单独处理，避免除零。

从边上的差异到广义特征值。 本段 $W \in \mathbb{R}^{n \times n}$ 是对称非负相似度，区别于上一方法允许负值的重构权重；本段的 D 是度矩阵，不是 Isomap 的距离矩阵。对单列坐标 $v \in \mathbb{R}^n$ 逐项展开，有

$$\frac{1}{2} \sum_{i,j} W_{ij} (v_i - v_j)^2 = \sum_i D_{ii} v_i^2 - \sum_{i,j} W_{ij} v_i v_j \quad (22.13)$$

$$= v^\top (D - W) v \geq 0. \quad (22.14)$$

在 $v^T D v = 1$ 下求驻点, $\nabla_v [v^T L v - \lambda(v^T D v - 1)] = 0$ 给出 $L v = \lambda D v$ 。还需 $v^T D \mathbf{1} = 0$ 排除常数方向。令 $u = D^{1/2} v$ 就转成对称问题 $D^{-1/2} L D^{-1/2} u = \lambda u$ 。低特征值表示沿强连接边缓慢变化, 因而可能分开弱连接的设备群, 但并不保证这些群等于故障类别。图密度、核带宽和正常工况的采样数量都可能决定这些方向。

扩散坐标与扩散距离。 Diffusion Maps 将邻接权归一化为随机游走转移矩阵, 以特征值的时间次幂缩放坐标[17]。设图连通、各度 $d_i > 0$, $P = D^{-1} W$, 则 P_{ij} 表示一步从 i 到 j 的概率, 平稳分布为 $\pi_i = d_i / \sum_a d_a$ 。对称性给出细致平衡 $\pi_i P_{ij} = \pi_j P_{ji}$, 故可选右特征函数 ψ_ℓ , 满足 $\sum_i \pi_i \psi_\ell(i) \psi_m(i) = \mathbf{1}[\ell = m]$ 。第一项为 $\lambda_0 = 1, \psi_0 = 1$ 。

走 t 步后的两行概率分布之差定义扩散距离:

$$D_t^2(i, j) = \sum_a \frac{[P_{ia}^t - P_{ja}^t]^2}{\pi_a} \quad (22.15)$$

$$= \sum_{\ell \geq 1} \lambda_\ell^{2t} [\psi_\ell(i) - \psi_\ell(j)]^2. \quad (22.16)$$

第二式由 $P_{ia}^t = \pi_a \sum_\ell \lambda_\ell^t \psi_\ell(i) \psi_\ell(a)$ 代入, 并用加权正交性消去交叉项得到。因此坐标 $\Psi_t(i) = (\lambda_1^t \psi_1(i), \dots, \lambda_r^t \psi_r(i))$ 的欧氏距离近似扩散距离, 截断误差正是未保留项之和。它衡量的是多个路径共同形成的可达性, 而非一条最短路径。

时间 t 越大, $|\lambda_\ell| < 1$ 的方向衰减越强; 短时间强调局部邻域, 较长时间突出缓慢变化的结构, 过长则使所有点近乎重合。二部图可能出现 -1 特征值和周期振荡, 可采用懒惰随机游走 $(I + P)/2$ 消除周期性。采样密度校正改变几何与密度的相对影响, 应按任务解释, 不能只选最美观的嵌入。

22.4 概率邻域可视化

t-SNE。 t-SNE 在原空间构造对称邻域概率 p_{ij} , 在低维空间使用重尾分布[107]:

$$q_{ij} = \frac{(1 + \|z_i - z_j\|^2)^{-1}}{\sum_{a \neq b} (1 + \|z_a - z_b\|^2)^{-1}}, \quad \min_Z \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}. \quad (22.17)$$

原空间高斯带宽逐点调整, 使条件分布熵对应指定 perplexity。重尾低维分布缓解拥挤问题, KL 方向更重视保留高概率邻居。优化非凸, 不同初始化、perplexity 和学习率可能改变结果。图中簇间空隙、面积和距离不能直接解释为真实故障严重程度。

t-SNE 的概率、熵与梯度。 先在高维空间定义条件邻域概率:

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / (2\sigma_i^2))}{\sum_{a \neq i} \exp(-\|x_i - x_a\|^2 / (2\sigma_i^2))}, \quad j \neq i, \quad p_{i|i} = 0. \quad (22.18)$$

带宽 σ_i 按 $\exp[-\sum_j p_{j|i} \log p_{j|i}]$ 等于给定 perplexity 调整; 它描述有效邻居数而不是类别数。再令 $p_{ij} = (p_{j|i} + p_{i|j}) / (2n)$, 便有 $\sum_{i \neq j} p_{ij} = 1$ 。

令 $a_{ij} = (1 + \|z_i - z_j\|^2)^{-1}$ 、 $A = \sum_{a \neq b} a_{ab}$ 。去掉不含 Z 的常数，目标为

$$C = - \sum_{i \neq j} p_{ij} \log a_{ij} + \log A. \quad (22.19)$$

式(22.19)右端的第一项鼓励原空间高概率邻居靠近，第二项因归一化耦合所有点而产生排斥。利用 $\nabla_{z_i} \log a_{ij} = -2a_{ij}(z_i - z_j)$ ，并计入有序点对的两个方向，可得

$$\nabla_{z_i} C = 4 \sum_{j \neq i} (p_{ij} - q_{ij}) \frac{z_i - z_j}{1 + \|z_i - z_j\|^2}. \quad (22.20)$$

当 $p_{ij} > q_{ij}$ 时梯度下降使两点靠近，反之使其分离。重尾使较远点仍能产生排斥，缓解把高维邻域挤到二维的拥挤问题，但不会恢复真实全局距离。平移、旋转不改变目标，初始化和优化路径却可能改变局部极小值；因此多次结果中稳定的邻域比某次图上的簇间距离更值得解释。

UMAP。 UMAP 用局部距离尺度构造模糊邻域图，再优化低维边连接强度[72]。设原图权重为 w_{ij} ，低维相似度为 $q_{ij} = (1 + a\|z_i - z_j\|^{2b})^{-1}$ ，其图交叉熵包含

$$- \sum_{i < j} [w_{ij} \log q_{ij} + (1 - w_{ij}) \log(1 - q_{ij})], \quad (22.21)$$

其中与 Z 无关的常数省略。实际实现用边采样与负采样近似优化，不能把采样目标不加区分地当成全对全精确计算。邻居数控制局部与较大尺度结构的折中，最小距离参数影响低维点的紧密程度，不是分类间隔的直接估计。

UMAP 的局部尺度与吸引排斥。 一种典型有向邻域强度在邻居上定义为

$$s_{j|i} = \exp \left[- \frac{\max\{0, d(x_i, x_j) - \rho_i\}}{\sigma_i} \right], \quad (22.22)$$

非邻居取零。其中 ρ_i 给出局部连接距离， $\sigma_i > 0$ 调节有效邻域规模。以模糊并集对称化得到

$$w_{ij} = s_{j|i} + s_{i|j} - s_{j|i}s_{i|j}, \quad (22.23)$$

从而即便只有一侧视对方为近邻，也可能保留该边。这与对条件概率取平均不是同一构图过程。

令 $r = \|z_i - z_j\| > 0$ 、 $q = (1 + ar^{2b})^{-1}$ ， $a, b > 0$ 。单对损失 $\ell = -w \log q - (1 - w) \log(1 - q)$ 对距离的导数为

$$\frac{dq}{dr} = -\frac{2b}{r} q(1 - q), \quad \frac{d\ell}{dr} = \frac{2b}{r} (w - q), \quad \nabla_{z_i} \ell = \frac{2b(w - q)}{r^2} (z_i - z_j). \quad (22.24)$$

推导式(22.24)只需先对 q 求导，再乘 dq/dr 。当 $w > q$ 时下降方向拉近点对，当 $w < q$ 时推远点对； $r = 0$ 附近需数值稳定处理。该式描述全对全理想目标，实际边采样和负采样的频率会改变有效权重，没有对应重要性校正时不能把随机更新称为该目标的严

格无偏梯度。 a, b 控制低维相似度曲线，因而紧簇大小部分来自人为设定，不是原始数据中的物理尺寸。

参数化嵌入学习显式映射，便于处理新数据；普通谱嵌入与非参数可视化通常需要邻域插值、Nyström 扩展或重新拟合。全数据联合嵌入属于传导式设定，不能据此声称对未见设备具备归纳泛化能力。

22.5 流形正则与工业验证

流形正则将未标注样本几何引入监督学习[5]：

$$\mathcal{L}(f) = \frac{1}{n_l} \sum_{i=1}^{n_l} \ell(f(x_i), y_i) + \lambda_A \|f\|_{\mathcal{H}}^2 + \lambda_I \mathbf{f}^\top L \mathbf{f}, \quad (22.25)$$

其中 $\mathbf{f}$ 为全部训练侧样本的预测向量。最后一项鼓励邻近样本预测平滑；若邻域跨越真实类别边界，它会损害少数故障。类别条件图可以利用已知标签约束邻接，但不能使用测试标签构图。

平方损失下把函数问题化为线性系统。 设训练侧共 n 个样本，其中 n_l 个有标签，取平方损失并假设 $\lambda_A > 0$ 。核展开 $f(x) = \sum_{j=1}^n a_j k(x_j, x)$ 足以表达最优解：任何与这些核截面正交的函数在训练点上取零，不改变经验损失和图项，却只会增加 Reproducing Kernel Hilbert Space (RKHS) 范数。因此令 $a \in \mathbb{R}^n$ 、 $\mathbf{f} = Ka$ ， $J \in \mathbb{R}^{n \times n}$ 为有标签位置为1的对角选择矩阵， y 在无标签位置补零，目标化为

$$\mathcal{L}(a) = \frac{1}{n_l} (Ka - y)^\top J (Ka - y) + \lambda_A a^\top Ka + \lambda_I a^\top K L K a. \quad (22.26)$$

对 a 求导并除以2，得到

$$\left(\frac{1}{n_l} K J K + \lambda_A K + \lambda_I K L K \right) a = \frac{1}{n_l} K J y. \quad (22.27)$$

该系统的矩阵对称半正定。若 K 正定， $\lambda_A > 0$ 保证唯一系数解；若 K 奇异，不能直接消去 K ，可在其非零特征子空间求解，系数虽可能不唯一，所表达的训练函数仍可相同。预测新点时使用核展开，不需要把测试标签或测试点加入训练图。

为理解图项的作用，也可暂时直接优化节点预测 $f \in \mathbb{R}^n$ 。在 $\frac{1}{2}(f - y)^\top J (f - y) + \frac{\gamma}{2} f^\top L f$ 中，驻点满足 $(J + \gamma L)f = Jy$ 。对无标签节点 i ，有 $d_i f_i = \sum_j W_{ij} f_j$ ，即预测等于邻居的加权平均。若一个连通分量完全没有标签，其常数水平无法由此确定；若正常与故障之间有错误强边，平滑会把真实突变抹掉。几何提供的是可检验的先验，而不是无标签数据自动携带正确标签的保证。

对多工况振动数据，先统一转速、负载和通道量纲，再比较 PCA、Isomap 和图嵌入。随后改变邻居数、距离定义和随机种子，检查哪些邻近关系始终稳定。图构造和参数选择只能用训练侧数据；新设备上线时，要按事先写好的映射规则处理，不能

把测试样本重新放回图中。除了邻域保持、重构误差或谱诊断，还要报告未见设备的故障召回、误报和计算成本。二维图看起来更整齐，却让异常召回下降时，它就不适合这个业务。

本章小结。 本章从同一批高维观测得到了不同的数学对象：PCA 的正交投影、核 PCA 的特征空间内积、Isomap 的测地距离、LLE 的局部重构权重、谱方法的图平滑与扩散距离，以及 t-SNE、UMAP 的邻域强度。每一种谱分解或梯度优化都服务于一个明确目标；它们不能因最终都画出二维点图而互相替代。

流形假设真正有用的地方，是把局部连续变化与有限样本下的学习联系起来；真正危险的地方，是把错误距离、采样密度或跨类别边界的邻接当成真实结构。工业验证因此要同时检查图连通性、邻域稳定性、新点映射和故障指标。低维图形提供可探索的线索，而不是类别存在性、因果关系或部署泛化的证明。

本章利用样本之间的邻近关系，下一章则利用做过多个任务的经验。例如已经在多台设备上练习过少样本诊断，能否让下一台设备只需少量标签就完成适应？流形学习要检查样本邻近是否有意义，元学习则要检查以往任务的共同规律是否适用于新任务。换了故障定义或设备机理以后，两种方法的原有假设都可能需要重审。

第二十三章 元学习

本章摘要。元学习在一组任务上优化学习过程，使新任务能够用少量数据完成适应。本章从支持集、查询集和任务分布出发，分别推导度量方法、梯度初始化与学习优化器，再比较一阶近似、隐式梯度和概率变体。少样本只是常见应用，任务级泛化才是评价核心。

上一章利用样本几何学习表示，但即使表示合理，新设备仍可能只有极少标注数据。普通迁移学习先学一个模型再微调；元学习更进一步，把“看到少量样本之后如何学习”本身作为训练对象。这里被共享的不是所有任务的同一个最优参数，而是比较规则、初始化、更新器或先验，使不同任务能够以较低代价形成各自的预测器。

可以把每台新设备的适应过程看成一次练习：支持集是允许先看的少量已标注记录，查询集用来检查适应后的效果。训练时重复经历多个任务，才学出共享的元参数。下面先介绍不更新全部参数的度量方法，再用链式法则推导 Model-Agnostic Meta-Learning (MAML) 及其近似，最后讨论学习优化器和概率适应。作为全书最后一章，这里仍要回到最初的检查：测试任务是否真的没见过，查询标签是否参与了适应？这些条件不成立，少样本高分也不能说明模型会适应新任务。

23.1 任务分布与双层目标




图 23.1: 元学习的双层结构：支持集用于适应，查询集评价适应后的模型并更新元参数。

图23.1将支持集上的任务内适应与查询集上的外层更新分开；查询误差衡量的是适应后的泛化，而不是支持集拟合程度。任务 $\mathcal{T} \sim p(\mathcal{T})$ 包含支持集 S 与查询集 Q 。支持集用于任务内适应，查询集用于评价适应结果。设适应算子为 $U_\phi(S)$ ，元目标为

$$\min_{\phi} \mathbb{E}_{\mathcal{T}} [\mathcal{L}_Q(U_\phi(S))]. \quad (23.1)$$

元参数可以是编码器、初始化、更新规则或概率先验[42]。元训练查询集提供外循环梯度，元测试查询标签则只能用于最终评价。把所有任务样本混合做监督训练是多任务或预训练基线，不等同于上述适应后目标。

N -way K -shot 表示每个任务有 N 个类别、每类 K 个支持样本。闭集分类中的 1-way 只需输出唯一类别，不能作为有意义的分类难度；单类故障检测需要另设正常参考、未知类别和拒识阈值。工业任务应按设备、批次或工况定义，并明确新任务的类别是否与元训练重合。

为什么必须在任务内划分支持与查询。 令元参数 $\phi \in \mathbb{R}^p$ ，适应后参数 $U_\phi(S) \in \mathbb{R}^d$ ；两者维度未必相同。训练批包含 B 个任务时，经验元目标为

$$\hat{R}(\phi) = \frac{1}{B} \sum_{i=1}^B \frac{1}{|Q_i|} \sum_{(x,y) \in Q_i} \ell(f_{U_\phi(S_i)}(x), y). \quad (23.2)$$

先在每个查询集内平均、再在任务间平均，表达的是任务等权风险；把所有查询样本直接汇总则偏向查询集更大的任务。两者都可以定义，但必须与部署时抽到任务的分布对应。在任务独立同分布且支持查询按声明机制抽样时，该经验目标估计适应后的期望风险。高度相关的窗口不是独立任务，任务数量不能用窗口数量替代。

若把支持集也作为外循环评价集，目标会偏向快速记住已见样本，而不是快速泛化到任务内的新样本。相反，元训练查询标签用于更新 ϕ 是算法本身所需，并非泄漏；真正禁止的是利用元测试查询标签选择初始化、步数、阈值或检查点。对于时间序列，支持与查询的时间关系也属于任务分布：训练时用随机窗口构造任务，部署时却要求从过去适应未来，会改变元目标所对应的条件分布。

23.2 度量与关系方法

Matching Networks 与原型网络。 Matching Networks 根据查询与支持样本的相似度对支持标签加权[111]：

$$p(y \mid x, S) = \sum_{i \in S} a(x, x_i) \mathbf{1}[y_i = y], \quad a(x, x_i) = \frac{\exp s(f(x), g(x_i))}{\sum_{j \in S} \exp s(f(x), g(x_j))}. \quad (23.3)$$

适应主要表现为改变支持集，而非更新全部网络参数。支持样本增加会提高推理成本，噪声支持样本可能直接传播错误标签。

若查询编码 $h = f(x) \in \mathbb{R}^r$ 、支持编码 $e_i = g(x_i) \in \mathbb{R}^r$ ，可取 $s(h, e_i) = -\|h - e_i\|^2/\tau$ ， $\tau > 0$ 。对类别 k ，Matching Networks 等价于

$$p(y = k \mid x, S) = \frac{\sum_{i: y_i = k} \exp[-\|h - e_i\|^2/\tau]}{\sum_j \exp[-\|h - e_j\|^2/\tau]}. \quad (23.4)$$

它可以看作嵌入空间中的核加权投票：当 $\tau \rightarrow 0$ 且最近点唯一时接近最近邻，当 $\tau \rightarrow \infty$ 时接近支持集类别频率。于是支持集不平衡会隐含改变类别先验，不能把“多放几

个正常样本”视为不影响预测规则的改动。训练查询交叉熵时，梯度同时改变查询和支持编码器，使适用于任务的近邻关系被反复强化；若相似度本身受新工况干扰，少量错误近邻就可能主导结果。

原型网络以类均值压缩支持集[100]：

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_\phi(x_i), \quad p(y = k | x, S) = \frac{\exp[-d(f_\phi(x), c_k)/\tau]}{\sum_j \exp[-d(f_\phi(x), c_j)/\tau]}. \quad (23.5)$$

每个 episode 先编码支持集并计算原型，再计算查询交叉熵，最后反向更新共享编码器。类均值与平方欧氏距离配合有明确几何意义，换用任意距离不保证均值仍是最佳代表。温度 τ 影响概率尖锐程度，应在元验证任务选择。

均值原型、概率模型与反向传播。 设每个编码 $h_i = f_\phi(x_i) \in \mathbb{R}^r$ ，类别 k 的原型解决 $\min_c \sum_{i \in S_k} \|h_i - c\|^2$ 。展开并求导得到 $2|S_k|c - 2\sum_i h_i = 0$ ，故最优解正是均值 c_k 。若再假设 $h | y = k \sim \mathcal{N}(c_k, \sigma^2 I_r)$ 且各类先验相同，贝叶斯公式给出平方欧氏原型的softmax，温度 $\tau = 2\sigma^2$ 。先验不同则需在logit中加 $\log \pi_k$ 。因此均值和距离的配合隐含了单峰、近似同尺度类别分布；同类多工况形成多个分支时，均值可能落在没有真实样本的位置。

对查询真标签 y ，令 $\ell = -\log p_y$ 、 $h = f_\phi(x)$ 。平方欧氏距离下

$$\frac{\partial \ell}{\partial h} = \frac{2}{\tau} \left(\sum_k p_k c_k - c_y \right), \quad \frac{\partial \ell}{\partial c_k} = \frac{2}{\tau} (p_k - \mathbf{1}[k = y])(h - c_k). \quad (23.6)$$

这来自交叉熵对logit的导数 $p_k - \mathbf{1}[k = y]$ 。又因 $\partial c_k / \partial h_i = I_r / |S_k|$ ，查询误差会通过原型回传到每个支持编码，不能在元训练中默认将原型从计算图分离。推理时则只需计算支持原型和新查询距离。若支持噪声独立且协方差为 Σ_k ，均值方差为 $\Sigma_k / |S_k|$ ；相关窗口会降低这种方差缩减收益，说明shot数必须按真正独立证据理解。

多原型变体用多个中心表示同类不同工况，但需要估计中心数和分配规则；类不平衡变体应避免支持样本数量被隐含当作类别先验。Relation Networks用可学习关系模块替代固定距离[103]，表达能力增加，同时也更易记住训练任务的比较模式。传导式变体联合利用无标签查询集结构，须与逐查询归纳预测分开比较。

可学习关系与无标签查询的边界。 关系模块可以取 $r_\psi([h; c_k]) \in \mathbb{R}$ ，其中拼接输入为 $2r$ 维，令 $p_k = \text{softmax}_k(r_\psi([h; c_k]))$ ，再用查询交叉熵训练 ϕ, ψ 。此时 $\partial \ell / \partial r_k = p_k - \mathbf{1}[k = y]$ ，随后通过关系网络传回编码器。关系分数不一定对称，也不必满足三角不等式，所以它是任务比较函数而非严格距离；灵活性提高的同时失去了固定度量的一些约束。

若允许一次看到整个无标签查询批，可用软分配 $r_{jk} \propto \exp[-\|h_j - c_k\|^2 / \tau]$ ，再以 $c_k^{\text{new}} = (\sum_{i \in S_k} h_i + \sum_{j \in Q} r_{jk} h_j) / (|S_k| + \sum_{j \in Q} r_{jk})$ 更新中心。它类似固定各向同性尺度混合模型的一次软聚类更新，不需要查询标签，但确实使用了查询分布。未知类、

类别不平衡或初始原型错误可能形成自我强化，因此必须与逐查询预测分开报告，也不能在只到达一个样本的部署流程中假定整批查询可见。

23.3 梯度初始化与一阶变体

MAML 的内外循环。 MAML 学习适于快速更新的初始化 θ [24]。单步内循环与外循环为

$$\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{S_i}(\theta), \quad \theta \leftarrow \theta - \beta \sum_i \nabla_{\theta} \mathcal{L}_{Q_i}(\theta'_i). \quad (23.7)$$

先采样多个任务，各自从同一初始化开始适应，再汇总查询梯度；不能让任务 $i+1$ 直接继承任务 i 的适应结果。链式法则给出

$$\nabla_{\theta} \mathcal{L}_{Q_i}(\theta'_i) = (I - \alpha H_{S_i})^T \nabla_{\theta'_i} \mathcal{L}_{Q_i}(\theta'_i). \quad (23.8)$$

这里 i 索引本批任务， $\alpha, \beta > 0$ 分别为内、外循环学习率， $H_{S_i} = \nabla_{\theta}^2 \mathcal{L}_{S_i}(\theta)$ 是在当前初始化处求值的 Hessian， I 与参数维数相同。实现通常使用 Hessian-向量积，无需显式存储整个 Hessian，但多步内循环仍增加计算图与显存。适应步数、内循环学习率 and 是否更新归一化统计量都属于算法设定。

多步链式法则与曲率直觉。 设 $\theta_{i,0} = \theta \in \mathbb{R}^d$ ，第 s 步 $\theta_{i,s+1} = \theta_{i,s} - \alpha \nabla \mathcal{L}_{S_i}(\theta_{i,s})$ 。记 $H_{i,s} \in \mathbb{R}^{d \times d}$ 为该步 Hessian、 $A_{i,s} = I - \alpha H_{i,s}$ ，则

$$\frac{\partial \theta_{i,m}}{\partial \theta} = A_{i,m-1} \cdots A_{i,0}, \quad \nabla_{\theta} \mathcal{L}_{Q_i}(\theta_{i,m}) = A_{i,0}^T \cdots A_{i,m-1}^T g_{Q_i}. \quad (23.9)$$

矩阵一般不可交换，顺序不能倒置。反向实现从查询梯度 $v_m = g_{Q_i}$ 出发，逐步计算 $v_s = v_{s+1} - \alpha H_{i,s}^T v_{s+1}$ 。对固定向量 v ， $Hv = \nabla_{\theta}[(\nabla_{\theta} \mathcal{L})^T v]$ ，所以无须建立 $d \times d$ 矩阵。但仍需保存或重算各步状态，而且内循环梯度必须保留可微路径；把更新后的参数无条件分离会改变算法。

用一维任务 $\mathcal{L}_S(\theta) = a(\theta - b)^2/2$ 、 $\mathcal{L}_Q(v) = c(v - b)^2/2$ 说明曲率作用，其中 $a, c > 0$ 。一步适应后 $\theta' - b = (1 - \alpha a)(\theta - b)$ ，外层损失及其梯度为

$$\mathcal{L}_Q(\theta') = \frac{c}{2}(1 - \alpha a)^2(\theta - b)^2, \quad \frac{d\mathcal{L}_Q(\theta')}{d\theta} = c(1 - \alpha a)^2(\theta - b). \quad (23.10)$$

元目标评价的是适应后误差，而非原点误差。若支持曲率 a 允许一步恰好到达 b ，该任务对初始化的梯度可以为零；若步长使 $|1 - \alpha a| > 1$ ，适应反而放大误差。这说明“容易微调”的初始化必须和步长、任务曲率共同讨论。实际支持与查询目标不同，有限支持样本产生的曲率还可能是噪声，不能把该示例的理想一步解推广到真实网络。

First-Order Model-Agnostic Meta-Learning (FOMAML) 忽略内循环 Jacobian 中的 Hessian 项，以降低开销；它是梯度近似，不是与 MAML 完全等价的目标。Reptile 在单任务上执行多步更新得到 θ'_i ，再令[75]

$$\theta \leftarrow \theta + \epsilon(\theta'_i - \theta). \quad (23.11)$$

式(23.11)不显式对查询损失求二阶梯度，多步任务内更新使算法偏向能在同一任务不同批次间泛化的初始化。一步更新时与多任务梯度训练的关系更接近，因此步数不是无关的实现细节。

一阶近似到底舍弃了什么。 单步时 FOMAML 使用 g_Q 代替 $(I - \alpha H_S)^T g_Q$ ，故误差为 $\alpha H_S^T g_Q$ ，若 $\|H_S\| \leq L$ 则范数不超过 $\alpha L \|g_Q\|$ 。小步长且曲率受控时这种近似较合理；多步情况下误差来自一串 Jacobian 的省略，不能只凭单步界判断。前述一维例中，FOMAML 给出 $c(1 - \alpha a)(\theta - b)$ ，而真梯度多一个 $1 - \alpha a$ 因子，过大步长甚至会使两者方向相反。

对 Reptile，考虑同一任务上两个小批次损失，初始点处梯度为 g_1, g_2 、第二批 Hessian 为 H_2 。两步内更新用 Taylor 展开得到

$$\theta_1 = \theta - \alpha g_1, \quad (23.12)$$

$$\theta_2 = \theta_1 - \alpha \nabla \mathcal{L}_2(\theta_1) = \theta - \alpha(g_1 + g_2) + \alpha^2 H_2 g_1 + O(\alpha^3). \quad (23.13)$$

因此 Reptile 的位移除平均梯度项外，还含跨批次相互作用。若批次交换对称， $\nabla(g_1^T g_2) = H_1 g_2 + H_2 g_1$ ，二阶位移在期望上与提高同任务梯度一致性有关。这只是光滑、小步长下的局部解释，不是 Reptile 与 MAML 完全等价的证明。只有一步时没有该项，更新退化为任务采样下的普通梯度训练。

Meta-SGD、Almost No Inner Loop (ANIL) 与隐式梯度。 Meta-SGD 同时学习初始化和逐参数更新尺度 α ，内循环写为 $\theta'_i = \theta - \alpha \odot \nabla \mathcal{L}_{S_i}$ [65]。更新尺度可改变方向和幅度，但也增加元参数与过拟合风险。ANIL 仅在内循环更新任务头，编码器由外循环训练[81]；它检验快速适应是否主要依赖可复用表示，而非整个网络都必须变化。

对 Meta-SGD， $\alpha \in \mathbb{R}^d$ 也是元参数。令 $g_S = \nabla \mathcal{L}_S(\theta)$ 、 $g_Q = \nabla \mathcal{L}_Q(\theta')$ ，链式法则给出

$$\nabla_\alpha \mathcal{L}_Q = -g_S \odot g_Q, \quad \nabla_\theta \mathcal{L}_Q = [I - \text{diag}(\alpha) H_S]^T g_Q. \quad (23.14)$$

当同一坐标的支持与查询梯度一致时，外循环倾向增大该坐标更新幅度；不一致时倾向减小。允许负尺度还可翻转方向，但这不再是传统的正学习率下降法，应监控任务外的稳定性。

对 ANIL，令参数为编码器 ω 与任务头 w ，仅更新 $w' = w - \alpha \nabla_w \mathcal{L}_S(\omega, w)$ 。编码器的外层梯度仍为

$$\nabla_\omega \mathcal{L}_Q(\omega, w') = \partial_\omega \mathcal{L}_Q + \left(\frac{\partial w'}{\partial \omega} \right)^T \nabla_{w'} \mathcal{L}_Q, \quad \frac{\partial w'}{\partial \omega} = -\alpha \frac{\partial(\nabla_w \mathcal{L}_S)}{\partial \omega}. \quad (23.15)$$

所以“内循环不更新编码器”不等于“外循环冻结编码器”，也不自动消除混合二阶导数；若额外舍弃该项，还应声明采用了一阶近似。

iMAML 在任务内目标加入到初始化的近端项[83]:

$$\theta_i^* = \arg \min_{\vartheta} \left[\mathcal{L}_{S_i}(\vartheta) + \frac{\lambda}{2} \|\vartheta - \theta\|^2 \right]. \quad (23.16)$$

在局部可微、驻点充分求解且相关矩阵可逆时，隐式微分给出

$$\frac{\partial \theta_i^*}{\partial \theta} = \lambda(H_{S_i} + \lambda I)^{-1}. \quad (23.17)$$

此处 $\lambda > 0$, $H_{S_i} = \nabla_{\vartheta}^2 \mathcal{L}_{S_i}(\vartheta)|_{\vartheta=\theta_i^*}$ 改在内层解处求值，不能沿用前面初始化处的数值。通过迭代解线性系统获得向量积，可避免保存全部内循环轨迹；代价转为内层求解和线性系统精度。它不是任意少量梯度步下都成立的精确替代。

隐式微分的驻点方程与数值误差。 令 $G(v, \theta) = \nabla \mathcal{L}_S(v) + \lambda(v - \theta)$ 。内层解满足 $G(\theta^*, \theta) = 0$ ，对初始化求全导数得到

$$(H_S + \lambda I) \frac{\partial \theta^*}{\partial \theta} - \lambda I = 0. \quad (23.18)$$

若 $A = H_S + \lambda I$ 可逆，就得到式(23.17)。对不直接依赖初始化的查询损失，先解 $A^T v = g_Q$ ，再返回 λv 作为元梯度。若 A 对称正定可用共轭梯度法，并以 Hessian-向量积执行矩阵作用；单纯可逆但不定时，不能无条件使用正定系统的收敛保证。

若线性求解的残差为 $r = g_Q - A^T \tilde{v}$ ，则 $\|\tilde{v} - v\| \leq \|A^{-T}\| \|r\|$ 。小残差在病态系统中仍可能对应大误差；内层未达到驻点还会引入另一项偏差。对凸二次支持损失的特征方向 $a \geq 0$ ，初始化敏感度为 $\lambda/(a + \lambda)$ ：证据曲率强的方向更由支持集决定，曲率弱的方向更依赖初始化。 λ 很大时稳定但适应受限，过小时可能病态，非凸情况下还可能切换局部解分支。隐式方法省去的是展开轨迹，而不是内层求解本身。

23.4 学习更新规则与概率适应

学习优化器将梯度与历史状态输入参数化更新器：

$$h_{r+1} = g_{\phi}(h_r, \nabla \mathcal{L}_S), \quad \theta_{r+1} = \theta_r + u_{\phi}(h_{r+1}). \quad (23.19)$$

外循环根据优化后的损失训练 ϕ [1]。相比学习一个初始化，这一路线学习整个更新行为，但展开步数、参数尺度和网络结构变化会造成新的分布偏移。

学习优化器的状态展开。 设 $\theta_r \in \mathbb{R}^d$ 、隐藏状态 $h_r \in \mathbb{R}^m$ ，合并状态 $s_r = (\theta_r, h_r)$ ，则上述更新可以写为 $s_{r+1} = T_{\phi}(s_r; S)$ 。若初始状态与 ϕ 无关，定义 $J_r = \partial s_r / \partial \phi$ ，有

$$J_0 = 0, \quad J_{r+1} = \frac{\partial T_{\phi}}{\partial s_r} J_r + \frac{\partial T_{\phi}}{\partial \phi}, \quad \nabla_{\phi} \mathcal{L}_Q(\theta_R) = J_R^T \nabla_{s_R} \mathcal{L}_Q. \quad (23.20)$$

若初始化也可学习，则 J_0 应包含相应导数。由于状态转移使用 $\nabla \mathcal{L}_S(\theta_r)$ ，第一项通常含 Hessian；对输入梯度停止求导可降低开销，但会改变元梯度。反复相乘的状态 Jacobian 还会产生梯度消失或爆炸，截断反向传播因此是一种有偏近似，而非免费计算技巧。

逐坐标共享更新器可让同一个小网络应用于不同维度参数，然而梯度尺度、层结构、训练时长仍可能超出元训练范围。训练只展开十步的优化器不能凭短期损失下降就保证运行一千步稳定。验证时应报告完整轨迹、不同展开长度及普通 SGD、Adam 在相同计算预算下的结果。

概率元学习不只输出单个适应参数，而是在少量证据下保留多个合理任务解释。Probabilistic Model-Agnostic Meta-Learning (PLATIPUS) 等方法学习初始化的不确定性，并通过任务内更新得到预测分布[25]。模型平均可表达任务歧义，但需要检查近似后验、采样成本与校准；支持样本少并不保证任何概率方法都能正确估计不确定性。

层次先验如何产生少样本适应。 一个可明确计算的概率元学习模型是 $\theta_i \sim p_\phi(\theta_i)$ 、 $S_i \sim p(S_i | \theta_i)$ 。任务内适应对应

$$p_\phi(\theta_i | S_i) = \frac{p(S_i | \theta_i)p_\phi(\theta_i)}{\int p(S_i | v)p_\phi(v) dv}, \quad p(y | x, S_i) = \int p(y | x, \theta_i)p_\phi(\theta_i | S_i) d\theta_i. \quad (23.21)$$

元训练可最大化支持条件下查询数据的预测概率，从而学习使新任务容易适应的先验。这是层次贝叶斯的基本解释，不意味着所有概率元学习算法都使用相同后验或目标。

以线性高斯任务为例， $\theta_i \in \mathbb{R}^d$ 、 $X_S \in \mathbb{R}^{m \times d}$ 、 $y_S \in \mathbb{R}^m$ ，设 $y_S | \theta_i \sim \mathcal{N}(X_S \theta_i, \sigma^2 I)$ ，先验 $\theta_i \sim \mathcal{N}(\mu, \Lambda^{-1})$ 、 $\Lambda \succ 0$ 。负对数后验中依赖 θ_i 的部分为

$$\frac{1}{2\sigma^2} \|y_S - X_S \theta_i\|^2 + \frac{1}{2} (\theta_i - \mu)^\top \Lambda (\theta_i - \mu). \quad (23.22)$$

展开二次项并配方得到

$$\Sigma_S = (\Lambda + \sigma^{-2} X_S^\top X_S)^{-1}, \quad m_S = \Sigma_S (\Lambda \mu + \sigma^{-2} X_S^\top y_S). \quad (23.23)$$

因此新输入 $x \in \mathbb{R}^d$ 的预测分布为 $\mathcal{N}(x^\top m_S, \sigma^2 + x^\top \Sigma_S x)$ 。第一项方差来自观测噪声，第二项来自任务参数不确定性。样本未覆盖的方向主要保留先验，样本充分的方向更多服从似然，给出了“借助任务经验”的精确含义。先验均值及精度可由多个训练任务学习，但若新设备机制不在训练任务覆盖范围内，强先验也可能造成自信错误。

非共轭模型常以 $q_\psi(\theta | S)$ 近似后验，由 Jensen 不等式有

$$\log p_\phi(S) \geq \mathbb{E}_{q_\psi} \log p(S | \theta) - \text{KL}(q_\psi(\theta | S) \| p_\phi(\theta)). \quad (23.24)$$

这个证据下界解释了数据拟合与接近共享先验的权衡；若元目标是条件查询预测，还需相应的外层训练，不能把优化支持集下界自动当作优化查询泛化。近似分布过于简单或采样不足会低估多种任务解释，因而概率输出仍须用覆盖率和校准检验。

记忆增强方法把任务内观测写入可寻址状态，以读取记忆完成预测。它与参数梯度适应的主要区别是任务状态的保存位置。元测试时应重置任务记忆，防止跨任务残留信息改变规则。对于序列任务，还必须保证读取的记忆均早于当前预测时刻。

记忆读取也是一种适应算子。 令任务记忆键 $k_j \in \mathbb{R}^r$ 、值 $v_j \in \mathbb{R}^q$ ，查询键 $k(x) \in \mathbb{R}^r$ 。一个基本读取形式是

$$a_j(x) = \frac{\exp(k(x)^\top k_j / \sqrt{r})}{\sum_b \exp(k(x)^\top k_b / \sqrt{r})}, \quad o(x) = \sum_j a_j(x) v_j. \quad (23.25)$$

若值存标签编码，这与软近邻分类相联系；若值存任务历史状态，则输出还依赖写入与遗忘规则。分母使权重和为一，读取向量位于值向量的凸包内；要产生凸包外的复杂响应，还需后续预测网络。记忆容量有限、错误标签写入和相似键冲突都会限制适应。尤其在顺序标注规则中，当前样本标签必须在本次预测之后才能写入，否则模型学到的是读取答案而非预测。

23.5 跨设备快速适应的完整设置

在轴承诊断中，可以把“正常”和一种故障组成 2-way 任务；只有确实有五类可靠标签时，才定义 5-way 任务。应按设备划分元训练、元验证和元测试，同一条原始记录的相邻窗口不能一边进入支持集、一边进入查询集。元测试时，支持集只能用于预先规定的适应步骤，查询集再用来评价不同时间和工况下的表现。类别不够就修改任务设计，不能复制标签来凑 way 数。

每个 episode 的步骤是抽取任务与类别、划分支持查询、重置初始化或任务状态、执行内循环、在查询上计算损失；只有元训练阶段反向更新共享元参数。比较原型网络、MAML、一阶方法与普通预训练微调时，应匹配支持样本、预训练数据和适应计算预算。预训练基线很强时，元学习的额外收益需要单独验证[15]。

评价以任务而非高度相关的窗口为统计单元，报告平均性能、任务间区间、失败任务比例、适应前后增益、校准与延迟。改变支持集大小、标签噪声和目标设备类型，检查元训练任务分布之外的退化。不能用同一设备随机切片上的高准确率证明快速跨设备适应。

本章小结。 元学习把一个预测器的训练问题改写为适应过程的训练问题。度量方法通过支持集重建比较规则，原型网络把平方距离下的类均值作为任务状态；MAML 通过内外循环链式法则学习初始化，一阶方法以梯度近似换取计算效率，隐式方法则以驻点方程替代轨迹展开。学习优化器和记忆方法把适应放在更新规则或显式状态中，概率方法进一步保留少量证据下的多种任务解释。这些路线的共同目标都是适应后的查询风险，而不是仅把支持样本拟合得更好。

本章最重要的限制同样位于任务层面：训练任务的共同性未必能延续到新设备，过强先验、错误近邻和不稳定更新都可能放大偏差。只有设备级隔离、合法的支持查询划分、匹配的适应预算以及强预训练基线，才能说明元学习带来了真实收益。对同一设备重复切窗，或者利用元测试查询表现调参，都会改变原本宣称的学习问题。

全书从怎样定义样本和损失开始，经过优化、概率推断和深度模型，最后讨论了不同的数据组织与学习方式。回到设备现场，仍应先问手上有什么记录、要提前作出什么判断，再选择模型和训练办法，最后检查误差、不确定性与运行成本。接下来的结语把这些检查整理为五个问题。开始新任务时，把记录来源、可用时间和评价方法写清楚，比先选一个热门模型更有帮助。

结语：如何开始一个工业数据智能问题

面对新的工业任务，先写下五件事：现在能看到哪些变量，要提前多久给出什么判断，线上什么时候拿得到每条记录，设备和工况会怎样变化，以及漏报、误报各会带来什么代价。例如要预测未来二十四小时内的故障，就必须同时写清标签确认时间、预测窗口和允许的告警延迟。五件事没有写清之前，模型结构的比较缺少明确依据。

回看全书，第一部分把实际问题写成数据、假设空间、损失和风险之间的关系，并说明训练误差为什么不能代替部署表现；第二部分把未知量纳入概率推理，区分参数估计、预测分布与决策所需的不确定性；第三部分根据时间、空间、语言、跨模态关系和物理规律组织模型；第四部分进一步改变数据到达、知识迁移、标注获取和协作学习的方式。这条顺序反映了一个基本判断：先明确需要保留的结构与需要承担的错误，再选择模型，而不是从某个热门模型反推问题。

数学推导使这种选择具有可检查的依据。最小二乘的正规方程揭示了可辨识性与数值条件的重要性，概率模型的似然揭示了损失函数背后的观测假设，泛化分析揭示了样本数量与复杂度之间的约束，梯度与近似推断揭示了可计算性所付出的代价。深度网络并没有取消这些问题；它只是把表示和参数空间扩展得更大。迁移、联邦或元学习也没有自动消除分布变化，而是为利用已有知识增加了新的结构假设。公式的价值因此不在于显得复杂，而在于让假设、推理和限制能够被逐项追问。

真正开始一个项目时，可以先固定预测时刻和标签窗口，建立按设备与时间隔离的评估集，再实现可解释的简单基线。只有在误差分析指出明确瓶颈之后，才引入更丰富的表示、不确定性估计或新的学习方式。每次修改都应留下可复核的比较：使用了哪些新增信息，改变了什么假设，改善了哪类错误，增加了多少计算与维护成本。在本文的维护案例中，风险预测、缺陷定位和规程问答最终都必须回到同一件事：现有证据是否足以支持下一步维护动作；若不足，系统应请求复检或补充观测，而不是用更肯定的输出掩盖知识的缺口。

因此，学完本书并不意味着为每种工业任务记住一个标准答案，而是形成一套可以反复使用的工作方式：把问题写清楚，把推导做完整，把近似讲明白，把证据与结论对应起来，并在环境变化后重新检验。能够说明一个方法何时不应使用，与能够实现它同样重要。

参考文献

- [1] Marcin Andrychowicz et al. Learning to learn by gradient descent by gradient descent. In *Advances in Neural Information Processing Systems*, 2016.
- [2] Jordan T. Ash, Chicheng Zhang, Akshay Krishnamurthy, John Langford, and Alekh Agarwal. Deep batch active learning by diverse, uncertain gradient lower bounds. In *International Conference on Learning Representations*, 2020.
- [3] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *International Conference on Learning Representations*, 2022.
- [4] Mikhail Belkin and Partha Niyogi. Laplacian eigenmaps for dimensionality reduction and data representation. *Neural Computation*, 15(6):1373–1396, 2003.
- [5] Mikhail Belkin, Partha Niyogi, and Vikas Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of Machine Learning Research*, 7:2399–2434, 2006.
- [6] Shai Ben-David, John Blitzer, Koby Crammer, Alex Kulesza, Fernando Pereira, and Jennifer Wortman Vaughan. A theory of learning from different domains. *Machine Learning*, 79:151–175, 2010.
- [7] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [8] Olivier Bousquet and André Elisseeff. Stability and generalization. *Journal of Machine Learning Research*, 2:499–526, 2002.
- [9] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [10] Tom B. Brown et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, 2020.

- [11] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision*, 2021.
- [12] Gavin C. Cawley and Nicola L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11:2079–2107, 2010.
- [13] Arslan Chaudhry, Marc’Aurelio Ranzato, Marcus Rohrbach, and Mohamed El-hoseiny. Efficient lifelong learning with A-GEM. In *International Conference on Learning Representations*, 2019.
- [14] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, 2020.
- [15] Wei-Yu Chen, Yen-Cheng Liu, Zsolt Kira, Yu-Chiang Frank Wang, and Jia-Bin Huang. A closer look at few-shot classification. In *International Conference on Learning Representations*, 2019.
- [16] Xinlei Chen and Kaiming He. Exploring simple siamese representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.
- [17] Ronald R. Coifman and Stéphane Lafon. Diffusion maps. *Applied and Computational Harmonic Analysis*, 21(1):5–30, 2006.
- [18] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20:273–297, 1995.
- [19] Matthias De Lange et al. A continual learning survey: Defying forgetting in classification tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7):3366–3385, 2022.
- [20] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019.
- [21] Laurent Dinh, Jascha Sohl-Dickstein, and Samy Bengio. Density estimation using real NVP. In *International Conference on Learning Representations*, 2017.

- [22] David L. Donoho and Carrie Grimes. Hessian eigenmaps: Locally linear embedding techniques for high-dimensional data. *Proceedings of the National Academy of Sciences*, 100(10):5591–5596, 2003.
- [23] Alexey Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [24] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. *International Conference on Machine Learning*, 2017.
- [25] Chelsea Finn, Kelvin Xu, and Sergey Levine. Probabilistic model-agnostic meta-learning. In *Advances in Neural Information Processing Systems*, 2018.
- [26] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [27] Yarin Gal, Riashat Islam, and Zoubin Ghahramani. Deep bayesian active learning with image data. In *International Conference on Machine Learning*, 2017.
- [28] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lempitsky. Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59):1–35, 2016.
- [29] Stuart Geman and Donald Geman. Stochastic relaxation, gibbs distributions, and the bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-6(6):721–741, 1984.
- [30] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, 2014.
- [31] Jean-Bastien Grill et al. Bootstrap your own latent: A new approach to self-supervised learning. In *Advances in Neural Information Processing Systems*, 2020.
- [32] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning*, 2017.
- [33] Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A. Smith. Don’t stop pretraining: Adapt language models

- to domains and tasks. In *Annual Meeting of the Association for Computational Linguistics*, 2020.
- [34] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.
 - [35] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.
 - [36] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *IEEE International Conference on Computer Vision*, 2017.
 - [37] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
 - [38] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 2020.
 - [39] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
 - [40] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
 - [41] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
 - [42] Timothy Hospedales, Antreas Antoniou, Paul Micaelli, and Amos Storkey. Meta-learning in neural networks: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(9):5149–5169, 2022.
 - [43] Neil Houlsby et al. Parameter-efficient transfer learning for NLP. In *International Conference on Machine Learning*, 2019.
 - [44] Neil Houlsby, Ferenc Huszár, Zoubin Ghahramani, and Máté Lengyel. Bayesian active learning for classification and preference learning. *arXiv preprint arXiv:1112.5745*, 2011.
 - [45] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

- [46] Jiayuan Huang, Alexander J. Smola, Arthur Gretton, Karsten M. Borgwardt, and Bernhard Schölkopf. Correcting sample selection bias by unlabeled data. In *Advances in Neural Information Processing Systems*, 2007.
- [47] Ameya D. Jagtap and George Em Karniadakis. Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations. *Communications in Computational Physics*, 28(5):2002–2041, 2020.
- [48] Rudolf E. Kalman. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1):35–45, 1960.
- [49] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank Reddi, Sebastian Stich, and Ananda Theertha Suresh. SCAFFOLD: Stochastic controlled averaging for federated learning. In *International Conference on Machine Learning*, 2020.
- [50] George Em Karniadakis, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021.
- [51] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):15:1–15:21, 2012.
- [52] Ehsan Kharazmi, Zhongqiang Zhang, and George Em Karniadakis. hp-VPINNs: Variational physics-informed neural networks with domain decomposition. *Computer Methods in Applied Mechanics and Engineering*, 374:113547, 2021.
- [53] Prannay Khosla et al. Supervised contrastive learning. In *Advances in Neural Information Processing Systems*, 2020.
- [54] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- [55] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. *International Conference on Learning Representations*, 2014.
- [56] James Kirkpatrick et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.
- [57] Andreas Kirsch, Joost van Amersfoort, and Yarin Gal. BatchBALD: Efficient and diverse batch acquisition for deep bayesian active learning. In *Advances in Neural Information Processing Systems*, 2019.

- [58] Aditi Krishnapriyan, Amir Gholami, Shandian Zhe, Robert Kirby, and Michael W. Mahoney. Characterizing possible failure modes in physics-informed neural networks. In *Advances in Neural Information Processing Systems*, 2021.
- [59] Solomon Kullback and Richard A. Leibler. On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1):79–86, 1951.
- [60] John Lafferty, Andrew McCallum, and Fernando Pereira. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In *International Conference on Machine Learning*, 2001.
- [61] David D. Lewis and William A. Gale. A sequential algorithm for training text classifiers. In *ACM SIGIR Conference on Research and Development in Information Retrieval*, 1994.
- [62] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, 2020.
- [63] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International Conference on Machine Learning*, 2023.
- [64] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks. In *Proceedings of Machine Learning and Systems*, 2020.
- [65] Zhenguo Li, Fengwei Zhou, Fei Chen, and Hang Li. Meta-SGD: Learning to learn quickly for few-shot learning. *arXiv preprint arXiv:1707.09835*, 2017.
- [66] Zhizhong Li and Derek Hoiem. Learning without forgetting. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(12):2935–2947, 2018.
- [67] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [68] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems*, 2023.
- [69] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael I. Jordan. Learning transferable features with deep adaptation networks. In *International Conference on Machine Learning*, 2015.

- [70] David Lopez-Paz and Marc'Aurelio Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, 2017.
- [71] Andrew McCallum, Dayne Freitag, and Fernando C. N. Pereira. Maximum entropy markov models for information extraction and segmentation. In *International Conference on Machine Learning*, 2000.
- [72] Leland McInnes, John Healy, and James Melville. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018.
- [73] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *International Conference on Artificial Intelligence and Statistics*, 2017.
- [74] Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.
- [75] Alex Nichol, Joshua Achiam, and John Schulman. On first-order meta-learning algorithms. *arXiv preprint arXiv:1803.02999*, 2018.
- [76] Long Ouyang et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, 2022.
- [77] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.
- [78] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.
- [79] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, 2021.
- [80] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Advances in Neural Information Processing Systems*, 2023.

- [81] Aniruddh Raghu, Maithra Raghu, Samy Bengio, and Oriol Vinyals. Rapid learning or feature reuse? towards understanding the effectiveness of MAML. In *International Conference on Learning Representations*, 2020.
- [82] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [83] Aravind Rajeswaran, Chelsea Finn, Sham M. Kakade, and Sergey Levine. Meta-learning with implicit gradients. In *Advances in Neural Information Processing Systems*, 2019.
- [84] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. iCaRL: Incremental classifier and representation learning. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [85] Herbert Robbins and Sutton Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.
- [86] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.
- [87] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention*, 2015.
- [88] Sam T. Roweis and Lawrence K. Saul. Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290(5500):2323–2326, 2000.
- [89] Nicholas Roy and Andrew McCallum. Toward optimal active learning through sampling estimation of error reduction. In *International Conference on Machine Learning*, 2001.
- [90] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986.
- [91] Andrei A. Rusu et al. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016.

- [92] Ameya Sathe and Jakob Mann. A review of turbulence measurements using ground-based wind lidars. *Atmospheric Measurement Techniques*, 6:3147–3167, 2013.
- [93] Bernhard Schölkopf, Alexander Smola, and Klaus-Robert Müller. Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5):1299–1319, 1998.
- [94] D. Sculley et al. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems*, 2015.
- [95] Ozan Sener and Silvio Savarese. Active learning for convolutional neural networks: A core-set approach. In *International Conference on Learning Representations*, 2018.
- [96] Burr Settles. Active learning literature survey. Technical Report 1648, University of Wisconsin–Madison, 2009.
- [97] H. Sebastian Seung, Manfred Opper, and Haim Sompolinsky. Query by committee. In *Workshop on Computational Learning Theory*, 1992.
- [98] Claude E. Shannon. A mathematical theory of communication. *Bell System Technical Journal*, 27:379–423, 623–656, 1948.
- [99] Hanul Shin, Jung Kwon Lee, Jaehong Kim, and Jiwon Kim. Continual learning with deep generative replay. In *Advances in Neural Information Processing Systems*, 2017.
- [100] Jake Snell, Kevin Swersky, and Richard Zemel. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, 2017.
- [101] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021.
- [102] Baochen Sun and Kate Saenko. Deep CORAL: Correlation alignment for deep domain adaptation. In *European Conference on Computer Vision Workshops*, 2016.
- [103] Flood Sung, Yongxin Yang, Li Zhang, Tao Xiang, Philip H. S. Torr, and Timothy M. Hospedales. Learning to compare: Relation network for few-shot learning. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2018.

- [104] Joshua B. Tenenbaum, Vin de Silva, and John C. Langford. A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500):2319–2323, 2000.
- [105] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288, 1996.
- [106] Michalis Titsias. Variational learning of inducing variables in sparse gaussian processes. In *International Conference on Artificial Intelligence and Statistics*, 2009.
- [107] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [108] Vladimir N. Vapnik and Alexey Ya. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2):264–280, 1971.
- [109] Ashish Vaswani et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- [110] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In *International Conference on Machine Learning*, 2008.
- [111] Oriol Vinyals, Charles Blundell, Timothy Lillicrap, Daan Wierstra, and Koray Kavukcuoglu. Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, 2016.
- [112] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *International Conference on Learning Representations*, 2021.
- [113] Sifan Wang, Yujun Teng, and Paris Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.
- [114] Liu Yang, Xuhui Meng, and George Em Karniadakis. B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data. *Journal of Computational Physics*, 425:109913, 2021.
- [115] Friedemann Zenke, Ben Poole, and Surya Ganguli. Continual learning through synaptic intelligence. In *International Conference on Machine Learning*, 2017.

- [116] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. In *IEEE/CVF International Conference on Computer Vision*, 2023.
- [117] Zhenyue Zhang and Hongyuan Zha. Principal manifolds and nonlinear dimensionality reduction via tangent space alignment. *SIAM Journal on Scientific Computing*, 26(1):313–338, 2004.